机器学习与人工智能 · 第四节

Agent 与 Harness

从“会说”到“会做”：RAG · Tool Calling · Agent · Harness

附：多模态与对齐·Diffusion 文生图·大模型幻觉



Harness：把“想法”变成可执行、可控制的行动

面向读者：第一次系统接触大模型应用的本科生（工科背景，学过线性代数与程序设计）

内容构成：知识讲解与图解·生活应用·相似知识对比·38 道分层练习与逐题图解

XeLaTeX 原生矢量排版·A4 ·2026 年 10 月

目录

阅读说明与本专题定位 **3**

预备：读懂本节需要的三件小工具 **4**

学科小史：从“聊天程序”到“会干活的 Agent” **5**

从课本到现实：这些知识在哪里被使用 **5**

原始资料重编码、纠错与知识总览 **6**

第 1 章 RAG：让模型“先查资料，再回答” **9**

1.1 问题引入：模型知道得再多，也缺“专家数据” . . . 9
1.2 学科坐标 . . . 10
1.3 正式定义 . . . 10
1.4 检索的数学核心：余弦相似度从哪里来 . . . 10
1.5 RAG 的完整流程：离线建库 + 在线问答 . . . 11
1.6 易错点 . . . 12
1.7 相近概念辨析：RAG、微调、长上下文 . . . 13
1.8 相似知识对比与迁移 . . . 13
1.9 后续知识联系 . . . 14

第 2 章 Tool Calling：让模型从“会说”变成“会做” **14**

2.1 问题引入：能不能让模型直接执行? . . . 14
2.2 学科坐标 . . . 15
2.3 正式定义 . . . 15
2.4 模型怎么知道有哪些工具：工具描述 . . . 15
2.5 Tool Calling 的六步执行流程 . . . 16
2.6 易错点 . . . 17
2.7 相近概念辨析 . . . 18
2.8 相似知识对比与迁移 . . . 18

第 3 章 Agent：从聊天机器人到任务执行者 **19**

3.1 问题引入：能不能让模型从头到尾全干完? . . . 19
3.2 学科坐标 . . . 20
3.3 正式定义 . . . 20
3.4 Agent 的循环：Plan → Act → Observe → Reflect . . . 20
3.5 把循环写成可执行的形式 . . . 21
3.6 易错点 . . . 22
3.7 相近概念辨析：普通模型、Tool Calling、Agent、固定工作流 . . . 23

3.8 相似知识对比与迁移 23

第 4 章 多模态与对齐：AI 不只会读文字 25

4.1 问题引入：能不能从文字延展到其他方式? 25
4.2 学科坐标 25
4.3 正式定义与“统一向量空间” 25
4.4 对齐是什么? ——跨模态对齐 26
4.5 多模态能做什么 27
4.6 易错点 28
4.7 相似知识对比与迁移 28

第 5 章 Diffusion：从一团噪声“雕”出一张图 29

5.1 问题引入：一张图为什么不能“一笔画成”? 29
5.2 学科坐标 30
5.3 正向扩散：图片逐渐变成噪声 30
5.4 模型学的是什么：预测噪声 31
5.5 反向生成：噪声逐渐变成图片 31
5.6 文字如何控制图像生成 32
5.7 易错点 33
5.8 相似知识对比与迁移 34

第 6 章 大模型幻觉：“说得像”不等于“真知道” 35

6.1 问题引入：什么是幻觉? 为什么会出现幻觉? 35
6.2 正式定义与例子 35
6.3 根本原因：模型在生成“像答案的话” 36
6.4 幻觉出现的四个主要原因 36
6.5 教学补全：为什么模型“宁可猜，也不说不知道” 36
6.6 怎样缓解幻觉：本节知识的汇合点 37
6.7 易错点 38
6.8 相近概念辨析 38
6.9 相似知识对比与迁移 38

第 7 章 Harness：Agent 工程化的关键 40

7.1 问题引入：为什么只靠 LLM 还不够? 40
7.2 学科坐标 40
7.3 正式定义 40
7.4 核心公式：Agent = LLM + Harness 41
7.5 Harness 最核心的机制：执行循环 42
7.6 Harness 的六大核心职责 43

7.7 状态管理的一个日常例子：handoff 文件 44
7.8 没有 Harness 会发生什么 45
7.9 最终总结：理解 Harness，就是理解 Agent 如何被组织起来 46
7.10 易错点 47
7.11 相近概念辨析：提示词、上下文、Harness 47
7.12 相似知识对比与迁移 47

全专题总结：知识地图、易错总表与后续连接 **49**

正式练习（38 题）：基础 25 ·提升 10 ·跨学科 3 **52**

答案速查与逐题图解 **58**

参考资料 **71**

阅读说明

这份讲义把一节信息量很大的课——课件 36 页、笔记 3 页——重新整理成可以**独立自学**的资料。课件的每一页都是一张“结论图”：它告诉你 RAG 有六步、Harness 有六大职责，却很少告诉你**为什么**要这样设计、**哪一步最容易出错**、它和你已经学过的知识**像在哪里、又不同在哪里**。讲义的工作就是把这些“课堂上口头带过”的部分补回来。

两种来源标签。正文中出现 原始资料 的内容可以从课件或笔记中可靠识别；出现 教学补全 的内容是课件没有展开、但初学者真正理解所必需的补充，均按公开论文、官方技术文档或标准教材核验后写入。

色块语义固定不变：

定义 / 核心公式　例题 / 生活 / 历史　易错 / 纠错　总结 / 自检　| 相似知识对照

对照模块中的迁移判断统一使用三个符号：✓ 可以直接迁移；△ 加条件才成立；✗ 不能迁移。

练习的用法。正文里的例题、“生活中的它”和对照算例都是教学示例，不计入正式练习。正式练习共 38 道，集中在讲义后部：先独立完成，再查答案速查表，最后读逐题图解。

本专题学什么：一条从“会说”到“会做”的升级路线

课件第 16 页给出了全课的主线（下图）。大语言模型（LLM）本身只会根据输入生成文字；为了让它**查得到资料**，人们给它接上知识库（RAG）；为了让它**做得了动作**，人们让它可以调用工具（Tool Calling）；为了让它**把多步任务从头做到尾**，人们给它加上规划、记忆和循环（Agent）；为了让这一切**稳定、安全、可追踪地运行**，人们需要一层工程外壳（Harness）。多模态与 Diffusion 则把输入和输出从文字扩展到图像、语音与视频。

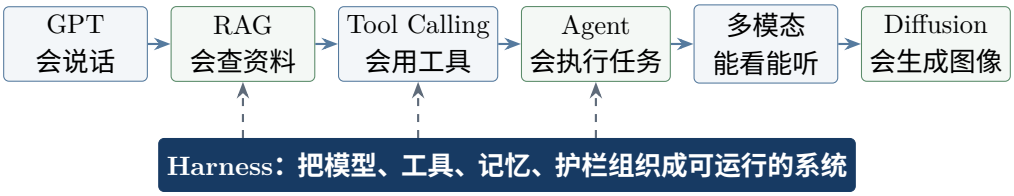


图 0.1　本专题主线：能力逐级升级，Harness 是贯穿其中的工程底座（据课件第 16、28 页重绘）

图中横向箭头表示“在前一层能力上再加一种能力”，并不表示后者取代前者：Agent 内部仍在使用 RAG 和 Tool Calling。下方深蓝条是第 7 章要讲的 Harness，虚线表示 Harness 负责组织上方几层能力。读图时最应该看出的是：**现代 AI 应用不是一个模型，而是“模型 + 外部系统”**。

本专题在课程体系中的位置

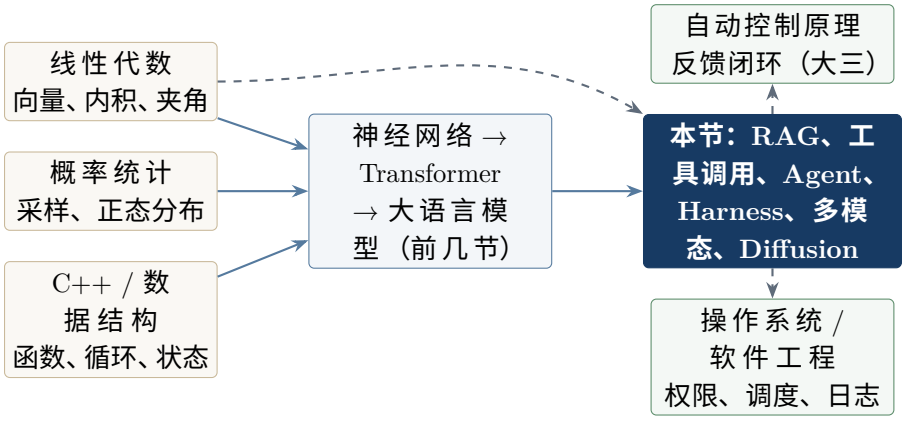


图 0.2　前置知识（米色）→ 本节（深蓝）→ 后续相关课程（绿色，虚线为“思想相通”）

图中米色框是你已经学过或正在学的课程：向量内积会在 RAG 检索里直接用到；正态分布会在 Diffusion 里用到；函数调用和循环会在 Tool Calling 与 Agent 循环里反复出现。绿色框是以后会再次遇到这些思想的课程：作为自动化类专业　　的学生，你会在《自动控制原理》里看到与 Agent 循环几乎同构的“反馈闭环”（第 3 章对照）。

预备：读懂本节需要的三件小工具

课件默认你已经知道“大模型是怎么生成文字的”。这里用一页把后文反复出现的三件工具补齐。

教学补全

工具一：大模型在做什么——预测下一个 token

token 是模型处理文字的最小单位，可以是一个汉字、一个词或词的一部分。大语言模型在每一步都根据前面所有内容，给“下一个 token 是什么”算出一个概率分布，再从中选出一个（或按概率抽取一个），接到末尾，然后重复。

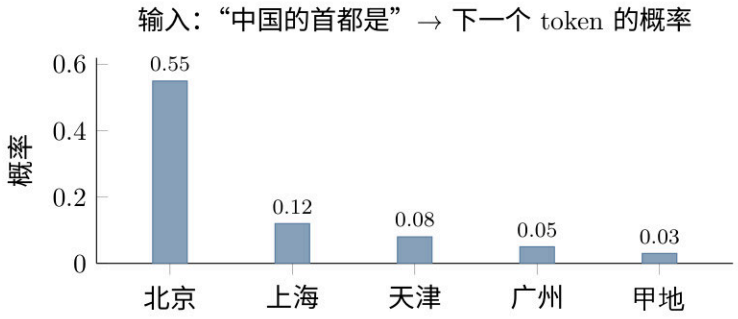


图 0.3　示意：模型输出的是“各候选 token 的概率”，而不是从数据库里查到的事实（数值为示意）

横轴是候选 token，纵轴是模型给出的概率。最该看出的是：模型**永远会给出一个分布**，哪怕它其实“不知道”。这一点是第 6 章“幻觉”的根源。

工具二：上下文窗口——模型一次能“看见”多少

模型每次生成时能参考的全部输入（系统提示、对话历史、检索到的资料、工具结果）合起来叫**上下文**（context），它的长度上限叫**上下文窗口**。窗口之外的内容，模型完全看不到；一次新对话开始时，上一段对话通常也不在窗口里。后文的 RAG、记忆模块、handoff 文件，本质上都是在**决定把什么放进这个窗口**。

工具三：向量与余弦相似度——让“意思相近”可以计算

把一段文字通过 Embedding 模型变成一个高维向量后，“意思相近”就变成了“方向相近”。线性代数中两向量夹角的余弦为

$$\cos\theta = \frac{\boldsymbol{q}\cdot\boldsymbol{d}}{\|\boldsymbol{q}\|\,\|\boldsymbol{d}\|} = \frac{\sum_i q_i d_i}{\sqrt{\sum_i q_i^2}\,\sqrt{\sum_i d_i^2}}, \qquad -1 \le \cos\theta \le 1. \tag{1}$$

其中 $\boldsymbol{q}$ 是问题的向量，$\boldsymbol{d}$ 是某段文档的向量，$\|\cdot\|$ 是向量长度。$\cos\theta$ 越接近 1，两个方向越一致，就认为二者语义越相近。这条公式会在第 1 章被完整使用。

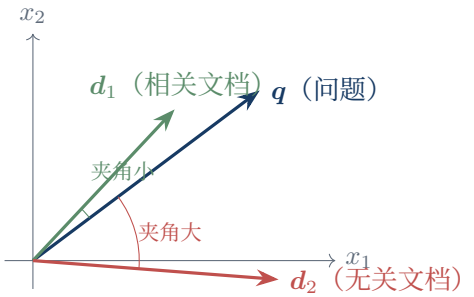


图 0.4　余弦相似度：比较的是方向（夹角），不是长度

学科小史：从“聊天程序”到“会干活的 Agent”

本节的知识并不是某一天突然被发明的。它们来自人们一次次碰到的同一个困境：**语言模型“说得像”，却“查不到、做不了、管不住”**。下面的时间轴只列与本节直接相关的节点。教学补全

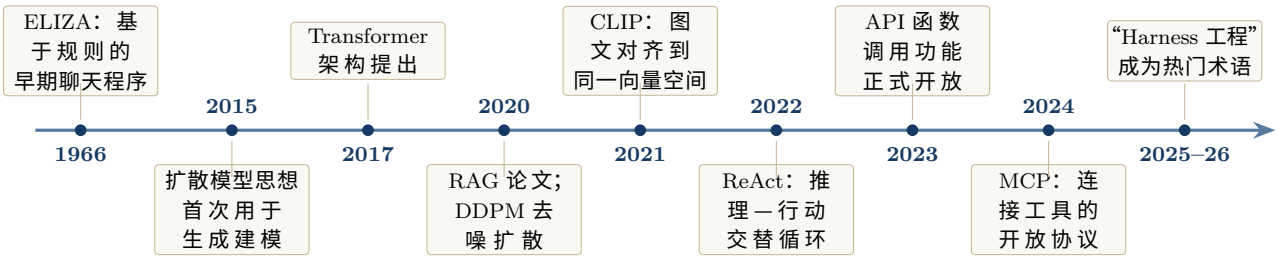


图 0.5　与本节相关的关键节点（年份依论文首次公开或官方发布时间，见参考资料）

这条时间轴告诉我们什么

- **“会说”早就有，“说得像”是近年的事。**ELIZA（1966）靠人工写好的规则对话；2017 年的 Transformer 让模型能从海量文本中学会语言规律，后来的 GPT 系列由此而来。
- **“查不到”催生了 RAG。**Lewis 等人在 2020 年的论文中把“检索器 + 生成器”组合起来，正式提出“检索增强生成”这个名称。
- **“做不了”催生了工具调用与 Agent。**2022 年的 ReAct 让模型在“思考”和“行动”之间交替；2023 年起，主流大模型接口开放了函数调用功能；2024 年 11 月，Anthropic 发布 MCP 协议，试图统一“模型如何连接工具”。
- **“管不住”催生了 Harness。**当 Agent 开始在真实电脑上读写文件、执行代码，人们发现决定成败的往往不是模型本身，而是包在模型外面的那层系统。2025—2026 年，“Agent = Model + Harness”的说法在工程界广泛流行。这个术语由谁最早提出，各方说法不一，本讲义不做断言。

从课本到现实：这些知识到底在哪里被使用？



图 0.6　四类典型应用（上）及其主要依赖的本节知识（下）

科普：课堂知识在真实系统里的位置

编程助手。课上提到的 Codex 一类工具，就是“大模型 + Harness”的典型：模型负责理解需求、写代码；Harness 负责把代码真正写进文件、在终端里运行测试、读取报错并交回给模型，再进入下一轮。没有这层外壳，模型只能“说出”代码，不能“跑起来”。

知识库问答。学校教务、企业制度、课程资料都不在模型的训练数据里，或者在训练之后才更新。RAG 先把这些文档切块、向量化、存入向量数据库，提问时先检索、再回答。课堂笔记中提到的“用 Obsidian 笔记库或飞书文档做知识库”，正是个人尺度上的同一思路。

服务器运维。笔记记录了老师提到“某 VPS 服务商提供自带的 agent 用于服务器维护”。这类场景最能说明“护栏”的必要：重启服务、删除文件属于高风险操作，必须由 Harness 拦截并请求人工确认。（该服务商产品的具体功能本讲义未能核验，这里只讨论一般原理。）

设计与创作。文生图模型从一团随机噪声出发，在文字条件的引导下一步步“去噪”，得到图像。第 5 章会说明“文字怎样在每一步给去噪指方向”。

原始资料重编码、纠错与知识总览

课件结构识别

课件共 36 页，按“问题页 → 结论图”的节奏组织。下表把每一组页面重新编码，并标出它在本讲义中的位置。所有页面均清晰可读。 原始资料

页码	页面标题	核心内容（重编码）	讲义位置
1–2	封面；§7 Agent	课程名“机器学习与人工智能”，本节进入第 7 部分	封面
3–6	问题页；RAG 为什么 / 是什么 / 完整流程	五个缺陷（过时、私有、幻觉、记不全、无出处）；RAG = 检索 + 生成；六步流程；“开卷考试”类比	第 1 章
7–9	问题页；Tool Calling 会说 → 会做；执行流程	工具调用六步；Function Calling 是一种实现方式；35×48 计算器示例	第 2 章
10–13	问题页；Agent 定义；Agent 循环；三者对比	Agent = 大模型 + 工具 + 记忆 + 规划 + 执行 + 反馈；Plan→Act→Observe→Reflect；杭州三日游示例；对比表	第 3 章
14–16	问题页；多模态；从大模型到 AI 应用系统	四种模态 → 统一向量空间；六级能力路线	第 4 章、图 0.1
17–22	§8 几个补充；Diffusion 总览、正向扩散、反向去噪、文字控制	加噪 / 去噪；文本向量在每一步引导去噪	第 5 章
23–25	问题页；大模型幻觉；四个原因	定义、虚构论文与虚构书名示例；四个原因	第 6 章
26–36	收尾 §9；再讲 Agent；Harness 七页	为什么只靠 LLM 不够；Harness 定义；六组件公式；九步执行循环；六大职责；无 Harness 的五类问题；总结	第 7 章

手写笔记识别（2026 年 10 月 11 日，三页）

笔记与课件大体平行，但有几处**课件没有的补充**：老师口头提到的工具、一个“对齐是什么?”的问题、一段写给 AI 的 handoff 提示词。下表列出与课程知识相关的条目。 原始资料

页	笔记原文（规范转写）	讲义中的处理
514	为什么需要 RAG：1. 知识可能过时；2. 不了解私有领域（例：高考报志愿 → 强基分数线公布）；3. 容易产生幻觉；4. 记不住全部细节；5. ……	第 5 条笔记留空，按课件补为“缺少可追溯来源”；例子归类见纠错 ④
514	RAG 到底是什么？（Obsidian）或飞书 CLI，Agent 直接写文档	第 1 章“生活中的它”与科普中作为个人知识库示例
514	红字：某 VPS 服务商（笔记写作 banwagon）内有自己的 agent，可自己作 service computer 的维护	科普“服务器运维”；术语纠错见 ⑤
515	Agent：从聊天机器人 → 任务执行者（大厂面试重点）；plan→act→observe→reflect（loop 循环，干完再检查）	第 3 章
515	五、能否从文本延伸到其他地方：1. 多模态，统一向量空间；2. **对齐是什么？**	第 4 章：笔记只有问题、课件无对应页，全部为教学补全
515	幻觉原因：① 训练目标；② 无实时知识库；③ 语言合理但事实不一定正确	课件第 25 页还有第 ④ 条“错误前提”，第 6 章补全
515	Harness（技术方法）：Tools + Memory + Control loop + Guardrails = harness；Agent = LLM + Harness	第 7 章；与课件写法的差异见纠错 ③
516	可以将 Agent 中的 LLM 换掉（CC Switch）	第 7 章“生活中的它”
516	Harness 的六大核心职责；红字：harness 是 agent 工程化的关键	第 7 章
516	PPT、Skills、frontend_slides（都是 html）	第 7 章“技能包”拓展
516	用 AI 做 PPT 快出成品时写一段话：① 表扬；② 怕新对话丢失细节；③ 总结一份完整的 handoff.md	第 7 章“状态管理”生活应用，并给出改进写法

无法可靠辨认的内容

- 第 514 页“例：___ 高考报志愿”中，“高考”前的两个字**原始资料此处无法可靠辨认**。可能解释：“参考”。以下属于推测，不属于原图可靠识别结果。该处不影响知识理解。
- 第 516 页“Clash verge 上有个链式穿_”末字笔画不清，可能为“穿越”。该条属于网络代理配置，未纳入正文（见下文）。

未纳入正文的笔记内容及原因　笔记第 514 页“新技能”（境外手机号、eSIM 服务网站）和第 516 页“如何作中间的 IP 中转”（代理节点、链式代理）、办卡提醒，属于上网工具信息，不是本节的课程知识点，且涉及具体商业服务与当地网络法规，本讲义不收录。

第 516 页还记录了“把某编程工具本地保存的登录凭证文件复制给别人，别人就能用我的账号”。**共享账号凭证通常违反服务条款，也会把你的账户完全交给他人**，本讲义不收录操作方法。但这条笔记恰好揭示了一个 Harness 知识点：**Agent 的身份凭证就是本地文件，谁拿到谁就能以你的身份行动**。这正是第 7 章“安全护栏——防止隐私泄露、控制权限”要防范的情形。

原始资料纠错

原图纠错 ①　课件第 20 页：“训练时，模型学习如何把图像一步步加噪”

原始写法：正向扩散页右侧提示框写“训练时，模型学习如何把图像一步步加噪”。
存在的问题：正向加噪过程是**人为规定的固定过程**，按预先设定的噪声日程逐步加入高斯噪声，不含任何需要学习的参数。模型真正学习的是**反向**：给定一张加了噪声的图和步数，预测其中的噪声（从而能把它去掉）。
规范写法：“训练时，先用固定的正向过程给图像加噪，制造出‘带噪图—所加噪声’的训练对；模型学习的是如何从带噪图中预测并去除噪声。”
为什么这样改：DDPM（Ho 等，2020）中正向过程 q 的噪声日程 β_t 是预先给定的，网络 $\epsilon_\theta(x_t, t)$ 学的是预测噪声 ϵ。
是否影响后续：影响。若误以为模型学的是加噪，就无法理解“生成时为什么能从噪声变出图像”。第 5 章按规范写法讲解，练习第 9、25 题专门考查。

原图纠错 ②　课件第 21 页：反向去噪的中间图画成了“线稿”

原始写法：第 2 步“出现轮廓”画成一张干净的猫的线描。　**问题：**这是示意化画法。真实的去噪中间结果是**模糊的大块颜色与大致构图**（先恢复低频的整体结构，后恢复高频的纹理细节），并不会出现线稿。　**规范理解：**“先粗后细”是对的，“先出线稿”不对。　**影响：**不影响结论，但读图时不要把线稿当成真实的中间状态。第 5 章图 5.3 用“由模糊到清晰”重绘。

原图纠错 ③　Agent / Harness 的“公式”出现了四种写法

原始写法：(a) 课件第 11 页：Agent = 大模型 + 工具 + 记忆 + 规划 + 执行 + 反馈；(b) 课件第 28 页：LLM + Tools + Memory + Control Loop + Guardrails = Agent System；(c) 课件第 32 页：Agent = LLM + Tools + Memory + Planning + Control Loop + Guardrails；(d) 笔记：Tools + Memory + Control loop + Guardrails = harness，Agent = LLM + Harness。
存在的问题：四种写法组件个数不同（6、5、6、4+1），初学者容易以为“标准答案有分歧”。另外笔记 (d) 中 Harness 的组成没有 Planning。
规范写法：这些“公式”都是**概念拆分**，不是数学恒等式，也没有业界统一的标准组件表。本讲义统一采用

$$\text{Agent} = \text{LLM} + \text{Harness},$$
$$\text{Harness} \supseteq \{\text{Tools},\ \text{Memory},\ \text{Planning 支持},\ \text{Control Loop},\ \text{Guardrails},\ \text{日志评估}\}.$$

其中“规划”由模型完成思考，但计划的保存、拆解格式与进度跟踪由 Harness 支撑，所以列为“Planning 支持”。(a) 中的“执行、反馈”就是 Control Loop 的 Act 与 Observe 两个阶段。
影响：考试或面试中按课件第 32 页的“六组件”作答即可；理解时记住“LLM 负责想，其余都是 Harness”。第 7 章图 7.2 给出四种写法的对应关系图。

表述商榷 ④⑤⑥　几处小问题

- ④ 笔记把“强基分数线公布”列在“不了解私有领域”下。分数线是公开信息，问题在于**训练截止之后才公布**，更贴切地属于“知识可能过时”。“私有领域”指学校内部通知、企业制度等**从未公开**的资料。
- ⑤ 笔记“service computer 的维护”应为“server（服务器）的维护”。
- ⑥ 课件第 5 页把 RAG 称为“RAG 模型”、第 6 页把检索写成“问题向量化”。RAG 更准确

地说是一种**系统架构**（检索器 + 生成模型），检索也不只有向量检索一种，关键词检索同样常用。课件第 24 页说模型“预测最可能出现的下一个 token”，实际生成时常按概率**采样**，不一定取概率最大者。这三处不影响主线，正文按准确说法表述。

知识点总览与知识关系图

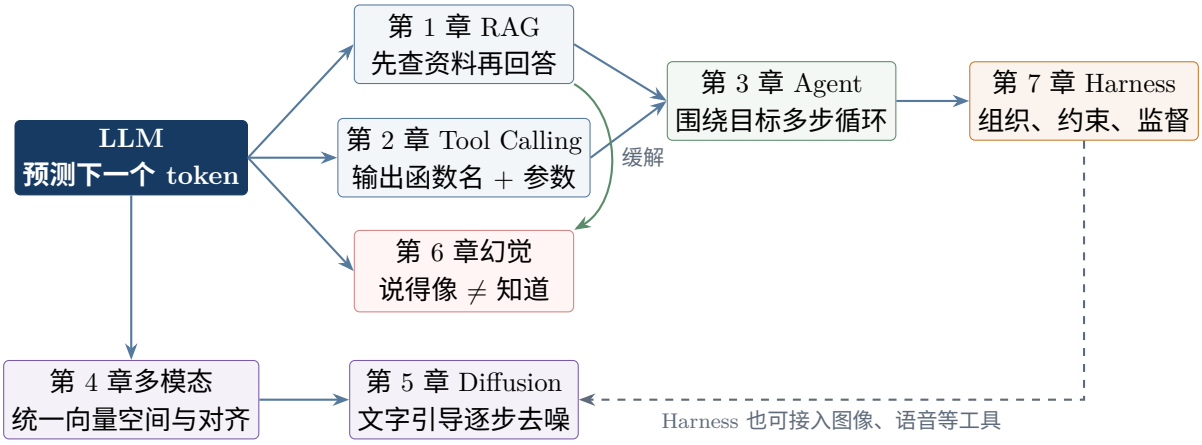


图 0.7　全讲义知识关系图（箭头表示“在此基础上”，绿色箭头表示“用于缓解”）

图中深蓝的 LLM 是一切的起点。向右是“让模型能做事”的主线（RAG、工具 → Agent → Harness）；向下是“让模型能看能画”的支线（多模态 → Diffusion）；右下方的幻觉是 LLM 的固有缺陷，绿色箭头表示 RAG 是缓解它的主要手段之一。课件的讲授顺序是 RAG → 工具 → Agent → 多模态 → Diffusion → 幻觉 → Harness；本讲义保持这一顺序，但在每章开头说明它和前一章的衔接。

第 1 章　RAG：让模型“先查资料，再回答”

本章回答三个问题： ① 大模型已经读过海量文本，为什么还需要查资料？ ② “查资料”在计算机里具体怎么做？ ③ 怎样用一个公式判断“哪段资料和问题最相关”？

本章路线： 模型的五个缺陷 → RAG 的定义 → 余弦相似度（检索的数学核心）→ 六步流程 → 例题 → 易错与对照。

1.1　问题引入：模型知道得再多，也缺“专家数据”

课件第 3 页只有一句话：“对于细分领域，大模型的知识再怎么全面，也缺乏实时落地的‘专家数据’。”原始资料 这句话指出了问题的关键。大模型的“知识”来自训练时读过的文本，训练一旦结束，参数就固定了。于是有三类信息它天然拿不到：**训练之后才发生的事、从未公开的资料、太细太多、参数记不住的细节**。

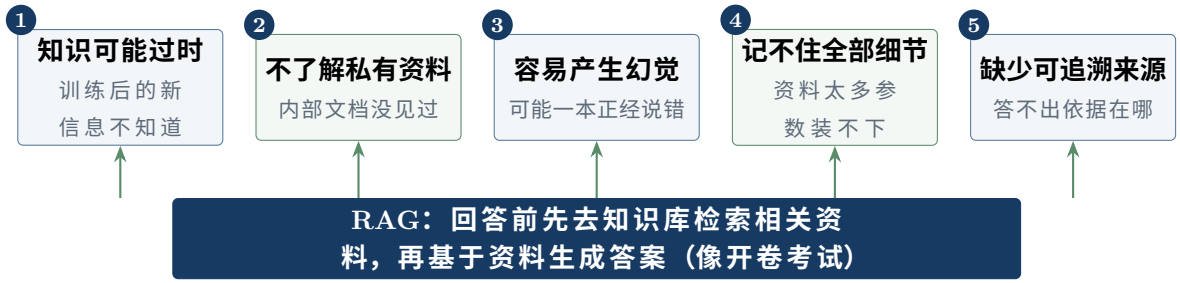


图 1.1　大模型的五个缺陷（上）与 RAG 的作用（下）。据课件第 4 页重绘 原始资料

上排五个框是课件列出的五个缺陷，下面深蓝条是 RAG。绿色箭头表示 RAG 对每一个缺陷都有缓解作用：把最新的、私有的、详细的资料在回答前**临时**放到模型眼前，并且因为资料来自哪里是已

知的，答案可以附上出处。注意“缓解”不等于“消除”：检索错了，模型照样会答错（见 1.7 节）。

1.2 学科坐标

所属课程	机器学习与人工智能·第 7 部分 Agent
前置知识	预备中的“上下文窗口”与“余弦相似度”；线性代数中的向量内积
后续知识	第 3 章 Agent 的“记忆”模块；第 7 章 Harness 的“给模型提供任务上下文”
相关课程	数据库（索引与查询）、数据结构（Top-k 问题）、信息检索
典型工程背景	企业知识库问答、课程资料助手、带引用的搜索问答

1.3 正式定义

定义：检索增强生成（Retrieval-Augmented Generation，RAG）

RAG 是一种系统架构：对用户问题 q，先由**检索器**从外部知识库 $\mathcal{D}$ 中找出与 q 最相关的若干文档片段 $d_1, \dots, d_k$，再把这些片段与问题一起放入**生成模型**的上下文，由模型基于这些资料生成回答。

- RAG 不修改模型参数，只改变模型**这一次**看到的输入。 原始资料
- 知识库可以随时增删更新，不需要重新训练模型。 教学补全

核心关系：RAG = 检索（Retrieval）+ 生成（Generation）

$$\text{答案} = \text{LLM}\Big(\underbrace{\text{指令}}_{\text{系统提示}} \oplus \underbrace{\text{TopK}_{d\in\mathcal{D}}\ \text{sim}(q,d)}_{\text{检索到的资料}} \oplus \underbrace{q}_{\text{用户问题}} \Big)$$

每个符号是什么意思。q：用户问题；$\mathcal{D}$：知识库中全部文档片段的集合；$\text{sim}(q,d)$：问题与片段 d 的相似度打分（最常用余弦相似度）；TopK：按打分从高到低取前 k 个；$\oplus$：把几段文字**拼接**进同一个上下文；$\text{LLM}(\cdot)$：生成模型根据整段上下文生成回答。这不是严格的数学函数式，而是一张“数据流向图”的文字写法。 教学补全

使用条件。① 知识库里**确实存在**能回答问题的资料；② 检索打分能把它排进前 k；③ 指令 + 资料 + 问题的总长度不超过上下文窗口。三者缺一，RAG 都会失效。

1.4 检索的数学核心：余弦相似度从哪里来

RAG 要回答“哪段资料最相关”。人读一遍就知道，计算机却需要一个可以计算的数。课件第 6 页的做法是把问题和文档都变成向量（Embedding），再在向量数据库中比较。比较的标准就是预备中的余弦相似度。下面把它补全证明。 教学补全

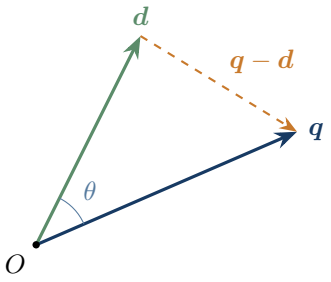


图 1.2　余弦定理推导示意

命题与证明　**要证：**对任意非零向量 $\boldsymbol{q}, \boldsymbol{d}$，$\boldsymbol{q}\cdot\boldsymbol{d} = \|\boldsymbol{q}\|\|\boldsymbol{d}\|\cos\theta$。
思路：三角形三边是 $\boldsymbol{q}$、$\boldsymbol{d}$、$\boldsymbol{q}-\boldsymbol{d}$，分别用余弦定理和内积展开计算第三边的平方，再比较。
证明：由余弦定理，

$$\|\boldsymbol{q}-\boldsymbol{d}\|^2 = \|\boldsymbol{q}\|^2 + \|\boldsymbol{d}\|^2 - 2\|\boldsymbol{q}\|\|\boldsymbol{d}\|\cos\theta.$$

由内积的双线性与对称性，

$$\|\boldsymbol{q}-\boldsymbol{d}\|^2 = (\boldsymbol{q}-\boldsymbol{d})\cdot(\boldsymbol{q}-\boldsymbol{d}) = \|\boldsymbol{q}\|^2 - 2\,\boldsymbol{q}\cdot\boldsymbol{d} + \|\boldsymbol{d}\|^2.$$

两式左边相同，比较右边即得结论。　□

一句话直观解释：内积 = 长度 × 长度 × 夹角余弦；除以两个长度，就只剩下“方向是否一致”。**为什么要除掉长度？**一段长文档的向量可能更“长”，但它并不因此更相关。余弦相似度只看方向，避免了“文档越长越占便宜”。

推论：向量归一化之后，余弦相似度就是内积　若事先把所有向量缩放为单位长度（$\|\boldsymbol{q}\| = \|\boldsymbol{d}\| = 1$），则 $\cos\theta = \boldsymbol{q}\cdot\boldsymbol{d}$，并且

$$\|\boldsymbol{q}-\boldsymbol{d}\|^2 = 2 - 2\cos\theta.$$

这说明**在单位向量下**，“余弦最大”与“欧氏距离最小”是同一件事；向量数据库常利用这一点加速检索。若向量没有归一化，二者一般**不**等价（见练习第 37 题）。教学补全

1.5　RAG 的完整流程：离线建库 + 在线问答

课件第 6 页给出了提问之后的六步。真实系统里，这六步之前还有一个**离线建库**阶段，课件没有画出，但没有它就没有可检索的向量库。下图把两部分合在一起。教学补全

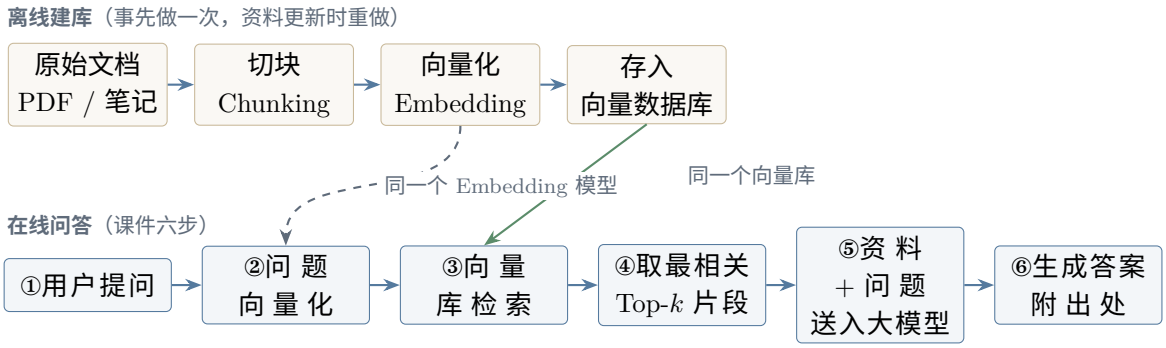


图 1.3　RAG 全流程。米色为离线建库（教学补全），蓝色为课件第 6 页的在线六步

读图要点：② 和离线阶段的“向量化”必须用**同一个** Embedding 模型，否则问题向量和文档向量不在同一个空间，余弦相似度没有意义（虚线）；③④ 就是公式中的 $\mathrm{TopK}\,\mathrm{sim}(q,d)$；⑤ 就是公式中的 $\oplus$ 拼接；⑥ 是 $\mathrm{LLM}(\cdot)$。**切块**的大小是一个工程权衡：块太大，一块里混入无关内容，且占上下文；块太小，一句话被拆散，丢失上下文。

例题　1.1　用余弦相似度给三段资料排序（课件第 6 页示例的数值化）

已知：问题“请总结 Transformer 课件的核心内容”的向量（为便于手算，取二维示意）$\boldsymbol{q} = (3,4)$。知识库三段片段：$\boldsymbol{d}_1 = (4,3)$（Transformer 结构介绍）、$\boldsymbol{d}_2 = (0,5)$（注意力机制公式）、$\boldsymbol{d}_3 = (5,-1)$

（课程考勤规定）。　**求：**相似度排序，并取 Top-2。

思路：逐个计算 $\cos\theta = \dfrac{\boldsymbol{q}\cdot\boldsymbol{d}}{\|\boldsymbol{q}\|\|\boldsymbol{d}\|}$，其中 $\|\boldsymbol{q}\| = 5$。

第一步：$\boldsymbol{q}\cdot\boldsymbol{d}_1 = 12+12 = 24$，$\|\boldsymbol{d}_1\| = 5$，$\cos\theta_1 = \dfrac{24}{25} = 0.96$。

第二步：$\boldsymbol{q}\cdot\boldsymbol{d}_2 = 0+20 = 20$，$\|\boldsymbol{d}_2\| = 5$，$\cos\theta_2 = \dfrac{20}{25} = 0.80$。

第三步：$\boldsymbol{q}\cdot\boldsymbol{d}_3 = 15-4 = 11$，$\|\boldsymbol{d}_3\| = \sqrt{26} \approx 5.10$，$\cos\theta_3 \approx \dfrac{11}{25.50} \approx 0.43$。

结果：$d_1 > d_2 > d_3$，Top-2 为 d_1, d_2，送入模型。

检查：三个值都在 $[-1,1]$ 内；图中 $\boldsymbol{d}_1$ 与 $\boldsymbol{q}$ 夹角最小，一致。

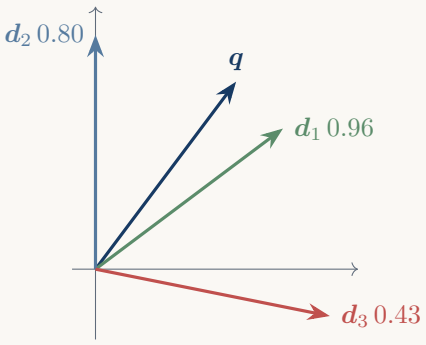


图 1.4　三段资料与问题的方向

本题真正想说明什么：“最相关”被翻译成了“夹角最小”。考勤规定 d_3 与问题方向差得远，所以不会被送进模型，模型也就不会被无关资料干扰。

生活中的它：期末开卷考试

生活场景：开卷考试时，你不会把整本书背下来，而是先看题，再翻目录找到相关几页，读完后用自己的话写答案，必要时注明“见第 37 页”。

对应关系：

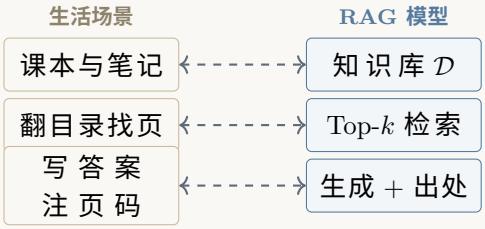
课本与笔记 → 知识库 $\mathcal{D}$

目录 / 索引 → 向量数据库

翻到相关的几页 → TopK 检索

读完再组织答案 → 大模型生成

写“见第 37 页” → 可追溯来源



小估算：一本 300 页的参考书切成 600 块，每次只取 Top-3 交给模型，模型真正“读”的只有 $3/600 = 0.5\%$ 的资料——这正是 RAG 能把海量资料塞进有限上下文窗口的原因。

边界说明：考试时你能读懂目录、判断哪页有用；RAG 的检索只是按向量方向打分，可能把“看起来像”但不相关的片段排在前面。

1.6　易错点

易错点

1. **“RAG 会让模型学到新知识。”**错。RAG 不改参数，换一个没有知识库的对话，模型仍然不知道。课件第 5 页：RAG 不是修改模型参数，而是临时把相关资料放进上下文。
2. **“用了 RAG 就不会幻觉。”**错。若检索到的片段不相关，或模型没有忠实使用资料，仍会答错。RAG 降低幻觉，不消除幻觉。
3. **“相似度越高，资料越正确。”**错。相似度只衡量“话题像不像”，不衡量“内容对不对”。一篇过时的文档可能与问题极其相似。

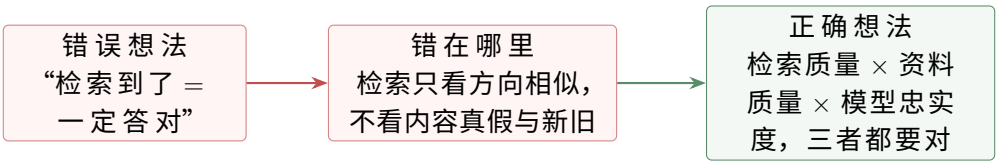


图 1.5　易错点 2、3 的“错误想法 → 错误所在 → 正确想法”对照

1.7 相近概念辨析：RAG、微调、长上下文

比较维度	RAG（检索增强）	微调（Fine-tuning）	直接塞进长上下文
是否改参数	否	是，用新数据继续训练	否
知识更新	改知识库即可，快	需重新训练，慢	每次手动粘贴
能否给出处	能，知道片段来自哪里	难	能，但要人工标
适合	资料多、常更新、需引用	学风格、格式、专业表达	资料少、一次性
类比	开卷考试	考前背书	把整本书摊在桌上

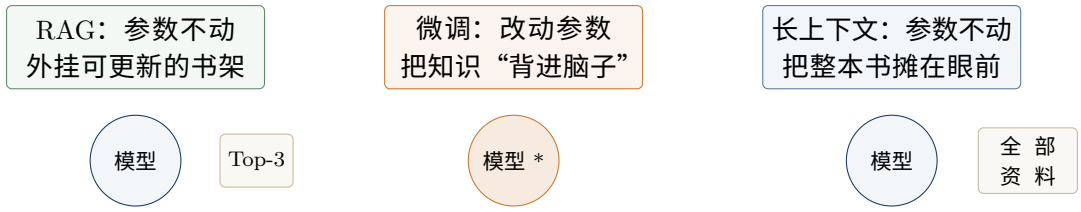


图 1.6　三种做法的区别：**改不改参数**（带 * 表示参数被改）与**放多少资料进上下文**

1.8 相似知识对比与迁移

对照：向量检索 ↔ 数据库精确查询 / Ctrl+F 关键词查找（方法互补型）

一句话定位：二者都是“从大量记录中找出需要的那几条”，但关键词查找比的是**字面是否相同**，向量检索比的是**意思是否相近**。

维度	关键词 / SQL 精确查询	向量检索（RAG）
比较对象	字符串是否包含、字段是否相等	两个向量的夹角（余弦相似度）
结果形态	命中 / 不命中，集合	按相似度连续打分，取 Top-k
同义改写（“考勤”vs“出勤要求”）	搜不到	通常能搜到
精确编号（“学号 2024…”）	非常可靠	可能不准
可解释性	强，一眼看出为何命中	弱，只有一个分数

相同之处：都需要事先建立**索引**，查询时只扫描索引而不是逐字读全文；都可以“先粗筛、再排序”。　**不同之处及根源：**关键词把文本当作**符号序列**，向量检索把文本当作**高维空间中的点**。根源在于 Embedding 把“意思”编码成方向，于是“意思近”变成可以连续度量的量。

旧知识中的结论	迁移	理由或反例
建索引能加速查询	✓	向量库同样建索引（近似最近邻索引）
查询结果要么命中要么不命中	✗	向量检索永远返回 Top-k，哪怕都不相关
查不到说明库里没有	△	只对关键词成立；向量检索“查不到”可能只是排名靠后

同一个小算例：库中有“出勤要求：缺课三次取消考试资格”。查询“考勤规定”：关键词查找因字面不同返回 0 条；向量检索因语义相近，可把这条排进 Top-1。反过来查询“202400150051”，关键词查找精确命中，向量检索却可能返回一串相似数字。**实际系统常把两者结合（混合检索）。**

教学补全

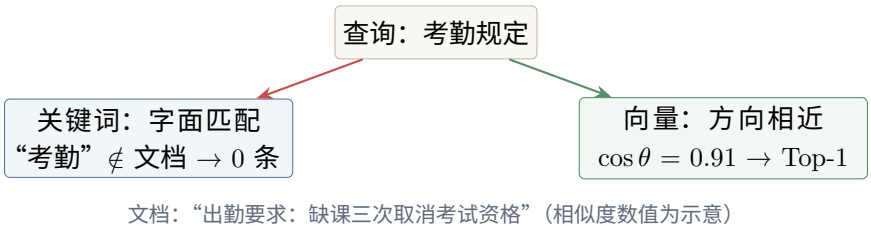


图 1.7　对照图：同一查询在两种检索方式下的结果

对照：Top-k 检索 ↔ 数据结构中的 Top-k 问题（思想重现型，精简版）

一句话定位：RAG 的“取最相关的 k 段”就是数据结构课里“从 n 个数中选出最大的 k 个”。用大小为 k 的小根堆，复杂度为 $O(n \log k)$，不必把 n 个分数全排序（$O(n \log n)$）。　**迁移判断：**堆方法 ✓ 直接可用；但当 n 达到百万级时，连逐个算 n 次余弦都太慢，向量库改用**近似**最近邻索引，结果可能漏掉真正的第 1 名——这是△ 加条件迁移（精确 → 近似）。教学补全

1.9　后续知识联系

知识联系　RAG 在第 3 章变成 Agent 的“记忆”之一（长期记忆常用同样的向量库实现）；在第 7 章变成 Harness 的第一项职责“给模型提供任务上下文”。线性代数里的内积、投影会在以后的《模式识别》《信息检索》中以“相似度度量”的身份反复出现。

学完这里，你应该能够回答

1. 大模型的哪五个缺陷促使人们引入 RAG？哪一个 RAG 无法根治？
2. RAG 改不改模型参数？换一个对话后模型还“知道”检索过的内容吗？
3. 余弦相似度公式中每个符号的意思？为什么要除以两个向量的长度？
4. 离线建库与在线问答各有哪些步骤？为什么必须用同一个 Embedding 模型？
5. 已知 $\boldsymbol{q} = (1, 0)$、$\boldsymbol{d} = (1, 1)$，能否算出 $\cos\theta = \frac{\sqrt{2}}{2}$？
6. 关键词检索与向量检索各擅长什么？

到这里，我们已经解决了什么？模型能“查到”训练之外的资料了。　**下一步还需要解决什么？**查资料只是读取信息；如果用户要“帮我发一封邮件”“帮我算一下”，模型需要**对外部世界做动作**。这就是第 2 章的 Tool Calling。

第 2 章　Tool Calling：让模型从“会说”变成“会做”

本章回答三个问题：① 模型只能输出文字，它怎么可能“查天气”“发邮件”？ ② 一次工具调用中，模型做了什么，系统做了什么？ ③ 工具调用和程序里的函数调用有什么异同？

本章路线：只会说 vs 会做 → 定义 → 工具描述与调用格式 → 六步执行流程 → 例题 → 易错与对照。

2.1　问题引入：能不能让模型直接执行？

第 1 章的 RAG 解决了“查得到”，但它只是**读**。课件第 7 页接着问：“能不能让模型直接执行？”原始资料 设想用户说“帮我查一下今天北京天气，并提醒我下午带伞”。普通模型只能给出“建议你打开天气 App 看看”之类的一般性建议；它既不知道**此刻**的天气，也无法真的在你手机上**创建**提醒。



图 2.1　从“只会说”到“会做”（据课件第 8 页重绘） 原始资料

左框是普通模型的能力边界：所有输出都是文字。右框是接上工具后的能力：文字之外，还能读取实时数据、执行计算、改变外部状态（发出邮件、写入文件）。中间的粗箭头就是本章的主角。

2.2　学科坐标

前置知识	第 1 章 RAG（也可看成“检索工具”）；C++ 中的函数声明与调用
后续知识	第 3 章 Agent 的 Act 阶段；第 7 章 Harness 的“工具管理”职责
相关课程	程序设计（函数）、操作系统（系统调用）、计算机网络（API 请求）

2.3　正式定义

定义：工具调用（Tool Calling）与函数调用（Function Calling）

Tool Calling：让模型在需要时，从事先提供给它的工具列表中**选择**合适的外部函数、API 或工具，并给出调用所需的参数；由外部系统执行后，模型再根据返回结果继续回答。 原始资料

Function Calling：Tool Calling 的一种具体实现方式——模型输出**结构化**的“函数名 + 参数”（通常是 JSON），由系统解析并执行该函数。 原始资料

> **一句话直观理解**　模型**只负责“写调用单”**，系统**负责“照单执行”**。模型从头到尾仍然只是在生成文字，只不过其中一段文字恰好是机器可读的调用指令。

核心关系：一次工具调用的数据流

$$
\begin{aligned}
(f,\ \boldsymbol{a}) &= \mathrm{LLM}\big(\text{上下文}\ \oplus\ \text{工具列表}\big) && \text{模型：选工具}f\text{，写参数}\boldsymbol{a}\\
r &= \mathrm{Execute}(f,\ \boldsymbol{a}) && \text{系统：真正执行，得到结果}r\\
\text{回答} &= \mathrm{LLM}\big(\text{上下文}\ \oplus\ (f,\boldsymbol{a})\ \oplus\ r\big) && \text{模型：读结果，组织语言}
\end{aligned}
$$

符号说明：f 是工具名（如 `get_weather`）；$\boldsymbol{a}$ 是参数（如 `city="北京"`）；r 是工具返回的结果；Execute 由系统（第 7 章称为 Harness）完成，**不是**模型完成。使用条件：工具必须事先**注册并描述**给模型，模型才知道有这个工具、该怎么填参数。 教学补全

2.4　模型怎么知道有哪些工具：工具描述

课件没有说明模型如何“知道”工具的存在。答案是：系统把每个工具的**名称、用途说明、参数格式**写成一段结构化描述，放进模型的上下文。模型读到这段描述，才可能在合适的时候“写出”对它的调用。下图把这三段文字逐项标注出来。 教学补全

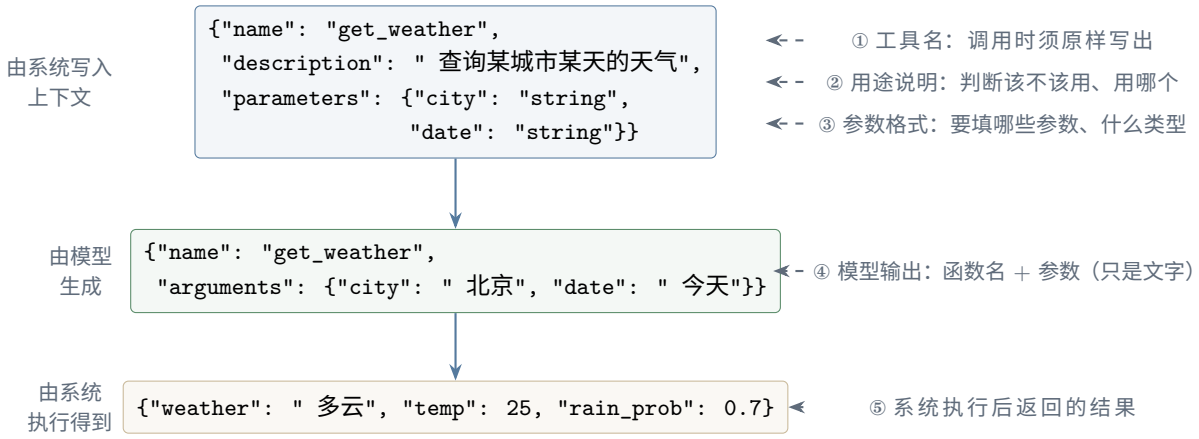


图 2.2　标注图：工具描述、调用单与返回结果三段文字（JSON 格式为常见写法的简化示意）

图中三个色块自上而下对应公式的三行：蓝色是系统提供的工具列表，绿色是模型生成的 $(f, \boldsymbol{a})$，米色是执行结果 r。最应该看出的是左侧的“由谁产生”：**只有绿色那一段是模型写的**。

2.5　Tool Calling 的六步执行流程

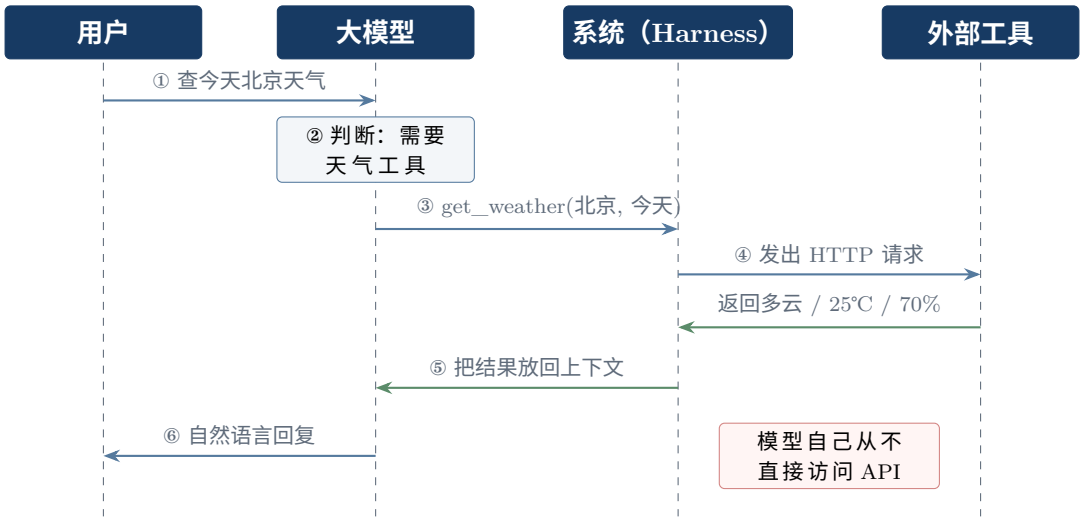


图 2.3　时序图：六步中模型只负责 ②③⑥，执行由系统完成（据课件第 9 页重绘并补充参与方）

四条竖虚线是四个参与方，箭头按时间从上到下。课件第 9 页把第 ④ 步写成“系统执行工具 / API”，这里把“系统”和“外部 API”分成两列，是为了看清：**模型与外部世界之间永远隔着一层系统**。这一层就是第 7 章的 Harness——它可以在第 ③④ 步之间检查参数、判断权限，拒绝危险调用。

> **为什么 35×48 也要交给计算器？**　课件第 9 页的计算器例子容易被误解为“模型不会乘法”。更准确的说法是：模型按 token 生成数字，每一位都是“预测”出来的，**没有任何机制保证位位正确**；计算器按算法执行，结果确定。手算核对：$35\times48=35\times50-35\times2=1750-70=1680$，与课件给出的 1680 一致。数字越长、步骤越多，“逐位预测”出错的机会越大，交给工具越划算。
>
> 教学补全

例题　2.1　查天气并设置带伞提醒（两次工具调用）

已知：用户说“帮我查一下今天北京天气，如果可能下雨，就提醒我下午 2 点带伞。”可用工具：`get_weather(city, date)`、`create_reminder(time, text)`。　**求：**写出调用过程。

第一步（模型）：输出 `get_weather(" 北京"," 今天")`。
第二步（系统）：执行，返回 `rain_prob = 0.7`。
第三步（模型）：读到降雨概率 $0.7 > 0.5$，判断“可能下雨”，输出 `create_reminder("14:00"," 带伞")`。
第四步（系统）：执行，返回“提醒已创建”。
第五步（模型）：回复“今天北京多云，降雨概率 70%，已为你设好下午 2 点的带伞提醒。”
检查：两次调用的参数都来自用户原话或上一步结果，没有凭空编造。

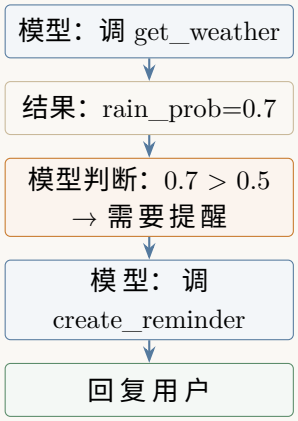


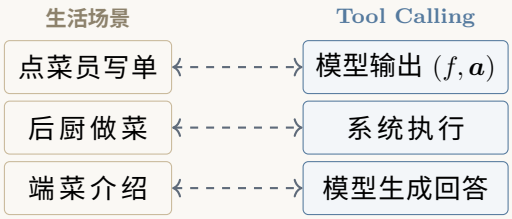
图 2.4　第二次调用的参数依赖第一次的结果

本题真正想说明什么：后一次调用依赖前一次的结果。当这种“调用—观察—再决定”的链条变长、需要规划时，单纯的 Tool Calling 就升级为第 3 章的 Agent。

生活中的它：餐馆里的点菜员与后厨

生活场景：你对点菜员说“来份不太辣的宫保鸡丁”。点菜员不会自己下厨，而是在点菜单上写“宫保鸡丁 × 1，微辣”，交给后厨；菜做好后，点菜员端上来并说“您的菜齐了”。

对应关系：
菜单 → 工具列表（名称 + 说明）
点菜单上的格式 → 参数格式
写下“宫保鸡丁，微辣” → 模型输出 $(f, \boldsymbol{a})$
后厨做菜 → 系统 Execute
端菜并介绍 → 模型组织回答



小判断：如果点菜单上漏写辣度，后厨会退回来问——这就是系统的**参数校验**：参数不全时不执行，而是请求补充信息（第 7 章“错误处理”）。
边界说明：真实的点菜员会察言观色、主动推荐；模型只能从“工具说明”里判断该用哪个工具，说明写得含糊，它就可能选错。

2.6　易错点

易错点

1. **“模型自己调用了 API。”**错。模型只输出调用单，执行的是系统。正因如此，系统才有机会在执行前拦截危险操作。
2. **“会调用工具就是 Agent。”**错。课件第 13 页：Tool Calling 偏重“调用”，通常是单步；Agent 偏重“完成任务”，会多次调用并规划步骤。
3. **“工具返回的结果一定可信。”**错。网页搜索可能返回过时信息，API 可能出错。返回结果也需要检查。
4. **“模型一定会选对工具、填对参数。”**错。模型可能选错工具、把日期写错格式，甚至调用不存在的工具。系统要做参数检查（第 7 章“工具管理”）。



图 2.5　易错点 1 的对照：模型和外部世界之间永远隔着系统

2.7 相近概念辨析

	Tool Calling	Function Calling	MCP（拓展联想）
是什么	一种能力：模型能用外部工具	一种实现：输出函数名 + 参数	一种开放协议：规定工具服务器如何向模型应用提供工具
层次	概念	接口格式	连接标准
类比	“会用工具”	“会填工单”	“统一的插座规格”

拓展联想：以下内容只用于建立知识联系，当前阶段不要求掌握。MCP（Model Context Protocol）由 Anthropic 于 2024 年 11 月发布。它要解决的是：每个应用都要为每个工具单独写对接代码太麻烦，于是约定一套统一格式，像 USB 接口那样“一次对接，到处可用”。

2.8 相似知识对比与迁移

对照：工具调用 ↔ C++ 函数调用（同名异义型）

一句话定位：两者都叫“调用函数”，都有“函数名 + 参数 + 返回值”；但 C++ 里**调用者自己执行**，工具调用里**模型只写出调用，执行者是另一个系统**。

维度	C++ 函数调用	大模型工具调用
谁决定调用	程序员写死在代码里	模型运行时根据上下文“决定”
谁执行	同一程序，CPU 跳转执行	系统解析调用单后执行
参数检查	编译期类型检查，类型不符编译不过	运行期按参数格式检查，模型可能写出不合格参数
返回值	内存中的值，类型确定	一段文字（如 JSON），放回上下文
是否一定发生	执行到这一行就一定调用	系统可以拒绝（无权限、高风险）

相同之处：都要先**声明**（C++ 的函数原型 ↔ 工具描述），调用时要**按声明给参数**，返回后**继续后面的流程**。

不同之处及根源：C++ 程序是确定性的指令序列；模型输出的是**概率生成的文本**，所以“调哪个、填什么”都可能出错，必须由外部系统兜底。

旧知识中的结论	迁移	理由或反例
调用前必须先声明函数	✓	工具不在工具列表里，模型就不知道它
参数类型不符就无法调用	△	要由系统在运行期检查；模型可能写出 `date="明天下午"` 这类格式不合规的参数
写了调用语句就一定执行	✗	系统可因权限或风险拒绝执行
同样输入一定得到同样的调用	✗	模型生成有随机性，同一问题可能选不同工具

同一个小算例：C++ 中写 `int r = mul(35, 48);`，程序直接得到 `r = 1680`。工具调用中，模型输出 `{"name":"mul","arguments":{"a":35,"b":48}}`，系统执行后把 1680 作为文字放回上下文，模型再说“结果是 1680”。 教学补全



图 2.6　对照图：执行路径中多出的“系统”一层，就是二者最本质的分歧点

对照：工具调用 ↔ 操作系统的系统调用（类比同构型，精简版）

一句话定位：普通程序不能直接操作硬盘、网卡，必须通过“系统调用”请求操作系统内核代为执行，内核会先检查权限；大模型也不能直接操作外部世界，必须请求 Harness 代为执行，Harness 也先检查权限。　**迁移判断：**“由更高权限的一方代为执行并检查”✓ 直接迁移；“权限规则写死、可被严格证明”△ 只部分成立——内核的权限检查是确定性规则，而 Harness 有时还要靠模型或人来判断“这个操作危险不危险”。这一对照会在第 7 章展开（拓展联想：《操作系统》课程会正式讲系统调用）。教学补全

知识联系　Tool Calling 是第 3 章 Agent 循环中 Act 阶段的具体手段；“注册工具、描述能力、检查参数、决定是否允许调用”在第 7 章被归为 Harness 的第一项职责“工具管理”。RAG 本身也可以被包装成一个“检索工具”交给模型按需调用。

学完这里，你应该能够回答

1. Tool Calling 和 Function Calling 是什么关系?
2. 六步流程中，哪几步由模型完成，哪几步由系统完成?
3. 模型是怎么知道有哪些工具可以用的? 工具描述包含哪三部分?
4. 为什么 35×48 这类计算也建议交给工具?
5. 工具调用与 C++ 函数调用最本质的区别是什么?

到这里，我们已经解决了什么? 模型能“做一个动作”了。　**下一步还需要解决什么?** 真实任务往往要做一连串动作，而且要根据中间结果随时调整——比如订旅行发现超预算就要换酒店。课件第 10 页问：“能不能让模型从头到尾全干完?”这就是第 3 章的 Agent。

第 3 章　Agent：从聊天机器人到任务执行者

本章回答三个问题：① Agent 和“会调用工具的模型”差在哪里?　② Agent 靠什么机制把多步任务做完?　③ 这个机制和控制专业的“反馈闭环”有什么异同?

本章路线：三级能力对比 → 定义 → Plan–Act–Observe–Reflect 循环 → 循环的形式化与伪代码 → 例题 → 误差累积 → 对照“反馈控制”。

笔记在本节标题旁写了“**大厂面试重点**”。原始资料 面试中最常被追问的正是本章的三件事：定义、循环、与 Tool Calling 的区别。

3.1　问题引入：能不能让模型从头到尾全干完?

第 2 章例题中，第二次工具调用要依赖第一次的结果。如果任务是“帮我做一个杭州三日游计划，预算 3000 元，避开下雨天，最后生成表格”（课件第 11 页），需要的就不是一两次调用，而是：查天气 → 查景点 → 查交通 → 估预算 → 发现超支 → 换方案 → 排日程 → 生成表格。中间任何一步的结果，都可能改变后面的计划。这正是课件第 10 页的问题：“能不能让模型从头到尾全干完?”原始资料



图 3.1　三级能力：从回答一句话，到完成一个目标（据课件第 11、13 页重绘）原始资料

三个框从左到右能力递增，箭头上的文字是“多加了什么”。从 ② 到 ③ 的关键不是“多调用几个

工具”，而是多了**规划、记忆和循环**：Agent 自己决定下一步做什么，并根据结果修改计划。

3.2 学科坐标

前置知识	第 1 章 RAG（记忆的来源之一）、第 2 章 Tool Calling（行动的手段）
后续知识	第 7 章 Harness 的“执行循环”与“状态管理”
相关课程	自动控制原理（反馈闭环）、程序设计（循环与终止条件）、人工智能导论（智能体）

3.3 正式定义

定义：Agent（智能体）

Agent 是以大模型为核心、能够**围绕给定目标**自主完成多步任务的系统：它理解目标、拆解步骤，通过工具对环境采取行动，观察行动结果，并据此检查和修正后续计划，直到任务完成或需要停止。 原始资料 教学补全

课件第 11 页的组成写法：　Agent = 大模型 + 工具 + 记忆 + 规划 + 执行 + 反馈。

组成	负责什么	在杭州三日游任务中的样子
大模型	理解、推理、决定下一步	读懂“预算 3000、避雨、要表格”
工具	对外部世界行动	天气 API、地图、票务查询、表格生成
记忆	保存目标、中间结果、进度	记住“已经查过酒店，花费 1400”
规划	把大目标拆成小步骤	先查天气，再定景点顺序
执行	真正调用工具	发出查询请求
反馈	根据结果调整	发现超预算，换酒店

3.4 Agent 的循环：Plan → Act → Observe → Reflect

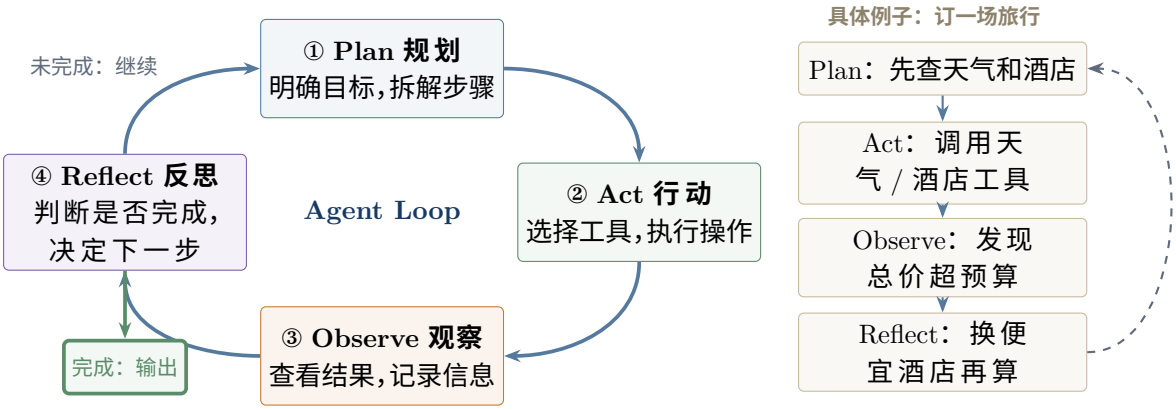


图 3.2　Agent 循环（左）与课件中的旅行示例（右）。据课件第 12 页重绘 原始资料

左侧四个阶段顺时针运行：Reflect 判断“没完成”就回到 Plan，“完成”就从左侧绿色出口输出最终结果。右侧米色是同一循环在订旅行中的样子：Observe 发现超预算，Reflect 就把它变成新的计划。笔记中“loop 循环，干完再检查”说的正是 Observe 与 Reflect 这两步——**没有检查的循环只是“一口气做到底”，不是 Agent**。

> **教学补全：这个循环从哪里来**　“边想边做、做完再看”的循环在学术上最常被引用的来源是 2022 年的 ReAct 方法（Reasoning + Acting）：模型交替输出“思考（Thought）—行动（Action）—观察（Observation）”，再进入下一轮。课件的 Plan–Act–Observe–Reflect 和第 7 章 Harness 的 Think–Act–Observe–Update 都是同一思想的不同命名。

3.5 把循环写成可执行的形式

课件只给了循环图。下面把它写成数学形式与伪代码，你会发现：**这正是一个带终止条件的 while 循环**。教学补全

核心关系：Agent 循环的形式化

设目标为 G，第 t 轮开始时的状态（已知信息、已完成步骤）为 s_t。每一轮：

$$\begin{aligned}
\text{Plan / Think:}\quad & a_t = \text{LLM}(G,\ s_t) && \text{决定动作}\\
\text{Act:}\quad & o_t = \text{Env}(a_t) && \text{执行，得到观察}\\
\text{Observe / Update:}\quad & s_{t+1} = \text{Update}(s_t,\ a_t,\ o_t) && \text{写入状态（记忆）}\\
\text{Reflect:}\quad & \text{若Done}(G, s_{t+1}) \text{ 或} t+1 \geq T_{\max},\ \text{停止} && \text{否则} t \leftarrow t+1
\end{aligned}$$

符号：Env 是外部环境（工具、文件、网络）；Update 是状态更新，通常由系统完成；Done 是“目标是否达成”的判断；$T_{\max}$ 是**最大轮数**——它不是模型自带的，而是外部系统强加的保险（第 7 章“执行控制：防止无限循环”）。

Listing 1: 极简 Agent 循环（教学用伪代码，省略了错误处理与权限检查）

```
def run_agent(goal, tools, max_steps=10):
    state = {"goal": goal, "history": []} # 记忆：目标与历史
    for step in range(max_steps): # 执行控制：最多 max_steps 轮
        action = llm_decide(state, tools) # Plan：模型决定下一步
        if action.type == "finish": # Reflect：模型认为已完成
            return action.answer
        result = tools[action.name](**action.args) # Act：系统执行工具
        state["history"].append((action, result)) # Observe/Update：写入状态
    return "达到最大轮数，停止并请求人工确认"
```

逐行说明：第 2 行建立“记忆”；第 3 行的 `for` 加上 `max_steps` 就是终止保险；第 4 行是唯一调用模型的地方；第 5–6 行是 Reflect 中“完成就退出”的分支；第 7 行由程序（不是模型）真正执行工具；第 8 行把结果写回状态，下一轮模型就能“看见”。**整段代码里只有第 4 行是 LLM，其余全是外壳**——这就是第 7 章“Agent = LLM + Harness”的雏形。

例题　3.1　杭州三日游：一次完整的循环

已知： 预算 3000 元；工具返回：第 2 天有雨；高铁往返 2×300 元；酒店 A 每晚 700 元（住 2 晚）；景点门票共 400 元；餐饮每天 250 元。　**求：** 模拟 Agent 循环，给出满足预算的方案。

第 1 轮 Plan：查天气 → 查交通、酒店、门票 → 估预算。
Act：依次调用工具。　**Observe：**第 2 天雨；总价 $= 600 + 2 \times 700 + 400 + 3 \times 250 = 3150$ 元。
Reflect：$3150 > 3000$，超支 150 元，未完成。
第 2 轮 Plan：换便宜酒店；雨天改去室内景点。
Act：查到酒店 B 每晚 600 元。
Observe：总价 $= 600 + 1200 + 400 + 750 = 2950$ 元。
Reflect：$2950 \le 3000$，已满足；生成表格，结束。
检查：两轮都在 $T_{\max}$ 之内；预算余量 50 元。

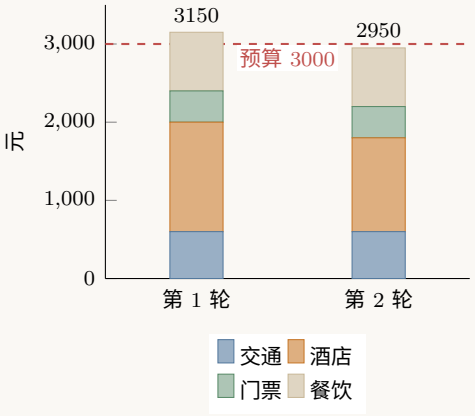


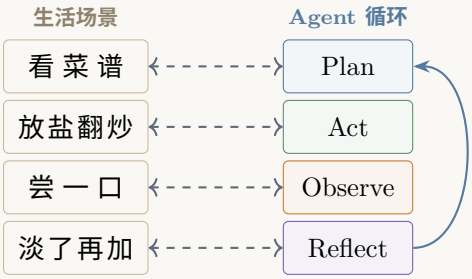
图 3.3　两轮循环的预算对比（红虚线为预算）

本题真正想说明什么：第 2 轮的计划**不是一开始就有的**，而是由第 1 轮的观察结果“长出来”的。这就是 Agent 与一次性写好的固定流程的区别。

生活中的它：照着菜谱炒菜，尝一口再调味

生活场景：炒一盘菜时，你先看菜谱定步骤（Plan），放盐翻炒（Act），夹一口尝尝（Observe），觉得淡了就再加一点（Reflect），直到味道合适再出锅。

对应关系：
“味道合适” → 目标 G
看菜谱 → Plan
放盐翻炒 → Act（调用工具）
尝一口 → Observe
判断淡了再加 → Reflect
“最多尝三次就出锅” → $T_{\max}$



小估算：菜谱建议放 5 克盐；你先放 3 克，每尝一次觉得淡就补 1 克，则需要 $(5-3)/1 = 2$ 轮“尝—加”才达标。若一开始就放 6 克，尝了发现太咸却**无法撤回**——这对应 Agent 中的“不可逆操作”，必须在行动前确认。
边界说明：人炒菜靠经验，第一勺就放得八九不离十；Agent 每多一轮都要额外调用模型和工具，花时间也花钱，所以轮数不是越多越好。

3.6　易错点

易错点

1. **“Agent 就是更聪明的大模型。”**错。Agent 是**系统**，同一个模型放进不同的外壳，表现可以天差地别（第 7 章）。
2. **“循环越多，结果越好。”**错。没有终止条件的循环会无限进行、浪费成本；模型也可能在两个方案之间来回切换。
3. **“有了 Reflect 就一定能改正错误。”**错。如果 Observe 拿到的信息本身是错的（工具返回过时数据），Reflect 会在错误的基础上“修正”。
4. **“每一步都很可靠，多步就也很可靠。”**错。误差会累积，见下面的计算。

多步任务的误差累积：为什么 Agent 需要检查和修正　设每一步独立地以概率 p 成功，任务需要连

续 n 步全部成功。由独立事件的乘法公式，整体成功率为

$$P(\text{全部成功}) = p^n.$$

取 $p = 0.95$，$n = 10$：$0.95^{10} \approx 0.599$。也就是说，**单步 95% 可靠，十步只剩约 60%**。这正是 Agent 必须有 Observe–Reflect（及时发现并修正错误）的定量理由；若每一步失败后都能被发现并重试一次，单步成功率变为 $1-(1-p)^2 = 0.9975$，十步整体约为 $0.9975^{10} \approx 0.975$。（独立性假设是简化，真实步骤之间往往相关。）教学补全

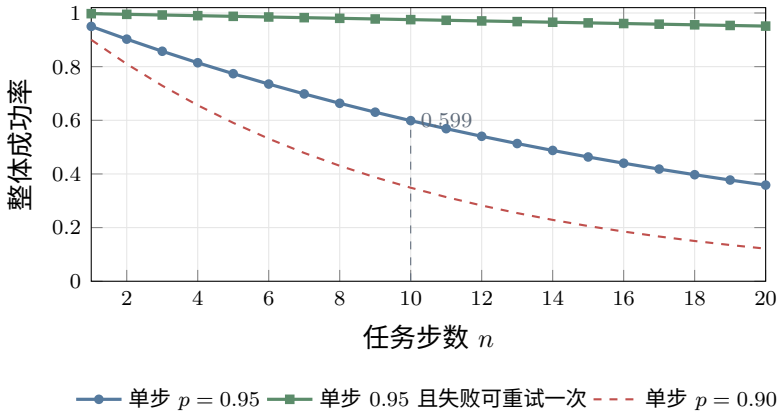


图 3.4　误差累积曲线 p^n：步数越多，越需要“检查—修正”

横轴是步数，纵轴是全部成功的概率。蓝线是单步 95%，在第 10 步降到约 0.6；绿线是加了“失败重试一次”后的情况，几乎保持水平；红虚线是单步 90%，下降得更快。最该看出的是：**提升长任务可靠性的关键，往往不是把单步做到完美，而是加上检查与恢复机制**——这正是 Harness 的价值（第 7 章）。

3.7　相近概念辨析：普通模型、Tool Calling、Agent、固定工作流

	普通语言模型	Tool Calling	Agent	固定工作流（补充）
核心能力	回答问题	调用工具	围绕目标执行任务	按预设步骤执行
外部工具	否	是	是（多次）	是
规划步骤	基本不会	很少	会，且随结果调整	由人事先写死
适合任务	问答、写作	查天气、计算	旅行规划、数据分析	流程固定的报销、审批
类比	会说话的人	会用工具的人	会做项目的人	照章办事的流水线

前三列据课件第 13 页 原始资料，第四列为教学补全 教学补全。工作流和 Agent 都能多步执行，区别在于**下一步由谁决定**：工作流由人在设计时决定，Agent 由模型在运行时根据观察决定。前者更可控，后者更灵活。

3.8　相似知识对比与迁移

对照：Agent 循环 ↔ 自动控制中的反馈闭环（类比同构型）

一句话定位：二者都是“设定目标 → 执行 → 测量结果 → 与目标比较 → 修正”的闭环；但控制系统处理的是**连续的物理量**，可以用微分方程和传递函数精确分析，Agent 处理的是**离散的文字与决策**，目前没有这样的数学模型。

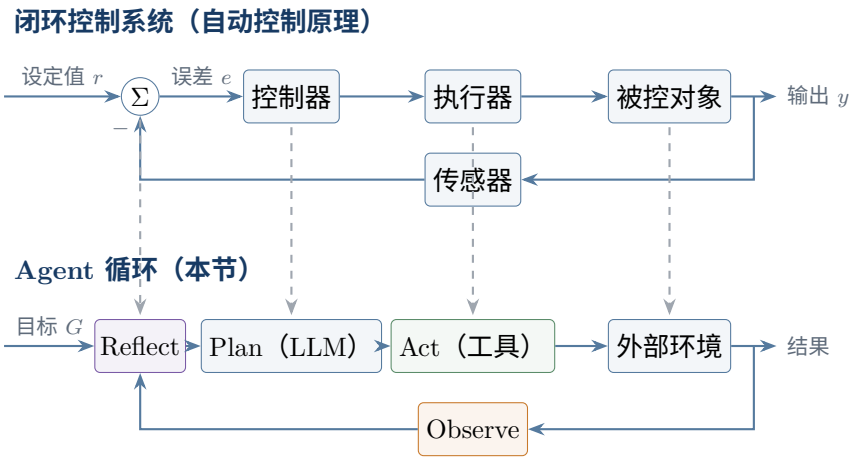


图 3.5　对照图：两个闭环逐块对应（灰虚线），差别在于每个方块里流动的是“物理信号”还是“文字与决策”

对照：续：对照表、迁移判断与同一个小算例

维度	反馈控制系统	Agent 循环
目标	设定值 r（如 22℃）	自然语言目标 G（如“预算内的三日游”）
比较	误差 $e = r - y$，一个数	Reflect：模型判断“是否完成、差在哪”
控制律	设计好的公式（如 PID）	模型每轮“想出来”的下一步
测量	传感器，有噪声但规律已知	工具返回结果，可能出错、过时
分析工具	传递函数、根轨迹、稳定性判据	目前主要靠实验与日志评估
停止	系统持续运行，追踪设定值	完成即停，或达到 $T_{\max}$ 被强制停止

相同之处：都靠**负反馈**纠偏（超预算 → 降低开销，就像温度高了 → 加大制冷）；都依赖**测量环节**的质量。

不同之处及根源：控制对象可以写成微分方程，所以能事先证明稳定；Agent 的“控制器”是概率生成的大模型，“对象”是开放的外部世界，二者都没有可解析的数学模型，所以只能用最大轮数、人工确认等工程手段兜底。

旧知识中的结论	迁移	理由或反例
负反馈能减小与目标的偏差	✓	观察到超预算就调整方案，偏差减小
测量不准会让系统调错方向	✓	工具返回过时数据，Reflect 会据此“修错”
增益太大会引起振荡	△	只能定性类比：模型可能在两方案间来回切换；没有“增益”这个可计算的量
可用传递函数 / 根轨迹判断稳定	✗	Agent 不是线性时不变系统，没有传递函数
闭环系统最终会收敛到设定值	✗	不保证完成，必须设置 $T_{\max}$ 强制停止

同一个小算例：空调设定 22℃，测得 25℃，误差 $e = 22 - 25 = -3$℃，控制器加大制冷；Agent 目标“≤ 3000 元”，测得 3150 元，偏差 $3000 - 3150 = -150$ 元，Reflect 决定换便宜酒店。二者都是“测得值超过目标 → 往减小方向调整”，但空调调多少由公式算出，Agent 换哪家酒店由模型决定。（**拓展联想：**你会在大三的《自动控制原理》中系统学习左半边。）教学补全

对照：Agent 循环 ↔ C++ 中的 while 循环（思想重现型，精简版）

一句话定位：Agent 循环就是“循环体由模型决定”的 while 循环。　**迁移判断：**“循环必须有终止条件，否则死循环”✓ 直接迁移，对应 $T_{\max}$；“循环条件写好就能确定执行几次”✗ 不成立——Agent 何时判定完成由模型决定，事先无法确定轮数，所以才需要外部的硬上限。

知识联系　Agent 循环在第 7 章被细化为 Harness 的九步执行循环（Think → Act → Observe → Update）；循环中的“记住做到哪一步”对应 Harness 的状态管理；$T_{\max}$ 对应执行控制。在后续的《人工智能导论》中，“智能体—环境—感知—行动”是强化学习的基本框架。

学完这里，你应该能够回答

1. Agent 与会 Tool Calling 的模型，差在哪几样东西?
2. 写出 Plan–Act–Observe–Reflect 循环，并说明每一步在旅行例子中做了什么。
3. 为什么 Agent 循环必须有最大轮数?
4. 单步成功率 0.9、连续 5 步的整体成功率是多少?（$0.9^5 \approx 0.59$）
5. Agent 与固定工作流的区别是什么?
6. 反馈控制中的哪些结论能搬到 Agent 上，哪些不能?

到这里，我们已经解决了什么? 模型能围绕目标连续做事了。　**下一步还需要解决什么?** 到目前为止，输入输出都是文字。课件第 14 页问：“能不能从文字延展到其他方式?”——让模型看图、听声音，这就是第 4 章的多模态。

第 4 章　多模态与对齐：AI 不只会读文字

本章回答三个问题： ① 图片、语音、视频怎么和文字放在一起理解?　② 笔记里的问题——“对齐是什么?”　③ “统一向量空间”在线性代数里对应什么?

本章路线： 四种输入 → 编码成向量 → 统一向量空间 → 跨模态对齐（对比学习）→ 例题 → 辨析“对齐”的两种含义。

4.1　问题引入：能不能从文字延展到其他方式?

前三章的输入输出都是文字。可真实任务里大量信息不是文字：拍一张电路板照片问“哪里烧了”、发一段语音、看一段监控视频。课件第 14 页问：“能不能从文字延展到其他方式?” 原始资料　笔记在这里多记了一个课件没有展开的问题：“**对齐是什么?**”本章的后半部分专门回答它。 教学补全

4.2　学科坐标

前置知识	预备中的向量与余弦相似度；第 1 章 Embedding
后续知识	第 5 章 Diffusion 的“文字向量引导去噪”；第 7 章 Harness 接入图像、语音工具
相关课程	线性代数（坐标与基）、数字图像处理、信号与系统（语音信号）

4.3　正式定义与“统一向量空间”

定义：多模态模型（Multimodal Model）

能够接收、理解（有的还能生成）多种形式信息——文字、图片、语音、视频等——的模型。课件的核心表述：多模态模型把不同形式的信息都变成向量，再统一理解。 原始资料

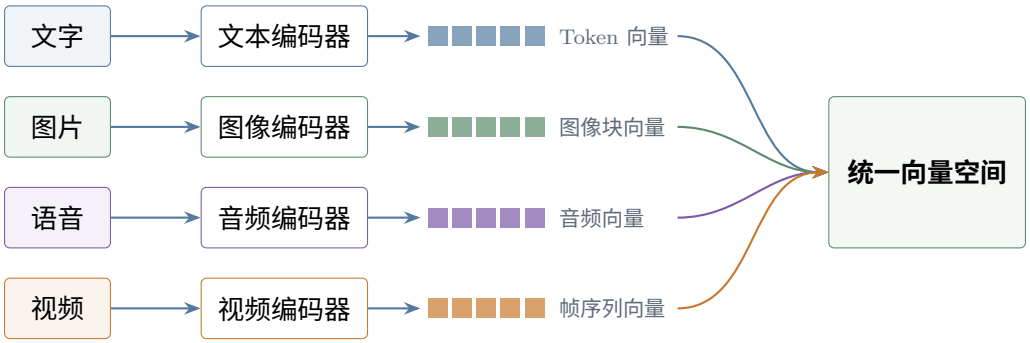


图 4.1　不同模态各自编码成向量，再映射到同一个向量空间（据课件第 15 页重绘，补充了“编码器”一列）

四行分别是四种模态。每种模态先经过**各自的编码器**（课件省略了这一列），变成一串向量（小方块）；四串向量最后进入同一个空间。“统一”的意思是：**在这个空间里，一张猫的图片的向量和“一只猫”这句话的向量可以直接比较远近**。教学补全

图片怎么变成“一串向量”？一种常用做法（视觉 Transformer）是把图片切成固定大小的小方块，每块展平后变成一个向量，像一句话里的一个个 token。例如一张 224×224 像素的图片按 16×16 切块，得到

$$\left(\frac{224}{16}\right)^2 = 14^2 = 196 \text{ 个图像块向量.}$$

语音通常先切成很短的时间帧（几十毫秒），视频则是“一帧帧图片 + 时间顺序”。教学补全

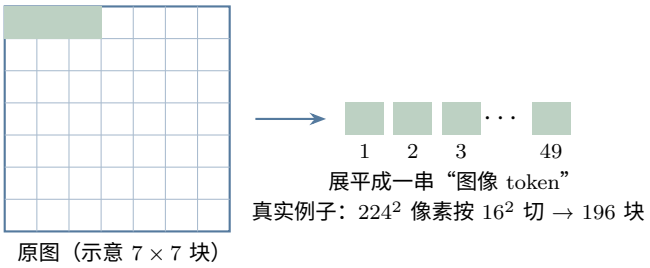


图 4.2　图像切块：把一张图变成一串向量，就能和文字 token 一样处理

4.4　对齐是什么？——跨模态对齐

有了统一空间还不够。如果两个编码器各学各的，“猫的图片”可能落在空间左上角，“一只猫”这句话却落在右下角——空间名义上统一，意思上并不相通。**对齐**就是让“意思相同”的不同模态内容，在空间里也靠在一起。教学补全

定义：跨模态对齐（Cross-modal Alignment）

训练图像编码器和文本编码器，使**描述同一内容**的图片与文字的向量相似度高，描述不同内容的相似度低。2021 年 OpenAI 的 CLIP 是这一思路的代表：用大量“图片—配文”对，以**对比学习**的方式训练两个编码器。教学补全

核心关系：对比学习的目标（直观形式）

一批 N 个图文对 $(I_1, T_1), \ldots, (I_N, T_N)$，计算 $N \times N$ 相似度矩阵 $S_{ij} = \cos(\boldsymbol{v}_{I_i}, \boldsymbol{v}_{T_j})$。训练目标：

让对角线S_{ii}（配对的）尽量大，非对角线S_{ij} $(i \neq j)$（不配对的）尽量小

符号：$\boldsymbol{v}_{I_i}$ 是第 i 张图的向量，$\boldsymbol{v}_{T_j}$ 是第 j 段文字的向量；“配对”指它们本来就是同一组图文。严格的损失函数（把每一行看成一次 N 选 1 的分类）超出本节要求，这里只需要理解“拉近配对、推远不配对”。教学补全

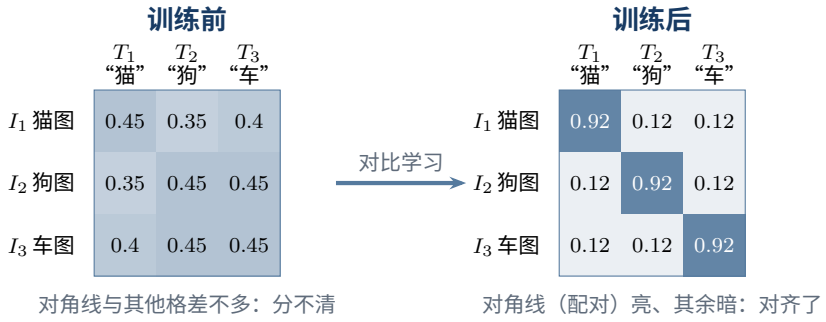


图 4.3　对齐前后的相似度矩阵（数值为示意）：颜色越深，相似度越高

行是三张图片，列是三段文字，格子里是余弦相似度。左图训练前，配对格和不配对格差不多，模型分不清哪段文字描述哪张图；右图对齐后，只有对角线是深色。读图要点：**对齐的结果就是“相似度矩阵的对角线变亮”**。

例题　4.1　用对齐后的向量做“看图选描述”

已知：对齐后（已归一化），猫图 $\boldsymbol{v}_I = (1, 0)$；候选描述 $\boldsymbol{v}_{T_1} = (0.8, 0.6)$“一只猫趴在沙发上”，$\boldsymbol{v}_{T_2} = (0.6, 0.8)$“一辆红色汽车”，$\boldsymbol{v}_{T_3} = (0, 1)$“一碗面条”。　**求：**选出最匹配的描述。

思路：单位向量下，余弦相似度 = 内积。
计算：$\boldsymbol{v}_I \cdot \boldsymbol{v}_{T_1} = 0.8$，$\boldsymbol{v}_I \cdot \boldsymbol{v}_{T_2} = 0.6$，$\boldsymbol{v}_I \cdot \boldsymbol{v}_{T_3} = 0$。
结果：选 T_1。
检查：三段描述的向量长度都是 1（如 $0.8^2 + 0.6^2 = 1$），可以直接比内积。
本题真正想说明什么：一旦对齐，“看图选描述”就退化为第 1 章的余弦相似度排序。**检索、匹配、零样本分类**都建立在这一步上。

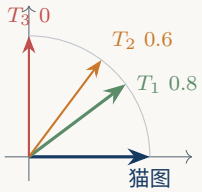
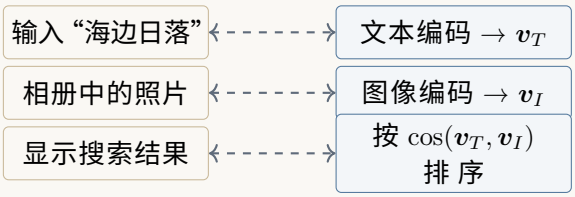


图 4.4　单位圆上比较方向

生活中的它：在手机相册里搜“海边日落”

生活场景：你从没给照片打过标签，但在相册搜索框里输入“海边日落”，相册能列出相关的照片。

对应关系：
输入的文字 → 文本向量
相册里每张照片 → 图像向量
“相关”的判断 → 跨模态相似度
列出前几张 → Top-k 检索



小估算：相册有 5000 张照片，图像向量可以**事先**算好存着；每次搜索只需把一句话编码一次，再做 5000 次内积，取前 20 张——与第 1 章 RAG 的“离线建库、在线检索”完全同构。
边界说明：不同厂商的相册搜索实现不同，有的用统一向量空间，有的先给照片自动打类别标签再按标签搜；这里说明的是前一种思路的原理。

4.5　多模态能做什么

课件第 15 页列出五类任务：看图问答、语音对话、视频理解、图文生成、文档理解。原始资料 它们的共同点是：**输入或输出至少有一端不是纯文字，而中间的“理解”都在统一向量空间里完成**。其中“图文生成”中的“生成图片”需要另一套方法——第 5 章的 Diffusion。

4.6 易错点

易错点

1. **“统一向量空间 = 图片和文字的向量完全相同。”**错。是“可以比较远近”，而不是“数值相等”。猫图与“一只猫”的相似度高，但两者向量并不相同。
2. **“有了统一空间就自动对齐了。”**错。空间统一只是“放在一起”；要让意思相同的靠近，必须用配对数据训练（对齐）。
3. **“对齐只有一个意思。”**错。在大模型领域，“对齐”还常指“价值对齐”，见下面的对照。

4.7 相似知识对比与迁移

对照：统一向量空间 ↔ 线性代数中的“换到同一组基”（类比同构型）

一句话定位：线性代数中，两个向量只有用**同一组基**表示坐标，才能直接计算内积；多模态中，图片和文字只有被编码进**同一个对齐过的空间**，才能直接比较相似度。编码器的角色类似“坐标变换”。

维度	线性代数：基变换	多模态：编码到统一空间
对象	同一向量在不同基下的坐标	同一“意思”的不同模态表达
变换	过渡矩阵 P，精确已知	神经网络编码器，从数据中学习
可逆性	P 可逆，可以换回去	不可逆，编码会丢失信息
统一后能做	内积、夹角、投影	相似度、检索、匹配

相同之处：“先统一坐标系，再比较”的思路完全一致。　**不同之处及根源：**基变换是线性、可逆、精确的；编码器是非线性、有损、近似的，因为“意思”无法用有限个精确规则描述，只能从大量数据中学习。

旧知识中的结论	迁移	理由或反例
同一基下才能直接算内积	✓	不同空间的向量（未对齐）直接比较没有意义
换基后内积（夹角）不变	△	只对正交变换成立；编码器不是正交变换，也不存在“原向量”
变换可逆，可以从坐标恢复原向量	✗	无法从图像向量完整还原原图

同一个小算例：向量 $(1,1)$ 在基 $\{e_1, e_2\}$ 下，与 $(1,0)$ 的夹角余弦为 $\frac{1}{\sqrt{2}} \approx 0.71$；把两者都换到旋转 45° 的正交基下再算，仍是 0.71。而在多模态中，“猫”的文本向量和猫图向量的相似度，完全取决于编码器**训练得是否对齐**，不存在一个“换基前的真值”。 教学补全

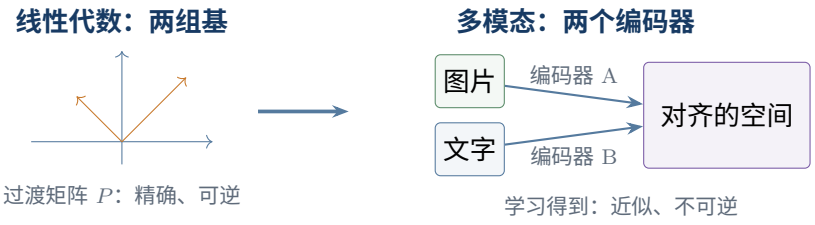


图 4.5　对照图：同样是“统一坐标系”，一个精确可逆，一个学习得到且不可逆

对照：“对齐”（跨模态对齐）↔ “对齐”（价值对齐）（同名异义型，精简版）

一句话定位：同一个词，两种对象。**跨模态对齐**让不同模态的向量在空间中对应起来，是表示层面的问题；**价值对齐（AI Alignment）**让模型的行为符合人类的意图与价值观（例如乐于助人、

诚实、不造成伤害），常用基于人类反馈的强化学习（RLHF）等方法训练。　**迁移判断：**“对齐要用成对数据训练”△ 两者都要用数据，但前者用“图—文配对”，后者用“人类对回答好坏的偏好”；“跨模态对齐得好，模型就安全可靠”✗ 两者互不保证。笔记“对齐是什么?”写在多模态之下，指的是前者；以后在 AI 安全话题中遇到的多是后者。 教学补全

知识联系　统一向量空间与对齐是第 5 章“文字如何控制图像生成”的前提：文本向量之所以能“告诉”去噪过程画什么，正因为它与图像在同一个对齐的空间里。线性代数中的“基与坐标”会在《数字图像处理》《信号与系统》（傅里叶基）中再次出现。

学完这里，你应该能够回答

1. 多模态模型如何把图片、语音、视频与文字放在一起处理?
2. 一张 224×224 的图按 16×16 切块，得到多少个图像块?
3. “统一空间”与“对齐”有什么区别?
4. 对比学习的目标用相似度矩阵怎么描述?
5. “对齐”的两种含义分别是什么?

到这里，我们已经解决了什么? 模型能“看懂”图片了。　**下一步还需要解决什么?** 反过来，能不能根据一句话**画出**图片、生成视频? 课件第 18 页：“文生图 / 视频核心原理”——这就是第 5 章的 Diffusion。

第 5 章　Diffusion：从一团噪声“雕”出一张图

本章回答三个问题： ① 图像为什么要从噪声开始生成，而不是一笔画成?　② 正向加噪和反向去噪各是什么? 模型到底学的是哪一个?　③ 一句文字怎样控制最后画出什么?

本章路线： 总览 → 正向扩散（含公式推导）→ 模型学什么（训练）→ 反向去噪（生成）→ 文字条件 → 例题 → 对照物理扩散。课件把本章列在“§8 几个补充”中。 原始资料

5.1　问题引入：一张图为什么不能“一笔画成”?

第 4 章让模型“看懂”图片。反过来生成图片要难得多：一张 512×512 的彩色图有 $512\times512\times3 \approx 79$ 万个数，它们之间有极其复杂的关系（毛发的纹理、光影的方向）。要模型一次性把 79 万个数全部写对，几乎不可能。Diffusion 的思路是**化整为零**：从纯噪声出发，每一步只去掉一点点噪声，经过几十到上千步，逐渐“雕”出一张清晰的图。 教学补全

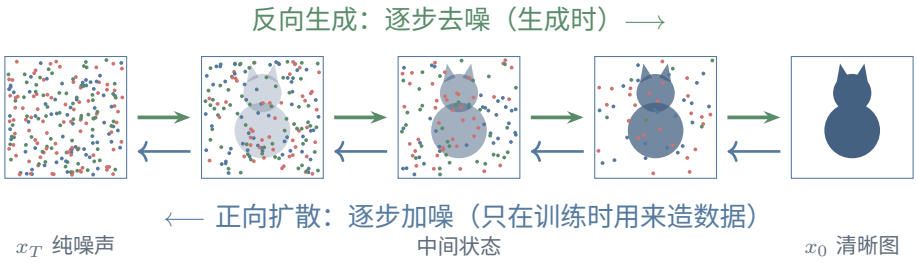


图 5.1　Diffusion 总览：同一条链，正向（下方箭头）加噪，反向（上方箭头）去噪。图中用简笔“猫”示意图像内容

五个方块从左到右噪声递减：最左是纯随机噪声 x_T，最右是清晰图 x_0。上方绿色箭头是生成方向，下方蓝色箭头是加噪方向。记号约定：下标 t 越大，噪声越多；$t=0$ 是原图，$t=T$ 是（几乎）纯噪声。

5.2 学科坐标

前置知识	概率：正态分布、独立随机变量之和；第 4 章文本向量与对齐
后续知识	视频生成（再加时间维度）、图像编辑与修复
相关课程	概率论与数理统计、大学物理（扩散、布朗运动）、数字图像处理（去噪）

5.3 正向扩散：图片逐渐变成噪声

定义：正向扩散（Forward Diffusion）

按照事先规定的噪声日程 $\beta_1, \beta_2, \ldots, \beta_T$（一组很小的正数），每一步对图像做

$$x_t = \sqrt{1-\beta_t}\, x_{t-1} + \sqrt{\beta_t}\, \epsilon_t, \qquad \epsilon_t \sim \mathcal{N}(0,1) \text{ 且相互独立},$$

即“把上一步的图稍微缩小一点，再加一点高斯噪声”。经过足够多步后，图像几乎变成纯噪声。**这个过程完全由公式给定，没有任何需要学习的参数。** 原始资料 教学补全

（为书写简单，这里把一个像素值当作一个数 x；整张图就是对每个像素同时做同样的事。）

课件说“图片加噪 $\to$ 变成噪声”，但没有说明：加噪 t 步之后，图到底是什么样？能不能一步直接算出来？答案是可以，这是训练能高效进行的关键。 教学补全

核心关系：正向扩散的一步到位公式

记 $\alpha_t = 1-\beta_t$，$\bar{\alpha}_t = \alpha_1\alpha_2\cdots\alpha_t$，则

$$\boxed{x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \qquad \epsilon \sim \mathcal{N}(0,1)}$$

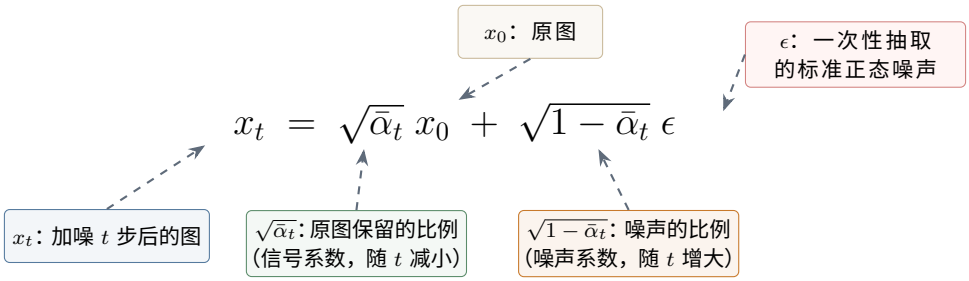


图 5.2　标注公式图：x_t 是“原图按比例缩小”与“噪声按比例放大”的混合

推导：为什么可以一步到位（补全课件省略的中间步骤） **需要的概率事实：**若 ϵ_1, ϵ_2 独立且都服从 $\mathcal{N}(0,1)$，则 $a\epsilon_1 + b\epsilon_2 \sim \mathcal{N}(0, a^2+b^2)$，即它和 $\sqrt{a^2+b^2}\,\epsilon$（$\epsilon \sim \mathcal{N}(0,1)$）同分布。（独立正态之和仍为正态，方差相加。）

第 1 步：写出前两步。

$$x_1 = \sqrt{\alpha_1}\, x_0 + \sqrt{1-\alpha_1}\, \epsilon_1,$$
$$x_2 = \sqrt{\alpha_2}\, x_1 + \sqrt{1-\alpha_2}\, \epsilon_2 = \sqrt{\alpha_1\alpha_2}\, x_0 + \underbrace{\sqrt{\alpha_2(1-\alpha_1)}\, \epsilon_1 + \sqrt{1-\alpha_2}\, \epsilon_2}_{\text{两个独立噪声之和}}.$$

第 2 步：用上面的概率事实合并噪声项，其方差为

$$\alpha_2(1-\alpha_1) + (1-\alpha_2) = 1 - \alpha_1\alpha_2,$$

所以 $x_2 = \sqrt{\alpha_1\alpha_2}\, x_0 + \sqrt{1-\alpha_1\alpha_2}\, \epsilon$，正是 $t=2$ 时的公式。

第 3 步（归纳）：若 $x_{t-1}=\sqrt{\bar\alpha_{t-1}}x_0+\sqrt{1-\bar\alpha_{t-1}}\,\epsilon'$，代入一步公式，噪声方差为 $\alpha_t(1-\bar\alpha_{t-1})+(1-\alpha_t)=1-\bar\alpha_t$，结论对 t 也成立。 □

一句话直观解释：每一步“缩小信号、补充噪声”的比例刚好使**信号系数的平方 + 噪声系数的平方 = 1**，所以整体“能量”不变，只是从信号逐渐转移到噪声。

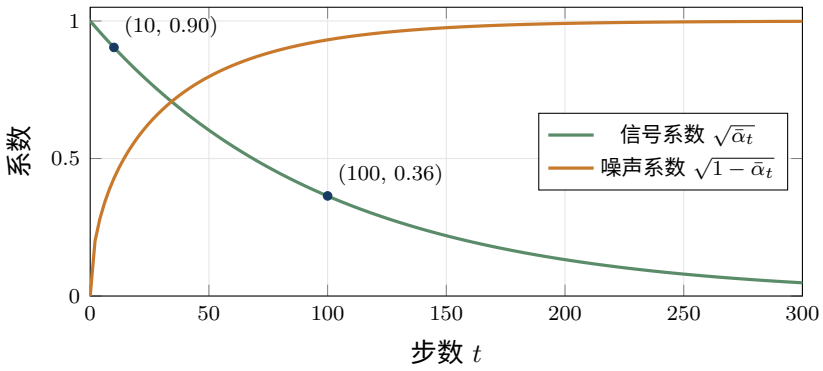


图 5.3　取恒定 $\beta_t=0.02$ 时两个系数随步数的变化（$\bar\alpha_t=0.98^t$）

横轴是步数，绿线是信号系数，橙线是噪声系数。第 10 步时 $\bar\alpha=0.98^{10}\approx0.817$，信号系数约 0.90，原图还很清楚；第 100 步时 $\bar\alpha\approx0.133$，信号系数约 0.36；第 300 步时 $\bar\alpha\approx0.0023$，信号系数不到 0.05，几乎是纯噪声。两条线在 $\bar\alpha=0.5$（约第 34 步）相交，此时信号与噪声“一样大”。实际系统中 β_t 通常随 t 变化，这里取常数只为便于计算。

5.4　模型学的是什么：预测噪声

有了一步到位公式，训练数据就可以**无限制造**：随便拿一张图 x_0，随便抽一个步数 t 和一份噪声 ϵ，算出 x_t，就得到一道“题”：**看着 x_t 和 t，猜出加进去的噪声 ϵ**。神经网络 $\epsilon_\theta(x_t,t)$ 就做这道题，答错多少就调整参数多少。这正是原图纠错 ① 中的规范写法。教学补全

核心关系：训练目标（DDPM 的简化形式）

$$\min_\theta\ \mathbb{E}\Big[\big\|\epsilon-\epsilon_\theta\big(\sqrt{\bar\alpha_t}\,x_0+\sqrt{1-\bar\alpha_t}\,\epsilon,\ t\big)\big\|^2\Big]$$

符号：θ 是网络参数；$\mathbb{E}$ 表示对随机抽取的 x_0、t、ϵ 求平均；$\|\cdot\|^2$ 是预测噪声与真实噪声之差的平方和（即“答错了多少”）。

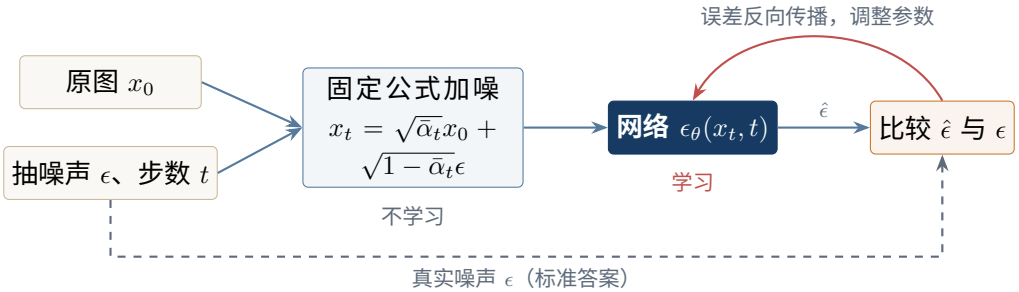


图 5.4　训练流程：加噪部分“不学习”，只有网络在学“预测噪声”

5.5　反向生成：噪声逐渐变成图片

生成时没有原图，只有一团随机噪声 x_T。模型每一步预测“这里面有哪些噪声”，去掉一部分，得到噪声少一点的 x_{t-1}，如此重复直到 x_0。原始资料 把一步到位公式反过来解，就能看出“预测出噪声”

为什么等于“猜出了原图”：

$$\hat{x}_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\,\hat{\epsilon}}{\sqrt{\bar{\alpha}_t}}.$$

实际采样并不直接跳到 $\hat{x}_0$，而是每次只朝它走一小步并重新加入少量随机性，所以需要很多步。教学补全

例题　5.1　一个像素的“加噪—去噪”算一遍

已知：某像素原值 $x_0 = 2$，第 t 步时 $\bar{\alpha}_t = 0.64$，抽到的噪声 $\epsilon = 0.5$。　**求：**① x_t；② 若模型预测 $\hat{\epsilon} = 0.5$ 或 $\hat{\epsilon} = 0.4$，分别恢复出的 $\hat{x}_0$。

第一步：信号系数 $\sqrt{0.64} = 0.8$，噪声系数 $\sqrt{1-0.64} = 0.6$。

第二步： $x_t = 0.8 \times 2 + 0.6 \times 0.5 = 1.6 + 0.3 = 1.9$。

第三步： $\hat{\epsilon} = 0.5$ 时，$\hat{x}_0 = \dfrac{1.9 - 0.6 \times 0.5}{0.8} = \dfrac{1.6}{0.8} = 2$，完全恢复。

第四步： $\hat{\epsilon} = 0.4$ 时，$\hat{x}_0 = \dfrac{1.9 - 0.24}{0.8} = 2.075$，偏差 0.075。

检查： $0.8^2 + 0.6^2 = 1$，符合“系数平方和为 1”。

本题真正想说明什么：噪声猜得越准，原图恢复得越准；所以训练“预测噪声”就是在训练“生成图像”。

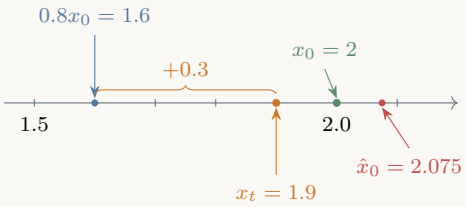


图 5.5　数轴上的加噪与恢复

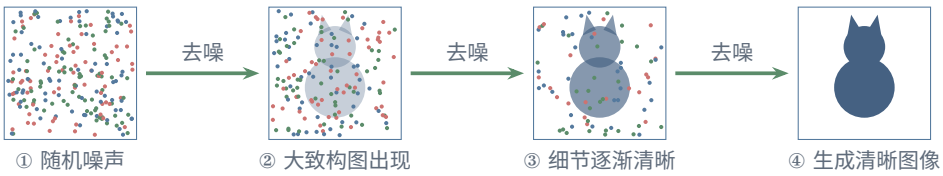


图 5.6　反向去噪：先出现模糊的大致构图，再逐渐出现细节（据课件第 21 页重绘；按纠错 ② 去掉了“线稿”中间态）

四个方块从左到右是生成过程。第 ② 格中“猫”只是一个淡淡的整体形状——高噪声阶段，模型只能确定**大块的明暗和位置**；到第 ③ 格，噪声变少，纹理、边缘这些**细节**才能被确定。这就是课件“噪声 → 轮廓 → 细节”的含义。

5.6　文字如何控制图像生成

课件第 22 页给出四步：文本 Prompt → 文本向量 → 指导去噪过程 → 生成图片。关键一句：“模型不是直接画图，而是在**每一步去噪时**参考文字条件。”原始资料 用公式写，就是把网络从 $\epsilon_\theta(x_t, t)$ 改成

$$\epsilon_\theta(x_t,\ t,\ \boldsymbol{c}), \qquad \boldsymbol{c} = \text{文本编码器}(\text{Prompt}).$$

网络在每一步都“读”一遍文本向量 $\boldsymbol{c}$，预测的噪声因此带有方向性：去掉这样的噪声，图像就朝“符合描述”的方向变化。第 4 章的对齐保证了 $\boldsymbol{c}$ 与图像处在相互对应的空间里，这种引导才有意义。教学补全

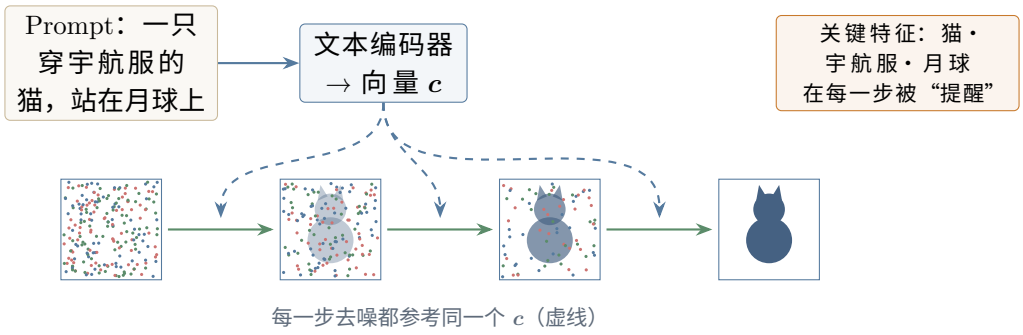


图 5.7　文字条件：文本向量在每一步去噪时提供方向（据课件第 22 页重绘）

拓展联想：引导强度与“潜空间”（当前阶段不要求掌握）　**无分类器引导。**常用做法是每一步算两次：有文字条件 $\epsilon_\theta(x_t, t, \boldsymbol{c})$ 与无条件 $\epsilon_\theta(x_t, t, \varnothing)$，再按

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \varnothing) + w\left[\epsilon_\theta(x_t, t, \boldsymbol{c}) - \epsilon_\theta(x_t, t, \varnothing)\right]$$

放大二者之差。w 越大，图越“听话”，但多样性下降。例：无条件预测 0.2，有条件预测 0.5，$w = 3$，则 $\hat{\epsilon} = 0.2 + 3 \times 0.3 = 1.1$。

潜空间扩散。直接在 79 万个像素上去噪太慢。Stable Diffusion 等方法先把图压缩成小得多的“潜向量”，在潜空间里去噪，最后再解码回图像。视频生成则还要保证相邻帧之间连贯。

生活中的它：大雾散去时看清前方的车

生活场景：清晨大雾里开车，前方先只是一团灰影；雾慢慢变薄，你先看出“那是一辆车”，再看出颜色，最后看清车牌。

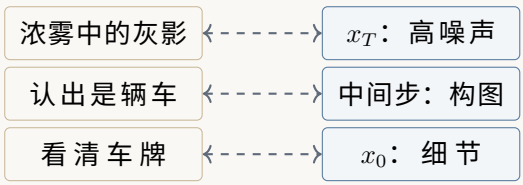
对应关系：

浓雾 → 高噪声的 x_t

雾一点点变薄 → 一步步去噪

先认车、后看车牌 → 先构图后细节

心里预期“是辆车” → 条件 $\boldsymbol{c}$



小判断：若生成共 50 步，只看第 10 步的中间结果，你能判断“画的是车还是猫”，但看不清车牌——这对应“高噪声阶段只决定大结构”。

边界说明：雾散后，你看到的是**真实存在**的那辆车；去噪模型却是在“猜”一张**最可能**的图，所以同一句提示词换一个随机种子，会生成不同的车。

5.7　易错点

易错点

1. **“模型在学习怎样加噪。”**错。加噪是固定公式；模型学习预测噪声，用于去噪（原图纠错 ①）。
2. **“Diffusion 一步就把图画出来。”**错。课件第 19 页：不是一笔画成，而是从混乱到清晰的渐进过程。
3. **“文字只在开始时输入一次，之后就不管了。”**错。文本向量在**每一步**去噪时都参与（课件第 22 页）。
4. **“去噪是把某张真实存在的原图还原回来。”**错。生成时根本没有原图，起点是随机噪声；结果是一张新的、符合描述的图。

5.8 相似知识对比与迁移

对照：Diffusion 的正向过程 ↔ 物理中的扩散与布朗运动（类比同构型）

一句话定位：名字来自物理：一滴墨水在水中靠分子的随机碰撞慢慢散开，最后均匀分布；图像在正向过程中靠随机噪声慢慢“散开”，最后变成均匀的噪声。二者都是**许多次独立小随机扰动的叠加**。

维度	物理扩散 / 随机游走	Diffusion 正向过程
每一步	位置加上一个独立随机位移	像素先乘 $\sqrt{1-\beta_t}$，再加独立高斯噪声
总方差	随步数**线性增长**：n 步后 $n\sigma^2$	**保持为 1**（信号与噪声此消彼长）
终态	均匀分布（墨水散满整杯水）	标准正态噪声
可逆吗	宏观上不会自发逆转（墨水不会自己聚回一滴）	不能“还原原图”，但能学会“生成一张合理的图”

相同之处：独立随机扰动的方差相加；扰动越多，原始信息越被淹没。

不同之处及根源：DDPM 每一步先把信号**缩小**再加噪声，专门设计成“方差保持”，这样不管走多少步，数值都不会发散；纯随机游走不缩小信号，方差会一直变大。至于“可逆”，物理定律不允许墨水自发聚回；而模型做的反向过程并没有找回原来那一滴，只是根据学到的统计规律生成**某一滴看起来合理的**墨水。

旧知识中的结论	迁移	理由或反例
独立扰动的方差相加	✓	正是一步到位公式推导的核心
扩散后方差随步数线性增大	△	只对纯随机游走成立；DDPM 由于缩放信号，总方差保持为 1
扩散过程不可逆，所以不可能反向生成	✗	模型不恢复原图，只学习“从噪声走向合理图像”的统计规律

同一个小算例：每步方差 0.01 的随机游走走 100 步，总方差 $100\times 0.01=1$，标准差 1；DDPM 取 $\beta=0.01$ 走 100 步，$\bar{\alpha}=0.99^{100}\approx 0.366$，信号方差 0.366、噪声方差 0.634，总和仍为 1（设原像素方差为 1）。教学补全

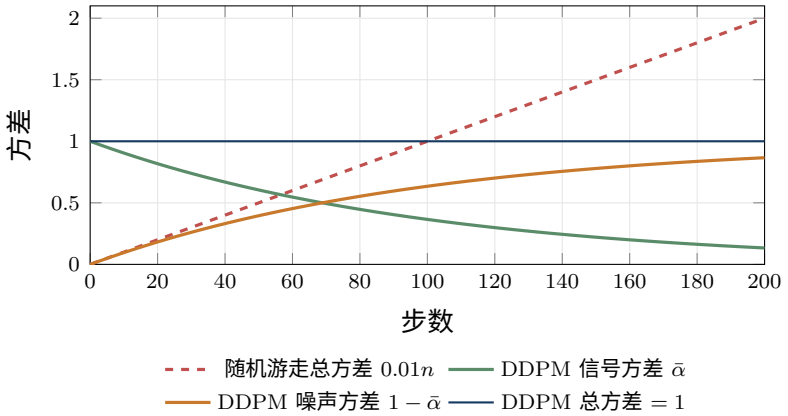


图 5.8　对照图：同样每步加方差 0.01，随机游走（红虚线）方差一直增长，DDPM（实线）总方差保持为 1

对照：Diffusion 生成图像 ↔ 大语言模型逐 token 生成文字（方法互补型，精简版）

一句话定位：两者都是“多步生成”，但 LLM **从左到右一次写一个 token**，写下就不再改；Diffusion **每一步同时修改整张图**，越改越清楚。　**迁移判断：**“生成需要多次调用模型、步数越多越慢”✓ 两者都成立；“前面生成的部分不能再修改”✗ 只对 LLM 成立，Diffusion 每一步都在整体修改；“采样有随机性，同一输入可能得到不同输出”✓ 两者都成立。

知识联系　本章的“独立正态之和方差相加”就是《概率论与数理统计》中正态分布的再生性；“噪声比例”与《信号与系统》《通信原理》中的信噪比思想相通。第 7 章中，文生图模型常作为 Agent 的一个“工具”被调用（课件第 16 页的第 6 级能力）。

学完这里，你应该能够回答

1. 正向扩散和反向生成分别发生在训练时还是生成时？
2. 写出一步到位公式，并说明信号系数与噪声系数的平方和为什么等于 1。
3. 模型到底学的是什么？为什么“猜噪声”等于“生成图”？
4. 文字条件在去噪的哪个阶段起作用？
5. $\bar{\alpha}_t = 0.36$ 时，信号系数和噪声系数各是多少？（0.6，0.8）
6. 物理扩散的哪些结论能搬到 Diffusion，哪些不能？

到这里，我们已经解决了什么？模型能看、能画了。　**下一步还需要解决什么？**能力越强，一个老问题越突出：模型有时会**一本正经地说错**。课件第 23 页：“什么是幻觉？为什么会出现幻觉？”

第 6 章　大模型幻觉：“说得像”不等于“真知道”

本章回答三个问题： ① 什么是幻觉？ ② 为什么模型会一本正经地说错？ ③ 前面几章的哪些工具能缓解它？

本章路线：定义与例子 → 根本原因（预测下一个 token）→ 四个具体原因 → “宁可猜”的数学解释 → 缓解手段 → 对照“统计外推”。

6.1　问题引入：什么是幻觉？为什么会出现幻觉？

预备中我们看到：模型每一步都会给出一个概率分布，**哪怕它其实不知道**。第 1 章也把“容易产生幻觉”列为需要 RAG 的原因之一。课件第 23 页把这个问题单独提出：“什么是幻觉？为什么会出现幻觉？”原始资料

6.2　正式定义与例子

定义：大模型幻觉（Hallucination）

模型生成了看起来很合理、语气很自信，但实际上**错误或没有依据**的内容。原始资料

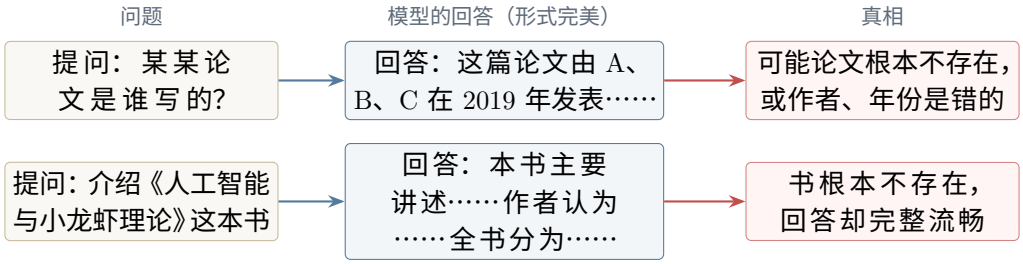


图 6.1　课件中的两个例子：虚构论文与虚构书名（据课件第 24 页重绘）原始资料

三列分别是问题、模型的回答、真相。中间一列的共同点是**格式完全正确**：有作者、有年份、有章节结构。笔记把第一个例子记为“虚构论文”。正因为形式像，幻觉才危险——读者很难一眼识破。

6.3　根本原因：模型在生成“像答案的话”

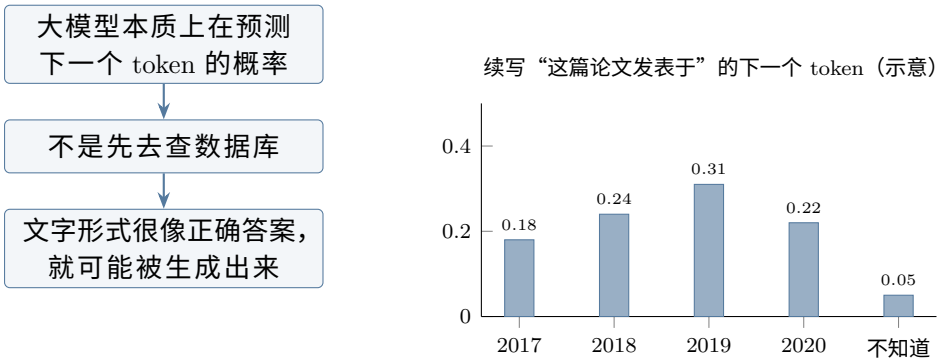


图 6.2　左：课件第 24 页的三步解释；右：示意——各个年份都“像”答案，“不知道”的概率反而很小

右图横轴是候选的下一个 token，纵轴是概率（数值为示意）。如果模型对这篇论文其实一无所知，各个年份的概率会差不多，但**它们加起来远大于“不知道”**，于是模型大概率会写出一个具体年份——一个“像答案”的错误答案。课件的结论：模型是在生成“像答案的话”，不等于它真的知道答案。原始资料

6.4　幻觉出现的四个主要原因

笔记记了三条，课件第 25 页列了四条，下面按课件补全第 ④ 条。原始资料

1. 训练目标不是判断真假
训练时学的是“根据前文预测下一个词”，不是“每句话必须事实正确”。所以它擅长生成流畅文本，但不天然保证真实。

2. 没有完整的实时知识库
最新新闻、政策、论文、价格、个人信息、小众资料，模型可能不知道或记不全，就按相似模式“补”出一个答案。

3. 语言上合理，不等于事实正确
作者、年份、机构、标题、引用格式它都会写；格式像真的，不代表内容是真的。

4. 问题本身可能带有错误前提
“为什么爱因斯坦发明了电话?”——电话不是爱因斯坦发明的。若模型没识别出错误前提，就会顺着问题继续编。

图 6.3　四个原因（据课件第 25 页重绘；第 4 条为笔记未记、讲义补全）

6.5　教学补全：为什么模型“宁可猜，也不说不知道”

课件的四条原因说明了“为什么会错”，但没有说明“为什么错得那么**自信**”。2025 年 OpenAI 研究者发表的分析（Kalai 等）给出了一个容易理解的解释：**训练和评测方式往往奖励猜测，而不奖励承认不确定**。这和选择题考试完全一样。教学补全

核心关系：猜测的期望得分

设模型对某题答对的把握是 p，答对得 1 分，答错扣 λ 分（$\lambda \geq 0$），回答“不知道”得 0 分。则

$$\boxed{\mathbb{E}[\text{猜}] = p \cdot 1 + (1-p)\cdot(-\lambda) = p - \lambda(1-p)}, \qquad \mathbb{E}[\text{不知道}] = 0.$$

猜测比说“不知道”更划算，当且仅当

$$p - \lambda(1-p) > 0 \iff p > \frac{\lambda}{1+\lambda}.$$

符号：p 是答对的概率；λ 是答错的惩罚。**推导**只用到期望的定义：两种结果的得分乘以各自的概率再相加；不等式两边同加 $\lambda(1-p)$ 再整理即得阈值。**条件：**得分规则是“答对 1、答错 $-\lambda$、不答 0”。

含义：若答错不扣分（$\lambda = 0$），阈值为 0——只要有一丝可能答对，猜就比“不知道”划算。按这种规则评分训练出来的模型，自然倾向于“永远给出一个具体答案”。只有让答错付出代价（$\lambda > 0$），“不知道”才会在把握不足时成为更优选择。

例题　6.1　四选一的题，该不该猜?

已知：模型完全没把握，只能在 4 个选项中随机选，$p = 0.25$。　**求：**① $\lambda = 0$；② $\lambda = \frac{1}{3}$；③ $\lambda = 1$ 时猜测的期望得分，并判断该不该猜。

第一步：$\lambda = 0$：$\mathbb{E} = 0.25 > 0$，猜更划算。
第二步：$\lambda = \frac{1}{3}$：$\mathbb{E} = 0.25 - \frac{1}{3} \times 0.75 = 0$，猜与不猜一样。
第三步：$\lambda = 1$：$\mathbb{E} = 0.25 - 0.75 = -0.5 < 0$，应说“不知道”。
检查：阈值 $\frac{\lambda}{1+\lambda}$ 在 $\lambda = \frac{1}{3}$ 时等于 0.25，恰好等于 p，与第二步一致。
本题真正想说明什么：幻觉不只是模型“能力不够”，也与**我们怎样给它打分**有关。

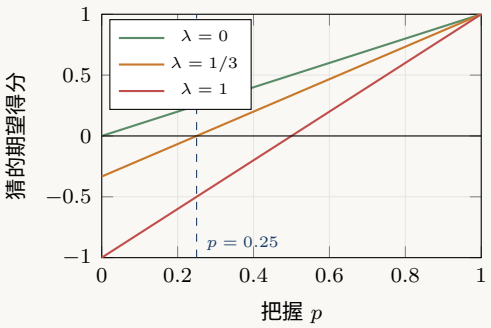


图 6.4　三条线与 0 线的交点就是阈值

6.6　怎样缓解幻觉：本节知识的汇合点

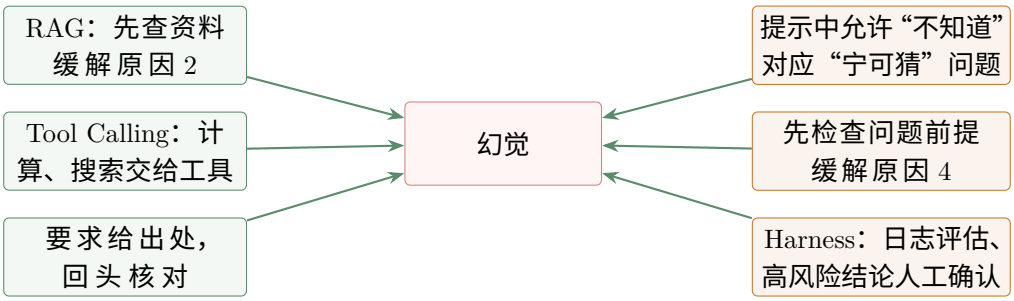


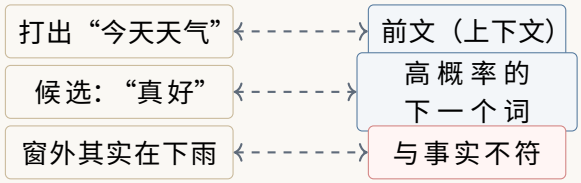
图 6.5　缓解手段汇总：前几章的工具几乎都能用来对付幻觉，但都只能“降低”，不能“消除”

图中中央红框是幻觉，周围六个手段都指向它。左侧绿色三项来自第 1、2 章；右侧橙色三项是“提问方式”和第 7 章 Harness 的设计。注意没有一条箭头上写着“消除”。

生活中的它：手机输入法的“联想词”

生活场景：你在输入法里打“今天天气”，候选栏马上跳出“真好”“不错”；可输入法根本不知道你那里今天下没下雨。

对应关系：
输入法 → 一个很小的语言模型
候选第一个词 → 最可能的下一个词
“真好”却正在下雨 → 幻觉
输入法不联网查天气 → 没有实时知识库



小判断：“今天天气”后面接“真好”是因为这种搭配在大量文本中常见，而不是因为它为真——这就是原因 1“训练目标不是判断真假”的最小实例。
边界说明：输入法只给候选，由你来选；大模型却会把一整段连贯的话直接写完，错误更难被察觉。

6.7 易错点

易错点

1. **“幻觉是模型故意撒谎。”**错。模型没有“明知是假还要说”的意图，它只是生成了高概率的文本。
2. **“回答越详细、越自信，就越可信。”**错。课件强调幻觉恰恰“很合理、很自信”。细节丰富不是正确的证据。
3. **“只有冷门问题才会幻觉。”**错。错误前提的问题（原因 4）可能非常常见；计算类问题也可能出错。
4. **“用了 RAG 就没有幻觉了。”**错。检索错了、资料过时、模型没有忠实引用，都会产生幻觉。

6.8 相近概念辨析

	幻觉（编造）	知识过时	计算 / 推理错误
本质	生成了没有依据的内容	训练时正确，现在已变	步骤中算错或推错
例子	虚构的论文、书名、引用	说某职位仍由已卸任的人担任	35×48 写成 1580
主要对策	检索 + 要求出处 + 核对	RAG 接入最新资料	交给计算器、代码等工具

三者常被统称为“模型说错了”，但对策不同。实际中它们也会叠加：过时知识加上编造的细节，就是最难识别的错误。 教学补全

6.9 相似知识对比与迁移

对照：大模型幻觉 ↔ 统计学中的“外推”（类比同构型）

一句话定位：用数据拟合一条曲线，在数据覆盖的范围内预测（内插）通常可靠，跑到范围外（外推）却可能离谱，而曲线本身照样给出一个“看起来很确定”的数。模型对训练中很少见到的问题作答，与外推相似。

维度	统计拟合与外推	大模型回答问题
“训练数据”	有限个观测点	海量文本
可靠区域	数据覆盖的区间	训练中常见、反复出现的知识
危险区域	区间之外	冷门、最新、私有、前提错误的问题
输出形式	永远给出一个数	永远给出一段流畅的文字
不确定性	可以算置信区间	词的概率存在，但不直接等于“事实正确的概率”

相同之处：都“用见过的规律去推没见过的情形”；都不会因为没把握就自动停止输出。

不同之处及根源：统计模型的不确定性可以量化（置信区间随远离数据而变宽）；大模型输出的是“语言上像不像”的概率，与“事实上对不对”的概率不是一回事，所以很难从它自身得到可靠的“我不确定”信号。

旧知识中的结论	迁移	理由或反例
在数据范围外的预测不可靠	✓	冷门、最新问题更易出现幻觉
可用置信区间量化不确定	△	token 概率可用作参考，但需要专门校准，不能直接当作“事实可信度”
增加数据能减小误差	△	对常见知识有效；对训练后才发生的事无效，需要 RAG

同一个小算例：5 个点 $(1,1),(2,4),(3,9),(4,16),(5,25)$ 用直线拟合，得 $y = 6x - 7$。在 $x = 3$ 处给出 11（真值 9，偏差 2）；在 $x = 10$ 处给出 53（真值 100，偏差 47）。数据外越远，“自信的错误”越大。 教学补全

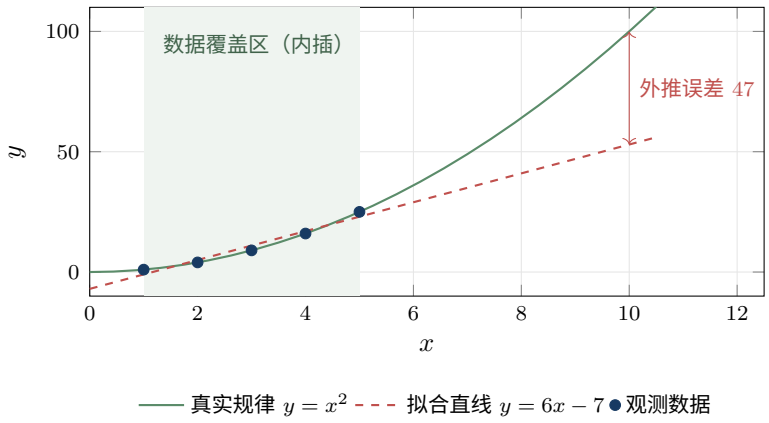


图 6.6　对照图：浅绿区域内拟合尚可，区域外误差迅速变大——就像模型面对训练中罕见的问题

对照：“幻觉”（AI）↔ “幻觉”（医学 / 心理学）（同名异义型，精简版）

一句话定位：医学中的幻觉指**没有外界刺激却产生了知觉**（如听到不存在的声音）；AI 中的幻觉指**没有事实依据却生成了内容**。二者都是“凭空产生”，但前者是感知层面的、主观体验到的，后者是输出层面的、模型自身并不“体验”任何东西。　**迁移判断：**“当事者往往自信它是真的”△ 只是表现上相似，模型并没有“相信”的心理状态；“需要外部核实来区分真假”✓ 两者都成立。

知识联系　幻觉是第 1 章 RAG、第 2 章 Tool Calling 的主要动机之一，也是第 7 章 Harness 中“日志与评估”“高风险操作前确认”存在的理由：Agent 一旦把幻觉当成事实去**执行**（例如按编造的路径删文件），后果比“说错一句话”严重得多。统计外推的思想会在《概率论与数理统计》的回归分析中正式出现。

学完这里，你应该能够回答

1. 幻觉的定义是什么？举出课件中的两个例子。
2. 为什么说“模型在生成像答案的话”？
3. 课件给出的四个原因是什么？笔记漏了哪一个？
4. 答错不扣分时，为什么猜总比说“不知道”划算？阈值公式是什么？
5. 幻觉、知识过时、计算错误的对策分别是什么？

到这里，我们已经解决了什么？我们看清了模型的能力（会查、会做、会看、会画）和它的固有

缺陷（会编）。 **下一步还需要解决什么？**要让这样一个“能力强但会出错”的模型真正可靠地完成任务，需要一层把它组织起来、约束起来、监督起来的外壳。课件最后一部分“细讲 Agent 工具”：这就是 Harness。

第 7 章　Harness：Agent 工程化的关键

本章回答四个问题： ① 为什么只靠 LLM 不够，还需要一层“外壳”？ ② Harness 到底是什么、由什么组成？ ③ 它在执行循环中具体管哪些事？ ④ 它与操作系统、反馈控制有什么相似之处？

本章路线：为什么不够 → 定义 → 核心公式（统一四种写法）→ 九步执行循环 → 六大职责 → 没有 Harness 会怎样 → 例题 → 对照“操作系统”。笔记用红笔写着：“**harness 是 agent 工程化的关键**”。原始资料

7.1　问题引入：为什么只靠 LLM 还不够？

前六章分别给模型接上了资料、工具、循环、眼睛和画笔，也看清了它会“编”。现在把这些拼在一起，问题就来了：谁来决定什么时候调用哪个工具？工具失败了怎么办？模型要删除文件时谁来拦？做到第几步了谁来记？课件第 29 页这样对比：原始资料

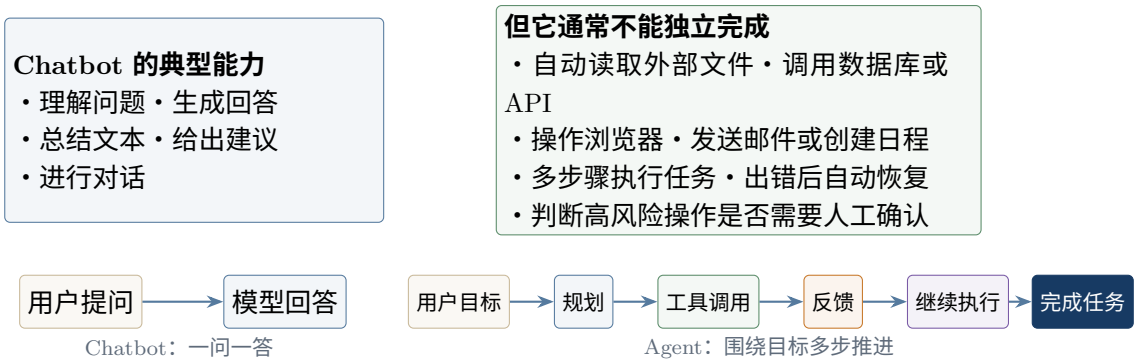


图 7.1　从 Chatbot 到 Agent：差别在哪里（据课件第 29 页重绘）原始资料

上半部分左框是 LLM 擅长的“想”和“说”，右框是它做不到的七件事；下半部分是两种工作方式。右框七件事里，前四件是“**做**”（需要工具与执行），后三件是“**管**”（需要循环、恢复与审核）。课件的结论是：**LLM 可以“想”和“说”，但 Agent 还需要“做”和“管”**——承担“做”和“管”的，就是 Harness。

7.2　学科坐标

前置知识	第 1–3 章（RAG、工具调用、Agent 循环），第 6 章（幻觉）
本章地位	把前面所有模块组织成可运行系统的“总装”章节；笔记标注的面试重点延续
相关课程	操作系统（权限、调度、日志）、软件工程（测试、监控）、自动控制（闭环、限幅、看门狗）

7.3　正式定义

定义：Harness（智能体运行框架 / 外壳）

Harness 是 Agent 的**运行外壳、控制系统和工程脚手架**。它负责把大模型的“想法”转化为**可执行、可追踪、可控制**的行动过程。原始资料

一句话理解：Harness 不是让模型更聪明，而是让模型**更可靠地**完成任务。原始资料

这个词为什么叫 Harness　英文 harness 本义是**马具**——把马和车连起来、让人能驾驭马的那一整套挽具与缰绳。马力气很大，但不套上马具，它不会替你拉车，还可能乱跑。大模型就是那匹马，Harness 就是让它的力量变成“可控地拉车”的那套装置。软件工程里也有“test harness（测试框架）”的说法，指包在被测代码外面、负责驱动和记录的那层代码，二者都是“外层控制装置”的意思。教学补全

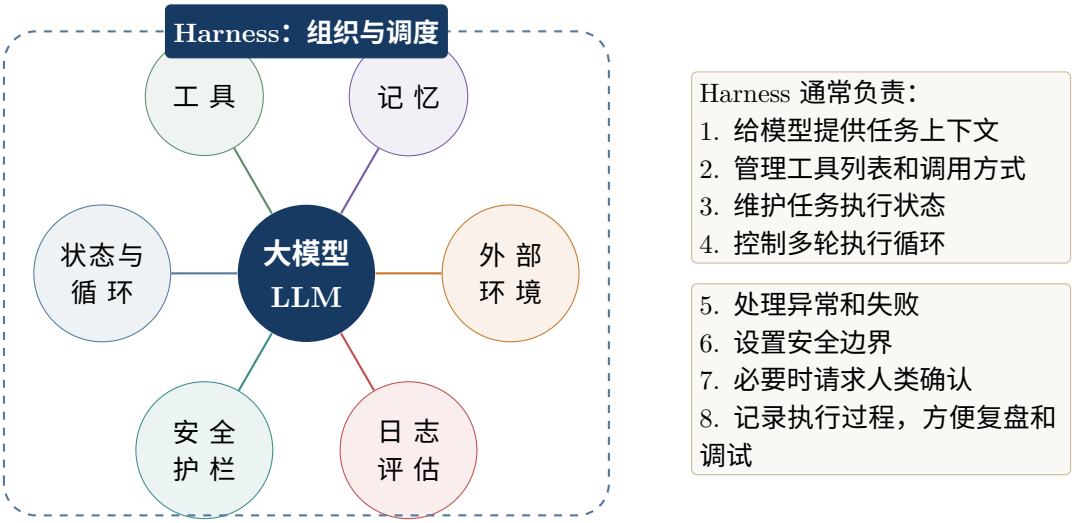


图 7.2　Harness 是包在大模型外面的一圈（虚线框）；右侧是它通常负责的八件事（据课件第 28、31 页重绘）原始资料

图中央深蓝圆是模型，周围六个圆是它需要连接的部件，虚线框就是 Harness：模型**不直接**接触任何一个部件，都要经过这层外壳。右侧的八件事是课件第 31 页列出的职责清单，后面 7.6 节会把它们归并为“六大职责”。

7.4　核心公式：Agent = LLM + Harness

核心关系：本讲义采用的统一写法

$$\text{Agent} = \underbrace{\text{LLM}}_{\text{负责“想”}} + \underbrace{\text{Harness}}_{\text{负责“做”和“管”}}$$

$$\text{Harness} \supseteq \{\ \text{Tools},\ \text{Memory},\ \text{Planning 支持},\ \text{Control Loop},\ \text{Guardrails},\ \text{日志评估}\ \}$$

这不是数学等式，而是一种**职责划分**。原图纠错 ③ 指出课件与笔记共有四种写法，下图把它们放在一起，可以看出**它们描述的是同一个东西，只是切分的粒度不同**。教学补全



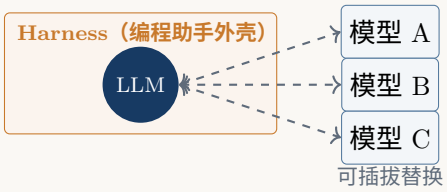
图 7.3　四种写法与统一写法逐列对齐：差别只是“哪几项被单独列出”（红色虚线为该写法未列出的项）

每一行是一种写法，每一列是一种职责。(a) 中的“执行 + 反馈”正好落在 Control Loop 一列；(b)(d) 没有单独写 Planning，(a)(b)(c)(d) 都没有单独写日志评估——但课件第 34 页的“六大职责”里有它。考试时按 (c)“六组件”作答，理解时记住“LLM 之外全是 Harness”即可。

生活中的它：用 CC Switch 给编程助手“换模型”

生活场景：笔记第 516 页记录：“可以将 Agent 中的 LLM 换掉（CC Switch）”。CC Switch 是一个开源的桌面工具，可以让 Claude Code、Codex 这类编程助手切换后端所用的模型服务商，而编程助手本身（读写文件、跑命令、管理会话的那一套）保持不变。

对应关系：
编程助手本身 → Harness
可切换的模型服务 → LLM
“换模型不换助手” → 公式中两项相互独立
换模型后表现变化 → 模型能力的差别



小判断：同一个任务、同一个外壳，模型 A 一次成功、模型 B 反复失败——差异应归因于模型；反过来，同一个模型放进两个不同的编程助手，表现也会不同——差异来自 Harness。这正是“Agent = LLM + Harness”两项可以**分开评价**的意义。
边界说明：外壳往往针对某个模型的输出习惯调过，换模型后不一定“即插即用”；使用第三方服务时还要遵守各服务商的条款。 原始资料 教学补全

7.5 Harness 最核心的机制：执行循环

课件第 33 页把第 3 章的 Agent 循环细化为九步，并把它概括为 Think → Act → Observe → Update。 原始资料 下图用颜色区分**每一步由谁负责**——这是课件没有标出、但对理解 Harness 最关键的一点。 教学补全

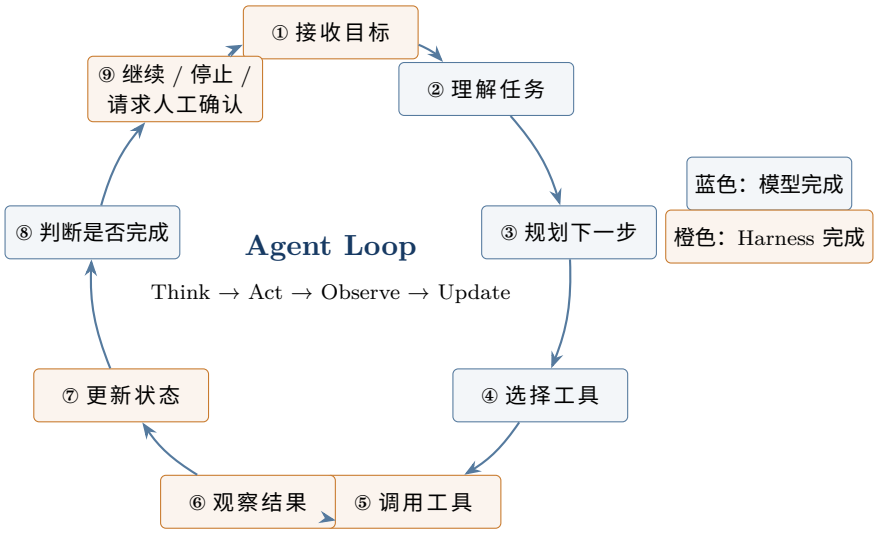


图 7.4　九步执行循环。蓝色由模型“想”，橙色由 Harness“做”和“管”（据课件第 33 页重绘并补充分工）

九个节点顺时针排列。四个蓝色节点（理解、规划、选工具、判断完成）对应 Think；五个橙色节点由 Harness 执行：⑤ 是 Act，⑥ 是 Observe，⑦ 是 Update，①⑨ 是循环的入口和出口。注意第 ⑧ 步“判断是否完成”虽然由模型提出，但第 ⑨ 步“继续还是停止、是否请人确认”的最终决定权在 Harness——它可以因为轮数到上限而强制停止，即使模型认为“还没完成”。课件的核心句：**Harness 的核心价值，是让 Agent 可以进行多轮、可控、可恢复的任务执行。**

第 3 章 Agent 循环	第 7 章 Harness 循环	九步中的对应
Plan	Think：模型判断下一步该做什么	②③④
Act	Act：Harness 调用对应工具	⑤
Observe	Observe：读取工具返回结果	⑥
Reflect	Update：更新任务状态，再进入下一轮	⑦⑧⑨

7.6 Harness 的六大核心职责



图 7.5　六大职责（据课件第 34 页重绘），每格底部标出它主要作用于九步循环的哪几步（教学补全）

六个格子是 Harness 要管的六类事情。底部的小字把它们挂回图 7.4：例如“工具管理”作用在选工具和调用工具的 ④⑤；“日志与评估”贯穿全部九步。课件结论：**Harness 不只是调工具，更是在管理整个任务系统的运行质量。**

下面用一段伪代码把其中四项职责落到程序上（承接第 3 章的极简循环，这里只展开“执行一个动作”这一步）：教学补全

Listing 2: Harness 执行一个动作时的检查顺序（教学用伪代码）

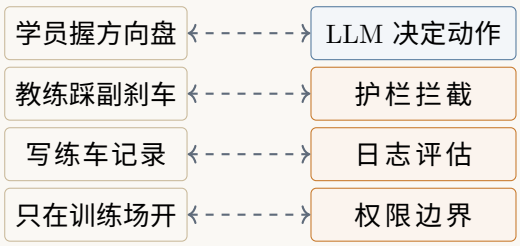
```
def execute(action):
    if action.name not in REGISTRY: # 工具管理：只能用已注册的工具
        return error("未知工具")
    if not schema_ok(action): # 工具管理：检查参数格式
        return error("参数格式错误，请重新生成")
    if action.name in HIGH_RISK and not ask_human(action): # 安全护栏：高风险先确认
        return "用户拒绝执行"
    for attempt in range(MAX_RETRY + 1): # 错误处理：失败重试
        try:
            result = REGISTRY[action.name](**action.args)
            log(action, result) # 日志：记录每一步
            return result
        except ToolError as e:
            log(action, e) # 日志：记录失败原因
    return error("多次失败：换备用工具或请用户补充信息")
```

逐段说明：第 2–5 行是工具管理（未注册、参数不合格都不执行，而是把错误信息交回模型）；第 6–7 行是安全护栏（高风险操作必须先得到人的同意）；第 8–14 行是错误处理和日志（每次尝试都记录，失败就重试）；第 15 行是“重试用完后怎么办”。**注意：这段代码里没有一行调用 LLM**——这些“管”的逻辑全部写在外壳里，不依赖模型自觉。

生活中的它：驾校教练车的副刹车

生活场景：学员开教练车，方向盘和油门都在学员手里；但副驾驶的教练脚下有一个副刹车，学员要闯红灯时，教练一脚踩下去；每次练车结束，教练还会在练车记录上写下问题。

对应关系：
学员 → LLM（能开，但会犯错）
副刹车 → 安全护栏（硬性拦截）
教练判断“这下危险” → 高风险操作前确认
练车记录 → 日志与评估
“只在训练场里开” → 权限范围限制



小判断：副刹车是**机械装置**，不依赖学员“自觉不闯红灯”。同理，“请不要删除文件”写在提示词里只是“劝学员”，把删除操作列入 `HIGH_RISK`、执行前必须人工确认，才是真正的“副刹车”。
边界说明：教练能看懂路况、随时判断；Harness 的规则是事先写好的，遇到规则没覆盖的新情况，仍可能漏拦。

7.7 状态管理的一个日常例子：handoff 文件

笔记第 516 页记录了老师教的一个技巧：用 AI 做 PPT 快出成品时，让它写一份 `handoff.md`，以免在新对话或换一个 AI 时丢失细节。原始资料 这其实是**人工完成的状态管理**：一次新对话就是一个空的上下文窗口（预备工具二），handoff 文件把“目标、已完成的工作、当前状态、下一步”写到窗口**外面**，下次再读进来。Anthropic 在 2025 年 11 月公开的长时间运行 Agent 实践中，也让 Agent 在每个工作时段结束时更新一个进度文件、配合 git 提交记录，让下一个时段的 Agent 能快速接上——思路完全一致。教学补全

生活中的它：换对话前写一份 handoff.md

生活场景：你和 AI 改了两个小时的 PPT，对话越来越长；你想开一个新对话继续，或者换一个 AI 工具接着做。

对应关系：
旧对话里的全部细节 → 当前上下文
新对话 → 空的上下文窗口
handoff.md → 外部记忆 / 状态文件
新对话先读 handoff → 状态恢复
写清“下一步” → 避免重复执行



小估算：若旧对话约 6 万 token，handoff 约 2 千 token，相当于把状态压缩约 30 倍；新对话一开始只占用很小一部分窗口，留出空间继续工作。（token 数为示意。）
边界说明：压缩必然丢信息，AI 写的 handoff 也可能漏掉或写错细节（第 6 章），所以“完美的、无需修改”只是期望，交接前最好自己读一遍。

改进笔记中的 handoff 提示词　笔记原写法分三步：① 表扬“你生成得很好”；② 说明担心新对话丢失细节；③ 要求总结一份完整的 handoff.md。其中真正起作用的是 ②③——说清**目的**与**要求**；第 ① 步“表扬”是否能提升输出质量，目前没有可靠证据，可有可无。更好的做法是直接写明 handoff 要包含哪些栏目，例如：

栏目	内容
目标	这份 PPT 给谁看、讲什么、几页
已完成	已定稿的页、已确定的配色与字体
当前状态	正在修改哪一页、未解决的问题
约束	必须保留的内容、不能改的格式
下一步	接手后第一件要做的事

这五栏正好对应“状态管理”的四个要点：记录目标、保存中间结果、记录已完成步骤、避免重复执行。

拓展联想：Skills（技能包）也是 Harness 的一部分　笔记写有“PPT、Skills、frontend_slides（都是 html）”。一些 Agent 产品允许把“做某类事情的说明书”打包成**技能**（Skill）：需要做 PPT 时，Harness 才把“怎样用 HTML 做幻灯片”的说明书和配套脚本加载进上下文。这属于“给模型提供任务上下文”与“工具管理”的结合——**不改模型，只改外壳给它看什么、给它什么工具**。笔记中提到的具体技能项目本讲义未逐一核验。

7.8　没有 Harness 会发生什么

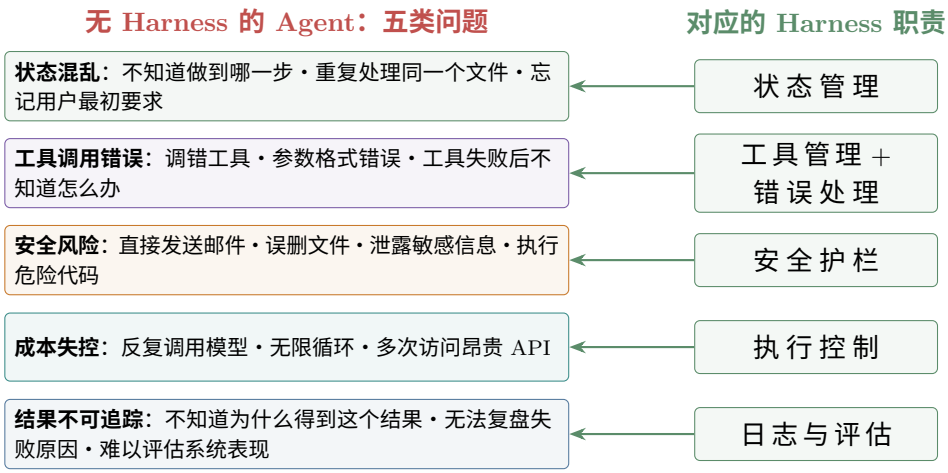


图 7.6　五类失败（左，据课件第 35 页）与解决它的职责（右，教学补全），一一对应

左列是课件列出的五类问题，右列是 7.6 节六大职责中对应的那一项，绿色箭头表示“由它来防止”。课件这一页的结论值得反复读：**模型越强，越需要 Harness 来约束、调度和监督。**能力越强的模型能做的事越多，没有约束时能造成的损失也越大。

例题　7.1　给“整理下载文件夹”的 Agent 设计 Harness

已知： Agent 要整理下载文件夹：列出文件 → 按类型分类 → 移动文件 → 删除重复文件。每轮循环约消耗 2500 token；单次工具调用失败率 0.1，相互独立。　**求：** ① 若成本上限为 20000 token，最多允许几轮？② 允许失败后重试 1 次，单个工具调用最终失败的概率？③ 哪些操作应列为高风险？

第一步（执行控制）： $\lfloor 20000/2500 \rfloor = 8$，设 $T_{\max} = 8$。
第二步（错误处理）： 两次尝试都失败的概率 $0.1 \times 0.1 = 0.01$，即 1%；不重试时为 10%。
第三步（安全护栏）： “删除重复文件”不可逆，必须列入高风险、执行前请人确认；“列出文件”只读，可直接允许；“移动文件”可逆，可允许但要写日志。
第四步（日志）： 每次移动记录“原路径 → 新路径”，出错时可以按日志移回。
检查： 8 轮 × 2500 = 20000，恰好不超上限。
本题真正想说明什么： 设计 Harness 就是**给每个风险配一个机制**：成本 → 轮数上限，失败 → 重试，不可逆 → 人工确认，出错 → 日志可回滚。

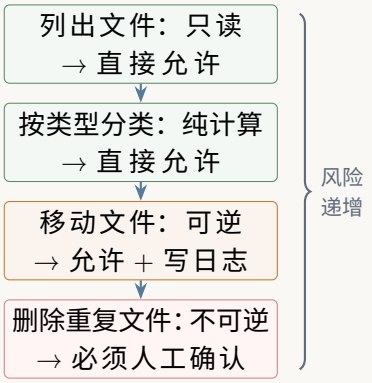
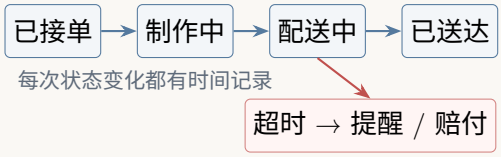


图 7.7　按“是否可逆”给操作分级

生活中的它：外卖订单的状态与超时处理

生活场景： 你点了一份外卖，订单依次显示“已接单 → 制作中 → 配送中 → 已送达”；骑手超时太久，平台会自动提醒，甚至提示你可以申请赔付。

对应关系：
订单的当前状态 → 状态管理
状态按固定顺序推进 → 执行控制
超时自动提醒 / 赔付 → 错误处理
订单详情里的时间记录 → 日志



小估算： 若平台承诺 30 分钟送达、超时 10 分钟触发提醒，则下单 40 分钟仍未“已送达”时，系统自动进入错误处理分支——不需要谁“想起来”去查。（数值为示意，各平台规则不同。）
边界说明： 外卖订单的状态是事先定义好的有限几种；Agent 的“状态”包含大量文字信息（目标、中间结果），远比订单复杂，所以更需要明确写下来。

7.9　最终总结：理解 Harness，就是理解 Agent 如何被组织起来

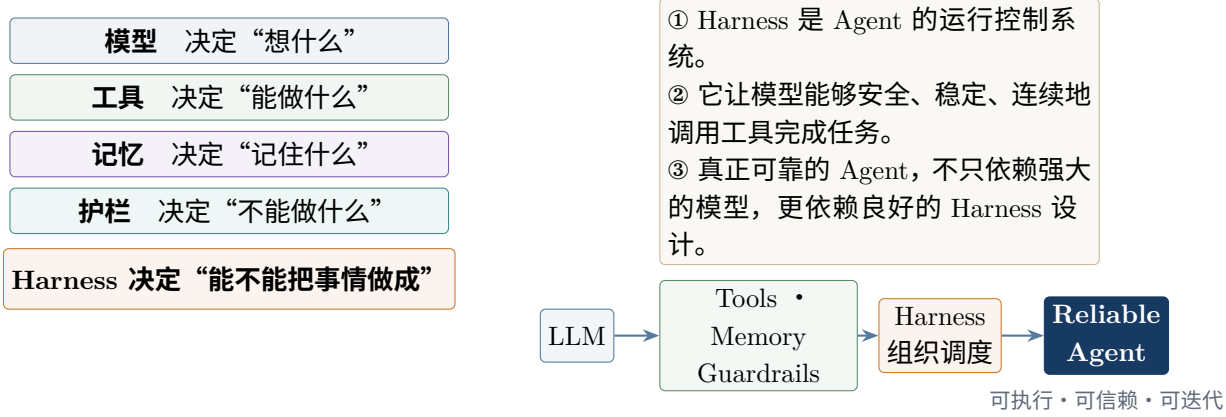


图 7.8　最终总结（据课件第 36 页重绘）

课件最后一句：“**没有 Harness，LLM 只是会回答；有了 Harness，LLM 才可能成为能执行任务的 Agent。**” 原始资料

7.10 易错点

易错点

1. **“Harness 能让模型更聪明。”**错。课件第 31 页：Harness 不是让模型更聪明，而是让模型更可靠地完成任务。模型的推理能力不因外壳而改变。
2. **“Harness 就是工具集合。”**错。工具只是六大职责之一；状态、控制、错误、护栏、日志同样重要。
3. **“模型越强，越不需要 Harness。”**错。课件第 35 页的结论相反：模型越强，越需要约束、调度和监督。
4. **“在提示词里写‘不要删除文件’就是护栏。”**不够。提示词只能“劝”，模型仍可能出错或被误导；真正的护栏要写在执行代码里（权限、白名单、人工确认）。
5. **“到了最大轮数说明任务失败了，应该取消上限。”**错。上限是防止无限循环和成本失控的保险；到达上限时应停止并请人确认，而不是取消保险。

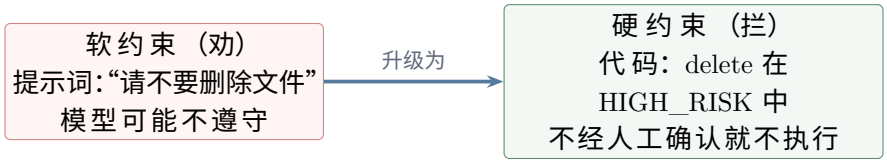


图 7.9 易错点 4：护栏必须从“劝”升级为“拦”

7.11 相近概念辨析：提示词、上下文、Harness

	提示词设计	上下文管理	Harness 设计
关注	一次输入怎么写	每一轮把什么放进窗口	整个运行系统怎么搭
例子	“请用三点总结”	RAG 检索结果、handoff 文件	工具注册、循环上限、权限、日志
作用范围	单次调用	多轮之间	全流程
关系	后者包含前者：Harness 中的“提供任务上下文”就包含了提示词与上下文管理		

工程界常把三者称为提示词工程、上下文工程、Harness 工程，大致代表关注范围从小到大。这些说法尚无统一的严格定义，理解它们的包含关系即可。 教学补全

7.12 相似知识对比与迁移

对照：Harness ↔ 操作系统（类比同构型）

一句话定位：操作系统管理“程序如何使用计算机资源”，Harness 管理“模型如何使用外部工具”。程序不能直接碰硬件，要经过内核；模型不能直接碰外部世界，要经过 Harness。

维度	操作系统	Harness
被管理者	进程（确定的程序）	模型（概率生成的决策）
访问资源	系统调用，内核代为执行	工具调用，Harness 代为执行
权限	用户态 / 内核态，文件权限	工具白名单、高风险操作确认
调度与上限	时间片、超时杀进程、内存上限	最大轮数、成本上限
状态	进程控制块记录运行状态	状态管理记录目标与进度
异常	中断与异常处理	错误处理：重试、换工具
日志	系统日志	每一步操作记录

相同之处：都是“在强大但可能出错的执行者与外部资源之间，加一层负责权限、调度、记录的

中间层”。

不同之处及根源：操作系统管理的程序是**确定的**，同样的输入产生同样的系统调用，所以权限规则可以写死并严格验证；Harness 管理的模型输出**有随机性、会幻觉**，它请求的动作可能“语法合法但语义危险”（例如合法地删除了不该删的文件），所以 Harness 还需要人工确认这类操作系统通常不需要的机制。

旧知识中的结论	迁移	理由或反例
程序不能绕过内核直接操作硬件	✓	模型只能输出调用单，执行一律经过 Harness
超时 / 超内存的进程会被强制终止	✓	超过最大轮数或成本上限，Harness 强制停止
权限检查是确定性规则，足以保证安全	△	只能拦住“越权”的操作；对“有权限但判断错误”的操作，还需人工确认
系统调用的含义精确定义、不会被误解	✗	工具说明是自然语言，模型可能误解用途或误填参数

同一个小算例：操作系统给某进程设 2 秒 CPU 时间上限，超时即终止；Harness 给 Agent 设 8 轮上限（例题 7.1），第 9 轮请求到来时直接拒绝并请人确认。两者都用“硬上限”防止失控。（拓展联想：《操作系统》课程会系统讲解进程、系统调用与权限。）教学补全

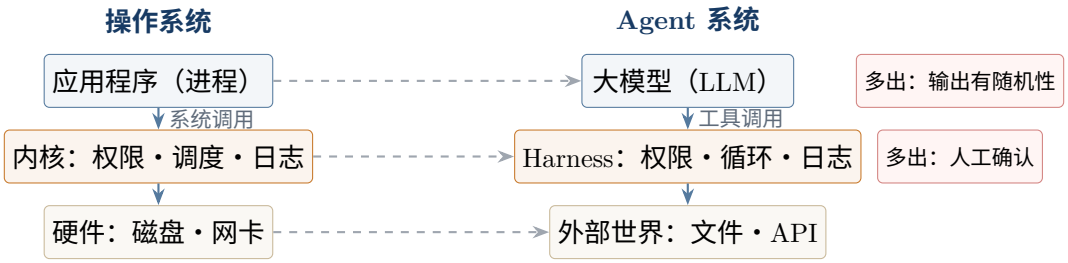


图 7.10　对照图：三层结构逐层对应；红框是 Harness 相比操作系统多出的部分

对照：执行控制 ↔ 嵌入式系统中的看门狗定时器（思想重现型，精简版）

一句话定位：单片机程序跑飞或卡死时，看门狗定时器（watchdog）在规定时间内收不到“喂狗”信号，就强制复位系统；Harness 在规定轮数或成本内任务没有完成，就强制停止 Agent。　**迁移判断：**“由独立于被监控者的机制来兜底”✓ 直接迁移——看门狗是独立硬件，Harness 的上限也不能交给模型自己判断；“触发后自动复位重来”△ 对 Agent 不一定合适：重来可能重复执行已完成的操作（如重复发邮件），所以通常是“停止 + 请求人工确认”，而不是自动重启。（你会在《微机原理》或嵌入式课程中见到看门狗。）

知识联系　本章把全讲义串成一条线：RAG 是 Harness“提供上下文”的手段；Tool Calling 是“工具管理”的对象；Agent 循环是“执行控制”的骨架；幻觉是“护栏”和“日志评估”存在的理由；多模态与 Diffusion 可以作为工具被接入。以后在《操作系统》《软件工程》中学到的权限、调度、测试、监控，在《自动控制原理》中学到的闭环、限幅，都能在 Harness 设计中找到对应。

学完这里，你应该能够回答

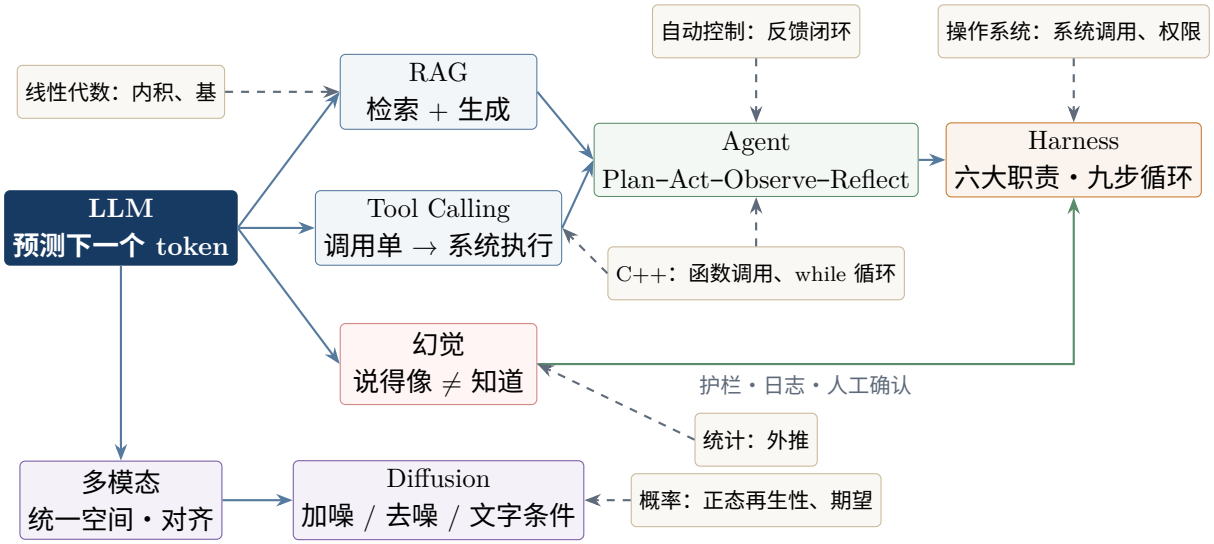
1. 为什么说“LLM 可以想和说，但 Agent 还需要做和管”？
2. Harness 的定义是什么？它让模型更聪明还是更可靠？
3. 写出 Agent = LLM + Harness，并列出 Harness 包含的组件。课件和笔记的四种写法有何异同？

4. 九步执行循环中，哪些步骤由模型完成，哪些由 Harness 完成?
5. 六大职责各包含哪四项?“无限循环”“误删文件”“重复处理同一个文件”分别由哪项职责防止?
6. 为什么“在提示词里写不要删除”不算真正的护栏?
7. 每轮 3000 token、上限 21000 token，最多几轮?（7 轮）

到这里，我们已经解决了什么? 一个“能想、能查、能做、能看、能画，但会出错”的模型，被 Harness 组织成了可执行、可控制、可追踪的 Agent。下面进入全专题的总结与练习。

全专题总结：知识地图、易错总表与后续连接

本专题知识地图



全专题知识地图：实线为本专题内的知识依赖，虚线为与其他课程的对照关系（米色框）

高频易错点总表

章	错误说法	正确理解
1	RAG 让模型学到了新知识	不改参数，只是临时把资料放进上下文
1	相似度越高，资料越正确	相似度只衡量话题是否相近，不衡量真假与新旧
2	模型自己调用了 API	模型只写调用单，执行者是系统（Harness）
2	会调用工具就是 Agent	工具调用偏单步；Agent 围绕目标多步循环并修正
3	循环越多越好	必须有最大轮数；误差会累积（p^n）
4	统一向量空间 = 向量相同	是“可以比较远近”；还需对齐训练
4	“对齐”只有一个意思	跨模态对齐（表示层面）与价值对齐（行为层面）
5	模型学习如何加噪	加噪是固定公式，模型学预测噪声（课件第 20 页纠错）
5	文字只在开始时输入一次	文本向量在每一步去噪时都参与
6	回答越详细越可信	幻觉恰恰“合理、自信、细节丰富”
6	用了 RAG 就没有幻觉	只能降低，不能消除
7	Harness 让模型更聪明	让模型更可靠，不改变模型能力
7	模型越强越不需要 Harness	模型越强，越需要约束、调度和监督
7	提示词写“不要删除”就是护栏	护栏要写在执行代码里（权限、白名单、人工确认）

基础解题步骤总结

四类常见计算题的固定步骤

1. **余弦相似度排序：** 算内积 → 算两个长度 → 相除 → 比大小 → 取 Top-k。单位向量可直接比内积。
2. **Diffusion 系数：** 由 $\bar{\alpha}_t$ 得信号系数 $\sqrt{\bar{\alpha}_t}$、噪声系数 $\sqrt{1-\bar{\alpha}_t}$ → 代入 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$ → 用“平方和为 1”检查。
3. **成本与轮数：** 最多轮数 $= \lfloor$上限/每轮消耗$\rfloor$；上下文能放几段 $= \lfloor$(窗口−固定部分)/每段长度$\rfloor$。
4. **可靠性：** 多步全部成功 p^n；独立重试 r 次后仍失败 q^{r+1}（q 为单次失败率）。

相近概念总对比

一对概念	关键区别	一句话记忆
RAG / 微调	改不改参数	开卷考试 vs 考前背书
Tool Calling / Function Calling	能力 vs 实现格式	会用工具 vs 会填工单
Tool Calling / Agent	单步调用 vs 多步循环	会用工具的人 vs 会做项目的人
Agent / 固定工作流	下一步由谁决定	运行时决定 vs 设计时写死
统一空间 / 对齐	放在一起 vs 意思对应	同一张地图 vs 地名标对位置
正向扩散 / 反向生成	固定加噪 vs 学习去噪	造训练题 vs 解题生成
幻觉 / 知识过时	编造 vs 曾经正确	没有依据 vs 依据旧了
提示词 / 上下文 / Harness	关注范围由小到大	一句话 → 一个窗口 → 整个系统

跨学科 / 相似知识总对比表

对照	类型	可以直接迁移（✓）	加条件（△）/ 不能迁移（✗）
向量检索 ↔ 关键词查询	方法互补	建索引加速查询	✗ 查询结果非此即彼；△ 查不到 ≠ 不存在
Top-k 检索 ↔ 数据结构 Top-k	思想重现	小根堆 $O(n \log k)$	△ 大规模时改用近似检索
工具调用 ↔ C++ 函数调用	同名异义	先声明后调用	✗ 写了就执行；△ 类型检查
工具调用 ↔ 系统调用	类比同构	高权限方代为执行	△ 权限规则能否保证安全
Agent 循环 ↔ 反馈闭环	类比同构	负反馈纠偏；测量误差会误导	✗ 传递函数分析稳定性；✗ 必然收敛
Agent 循环 ↔ while 循环	思想重现	必须有终止条件	✗ 事先确定执行次数
统一空间 ↔ 基变换	类比同构	同一坐标系才能比内积	✗ 可逆；△ 内积不变
跨模态对齐 ↔ 价值对齐	同名异义	都需外部数据训练	✗ 互相保证

对照	类型	可以直接迁移（✓）	加条件（△）/ 不能迁移（✗）
正向扩散 ↔ 布朗运动	类比同构	独立扰动方差相加	△ 方差线性增长；✗ 不可逆故不能生成
Diffusion ↔ LLM 逐 token	方法互补	多步、有随机性	✗ 已生成部分不再改
幻觉 ↔ 统计外推	类比同构	范围外不可靠	△ 置信区间；△ 加数据
Harness ↔ 操作系统	类比同构	不能绕过中间层；超限强制终止	△ 规则足以保证安全；✗ 接口无歧义
执行控制 ↔ 看门狗	思想重现	独立机制兜底	△ 触发后自动重启

后续课程连接

知识联系　《**概率论与数理统计**》：正态分布再生性（Diffusion 推导）、期望（幻觉的“猜测得分”）、独立事件乘法（多步成功率）、回归与外推。　《**自动控制原理**》：反馈闭环、误差、稳定性——与 Agent 循环对照，也能看清 Agent 为什么缺少“可证明的稳定性”。　《**操作系统**》《**软件工程**》：系统调用、权限、调度、日志、测试框架——Harness 的工程原型。　《**模式识别**》《**数字图像处理**》：相似度度量、图像去噪——RAG 与 Diffusion 的数学基础。　**本学期**《**数据结构与算法**》：Top-k 与堆、状态与循环——可以直接拿来实现一个小型 RAG 或 Agent 原型。

面试速答卡：笔记标注的“大厂面试重点”

Q：Agent 和普通大模型的区别? 普通模型偏重回答；Agent 围绕目标，规划、调用工具、观察结果并修正，连续完成多步任务。

Q：Agent 的核心循环? Plan → Act → Observe → Reflect（或 Think → Act → Observe → Update），未完成就继续，完成或达上限就停止。

Q：Tool Calling 中模型会执行代码吗? 不会。模型输出函数名 + 参数，系统解析、检查后执行，再把结果放回上下文。

Q：什么是 Harness? Agent 的运行外壳与控制系统：工具管理、状态管理、执行控制、错误处理、安全护栏、日志评估。Agent = LLM + Harness。

Q：RAG 能消除幻觉吗? 不能，只能降低：检索可能出错，资料可能过时，模型可能不忠实引用。

正式练习（38 题）

使用说明：先独立完成全部题目，再查“答案速查”，最后读“逐题图解”。题号后的标签说明层级；题目区的图只呈现题目已给出的信息，不含答案提示。

知识点—题目对应表

核心知识点	基础题	提升题	跨学科	涉及的对照
RAG 与检索	1, 2, 3, 11, 16, 18, 21, 22	27, 31, 34	37	关键词检索；基变换
Tool Calling	4, 5, 13, 23	29	—	C++ 函数调用
Agent 循环	6, 7, 17	26, 35	36	反馈闭环
多模态与对齐	8	—	37	基变换
Diffusion	9, 19, 25	28, 33	38	布朗运动
幻觉	10, 15	29	—	统计外推
Harness	12, 14, 20, 24	26, 30, 32, 35	36	操作系统；看门狗

A 基础巩固训练（25 题）

A-1　单项选择题（10 题）

1. 基础单选　关于 RAG，下列说法正确的是（　　）。

A. RAG 通过重新训练，把知识库内容写入模型参数

B. 使用 RAG 之后，模型就不会再产生幻觉

C. RAG 在回答前先检索相关资料，再把资料与问题一起交给模型生成答案

D. RAG 只能检索互联网上的公开网页

2. 基础单选　RAG 在线问答中，下列四个步骤的正确顺序是（　　）。（① 问题向量化；② 在向量库中检索 Top-k；③ 把资料与问题一起送入大模型；④ 生成答案）

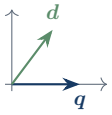
A. ①向量化 → ②检索 → ③送入模型 → ④生成　　B. ②检索 → ①向量化 → ③送入模型 → ④生成

C. ①向量化 → ③送入模型 → ②检索 → ④生成　　D. ③送入模型 → ①向量化 → ②检索 → ④生成

3. 基础单选　问题向量 $\boldsymbol{q}=(1,0)$，文档向量 $\boldsymbol{d}=(0.6,0.8)$（见右图），二者的余弦相似度为（　　）。

A. 0.8　　B. 0

C. 1　　D. 0.6



4. 基础单选　用户请模型“查今天北京的天气”。下图是参与这次工具调用的四方。真正执行“访问天气 API”这一动作的是（　　）。

用户　　大模型　　系统（Harness）　　天气 API

A. 大模型　　B. 系统（Harness）

C. 用户　　D. 向量数据库

5. 基础单选 在 Function Calling 中，模型输出的内容通常是（　　）。

A. 工具执行后的结果　　B. 一张网页截图

C. 模型更新后的参数　　D. 结构化的函数名和参数

6. 基础单选 下列任务中，最需要 Agent（而不只是一次 Tool Calling）的是（　　）。

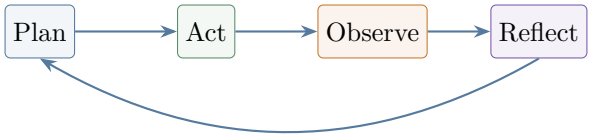
A. 把一句中文翻译成英文

B. 规划三日游：查天气、比价格，超预算就调整，最后生成表格

C. 查询今天北京的气温

D. 计算 35×48

7. 基础单选 在课件“订一场旅行”的例子里，“发现总价超预算”属于 Agent 循环的哪一阶段（　　）。



A. Plan　　B. Act

C. Observe　　D. Reflect

8. 基础单选 关于多模态模型的“统一向量空间”，下列说法正确的是（　　）。

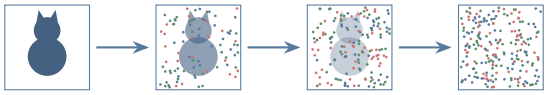
A. 不同模态的信息编码成向量后，可以在同一空间中比较相似度

B. 在统一空间中，猫的图片与“一只猫”这句话的向量完全相同

C. 只有文字能转成向量，图片和语音不能

D. 只要使用统一空间，就不需要对齐训练

9. 基础单选 关于 Diffusion 的正向扩散过程（下图从左到右），下列说法正确的是（　　）。



A. 模型在训练中学习如何给图像加噪

B. 这个过程从随机噪声生成清晰图像

C. 按事先规定的公式逐步加噪，不含需要学习的参数

D. 文本向量在这个过程中控制加噪的方向

10. 基础单选 下列情形中，属于大模型“幻觉”的是（　　）。

A. 问到一本并不存在的书，模型详细介绍了它的章节结构与作者观点

B. 问到训练截止后发生的新闻，模型回答“我不确定，建议查询最新报道”

C. 模型调用计算器，得到 $35 \times 48 = 1680$

D. 模型检索到课程资料后，据此总结出要点并标注出处

A-2　多项选择题（5 题）

11. 基础多选 根据课件，RAG 能够缓解大模型的哪些问题（　　）。

A. 知识可能过时　　B. 不了解私有资料

C. 缺少可追溯来源　　D. 推理能力不足，需要通过修改参数来增强

12. 基础多选 下列各项中，属于 Harness“安全护栏”职责的是（　　）。

A. 高风险操作前请求确认　　B. 防止隐私泄露

C. 记录每一步操作，方便复盘　　D. 控制成本和权限

13. 基础多选 关于 Tool Calling，下列说法正确的是（　　）。

A. 模型需要事先获得工具的名称、用途说明和参数格式

B. 模型自己直接访问外部 API 获取数据

C. 工具返回的结果会被放回上下文，供模型组织回答

D. Function Calling 是 Tool Calling 的一种具体实现方式

14. 基础多选 在“Agent = LLM + Harness”中，下列各项属于 Harness 而不属于 LLM 的是（　　）。

A. 预测下一个 token　　B. 注册工具并检查参数格式

C. 限制最大循环次数　　D. 保存中间结果与已完成步骤

15. 基础多选 课件列出的“幻觉出现的主要原因”包括（　　）。

A. 训练目标是预测下一个词，而不是判断真假

B. 模型参数太多，因此必然故意说谎

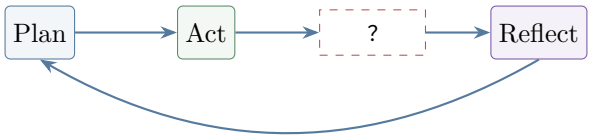
C. 语言上合理，不等于事实正确

D. 问题本身可能带有错误前提

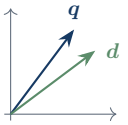
A-3　填空题（5 题）

16. 基础填空 RAG 的全称是 Retrieval-Augmented Generation，其核心可以概括为：RAG = 检索 + ____。

17. 基础填空 下图是 Agent 的循环，问号处应填 ____。



18. 基础填空 问题向量 $\boldsymbol{q} = (3, 4)$，文档向量 $\boldsymbol{d} = (4, 3)$，二者的余弦相似度为 ____。



19. 基础填空 Diffusion 正向公式 $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon$。若 $\bar{\alpha}_t = 0.64$，则信号系数为 ____；若 $x_0 = 1$，$\epsilon = 0.5$，则 $x_t =$ ____。

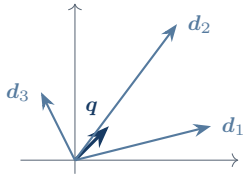
20. 基础填空 某 Agent 每轮循环消耗约 1500 token，Harness 设定的成本上限为 6000 token，则最多允许 ____ 轮完整循环。

A-4　解答题（5 题）

21. 基础解答 按顺序写出课件中 RAG 在线问答的六个步骤（可填入下面六个框），并说明：为什么问题向量化与文档向量化必须使用同一个 Embedding 模型?



22. 基础解答 问题向量 $\boldsymbol{q}=(1,1)$，知识库三段片段的向量为 $\boldsymbol{d}_1=(4,1)$，$\boldsymbol{d}_2=(3,4)$，$\boldsymbol{d}_3=(-1,2)$（见下图）。① 分别计算三者与 $\boldsymbol{q}$ 的余弦相似度（保留三位小数）；② 写出排序并给出 Top-2。



23. 基础解答 用户说：“帮我查一下今天北京天气。”模型可用工具 `get_weather(city, date)`。请按课件六步写出这次 Tool Calling 的完整过程，并在下面的时序图框架中标出**每一步由谁完成**。



24. 基础解答 课件第 35 页列出“没有 Harness 的 Agent”会出现五类问题。请写出这五类问题，各举一个具体例子，并指出 Harness 六大职责中哪一项负责防止它。

25. 基础解答 分别说明 Diffusion 的“正向扩散”和“反向生成”各在训练时还是生成时使用、各做什么；并说明训练时神经网络学习的是什么，为什么“训练时模型学习如何给图像加噪”这一说法是错误的。

B 中等偏下提升训练（10 题）

B-1　单项选择题（3 题）

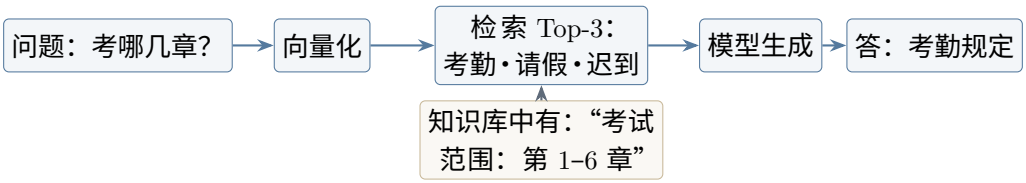
26. 提升单选 某 Agent 整理文件夹时的执行日志如下图所示：它三次处理了同一个文件，最后还忘了用户最初“只整理 PDF”的要求。最可能缺少的 Harness 职责是（　　）。



A. 工具管理　　B. 状态管理

C. 安全护栏　　D. 日志与评估

27. 提升单选 某课程 RAG 助手被问“期末考试考哪几章?”，却回答了考勤规定。检查发现：知识库中**确有**“考试范围”这一片段，但检索返回的 Top-3 全是考勤相关片段（下图）。问题最可能出在（　　）。



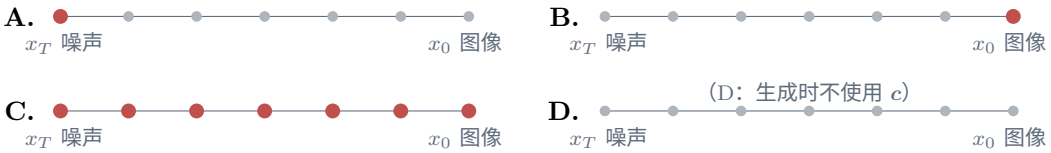
A. 检索环节（向量化与相似度排序）没有把相关片段排进 Top-3

B. 用户提问方式错误

C. 大模型生成环节无法读懂资料

D. 知识库没有收录考试范围

28. 提升单选 在文生图 Diffusion 中，文本向量 $\boldsymbol{c}$ 在哪些时刻参与去噪？下列四幅时间轴中，红点表示“该步使用了 $\boldsymbol{c}$”。正确的是（　　）。



A. 只在第一步使用　　B. 只在最后一步使用

C. 每一步去噪都使用　　D. 只在训练时使用，生成时不用

B-2　多项选择题（2 题）

29. 提升多选 用户问：“为什么爱因斯坦发明了电话?”下列处理方式中合理的是（　　）。

A. 先指出问题的前提有误，再给出正确信息

B. 调用检索工具核实电话的发明史后再回答

C. 顺着问题，描述爱因斯坦发明电话的经过

D. 列出“爱因斯坦发明电话的三个原因”

30. 提升多选 为一个“自动回复并发送邮件”的 Agent 设计 Harness，下列做法合理的是（　　）。

A. 每封邮件发送前请求用户确认

B. 收件人限定在白名单范围内

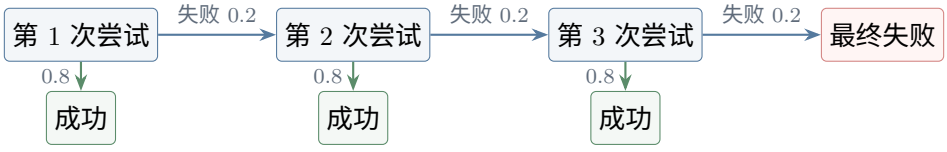
C. 发送失败时无限次重试，直到成功为止

D. 记录每封邮件的发送时间、收件人与内容摘要

B-3　填空题（3 题）

31. 提升填空 三维向量 $\boldsymbol{q}=(1,2,2)$，$\boldsymbol{d}=(2,1,2)$，二者的余弦相似度为 ____（用分数表示）。

32. 提升填空 某工具单次调用失败的概率为 0.2，各次调用相互独立。Harness 规定失败后最多重试 2 次（即最多共尝试 3 次）。则这次工具调用最终仍失败的概率为 ____。



33. 提升填空 已知第 t 步 $\bar{\alpha}_t=0.36$。则噪声系数 $\sqrt{1-\bar{\alpha}_t}=$ ____；在 x_t 的总方差中（设 x_0 方差为 1），噪声方差所占比例为 ____。

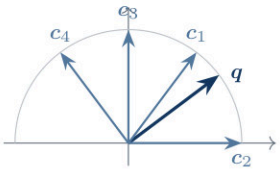
B-4　综合大题（2 题）

34. 提升综合 **课程资料 RAG 助手。**知识库四个片段的（已归一化）向量为：$\boldsymbol{c}_1 = (0.6, 0.8)$“Transformer 结构”、$\boldsymbol{c}_2 = (1, 0)$“注意力公式”、$\boldsymbol{c}_3 = (0, 1)$“课程安排表”、$\boldsymbol{c}_4 = (-0.6, 0.8)$“考勤规定”。问题“总结 Transformer 课件”的向量 $\boldsymbol{q} = (0.8, 0.6)$。

(1) 计算 $\boldsymbol{q}$ 与四个片段的余弦相似度，写出排序。

(2) 系统提示 150 token，问题 50 token，每个片段 300 token，上下文窗口上限 1000 token。取 Top-2 时输入总长度是多少？最多能取几个片段？

(3) 若排名第一的片段其实是**上学期**的旧版课件，模型会受到什么影响？给出两条改进办法。



35. 提升综合 **海滨两日游 Agent。**预算 2000 元。工具返回：高铁往返每人 2×250 元；酒店甲每晚 700 元（住 1 晚）；门票共 300 元；餐饮每天 300 元（2 天）；第二次查询得到酒店乙每晚 550 元。

(1) 写出第 1 轮循环的 Plan、Act、Observe、Reflect，并计算总价。

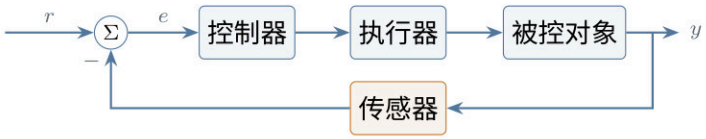
(2) 写出第 2 轮循环的关键变化，计算新总价，判断是否结束。

(3) 若每轮循环消耗 2000 token，Harness 设定成本上限 10000 token，最多允许几轮？本任务实际消耗多少 token？

(4) 若最后一步是“用信用卡支付酒店押金”，Harness 应如何处理？请指出涉及的职责。

C 跨学科迁移训练（3 题）

36. 跨学科单选 · 自动控制 下图是自动控制中的闭环系统：设定值 r 与传感器测得的输出 y 相减得到误差 $e = r - y$，控制器据此调整执行器。若把它与 Agent 的 Plan–Act–Observe–Reflect 循环作类比，图中的“传感器”最对应 Agent 循环中的（　　）。



A. Plan　　B. Act

C. Observe　　D. 用户给出的目标

37. 跨学科多选 · 线性代数 已知向量 $\boldsymbol{a} = (1, 0)$，$\boldsymbol{b} = (2, 0)$，$\boldsymbol{c} = (0, 3)$，$\boldsymbol{d} = (1, 1)$，$\boldsymbol{e} = (0.5, 0.5)$。下列关于“用余弦相似度做检索”的判断正确的是（　　）。

A. $\cos(\boldsymbol{a}, \boldsymbol{b}) = 1$，说明余弦相似度只看方向，不看长度

B. $\cos(\boldsymbol{a}, \boldsymbol{c}) = 0$，此时两向量正交，按余弦相似度看最不相关

C. 把 $\boldsymbol{d}$ 放大为 $2\boldsymbol{d}$，$\cos(\boldsymbol{a}, 2\boldsymbol{d})$ 也变为原来的 2 倍

D. 对未归一化的向量，欧氏距离越小，余弦相似度一定越大

38. 跨学科填空 · 大学物理 / 概率 一个粒子在一维方向做随机游走（布朗运动的简化模型）：每一步的位移是一个独立的随机量，均值为 0、方差为 0.01。已知：**相互独立的随机量之和的方差，等于各自方差之和**；标准差是方差的算术平方根。则走 100 步后，总位移的标准差为 ____。

答案速查

A 基础巩固

单选	1. C	2. A	3. D	4. B
	5. D	6. B	7. C	8. A
	9. C	10. A		
多选	11. ABC	12. ABD	13. ACD	14. BCD
	15. ACD			
填空	16. 生成（Generation）	17. Observe（观察）	18. 0.96	19. 0.8；1.1
	20. 4			
解答	21. 提问 → 问题向量化 → 向量库检索 → 取 Top-k → 资料 + 问题送入模型 → 生成答案；同一空间才可比较			
	22. $\cos \approx 0.857,\ 0.990,\ 0.316$；$d_2 > d_1 > d_3$；Top-2 为 d_2, d_1			
	23. 模型完成 ②③⑥，系统完成 ④⑤（详见解析）		24. 见解析五类问题与对应职责	
	25. 正向：训练时、固定加噪造数据；反向：生成时、逐步去噪；网络学预测噪声			

B 中等偏下提升

单选	26. B	27. A	28. C
多选	29. AB	30. ABD	
填空	31. $\frac{8}{9}$	32. 0.008	33. 0.8；64%
综合	34. 0.96, 0.8, 0.6, 0；800 token；最多 2 段；过时资料会被当作依据		
	35. 2100 元超支 → 1950 元结束；最多 5 轮，实际 4000 token；支付需人工确认		

C 跨学科迁移

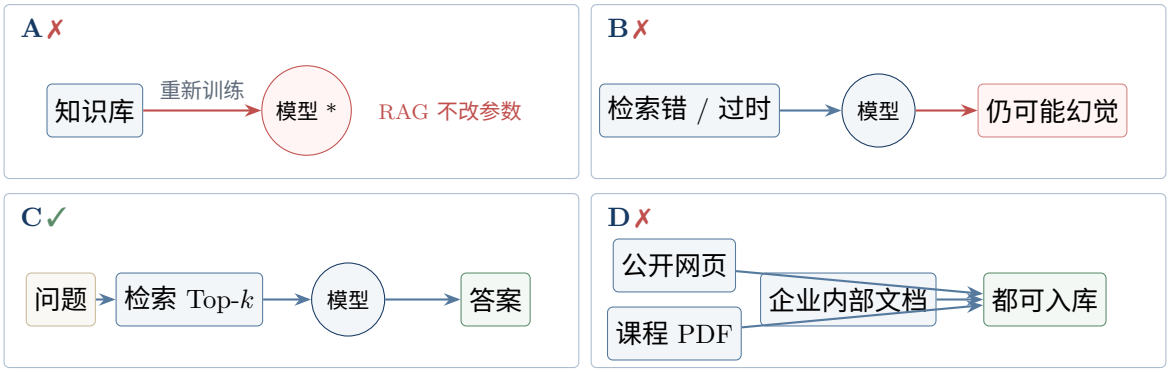
36. C	37. AB	38. 1

A-1　基础单选详细解析

第 1 题　答案：C　基础

考查知识： RAG 的定义（第 1.3 节）：检索 + 生成，不改参数；易错点 1、2。

思路： 判断每个选项说的是“改参数”“消除幻觉”“检索后生成”还是“资料来源”。下面四幅小图使用同一套部件（问题、知识库、模型、答案），差别只来自选项本身。



A 错： 图中红色“模型 *”表示参数被改，而 RAG 只改变本次输入，不训练。**B 错：** 检索出错或资料过时时，模型照样会说错，RAG 只是降低幻觉。**C 对：** 与课件第 5 页“回答前先检索，再基于资料生成”一致。**D 错：** 知识库可以是课程资料、企业文档等私有资料——这正是 RAG 要解决的“不了解私有资料”。

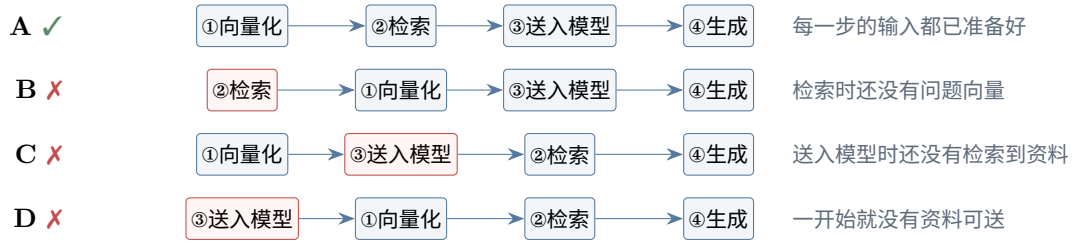
常见错误： 把 RAG 理解成“给模型补课”。

一句话总结： RAG 是开卷考试，不是考前背书。

第 2 题　答案：A　基础

考查知识： RAG 在线六步的顺序与依赖关系（图 1.3）。

思路： 每一步都需要前一步的输出：没有问题向量就无法检索；没有检索结果就没有资料可送入模型。下图把四个选项的流程画在同一基准上，第一个违反依赖的步骤标红。



第 2 题解析图：四个选项的流程，红框为第一个“输入还不存在”的步骤

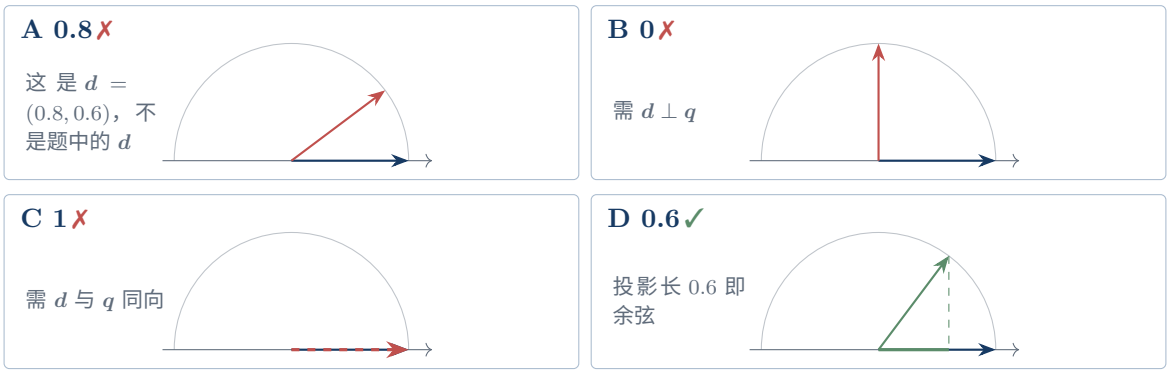
常见错误： 记住了六个名词，没记住它们的依赖。

一句话总结： 排顺序就问：这一步的输入，前面产生了吗?

第 3 题　答案：D　基础

考查知识： 余弦相似度公式（预备工具三、1.4 节）。

计算： $\boldsymbol{q}\cdot\boldsymbol{d}=1\times0.6+0\times0.8=0.6$；$\|\boldsymbol{q}\|=1$，$\|\boldsymbol{d}\|=\sqrt{0.36+0.64}=1$；所以 $\cos\theta=0.6$。几何上，0.6 是 $\boldsymbol{d}$ 在 $\boldsymbol{q}$ 方向上的投影长度。下面四幅小图使用同一个单位圆和同一个 $\boldsymbol{q}$，分别画出“余弦等于各选项值”时 $\boldsymbol{d}$ 应有的方向：



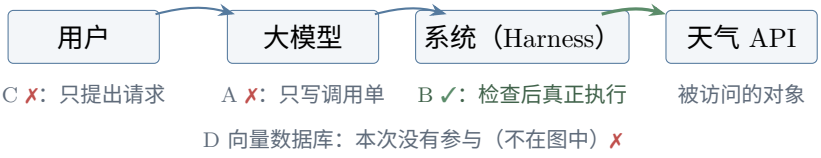
A 错： 0.8 是 $\boldsymbol{d}$ 的纵坐标（$\sin\theta$），误把正弦当余弦。**B 错：** 余弦为 0 要求两向量垂直，图中 $\boldsymbol{d}$ 不垂直于 $\boldsymbol{q}$。**C 错：** 余弦为 1 要求同向。**D 对。**

常见错误： 把 $\boldsymbol{d}$ 的第二个分量当成答案。

一句话总结： 单位向量下，余弦 = 内积 = 投影长度。

第 4 题　答案：B　基础

考查知识： Tool Calling 中模型与系统的分工（图 2.3、易错点 1）。



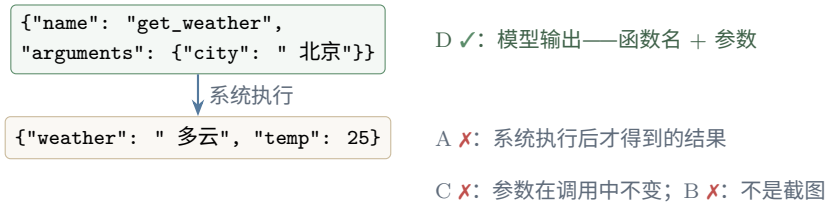
第 4 题解析图：四方的角色。加粗绿色箭头是唯一“真正访问 API”的动作

常见错误： 认为“模型调用了 API”。

一句话总结： 模型写单，系统执行。

第 5 题　答案：D　基础

考查知识： Function Calling 的输出格式（图 2.2）。



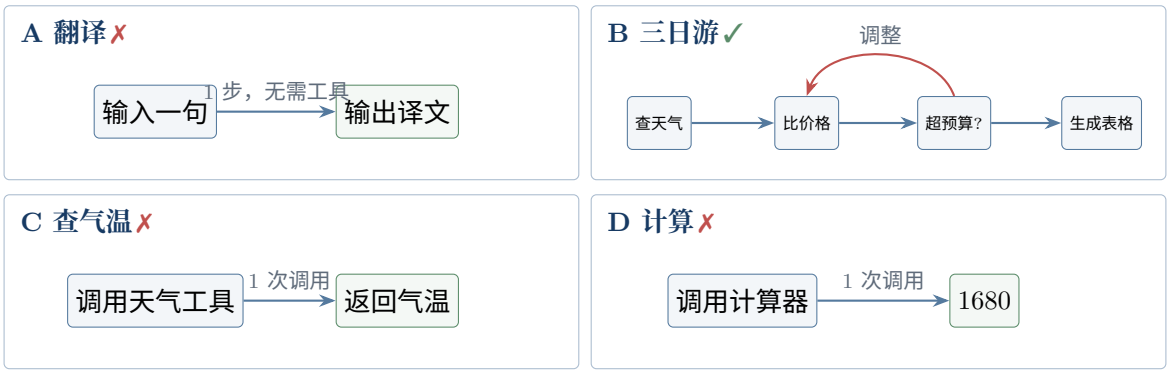
第 5 题解析图：模型写出的（绿）与系统返回的（米）是两段不同文字

常见错误： 把工具结果当成模型输出。

一句话总结： 模型输出的是“要调用什么”，不是“调用得到什么”。

第 6 题　答案：B　基础

考查知识： Tool Calling 与 Agent 的区别（第 3 章、课件第 13 页）。



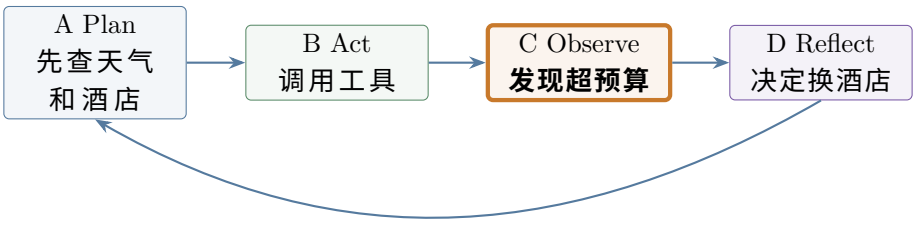
只有 B 有多步、有依赖，并且会**根据中间结果回头调整**（红色箭头），这是 Agent 的标志。A、C、D 一步即可完成。

常见错误： 认为“用到工具就需要 Agent”。

一句话总结： 看有没有“观察后再决定”的循环。

第 7 题　答案：C　基础

考查知识： Agent 循环四阶段（图 3.2）。



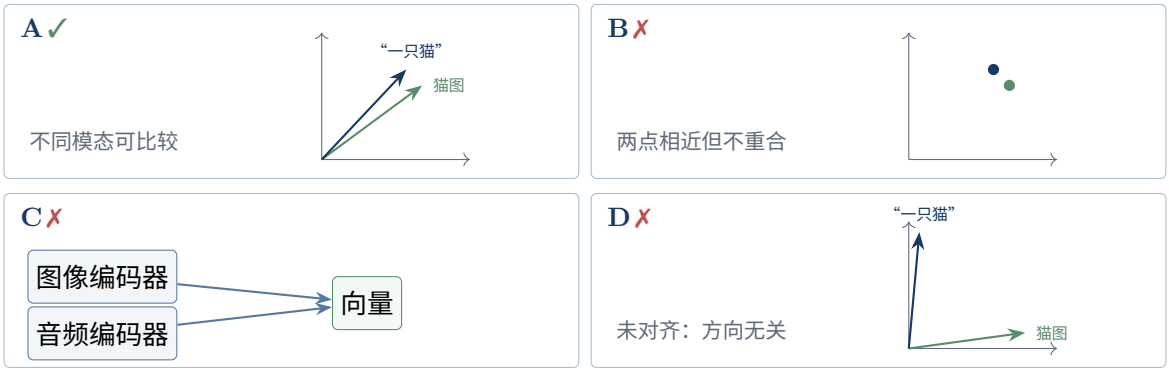
第 7 题解析图：“发现”是读取工具结果，属于 Observe；“决定换”才是 Reflect

常见错误： 选 D：把“发现问题”和“决定怎么改”混为一谈。

一句话总结： 看到是 Observe，想清楚是 Reflect。

第 8 题　答案：A　基础

考查知识：统一向量空间与对齐（第 4 章）。

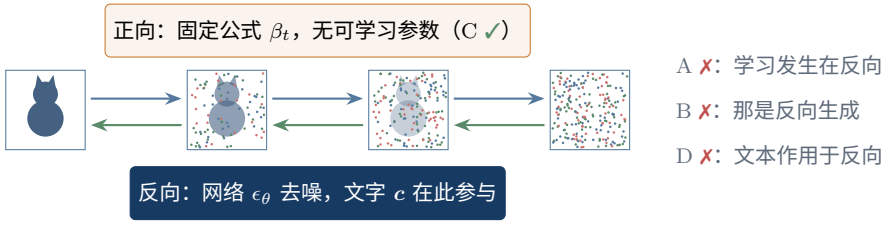


A 对：统一空间的意义就是“可比较”。B 错：相近 $\neq$ 相同（两个点不重合）。C 错：图片、语音都有各自的编码器。D 错：不对齐时同义的图文向量可能毫不相关（右下图）。

一句话总结：统一空间让它们能比，对齐让该近的真的近。

第 9 题　答案：C　基础

考查知识：正向扩散与反向生成的区别；原图纠错 ①。



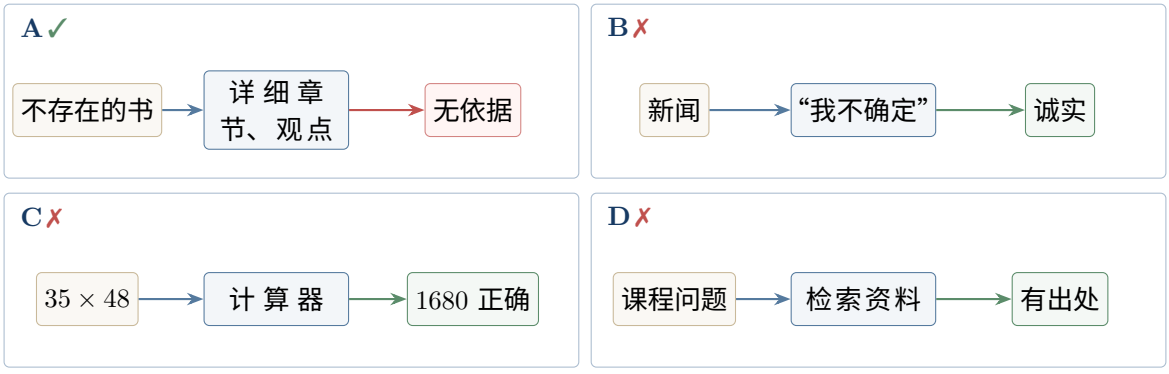
第 9 题解析图：上方蓝箭头为正向（固定），下方绿箭头为反向（学习、受文字控制）

常见错误：A 恰是课件第 20 页的原有写法，见原图纠错 ①。

一句话总结：加噪靠公式，去噪靠学习。

第 10 题　答案：A　基础

考查知识：幻觉的定义：看似合理但错误或无依据（第 6.2 节）。



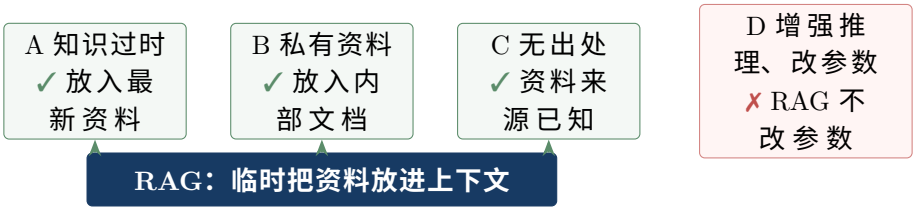
四幅图结构相同：问题 $\rightarrow$ 处理 $\rightarrow$ 结果。只有 A 的结果“没有依据”（红框）。B 承认不确定，恰恰是避免幻觉的好行为。

一句话总结：幻觉的关键词是“没有依据却说得很像”。

A-2　基础多选详细解析

第 11 题　答案：ABC　基础

考查知识：RAG 的动机（图 1.1）。



第 11 题解析图：RAG 只作用于“信息”，不作用于“参数与推理能力”

一句话总结：RAG 补的是资料，不是脑力。

第 12 题　答案：ABD　基础

考查知识：Harness 六大职责的边界（图 7.5）。

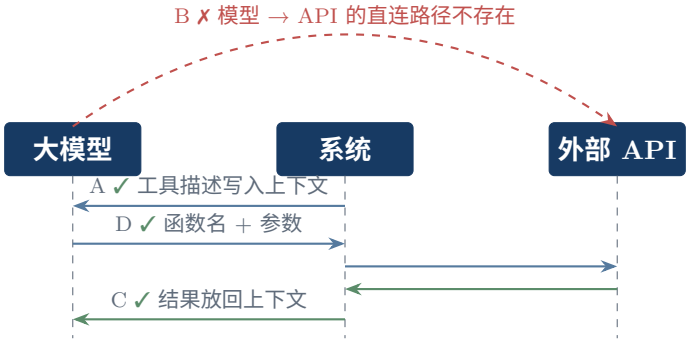


第 12 题解析图：C 属于“日志与评估”

一句话总结：护栏管“不能做什么”，日志管“做了什么”。

第 13 题　答案：ACD　基础

考查知识：Tool Calling 的工具描述与执行流程（图 2.2、2.3）。



第 13 题解析图：模型与 API 之间没有直接连线（红色虚线不存在）

一句话总结：模型知道工具（A）、写出调用（D）、读到结果（C），但从不亲自执行（B）。

第 14 题　答案：BCD　基础

考查知识：Agent = LLM + Harness 的分工（7.4 节）。



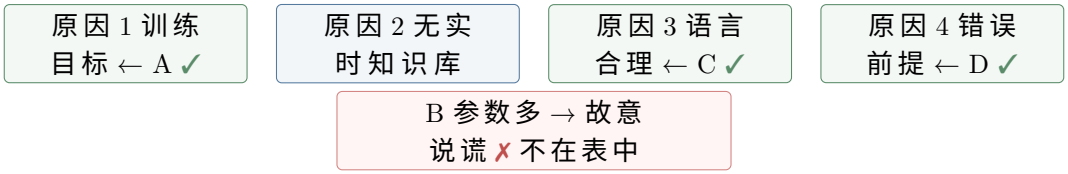
第 14 题解析图：A 是模型本身的工作，B、C、D 都在 Harness 中

一句话总结：“想下一个词”是模型，其余“管理”都是外壳。

第 15 题　答案：ACD　基础

考查知识：幻觉的四个原因（图 6.3）。

A、C、D 分别是课件第 25 页的原因 1、3、4。**B 错**在两处：参数多少不是课件给出的原因；“故意说谎”也不对——模型没有“明知是假还要说”的意图（易错点 1）。下图把四个选项放到“课件四个原因”表里对照：



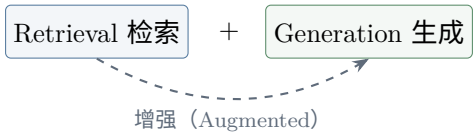
第 15 题解析图

A-3　基础填空详细解析

第 16 题　答案：生成（Generation）　基础

考查知识：RAG 的名称结构。

Retrieval = 检索，Augmented = 增强，Generation = 生成。“检索”增强了“生成”：先 Retrieval 再 Generation。可接受答案：生成、Generation、大模型生成。

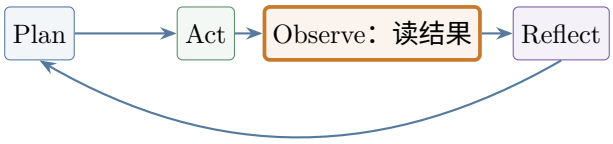


第 16 题解析图

第 17 题　答案：Observe（观察）　基础

考查知识：Agent 循环。

Act 执行工具之后，必须先**读取结果**（Observe），Reflect 才有依据判断“是否完成”。笔记“干完再检查”中的“检查”就从这一步开始。

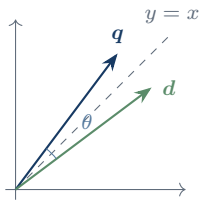


第 17 题解析图

第 18 题　答案：0.96　基础

考查知识：余弦相似度。

$\boldsymbol{q}\cdot\boldsymbol{d}=12+12=24$；$\|\boldsymbol{q}\|=\|\boldsymbol{d}\|=5$；$\cos\theta=24/25=0.96$。**检查：**两向量关于 $y=x$ 对称、夹角很小（约 16°），余弦接近 1，合理。可接受：$\frac{24}{25}$。

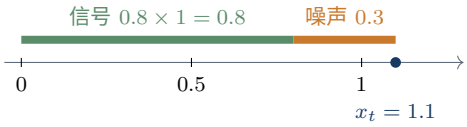


第 18 题解析图：对称于 $y=x$，夹角小

第 19 题　答案：0.8；1.1　基础

考查知识：正向一步到位公式。

信号系数 $\sqrt{0.64}=0.8$，噪声系数 $\sqrt{0.36}=0.6$；$x_t=0.8\times1+0.6\times0.5=0.8+0.3=1.1$。**检查：**$0.8^2+0.6^2=1$。**易错：**把 $\bar{\alpha}_t=0.64$ 直接当系数，算成 $0.64\times1+0.36\times0.5=0.82$。

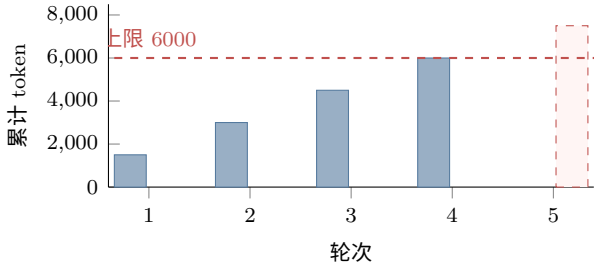


第 19 题解析图：x_t = 信号部分 + 噪声部分

第 20 题　答案：4　基础

考查知识：执行控制：成本上限。

$\lfloor 6000/1500\rfloor=4$。第 4 轮结束时累计 6000，恰好达到上限；第 5 轮会超过，被 Harness 拒绝。

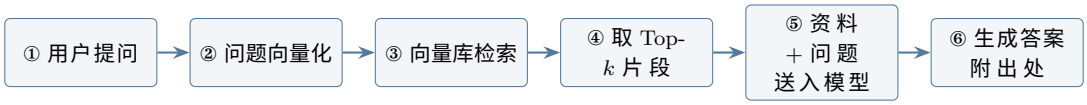


第 20 题解析图：第 5 轮（虚线柱）会超过上限

A-4　基础解答详细解析

第 21 题　答案：见下　基础

题意分析：写出顺序，并解释“同一 Embedding 模型”的理由。　**知识定位：**图 1.3；余弦相似度。



第 21 题解析图 1：六步填写结果

第二问：余弦相似度只在**同一个坐标系**里有意义。不同的 Embedding 模型会把同一句话映射到完全不同的方向（甚至维数都不同），就像用两套不同的基表示两个向量，再直接算内积，结果没有意义。



第 21 题解析图 2：不同模型的向量不在同一坐标系，相关文档也可能“看起来”方向很远

易错点：把 ③④ 合并或漏写“送入模型”。**同类题以后怎么做：**按“每步的输入从哪来”排序。

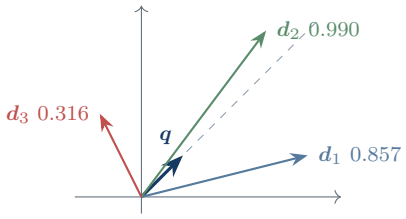
第 22 题　答案：$d_2 > d_1 > d_3$；Top-2 为 d_2, d_1　基础

已知：$\boldsymbol{q} = (1,1)$，$\|\boldsymbol{q}\| = \sqrt{2} \approx 1.414$。　**公式：**$\cos\theta = \dfrac{\boldsymbol{q}\cdot\boldsymbol{d}}{\|\boldsymbol{q}\|\|\boldsymbol{d}\|}$。

第一步：$\boldsymbol{q}\cdot\boldsymbol{d}_1 = 5$，$\|\boldsymbol{d}_1\| = \sqrt{17} \approx 4.123$，$\cos\theta_1 = \dfrac{5}{1.414 \times 4.123} \approx \dfrac{5}{5.831} \approx 0.857$。

第二步：$\boldsymbol{q}\cdot\boldsymbol{d}_2 = 7$，$\|\boldsymbol{d}_2\| = 5$，$\cos\theta_2 = \dfrac{7}{7.071} \approx 0.990$。

第三步：$\boldsymbol{q}\cdot\boldsymbol{d}_3 = 1$，$\|\boldsymbol{d}_3\| = \sqrt{5} \approx 2.236$，$\cos\theta_3 = \dfrac{1}{3.162} \approx 0.316$。



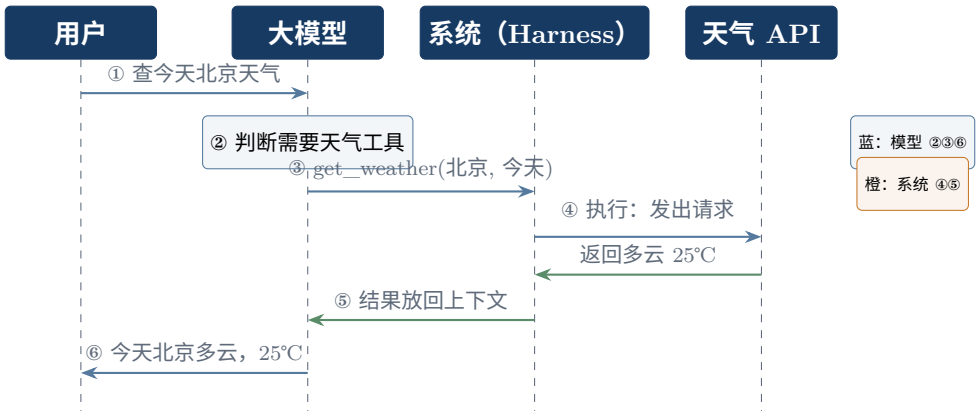
第 22 题解析图：虚线为 $\boldsymbol{q}$ 的方向

结果：$d_2 > d_1 > d_3$，Top-2 为 d_2、d_1。

检查：$\boldsymbol{d}_1$ 最长，但排第二——**长度不影响余弦**；右图中 $\boldsymbol{d}_2$ 与 $\boldsymbol{q}$ 夹角最小（约 8°），$\boldsymbol{d}_3$ 最大（约 72°）。

易错点：按长度或按内积大小排序（内积排序会得 $d_2 > d_1 > d_3$ 碰巧一致，但一般不可靠）。

第 23 题　答案：见下　基础



第 23 题解析图：六步时序与分工

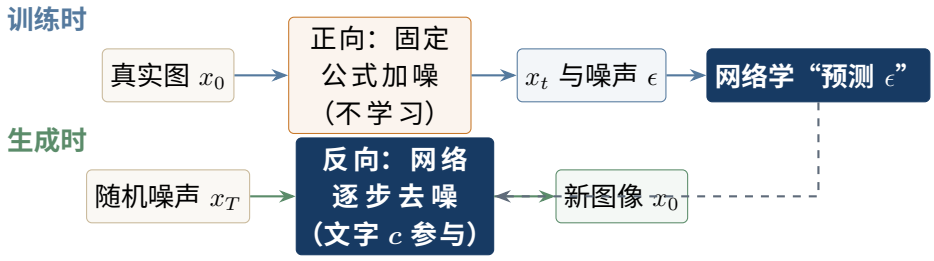
结果检查：每个参数都能在用户原话中找到（北京、今天），没有编造。**易错：**把 ④ 写在模型列。**同类题怎么做：**先画四条竖线，再按时间往下画箭头。

第 24 题　答案：见下　基础

问题	具体例子	负责防止的职责
状态混乱	重复处理同一个文件；忘记用户最初要求	状态管理
工具调用错误	参数格式错误；工具失败后不知道怎么办	工具管理、错误处理
安全风险	直接发送邮件；误删文件；泄露敏感信息	安全护栏
成本失控	无限循环；反复调用昂贵 API	执行控制
结果不可追踪	不知道为什么得到这个结果，无法复盘	日志与评估

对应关系见正文图 7.6。**易错：**把“成本失控”归到安全护栏。护栏中的“控制成本和权限”也相关，但**防止无限循环**的直接机制是执行控制的循环次数上限，两种答法都可接受，需说明理由。

第 25 题　答案：见下　基础



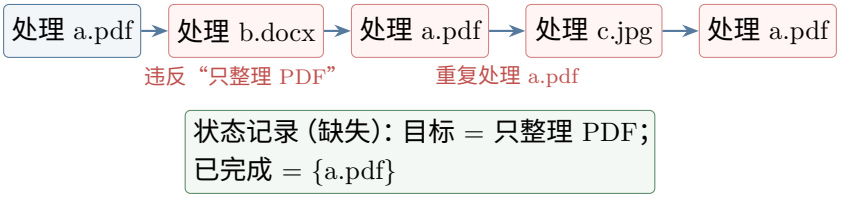
第 25 题解析图：训练时用正向造题，网络学答题；生成时只走反向

为什么“模型学习如何加噪”错：加噪按 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$ 直接算出，没有任何参数要学；网络学的是从 x_t 中**预测** ϵ，以便去噪（原图纠错 ①）。

B　提升题详细解析

第 26 题　答案：B　提升

考查知识： Harness 状态管理：记录目标、已完成步骤、避免重复执行。



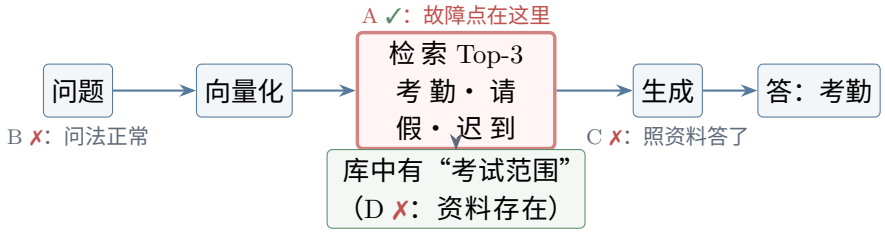
第 26 题解析图：红框都是“没有状态记录”导致的；绿框是本应存在的状态

A 错： 工具本身能用，调用格式也没错。**C 错：** 没有高风险操作。**D 错：** 日志能**事后发现**重复，但不能**事前避免**；避免重复的是状态管理。

一句话总结：“重复做、忘目标”是状态问题。

第 27 题　答案：A　提升

考查知识： RAG 的使用条件（1.3 节）：资料存在、能排进 Top-k、能放进窗口。



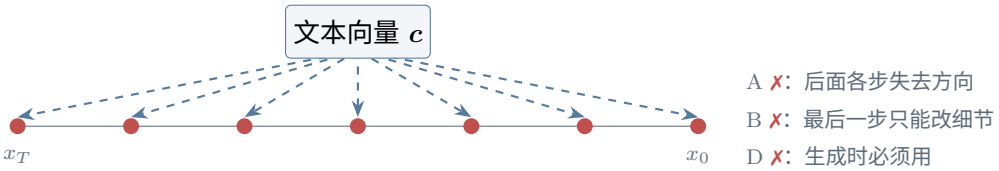
第 27 题解析图：沿流程逐段排查，只有检索段的输出与事实不符

模型“忠实地”按考勤资料作答，说明生成环节没坏；坏在检索没把正确片段排进来。改进：换更合适的 Embedding、调整切块、加入关键词检索（混合检索）。

一句话总结： 答非所问，先查检索。

第 28 题　答案：C　提升

考查知识： 文字条件 $\epsilon_\theta(x_t, t, \boldsymbol{c})$ 在每一步都输入（5.6 节）。

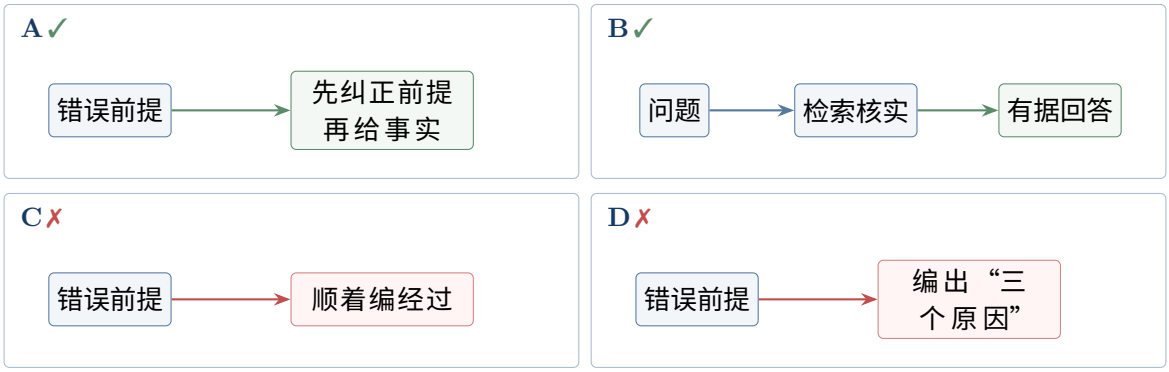


第 28 题解析图：每一步都从 $\boldsymbol{c}$ 接收方向（虚线）

一句话总结： 文字在每一步都“提醒”画什么。

第 29 题　答案：AB　提升

考查知识：幻觉原因 4：错误前提；缓解手段（图 6.5）。

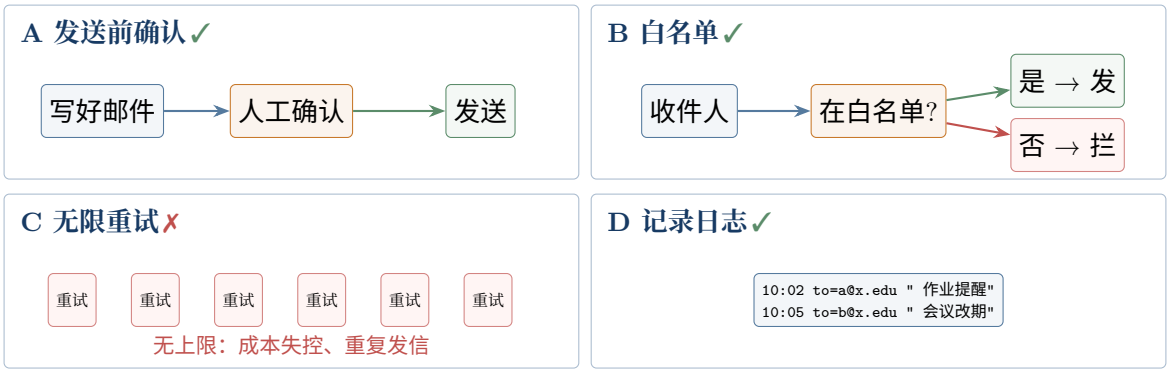


电话通常被认为由贝尔等人在 19 世纪 70 年代发明并取得专利；爱因斯坦以相对论等物理学工作闻名。C、D 都接受了错误前提，是课件原因 4 的典型幻觉。

一句话总结：先审题干，再答问题。

第 30 题　答案：ABD　提升

考查知识：安全护栏、错误处理、执行控制、日志（7.6 节、例题 7.1）。



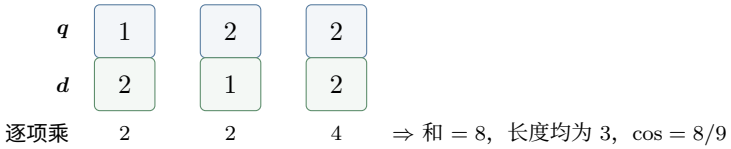
C 错：失败重试必须有上限，否则既浪费成本，又可能在“其实已发出、只是回执超时”的情况下重复发信。

一句话总结：能确认、能限制、能记录；重试要有上限。

第 31 题　答案：$\frac{8}{9}$　提升

考查知识：余弦相似度推广到三维。

$\boldsymbol{q}\cdot\boldsymbol{d}=1\cdot2+2\cdot1+2\cdot2=8$；$\|\boldsymbol{q}\|=\sqrt{1+4+4}=3$，$\|\boldsymbol{d}\|=3$；$\cos\theta=\dfrac{8}{9}\approx0.889$。



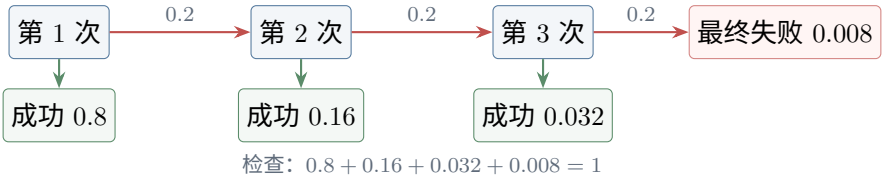
第 31 题解析图：维数增加，算法不变

常见错误：把长度算成 $1+2+2=5$（忘了平方再开方）。

第 32 题　答案：0.008　提升

考查知识：错误处理：重试；独立事件乘法。

三次都失败才算最终失败：$0.2 \times 0.2 \times 0.2 = 0.008$（0.8%）。对比：不重试时 20%。



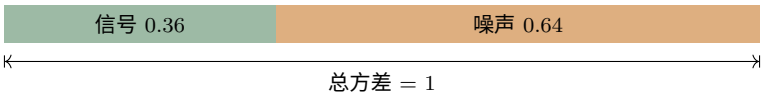
第 32 题解析图：红色路径概率相乘；各分支概率之和为 1

常见错误：算成 $3 \times 0.2 = 0.6$ 或 0.2^2（把“重试 2 次”当成“共 2 次”）。

第 33 题　答案：0.8；64%　提升

考查知识：信号 / 噪声方差分配。

$\sqrt{1 - 0.36} = 0.8$；噪声方差 $= 0.8^2 = 0.64$，信号方差 $= 0.36$，总方差 1，噪声占 64%。



第 33 题解析图

常见错误：把“系数 0.8”当成“比例 80%”——比例看的是系数的平方。

第 34 题　答案：见下　提升 · 综合

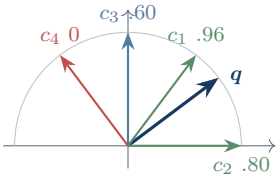
1. 题目在问什么：检索排序 → 上下文容量 → 资料质量。　**知识链：**余弦相似度 → Top-k → 上下文窗口 → RAG 的局限。

(1) 已归一化，余弦 = 内积：

$\boldsymbol{q} \cdot \boldsymbol{c}_1 = 0.48 + 0.48 = 0.96$；$\boldsymbol{q} \cdot \boldsymbol{c}_2 = 0.8$；

$\boldsymbol{q} \cdot \boldsymbol{c}_3 = 0.6$；$\boldsymbol{q} \cdot \boldsymbol{c}_4 = -0.48 + 0.48 = 0$。

排序：$c_1 > c_2 > c_3 > c_4$。



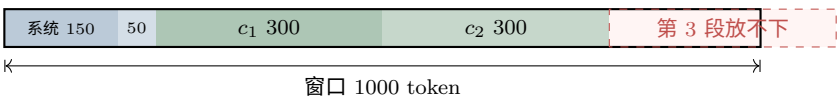
第 34 题解析图 1

(2) Top-2：$150 + 50 + 2 \times 300 = 800 \le 1000$。

最多片段数：$\lfloor (1000 - 200)/300 \rfloor = \lfloor 2.67 \rfloor = 2$。

为什么这样做：第 (1) 问先判断“单位向量”，省去除法；

第 (2) 问先扣除固定部分，再看剩余空间能放几块。



第 34 题解析图 2：800 token 已用，剩余 200 放不下第 3 段

(3) 余弦相似度只看话题，不看新旧，旧课件会以 0.96 排第一并被模型当作依据，答案可能与本学期内容不符（易错点“相似度高 ≠ 资料正确”）。改进：① 建库时给片段加“学期 / 日期”标签并按时间过滤；② 及时删除或替换过时文档；③ 让回答附上出处，便于人工核对。（任两条即可）

合理性检查：c_4 与 $\boldsymbol{q}$ 正交，相似度 0，“考勤规定”与“总结 Transformer”无关，合理。　**最容易卡在哪里：**(2) 忘了扣除系统提示与问题。　**变式思考：**若窗口扩大到 2000 token，最多能放几段？（6 段，但只有 4 段可用，且 c_4 无关，不该放。）

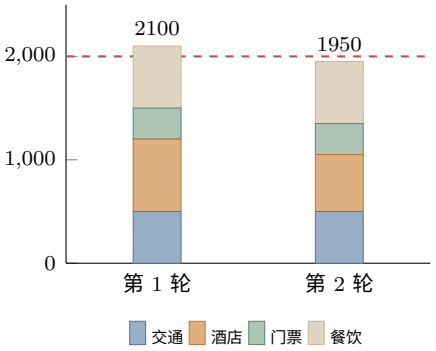
第 35 题　答案：见下　提升 · 综合

知识链： Agent 循环 → 预算计算 → 执行控制 → 安全护栏。

(1) 第 1 轮 Plan：查交通、酒店、门票，估算预算。Act：调用查询工具。Observe：
$500 + 700 + 300 + 2 \times 300 = 2100$ 元。
Reflect：$2100 > 2000$，超 100 元，未完成。

(2) 第 2 轮关键变化：换酒店乙。
$500 + 550 + 300 + 600 = 1950$ 元 ≤ 2000，满足，结束。

(3) 上限 $10000/2000 = 5$ 轮；实际 2 轮，消耗 $2 \times 2000 = 4000$ token。



第 35 题解析图 1：红虚线为预算

(4) 支付涉及资金，不可逆，属于高风险操作。Harness 应：① 安全护栏——暂停并请求用户确认（显示金额、商户）；② 权限控制——Agent 默认不持有支付权限，或仅能使用限额；③ 日志——记录这一步的金额、时间与确认人。模型不应自行完成支付。



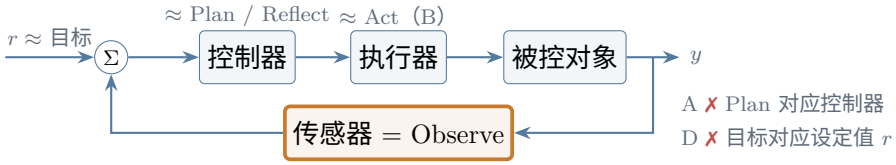
第 35 题解析图 2：高风险操作的处理流程

最容易卡在哪里： 餐饮漏乘 2 天。　**变式思考：** 若酒店乙也要 650 元，总价 2050 仍超支，Agent 下一轮可以考虑什么？（减少收费景点或换更便宜的交通；若已达上限 5 轮仍不满足，应停止并告知用户。）

C　跨学科迁移题详细解析

第 36 题　答案：C　跨学科 · 自动控制

当前专题知识： Agent 循环四阶段。　**借用的外部情境：** 自动控制中的闭环系统。　**为什么不算超纲：** 题干已给出“传感器测量输出 y，用于计算误差”的全部必要信息，不需要会分析传递函数。　**迁移点：**“测量执行后的结果”= Observe。

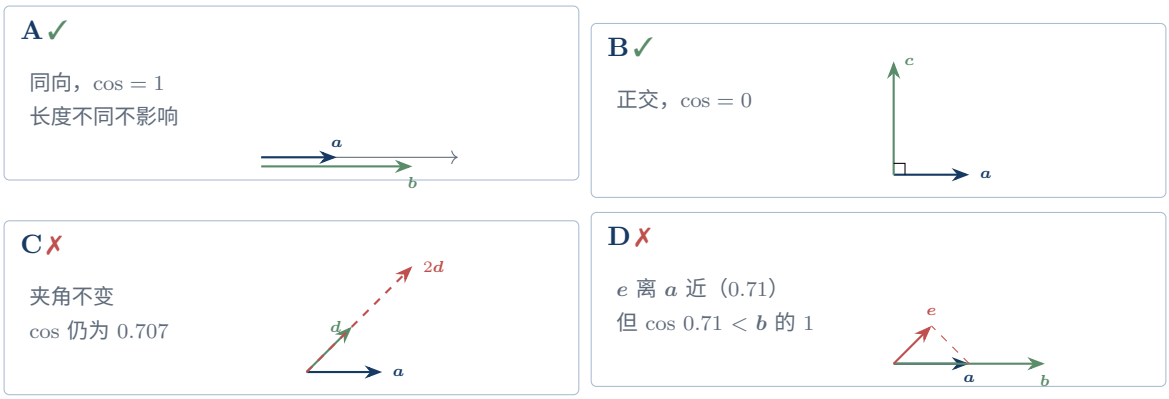


第 36 题解析图：两套闭环的逐块对应

一句话总结： 测量结果的环节，就是观察。

第 37 题　答案：AB　跨学科 · 线性代数

当前专题知识：余弦相似度的性质（1.4 节推论）。　**借用的情境：**线性代数中的向量长度、正交、欧氏距离——均为已学内容。　**迁移点：**检索打分 = 两向量夹角的余弦。



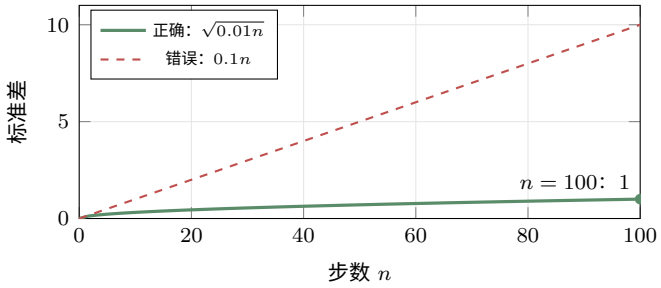
A 对：$\cos(\boldsymbol{a},\boldsymbol{b})=\frac{2}{1\times 2}=1$。**B 对：**$\boldsymbol{a}\cdot\boldsymbol{c}=0$。**C 错：**$\cos(\boldsymbol{a},2\boldsymbol{d})=\frac{2}{1\times 2\sqrt{2}}=\frac{\sqrt{2}}{2}$，与 $\cos(\boldsymbol{a},\boldsymbol{d})$ 相同——缩放不改变夹角。**D 错：**反例：$\|\boldsymbol{a}-\boldsymbol{e}\|=\sqrt{0.5}\approx 0.71<\|\boldsymbol{a}-\boldsymbol{b}\|=1$，但 $\cos(\boldsymbol{a},\boldsymbol{e})\approx 0.71<\cos(\boldsymbol{a},\boldsymbol{b})=1$。只有在**单位向量**下二者才等价（1.4 节推论）。

一句话总结：余弦看方向；距离看位置；归一化后二者一致。

第 38 题　答案：1　跨学科 · 大学物理 / 概率

当前专题知识：Diffusion 推导中“独立正态之和方差相加”（5.3 节）。　**外部情境：**布朗运动 / 随机游走。　**为什么不算超纲：**方差相加规则与标准差定义已在题干给出。　**迁移点：**与 5.8 节对照完全一致。

计算：总方差 $=100\times 0.01=1$，标准差 $=\sqrt{1}=1$。**常见错误：**把标准差也直接相加（每步标准差 0.1，$100\times 0.1=10$）——方差相加，标准差不相加。



第 38 题解析图：标准差按 $\sqrt{n}$ 增长，而不是按 n 增长

一句话总结：独立随机量：方差相加，标准差开方。

参考资料

原始教学依据

[1]《机器学习与人工智能》第四节课件《Agent 与 Harness》（36 页）。
[2] 2026 年 10 月 11 日课堂手写笔记（Memo No. 514–516）。

核心定义与公式核验

[3] Lewis P., et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020. arXiv:2005.11401.
[4] Yao S., et al. ReAct: Synergizing Reasoning and Acting in Language Models. arXiv:2210.03629 (2022); ICLR 2023.

[5] Ho J., Jain A., Abbeel P. Denoising Diffusion Probabilistic Models. NeurIPS 2020. arXiv:2006.11239.
[6] Sohl-Dickstein J., et al. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. ICML 2015.
[7] Ho J., Salimans T. Classifier-Free Diffusion Guidance. arXiv:2207.12598 (2022).
[8] Rombach R., et al. High-Resolution Image Synthesis with Latent Diffusion Models. CVPR 2022.
[9] Radford A., et al. Learning Transferable Visual Models From Natural Language Supervision (CLIP). arXiv:2103.00020 (2021).
[10] Dosovitskiy A., et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR 2021.
[11] Kalai A. T., Nachum O., Vempala S. S., Zhang E. Why Language Models Hallucinate. arXiv:2509.04664 (2025).

工程实践与工具核验

[12] Anthropic Engineering. Effective harnesses for long-running agents. 2025-11-26. https://www.anthropic.com/engineering/effective-harnesses-for-long-running-agents
[13] Böckeler B. Harness engineering for coding agent users. martinfowler.com, 2026. https://martinfowler.com/articles/harness-engineering.html
[14] Wikipedia: Agent harness（用于术语沿革的交叉核对）. https://en.wikipedia.org/wiki/Agent_harness
[15] CC Switch 开源项目主页（MIT 许可）. https://github.com/farion1231/cc-switch
[16] Model Context Protocol 官方文档(Anthropic 于 2024-11-25 发布该协议). https://modelcontextprotocol.io

学科史

[17] Weizenbaum J. ELIZA—A Computer Program for the Study of Natural Language Communication between Man and Machine. Communications of the ACM, 1966.
[18] Vaswani A., et al. Attention Is All You Need. NeurIPS 2017.
[19] Schick T., et al. Toolformer: Language Models Can Teach Themselves to Use Tools. arXiv:2302.04761 (2023).

本讲义的边界说明

- 正文中的数值示意（token 概率、相似度矩阵、预算、token 消耗等）为教学构造，用于演示计算，不代表某个真实系统的测量结果。
- “Harness”一词在业界尚无统一的标准定义与组件表；本讲义以课件为准，并给出统一写法供理解。
- 课堂笔记中与课程知识无关的上网工具、账号共享等内容未收录。