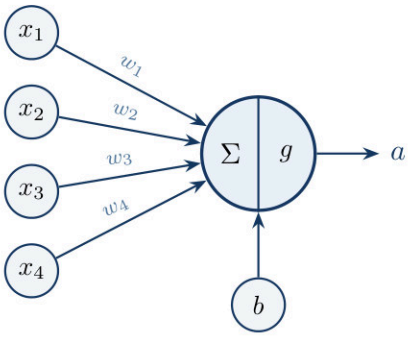
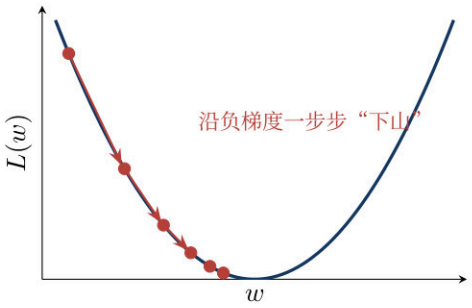
AI 发展脉络与机器学习入门

从 M--P 神经元到梯度下降：数据 · 模型 · 目标函数 · 优化算法





适用对象	第一次接触人工智能 / 机器学习、线性代数与微积分基础尚不牢固的本科生
内容来源	357–362）
本讲结构	AI 发展脉络 → 机器学习是什么 → 数据 → 模型（神经元）→ 目标函数 → 优化算法（梯度下降 / Adam / 反向传播）
配套练习	38 道：25 道基础巩固 + 10 道中等偏下提升 + 3 道跨学科迁移，答案与图解集中在书末

编排：XeLaTeX · 版本：2026 年 9 月

阅读说明

这份讲义是对课堂课件和手写笔记的**教学重构**，不是逐页转写。阅读时请留意下面几种标记：

标记	含义
原始资料	能从课件 / 笔记中可靠识别的内容（原始资料重编码）。
教学补全	课件没有写出、但为了让初学者真正看懂而补充的定义、条件、推导、证明、例子（已按标准教材核验）。
蓝色框	核心定义、核心公式、重要结论——必须掌握。
米色框	例题、学科小史、科普应用。
红色框	易错点、原图纠错。
绿色框	方法总结、学习自检。

建议阅读顺序：第 1 章可以当作“故事”快速读完；第 2–6 章是本讲真正要掌握的知识，请配合图形逐段读；每章末的“学习自检”能回答了，再去做书末的 38 道练习。

数学准备：只需要高中函数与导数、向量的加法和数量积。偏导数与链式法则会在用到的地方就地补全（第 6 章“前置速补”）。

目　录

阅读说明 i

本讲总览：我们要回答什么问题? 1

原始资料识别与重编码说明 2

1　AI 发展脉络 3

1.1　五个阶段的总时间轴 . . . 3
1.2　阶段①：萌芽——能不能用数学描述“一个神经元”？ . . . 3
1.3　阶段②：给学科起名字，以及“规则 vs. 学习”的分岔 . . . 4
1.4　阶段③：深度学习爆发（2006–2016） . . . 4
1.5　阶段④：Transformer 与大模型（2017–2021） . . . 5
1.6　阶段⑤：生成式 AI 与智能体（2022–今） . . . 5
1.7　原图纠错：历史部分 . . . 7

2　机器学习是什么 9

2.1　问题引入：为什么我们需要机器学习 . . . 9
2.2　正式定义 . . . 10
2.3　AI、机器学习、深度学习的关系 . . . 10
2.4　机器学习的四要素：用“学做题”来理解 . . . 11

3 数据 12

3.1 样本、特征与标签 12
3.2 数据需要数学表示：向量、矩阵、张量 13
3.3 图像怎样变成数字 14
3.4 特征空间与距离：“相似”也能被计算 15
3.5 数据的质量比数量更重要 16
3.6 训练集、验证集、测试集 16

4 模型与神经元 17

4.1 模型是一种映射 17
4.2 最简单的模型：线性模型（“拉一条线”） 18
4.3 M–P 神经元：1943 年的“细胞” 18
4.4 现代神经元：线性变换 + 非线性激活 19
4.5 为什么必须有非线性激活? 20
4.6 从一个神经元到神经网络：层与“深度” 21
4.7 常见模型家族与“模型是训练出来的” 22

5 目标函数与损失函数 23

5.1 从“学习的目的”到目标函数 23
5.2 回归任务：均方误差（MSE） 24
5.3 分类任务：交叉熵损失 24
5.4 损失低 $\neq$ 学得好：泛化与过拟合 25
5.5 如何防止过拟合 26

6 优化算法 27

6.1 前置速补：偏导数、梯度、链式法则 27
6.2 一维梯度下降：沿着“下坡方向”走一步 28
6.3 多维情况：梯度向量及其几何意义 29
6.4 学习率：走多远才合适 30
6.5 梯度下降不是完美的：局部最小值与鞍点 31
6.6 三种梯度下降：一次用多少数据算梯度 31
6.7 Adam：会“记方向”又会“看地形”的梯度下降 32
6.8 反向传播：成千上万个参数的梯度怎么算 33

7 总结与联系 34

7.1 本讲知识地图 35

7.2 相近概念总对比 35
7.3 高频易错点总表 36
7.4 基础解题步骤总结 36
7.5 从课本到现实：这些知识到底用在哪里 36
7.6 后续课程连接 37

正式练习（38 道） 38

答案速查 49

详细解析 · A. 基础巩固 50

详细解析 · B. 中等偏下提升 58

详细解析 · C. 跨学科迁移 63

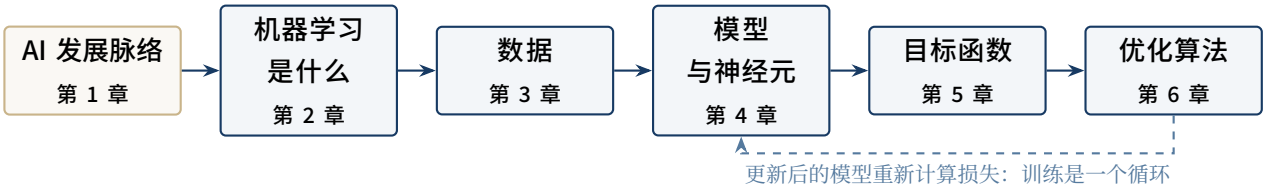
参考资料 65

本讲总览：我们要回答什么问题?

课堂上，老师先用 60 多页幻灯片“速通”了人工智能从 1943 年到今天的发展，然后用第二份课件讲了**机器学习的四个要素**。这两部分看起来一个是“历史”、一个是“技术”，其实是同一条线索：

> **一句话主线**　人工智能想让机器“像人一样做判断”。早期人们试图**手写规则**，后来发现规则写不完，于是转向**让机器从数据中自己学规律**——这就是机器学习。机器学习的全部工作可以拆成四件事：**准备数据、选择模型、定义“什么叫好”（目标函数）、用算法把模型调好（优化）**。今天所有的大模型、智能体，本质上都还是这四件事做到了极大规模。

本讲知识路线



学完本讲，你应当能够

1. 说出 AI 发展中 8–10 个关键节点，并说清“为什么从规则走向学习、从浅层走向深层、从判别走向生成”；
2. 解释机器学习的定义，以及 AI、机器学习、深度学习三者的包含关系；
3. 把一张图片、一个商品、一个学生写成向量 / 矩阵 / 张量，并算出数据集的形状；
4. 手算一个神经元的输出（加权和 + 激活函数），并说明为什么必须有**非线性**激活；
5. 手算均方误差（MSE）和二分类交叉熵，识别过拟合曲线，说明早停与数据增强的作用；
6. 手算梯度下降的若干步，说明学习率过大 / 过小的后果，区分 BGD、SGD、小批量，读懂 Adam 公式；
7. 用链式法则完成一个极小网络的反向传播。

前置知识地图

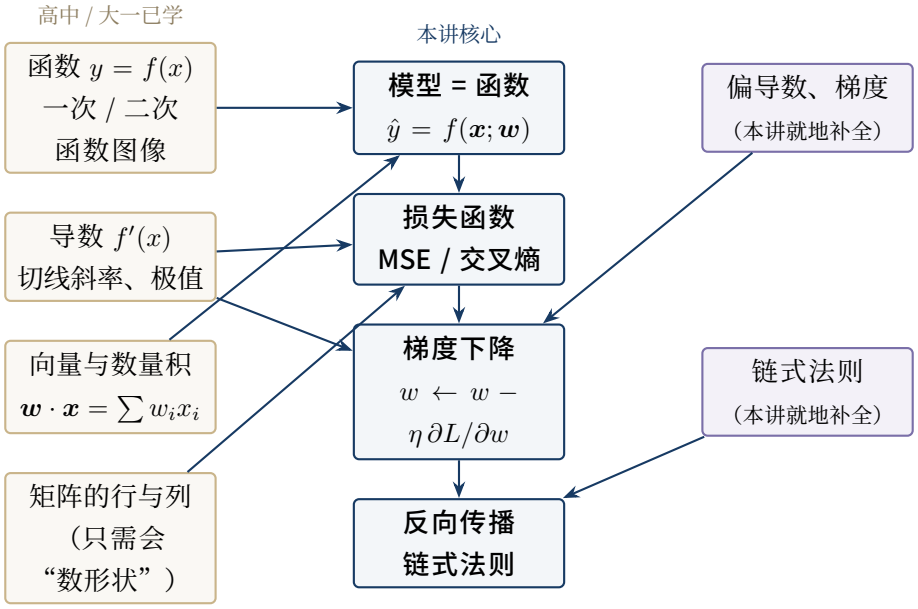


图 0.1　前置知识（米色）→ 本讲核心（蓝色）；紫色为本讲顺带补全的微积分工具

原始资料识别与重编码说明

本讲义依据三份材料：课件 A《第一节 神经网络入门》（58 页，下称“入门课件”）、课件 B《第一节 AI 发展速通》（62 页，下称“速通课件”）、手写笔记 Memo 357–362（2026 年 9 月 18–19 日）。

材料	可靠识别的核心内容	本讲义对应位置
速通课件 + 笔记 357–359	1943 M–P 模型、1950 图灵测试、跳棋程序、1956 达特茅斯会议、1959 机器学习……直到 2026 年的 Fable 5、GPT-6 Astra，共 47 个节点	第 1 章（按主题重组，并核验日期）
入门课件 p.3–16 + 笔记 360	为什么需要机器学习；定义；“做题”类比：训练集、模型、目标 / 损失函数、优化算法	第 2 章
入门课件 p.17–28 + 笔记 360	样本、特征、标签、独立同分布；向量 / 矩阵 / 张量表示；灰度、二值、RGB 图像；数据质量；数据偏见	第 3 章
入门课件 p.29–38 + 笔记 361	训练 / 验证 / 测试集；模型是映射；神经元 = 线性变换 + 非线性激活；ReLU；深度	第 3.6 节、第 4 章
入门课件 p.39–46 + 笔记 361	目标函数与损失函数；MSE；交叉熵；过拟合与泛化；早停；数据增强	第 5 章
入门课件 p.47–58 + 笔记 361–362	梯度下降；梯度的几何意义；学习率；BGD / SGD / 小批量；Adam；反向传播	第 6 章

无法可靠辨认 / 不收录的内容

· 笔记 359 页第 42 条红笔补充“如今已经不 vibe-coding，直接语音交 → AI 对话口

> 罩”：“语音交”后一字与“口罩”二字笔迹潦草，**原始资料此处无法可靠辨认**。可能解释：老师在说“现在人们直接用语音与 AI 交互”，属于课堂即兴评论，不影响知识主线。（以上属于推测，不属于原图可靠识别结果。）
> · 笔记 359 页“二、如何自搭机场”（VPS、sing-box、Trojan / VLESS 等网络代理协议）与人工智能课程知识无关，本讲义不收录。
> · 速通课件中的人物照片、产品截图、新闻截图属于课堂展示素材，本讲义只提取其中的**事实信息**，不复制图片。

第 1 章　AI 发展脉络：机器是怎样一步步“学会判断”的

本章回答三个问题：(1) 人工智能为什么会从“手写规则”走向“从数据中学习”？(2) 深度学习为什么在 2012 年前后突然爆发？(3) 从 ChatGPT 到智能体（Agent），这几年到底变的是什么？

本章知识路线： 神经元模型 → 规则与符号 → 机器学习 → 深度学习 → Transformer 与大模型 → 多模态 / 推理 / 智能体。

课堂上这一部分列了 47 个时间节点。如果把它们当成 47 个孤立事件去背，既记不住也没有意义。下面把它们按“**人们遇到了什么问题 → 用什么办法解决 → 又留下什么新问题**”重新组织成五个阶段。

1.1　五个阶段的总时间轴



图 1.1　AI 发展五阶段时间轴（节点位置为示意，不按比例）

1.2　阶段①：萌芽——能不能用数学描述“一个神经元”？

原始资料　1943 年，神经生理学家沃伦·麦卡洛克（W. McCulloch）与数学家沃尔特·皮茨（W. Pitts）发表了一个极简的神经元数学模型，后人称为 **M--P 模型**。笔记中记下的公式是

$$f = x_1 w_1 + x_2 w_2 + \cdots + x_i w_i + \cdots + x_n w_n - \theta, \tag{1}$$

其中 x_i 是**特征**（输入），w_i 是**权重**，θ 是**阈值**。当 $f \geq 0$ 时神经元输出 1（“激活”），否则输出 0。速通课件用“西瓜 / 香蕉”举例：颜色、纹理、形状等特征各乘一个权重再相加，减去阈值后经过一个阶跃函数，输出 1 表示西瓜、0 表示香蕉。这个模型会在第 4 章被完整展开——它就是今天所有神经网络的“细胞”。

1950 年，艾伦·图灵在论文《计算机器与智能》（Computing Machinery and Intelligence）中提出“模仿游戏”，即**图灵测试**：提问者隔着屏幕与一台机器和一个人对话，如果无法可靠分辨

哪个是机器，就可以认为机器表现出了智能。它把“机器能否思考”这个哲学问题变成了一个可以操作的测试。

1.3 阶段②：给学科起名字，以及“规则 vs. 学习”的分岔

- **1956 年达特茅斯会议**：约翰·麦卡锡（J. McCarthy）等人召集的夏季研讨会，“Artificial Intelligence”一词在会议提案（1955 年）中首次使用，这次会议通常被视为 AI 作为独立学科诞生的标志。
- **跳棋程序与“机器学习”一词**：IBM 的阿瑟·塞缪尔（A. Samuel）自 20 世纪 50 年代起开发会“越下越好”的西洋跳棋（checkers）程序，并在 1959 年的论文中使用了 machine learning 这一说法。笔记中将这一节点记为“1959 年：机器学习（实现人工智能的方法）”，下分深度学习、强化学习。
- **1966 年 ELIZA**：MIT 的约瑟夫·魏泽鲍姆（J. Weizenbaum）发表的聊天程序，模仿心理咨询师，用**关键词匹配 + 预设模板**回复。笔记把它概括为“If–else”——这很好地说明了**规则式 AI** 的样子：看起来会聊天，实际上没有从数据中学到任何东西。
- **1965 年“智能爆炸”担忧**：数学家 I. J. 古德（I. J. Good）在 1965 年的文章中设想“超智能机器”可能自我改进、超过人类，这是 AI 风险讨论的早期源头之一。课件由此一直延伸到 2023–2026 年的 AI 安全事件（公开信、安全承诺、国际 AI 安全报告等）。
- **1989 年 ALVINN**：卡内基梅隆大学 D. Pomerleau 用一个只有一层隐藏层（29 个隐藏单元）的神经网络，把 30×32 的道路图像映射为方向盘转向，是**早期用神经网络实现自动驾驶**的代表性工作。
- **1989 年 Python**：Guido van Rossum 在 1989 年圣诞假期开始设计 Python（1991 年首次公开发布）。它今天是机器学习最常用的编程语言。

> **这一阶段留下的问题**　规则式系统（ELIZA、专家系统）遇到了“规则写不完”的墙：什么样的动物一定是猫？有胡须、会喵喵叫、有尾巴……但总有例外（卡通猫、只露半张脸的猫）。而早期神经网络又太浅、数据太少、算力太弱。**于是问题变成：怎样让模型更深、数据更多、训练更快？**

1.4 阶段③：深度学习爆发（2006--2016）

- **2006 年**：杰弗里·辛顿（G. Hinton）等人发表“深度信念网络”的逐层预训练方法，使训练多层网络重新变得可行，笔记记为“深度学习元年”。
- **ImageNet**：李飞飞团队约 2006–2007 年启动、2009 年发表的大规模标注图像数据集（1400 多万张图片）；2010 年起举办 ILSVRC 图像识别挑战赛。它说明了**数据**的重要性。笔记还记下了李飞飞团队近期关于“世界模型”的文章 From Words to Worlds。
- **2012 年 AlexNet**：多伦多大学团队的深度卷积神经网络（5 个卷积层 + 3 个全连接层，使用 ReLU、Dropout 和 GPU 训练）在 ILSVRC-2012 中取得 15.3% 的 top-5 错误率，远低于第二名的 26.2%。这是深度学习在计算机视觉中“出圈”的标志。
- **2014 年 GAN**：伊恩·古德费洛（I. Goodfellow）等人提出**生成对抗网络**：生成器负责“造假”，判别器负责“打假”，二者对抗训练。它让神经网络从“判别”（这是什么）走向“生

成”（造一个新的）。

- **2016 年 AlphaGo**：DeepMind 的 AlphaGo 在 2016 年 3 月以 4:1 战胜李世石；2017 年 5 月以 3:0 战胜柯洁。它把深度神经网络与强化学习、蒙特卡洛树搜索结合在一起。

1.5 阶段④：Transformer 与大模型（2017--2021）

- **2017 年 Transformer**：谷歌团队论文 Attention Is All You Need 提出完全基于**注意力机制**的 Transformer 架构，不再依赖循环网络。它像给模型装上“全局阅读能力”：处理一个词时可以同时看整句话里所有词，并决定哪些词最相关；同时便于并行计算。
- **2018 年 BERT**：只用 Transformer 编码器，通过“完形填空”（掩码语言模型）和“下一句预测”预训练，擅长**语义理解**。
- **2019 年 GPT-2**：论文 Language Models are Unsupervised Multitask Learners。训练目标只有一个——**根据前文预测下一个词**（笔记：“续写 → 预测”）。
- **2020 年 GPT-3**：1750 亿参数，论文 Language Models are Few-Shot Learners。只需在提示词里给几个例子，就能完成翻译、问答等任务。笔记记为“算力多 → 神经元多 → 展现出未要求过的能力”，即所谓**涌现**。

> **如何看待“涌现”与“理解世界”**　笔记中红笔写道：“但现在已经开始理解世界：被需求逼迫”。这是课堂上的**观点性评论**。学术界对“大模型能力是否真的突然涌现”“语言模型是否理解世界”仍有争论（例如有研究指出部分“涌现”与评价指标的选择有关）。学习时把它当作一个开放问题，而不是定论。

1.6 阶段⑤：生成式 AI 与智能体（2022--今）

2022 年 11 月 30 日 ChatGPT 发布后，大模型产品密集出现。下表把课件和笔记中的节点整理为一张速查表（日期按北京时间或官方发布日，个别为“开放 / 公测”日期）。

时间	节点	它带来了什么（一句话）
2022.11.30	ChatGPT（GPT-3.5）	用自然语言即可使用 AI，大众第一次感到“通用性”
2023.2.20	MOSS（复旦大学）	国内早期对话大模型，宣布开源
2023.3.14–16	ChatGLM-6B / GPT-4 / Midjourney V5 / 文心一言	开源中文对话模型、更强的多能力模型、高质量文生图、百度对话模型
2023.3.20–24	Runway Gen-2 / ChatGPT 插件与联网	文生视频雏形；大模型开始调用外部工具
2023.4–5	通义千问、讯飞星火、Microsoft Copilot	大模型进入企业服务与办公软件
2023.7–10	Claude 2、盘古 3.0、Llama 2、妙鸭相机、豆包、混元、Kimi	长上下文、行业模型、开源模型、AI 写真等应用爆发
2023.12.6	Gemini	原生多模态模型
2024.5	GPT-4o	实时处理文本、图像、语音的多模态模型
2024.9	OpenAI o1	**推理模型**：回答前先生成较长的中间推理过程
2024.11	MCP（Anthropic）	连接 AI 与外部工具 / 数据的开放协议，常被比作“USB-C 接口”
2024.12	Sora 正式开放	文生视频（2024 年 2 月首次公布）
2025.1	DeepSeek-R1	以较低训练成本达到强推理能力的开源推理模型
2025	具身智能（VLA 模型）、Seedance、Nano Banana 等	把视觉 + 语言转化为机器人动作；视频 / 图像生成继续进步
2025.2	Vibe coding（A. Karpathy）	用自然语言描述需求、让 AI 写代码、人负责判断效果
2025–2026	智能体（Agent）：OpenClaw、Codex、Hermes、Claude Code 等；Skills	AI 从“回答问题”走向“规划并执行任务”
2026.6.9	Claude Fable 5 / Mythos 5	Anthropic 发布的新一代模型（Fable 5 面向公众）
2026.9	GPT-6 Astra	OpenAI 新一代模型

智能体（Agent）到底新在哪里？　课件把 Agent 定义为“能自主**思考 + 计划 + 执行任务**的 AI”，由五个部件组成：语言模型（理解与生成）、计划模块（拆解任务）、工具接口（API / MCP）、执行器（打开网页、写代码、发邮件）、记忆（上下文）。和单纯聊天相比，它形成了一个“**感知 → 决策 → 行动 → 观察结果 → 再决策**”的闭环——这与控制学科中的**反馈控制**思想非常相似。

教学补全：Skills 是什么　笔记写“Skills：就是提示词，很复杂的提示词（markdown）”。更准确地说：一个 Skill 通常是一**个文件夹**，核心是一份 Markdown 格式的说明文件（告诉模型在什么情况下、按什么步骤做事），还可以附带脚本、模板、参考资料；智能体在需要时

> 才加载它。所以“复杂的提示词”抓住了本质，但 Skill 还可以包含可执行的代码和资源。

1.7　原图纠错：历史部分

下列问题在核验后发现，与后文知识无冲突，但会影响你对历史的准确记忆。

原图纠错 1　NASA Deep Space One 的年份

原始写法：速通课件与笔记均写“1985 年 NASA 在一次航天任务中使用了名为 Deep Space One 的人工智能系统，这是历史上第一个在航天领域应用人工智能技术”。

存在的问题：深空一号（Deep Space 1）是 NASA 于 **1998 年 10 月**发射的技术验证探测器，而不是一个 AI 系统的名字；其上的 AI 自主控制软件叫 **Remote Agent**，于 **1999 年 5 月**完成在轨实验。“历史上第一个”的说法也过强。

规范写法：1999 年，NASA 深空一号探测器上的 Remote Agent 软件在轨实验中自主规划并控制航天器，是 AI 自主控制航天器的里程碑。

是否影响后续：不影响。

原图纠错 2　其它需要修正或补充的历史表述

原始写法	规范写法 / 说明
ChatGPT“22 年 11 月 20 日”	应为 **2022 年 11 月 30 日**。
AlphaGo 页：“2016……3:0 击败柯洁”	2016 年 3 月是 **4:1 胜李世石**；**3:0 胜柯洁是 2017 年 5 月**。“AlphaZero 30 小时”一项未能在可靠来源中核实到该具体数字，本讲义不采用。
笔记“Alaph Go”	笔误，应为 **AlphaGo**。
ALVINN“第一套无人驾驶系统”	过强。更早已有德国 Dickmanns 团队的 VaMoRs、CMU 的 Navlab 等自动驾驶车辆；ALVINN 是**早期基于神经网络**的代表。
“1956 年 McCarthy 首次提出 AI”	“Artificial Intelligence”一词首次出现在 **1955 年**的会议提案中，1956 年会议召开。二者不矛盾，但要区分“提出”与“开会”。
跳棋程序标为“1950”	塞缪尔的跳棋程序始于 20 世纪 50 年代初（常见说法为 1952 年起在 IBM 701 上开发），1959 年发表论文。“1950”只能理解为“50 年代”。
ImageNet 标为“2006”	项目约 2006–2007 年启动，数据集 **2009 年**正式发表，挑战赛 2010 年开始。
“辛顿提出深度学习概念”	“深度学习”一词更早已出现。辛顿 2006 年的贡献是让深层网络**重新可以有效训练**。
LLaMA 页：“23 年 7 月 13 日”，配图为 Llama 3	LLaMA（第一代）2023 年 2 月发布；**Llama 2 于 2023 年 7 月 18 日**发布；Llama 3 为 2024 年 4 月。配图与日期不对应。
GPT-3 页示例标为“GPT-2 自主输出”	页面讲的是 GPT-3 的少样本能力，标签应为 GPT-3。
Sora 标为“2024 年 12 月”	2024 年 2 月首次公布，2024 年 12 月正式向用户开放。
Fable 5“2026.6.11”（笔记）	Anthropic 官方公告日期为 **2026 年 6 月 9 日**（美国时间），北京时间 6 月 10 日；6 月 11 日是所截新闻的发布日期。
ELIZA“只有两百行代码”	未能在可靠来源中核实该数字，本讲义不采用。课件截图实为后来 Emacs 编辑器中的 `doctor` 仿制版，并非 1966 年原版界面。
Transformer“（前馈神经网络）”	Transformer 的核心是**注意力机制**，每层内部包含前馈子层；它不含循环结构，但不宜直接称为“前馈神经网络”这一类别。

学科小史：一句话串起 80 年

1943 用数学描述神经元 → **1950s** 提出“机器能思考吗”并给学科命名 → **1960s–80s** 规则式系统看似聪明、却写不完规则 → **1959 起**“让机器从经验中学习”逐渐成为主流 → **2006–2012** 数据（ImageNet）+ 算力（GPU）+ 算法（深层网络、ReLU）三者同时成熟，深度学习爆发 → **2017** Transformer 让模型能“同时看全局”并大规模并行训练 → **2020** 以后规模带来新能力，AI 从判别走向生成 → **2024** 以后从“会聊天”走向“会推理、会用工具、会行动”。

为什么今天仍要学最基础的神经元和梯度下降？因为无论模型多大，训练它的仍然是本讲第 3–6 章的四个要素。

到这里，我们已经解决了什么？下一步还需要解决什么？

我们知道了 AI 的主线是“从手写规则走向从数据中学习”。但“从数据中学习”具体是什么意思？学到的东西存放在哪里？怎样判断学得好不好？下一章先把“机器学习”这个词拆开。

第 2 章　机器学习是什么：从“写规则”到“学规律”

本章回答三个问题：(1) 已经会编程了，为什么还需要机器学习？(2) 机器学习的正式定义是什么？它和 AI、深度学习是什么关系？(3) “学习”具体由哪几个零件组成？

本章知识路线： 规则写不完 → 从数据中学习 → 定义（T, E, P）→ AI ⊃ ML ⊃ DL → 四要素与训练循环。

2.1　问题引入：为什么我们需要机器学习

原始资料　入门课件用三个程序开场：

- 写一个电商程序，实现商品展示和购物车——**但如何识别用户的偏好并精准推荐？**
- 写一个相册，收集用户的照片——**但如何自动把照片分成人物 / 风景 / 猫？**
- 写一个客服程序，按关键词回复预设内容——**但遇到超出范围的问题怎么办？**

前半句都是“传统编程”能做的：程序员知道规则，把规则写成代码。后半句的共同点是：**人类可以毫不费力地做出判断，却讲不清其中的准确计算逻辑**。看到一张照片，我们一眼就知道是猫还是狗；听到语气就能感到对方是开心还是生气；看到乌云和降温就觉得可能要下雨；看到价格、评价、销量就能判断值不值得买。

试着为“猫”写规则：“有胡须、会喵喵叫、有尾巴、耳朵尖尖的”。立刻就会遇到反例——只露半张脸的猫看不到尾巴，卡通猫没有胡须，照片里的猫不会叫，而狗也有尾巴和胡须。**规则很难写死**，这正是机器学习要解决的问题。



图 2.1　传统编程：规则 + 数据 → 答案；机器学习：数据 + 答案 → 规则（模型）

图 2.1 的关键是箭头方向变了：传统编程中“规则”是输入；机器学习中“规则”变成了**输出**——它是算法从大量“题目 + 答案”中总结出来的。

2.2　正式定义

定义　机器学习（Machine Learning, ML）

原始资料　机器学习是一类**可以从经验中学习**的技术：让计算机从数据中自动学习规律，并基于这些规律进行预测或决策，而**无需明确编程所有规则**。

教学补全　**教材常用的形式化定义**（T. Mitchell, 1997）：对于某类任务 T 和性能度量 P，如果一个计算机程序在 T 上以 P 衡量的性能随着经验 E 而提高，就称这个程序从经验 E 中学习。

为什么要这样定义？　这个定义要求同时说清三件事：**做什么**（任务 T，如“判断照片是不是猫”）、**凭什么学**（经验 E，如“一万张标好‘猫 / 不是猫’的照片”）、**怎么算学会了**（性能 P，如“在新照片上的正确率”）。缺了 P，就无法判断“是否提高”；缺了 E，就不是“学习”而是“写死”。第 3、5 章会分别把 E（数据）和 P（目标函数）展开。

正例：垃圾邮件过滤器。T = 判断邮件是否垃圾；E = 用户标记过的大量邮件；P = 分类正确率。用户标记得越多，过滤越准——性能随经验提高，**是**机器学习。

反例：ELIZA 式的关键词客服。回复规则全部由程序员预先写好，和它“聊”一万次也不会变得更好——性能不随经验提高，**不是**机器学习（尽管它可能被称为一种 AI）。

原始资料　课件强调“生活中处处是 ML，只是你很少感知”：语音识别（Siri）、手机人脸解锁、输入法智能联想、B 站 / 淘宝 / 抖音推荐、音乐 App 歌单、导航软件估计到达时间、相册自动分类。

2.3　AI、机器学习、深度学习的关系

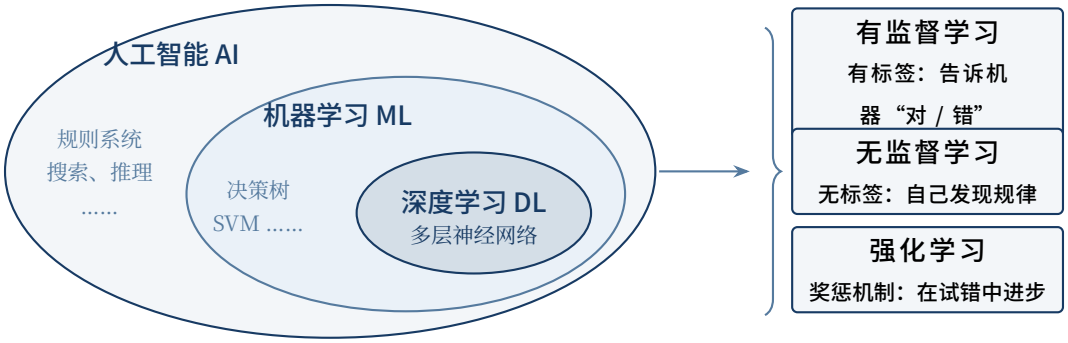


图 2.2　AI ⊃ 机器学习 ⊃ 深度学习；机器学习按“反馈信号”分为三大范式

原始资料　速通课件的“1959 机器学习”页给出：AI 是让机器模拟人类智能的广泛领域；ML 是 AI 的核心实现方式；DL 是 ML 的子集，使用多层神经网络。笔记补充：深度学习 = 神经网络层数多。三种学习范式的对比如下。

	有监督学习	无监督学习	强化学习
数据	特征 $\boldsymbol{x}$ + 标签 y	只有特征 $\boldsymbol{x}$	状态、动作、奖励
目标	学会从 $\boldsymbol{x}$ 预测 y	发现分组、结构	学会让长期奖励最大的策略
典型例子	猫狗识别、房价预测	用户分群、异常检测	下棋（AlphaGo）、机器人控制
本讲重点	**是**（第 3–6 章均以此为例）	了解	了解

易错提醒　**“深度学习 = 人工智能”是常见误解。**深度学习只是 AI 中的一个子集。例如 ELIZA、专家系统、路径搜索算法都属于 AI，但都不是机器学习；决策树、支持向量机属于机器学习，但不是深度学习。

2.4　机器学习的四要素：用“学做题”来理解

原始资料　课件问：“如何实现机器学习？很简单，思考下你自己是怎么学习的。”以解一元二次方程 $x^2 + 5x + 6 = 0$ 为例：

机器学习要素	你学做题时的对应物（课件）	机器里是什么
训练数据集	你刷过的很多题，每道题就是一个训练样本	一组（特征，标签）对 $\{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}$
模型 Model	脑子里总结出的解题套路：“二次项系数是 1，可以用因式分解”	带参数的函数 $\hat{y} = f(\boldsymbol{x}; \boldsymbol{w})$
目标 / 损失函数	衡量对错的标准：100 道题错 10 道；每错一道扣一分	一个数 $L(\boldsymbol{w})$，越小越好
优化算法	看解析、发现老看错负号、提醒自己注意；根公式不熟就反复背	按规则修改参数 $\boldsymbol{w}$ 使 L 变小

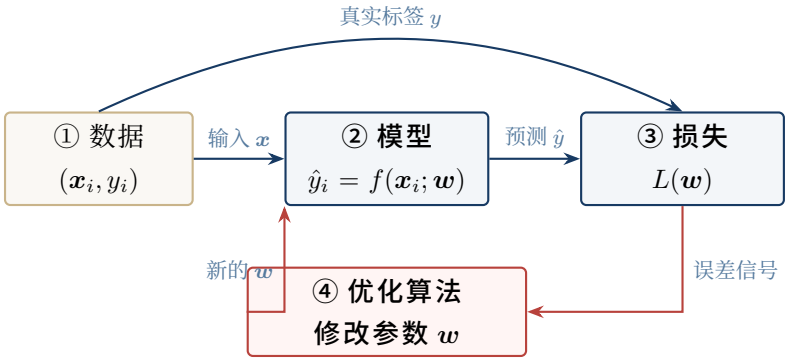


图 2.3　训练循环：数据进入模型得到预测，损失函数给出“错多少”，优化算法据此调整参数，然后重复

易错提醒

1. **模型不是数据。**训练结束后，真正被保存下来的是模型的**参数**（权重），而不是把所有题目背下来。如果模型只是“背答案”，就会出现第 5 章的**过拟合**。
2. **目标函数与损失函数不完全相同。**目标函数是“要优化的那个量”的统称（可能要最大

> 化，如正确率、奖励）；损失函数专指“预测与真实之间的偏差”，总是要最小化。本讲的训练中，目标就是让损失最小，因此两者经常混用。

学完这里，你应该能够回答

1. 为什么“识别猫”很难用 if-else 写出来?
2. 用 T、E、P 描述“导航软件预测到达时间”这一任务。
3. 画出 AI、ML、DL 的包含关系，各举一个“是 AI 但不是 ML”的例子。
4. 四要素分别是什么？训练循环中哪一个环节负责“改参数”？

到这里，我们已经解决了什么？我们知道了机器学习由四个零件组成。**下一步：**第一个零件“数据”到底长什么样？计算机只认识数字，一张照片、一段话、一个人是怎样变成数字的?

第 3 章　数据：机器学习的“燃料”

本章回答三个问题：(1) 什么是样本、特征、标签？(2) 图片、商品、学生怎样变成向量、矩阵、张量？数据集的“形状”怎么数？(3) 为什么说“数据的质量比数量更重要”？数据集为什么要分成训练、验证、测试三份?

3.1　样本、特征与标签

定义　样本 / 特征 / 标签 / 数据集

原始资料

- **样本**（example, sample，又叫数据点、数据实例）：一个个体，例如一张图片、一段文字、一位病人、一次交易记录。
- **特征**（feature）：机器用来“做判断”的输入，例如身高、年龄、图像像素，记为 $\boldsymbol{x}$。
- **标签**（label）：我们希望机器“预测”的结果（目标），例如房价、是否患病、图像是猫还是狗，记为 y。
- **数据集**（dataset）：多个样本组成的集合 $\{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_n, y_n)\}$。

数据就是一组样本所具有的**特征与结果**。

样本	身高/cm	体重/kg	年龄	是否近视
学生 1	170	60	18	是
学生 2	165	55	17	否
学生 3	180	75	19	是
学生 4	172	68	18	否

← 一行 = 一个样本

特征 $\boldsymbol{x}$（3 维）　　标签 y

图 3.1　一张表就是一个数据集：行是样本，蓝框列是特征，红框列是标签（示例数据）

> **特征与标签由“任务”决定，不由“数据本身”决定**　同一列数据，在不同任务里角色不同：若任务是“根据身高、年龄预测体重”，体重就是标签；若任务是“预测是否近视”，体重就成了特征。判断方法只有一句话：**要预测的是标签，拿来预测的是特征**。

原始资料　课件提到数据通常“遵循独立同分布（i.i.d.）”，并注明“（非必要）”。教学补全 它的含义是：

- **独立**：一个样本的出现不影响另一个样本（抽第 1 位学生不会改变第 2 位学生的身高）；
- **同分布**：所有样本都来自同一个“总体”（都是同一所学校、同一时期的学生）。

它之所以重要，是因为训练集和测试集若来自同一分布，“在训练数据上学到的规律”才有理由在新数据上成立。课件写“非必要”，是指现实数据常常不严格满足它（例如股价的相邻两天明显相关），很多方法仍能使用，但此时要格外警惕 3.5 节的**样本偏差**。

3.2　数据需要数学表示：向量、矩阵、张量

计算机只能处理数字，所以每个样本都要写成一串数。原始资料 一个学生有 3 个特征：身高 170、体重 60、年龄 18，就写成一个 3 维向量

$$\boldsymbol{x} = [170,\ 60,\ 18].$$

4 个学生的特征向量按行堆起来，就是一个矩阵：

$$X = \begin{bmatrix} 170 & 60 & 18 \\ 165 & 55 & 17 \\ 180 & 75 & 19 \\ 172 & 68 & 18 \end{bmatrix} \begin{array}{l} \leftarrow \text{第 1 个样本的特征向量} \\ \leftarrow \text{第 2 个样本} \\ \leftarrow \text{第 3 个样本} \\ \leftarrow \text{第 4 个样本} \end{array}$$

核心公式　数据集的形状

当每个样本的特征数量一致时，数据集构成一个固定维度（dimensionality）的矩阵：

$$\boxed{\text{数据集形状} = \text{样本数} \times \text{特征维度} = n \times d}$$

行数 n = 样本个数，列数 d = 每个样本的特征个数。上例 X 的形状是 4×3。

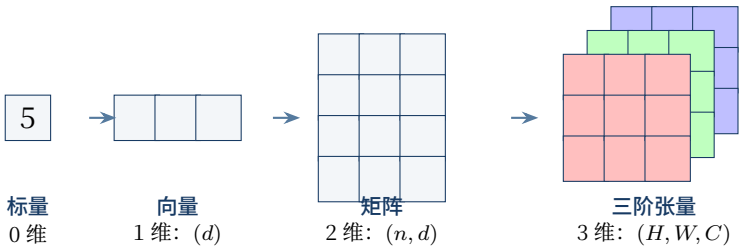


图 3.2　标量 → 向量 → 矩阵 → 张量：维度（轴的个数）逐级增加

笔记总结为：数学表示①矩阵（线性代数）②张量（计算机中的多维数组）。**张量**可以理解为“多维数组”：向量是 1 维张量，矩阵是 2 维张量，彩色图片是 3 维张量，一批彩色图片是 4 维张量 (N, H, W, C)。

3.3　图像怎样变成数字

灰度（黑白）图像：一个矩阵

把照片分成很多小方格（像素），每个像素记录一个亮度值。常见的 8 位灰度图用**0--255** 的整数表示：**0 = 黑色，255 = 白色**。一张 $H \times W$ 的灰度图就是一个 $H \times W$ 的矩阵。



图 3.3　灰度值与亮度的对应关系

> **为什么是 0--255?**　一个字节（byte）有 8 个二进制位，能表示 $2^8 = 256$ 种不同的值，即 $0 \sim 255$。这样存储一个像素恰好占 1 字节，既够人眼分辨，又节省空间。这也是 C/C++ 中常用 `unsigned char` 存像素的原因。

二值图像：只有 0 和 1

原始资料　课件用手写数字“5”说明：把图像放到网格里，黑色像素记为 1，白色记为 0。下图是本讲义重新绘制的 8×8 例子，左边网格和右边矩阵逐格对应。

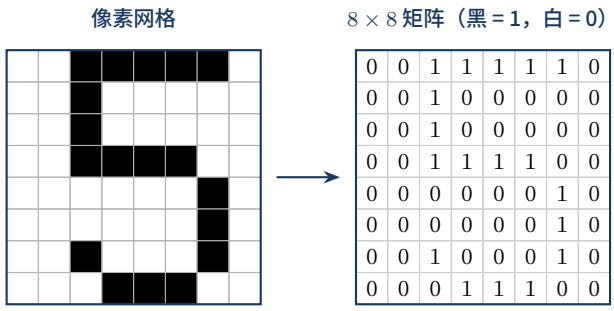


图 3.4　二值图像的矩阵存储（本讲义重绘，网格与矩阵逐格一致）

彩色图像：三个通道叠成张量

彩色图片的每个像素由红（R）、绿（G）、蓝（B）三个分量组成，每个分量同样是 0–255。例如某像素为 $[R, G, B] = [120, 200, 90]$，是偏绿的颜色。整张图拆成 R、G、B 三个矩阵，叠在一起就是形状为 $H \times W \times 3$ 的三维张量。

核心公式　图像的数值个数

灰度图：$H \times W$ 个数　　彩色图：$\boxed{H \times W \times 3}$ 个数

例题 3.1　数一数图片里有多少个数

题目：一张 28×28 的灰度手写数字图片、一张 32×32 的 RGB 彩色图片，各由多少个数值组成？若把前者“拉平”成一个向量，维度是多少？

思路： 灰度图每像素 1 个数，彩色图每像素 3 个数。
计算： $28 \times 28 = 784$；$32 \times 32 \times 3 = 3072$。拉平后的向量维度为 784。
检查： $784 = 28^2$ 正是著名的 MNIST 手写数字数据集的输入维度。
本题想说明： “维度”就是描述一个样本所用的数的个数。图片虽小，维度却很高——这正是后面需要神经网络逐层“提炼”特征的原因。

原图纠错 3　课件“图像被转化为数字类型”示例矩阵中出现 260

原始写法： 入门课件第 19 页，猫图下方的矩阵含有元素 260，同时标注灰度范围 0–255。
存在的问题： 8 位像素值不可能超过 255，260 超出取值范围。
规范写法： 应为 0–255 之间的整数（例如 255 或 250）。
为什么这样改： 1 字节最多表示 256 个值。　**是否影响后续：** 不影响，示意图性质。另外，课件第 24 页数字“5”的像素网格与右侧 0/1 矩阵并不逐格一致（仅为示意），本讲义图 3.4 已重绘为一致版本。

3.4　特征空间与距离：“相似”也能被计算

一旦每个样本都是一个向量，就可以把它看作特征空间中的一个**点**。原始资料 课件用两个特征描述水果：$\boldsymbol{x} = [\text{重量}, \text{甜度}]$。

水果	重量 / g	甜度
苹果	180	7
香蕉	120	9
西瓜	3000	8
柠檬	100	2

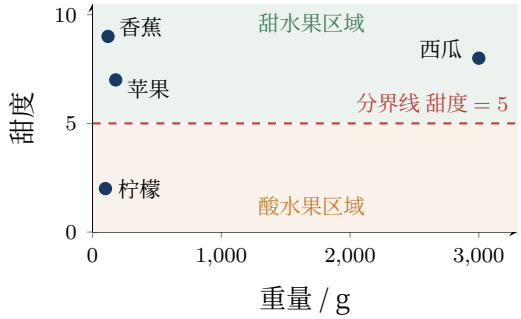


图 3.5　每种水果是特征平面上的一个点；一条分界线就把平面分成两个“类别区域”

图 3.5 说明了两件事：(1) **分类**就是在特征空间中画分界线（甜度 $= 5$ 以上是“甜水果”）；(2) 距离近的点“更相似”。模型要学的，正是这条分界线的位置和方向。

原始资料　课件的“淘宝商品推荐”例子：$\boldsymbol{x} = [\text{价格}, \text{评分}, \text{销量}, \text{收藏数}, \text{评论数}]$，

$$A = [99, 4.8, 12000, 3500, 860], \quad B = [109, 4.7, 11800, 3300, 820], \quad C = [9999, 4.2, 300, 50, 12].$$

结论是“A 和 B 距离近，A 和 C 距离远；用户喜欢 A，就推荐空间中离 A 最近的商品”。

核心公式　欧氏距离 教学补全

两个 d 维向量 $\boldsymbol{p} = (p_1, \ldots, p_d)$ 与 $\boldsymbol{q} = (q_1, \ldots, q_d)$ 的欧氏距离为

$$d(\boldsymbol{p}, \boldsymbol{q}) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_d - q_d)^2} = \sqrt{\sum_{k=1}^{d} (p_k - q_k)^2}$$

$d = 2$ 时它就是平面上两点间的距离（勾股定理）；$d > 2$ 时是同一公式的自然推广。

代入可得 $d(A,B) = \sqrt{10^2 + 0.1^2 + 200^2 + 200^2 + 40^2} \approx 285.8$，$d(A,C) \approx 15733$，课件结论成立。但请注意：在 $d(A,B)^2 \approx 81701$ 中，评分差 $0.1^2 = 0.01$ 只占约一千万分之一——**评分几乎没有起作用**，距离完全被销量、收藏数这些“数值大”的特征决定。

教学补全：特征缩放（归一化）　不同特征的单位和数量级不同时，直接算距离会让“数值大”的特征说了算。常用**最小--最大归一化**把每个特征压到 $[0,1]$：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

对 A、B、C 三件商品逐个特征归一化后，$d(A,B) \approx 0.18$，$d(A,C) \approx 2.24$，结论不变，但此时**每个特征都能按比例发挥作用**。练习第 28 题会看到一个“不缩放就得出错误结论”的例子。

3.5　数据的质量比数量更重要

原始资料　“Garbage in, garbage out”（垃圾进，垃圾出）。课件列出三类问题：

问题	后果	课件例子
标签错误	模型会学错	手势识别模型的训练数据中混入大量“猫爪”图片
特征冗余或无意义	增加训练难度	训练专属“唤醒词”，输入的却全是 60 秒长语音
样本偏差	模型只适用于少数情况	用大量杭州天气数据训练，去预测哈尔滨明天的天气

数据并不客观　原始资料　数据不代表现实世界的全部。如果数据只记录了“过去的策略”“片面的历史经验”，模型就可能**强化旧偏见**。例如用过去 20 年中国投资机构的回报数据给用户推荐“最佳投资策略”——过去的市场环境不会简单重复。笔记红笔总结：**数据不客观，反映人类数据的偏见和历史的偏见性。**

3.6　训练集、验证集、测试集

原始资料　数据的收集、预处理、使用、验证、测试是一个庞大的学科体系，统称“数据科学”（Data Science）。在机器学习中，数据集常被分为三份（笔记记录的比例为 70% / 10% / 20%）：

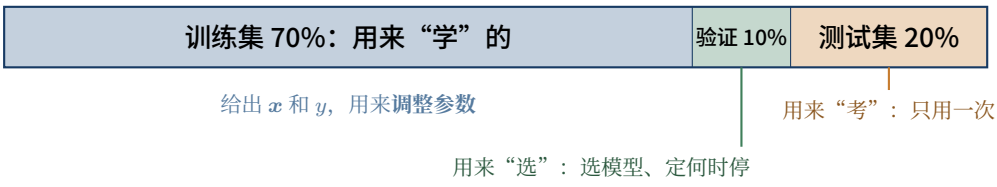


图 3.6　数据集划分：训练集“学”、验证集“选”、测试集“考”

定义　三种数据集

- **训练集**：模型用来“学”的——计算损失、更新参数，得到模型。
- **验证集**：模型用来“选”的——比较不同模型、不同超参数（如学习率、训练轮数），决定选哪一个。
- **测试集**：模型用来“考”的——在全部选择完成后评估最终性能。课件强调：**期末题不能被泄露**。

笔记中两处容易误读的写法

1. 笔记写“训练集：用来学的（生成模型：X 与 Y 都给）”。这里的“生成模型”意思是“**得到**一个模型”，不是第 1 章 GAN 那种“生成式模型”（generative model），不要混淆。
2. 笔记写“验证集：给 X 看 Y 能不能对上”“测试集：只给 X 让它猜 Y”。实际上两者在计算时**都只把 x 输入模型，再把输出与 y 比较**；区别不在“给不给 y”，而在**用途**：验证集的结果会被用来做决定，测试集的结果不能再被用来修改模型，否则它就变成了“泄露的期末题”。

学完这里，你应该能够回答

1. 在“根据面积、楼层预测房价”中，特征和标签分别是什么？
2. 500 个样本、每个 12 个特征，数据矩阵是几行几列？
3. 64×64 的 RGB 图片有多少个数值？为什么像素值不超过 255？
4. 为什么计算商品距离前常要做特征缩放？
5. 能不能用测试集来决定训练多少轮？为什么？

到这里，我们已经解决了什么？数据已经被变成了向量和矩阵。**下一步：**拿到向量 $\boldsymbol{x}$ 之后，用什么“公式”把它变成预测 $\hat{y}$？这个公式就是**模型**。

第 4 章　模型：从一条直线到一个神经网络

本章回答三个问题：(1) “模型”在数学上到底是什么？(2) 一个神经元怎样计算？M–P 模型和今天的神经元有什么关系？(3) 为什么神经网络必须有**非线性激活函数**？为什么要“深”？

本章知识路线： 模型 = 映射 → 线性模型 → M–P 神经元 → 线性变换 + 激活 → 非线性的必要性（证明）→ 多层网络 → 参数是训练出来的。

4.1　模型是一种映射

原始资料　课件问：如果你有 1000 天的股价数据，想预测第 1001 天的价格，你靠什么判断？——靠你头脑中总结的规律，这就是你心里的模型。

定义 模型（Model）

原始资料　模型是机器学习中用于**将输入数据映射到输出结果**的数学结构或计算规则；模型的本质是从输入到输出的一种转换关系（映射）。

教学补全　用数学符号写作

$$\hat{y} = f(\boldsymbol{x};\, \boldsymbol{w}),$$

其中 $\boldsymbol{x}$ 是输入特征，$\hat{y}$（读作“y hat”）是模型的**预测值**，$\boldsymbol{w}$ 是模型的**参数**（权重、偏置等）。分号表示：$\boldsymbol{x}$ 是“题目”，$\boldsymbol{w}$ 是“套路里可调的旋钮”。

例子（课件）：图像输入 → 情绪输出；传感器读数 → 正常 / 异常。模型可以很简单（线性），也可以非常复杂（神经网络）。

4.2 最简单的模型：线性模型（“拉一条线”）

原始资料　课件例子：“中国人幸福吗？”输入 10 万个样本，每个样本 56 个维度和一个标签；输出：幸福指数 = 参数 1 × 维度 1 + 参数 2 × 维度 2 + ... + 偏置量。这就是用“拉一条线”来拟合数据。

核心公式 线性模型

$$\hat{y} = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + b = \sum_{i=1}^{d} w_i x_i + b = \boldsymbol{w} \cdot \boldsymbol{x} + b$$

x_i	第 i 个特征（“维度 i”）　　w_i：第 i 个特征的权重（“参数 i”），表示该特征有多重要、朝哪个方向起作用
b	偏置（bias，“偏置量”）：所有特征都为 0 时的输出，使直线不必过原点
$\boldsymbol{w} \cdot \boldsymbol{x}$	向量的数量积（内积）$= \sum_i w_i x_i$

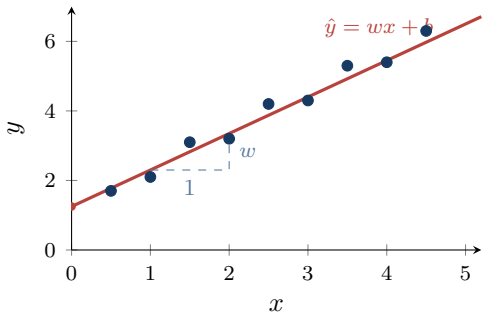


图 4.1　一维线性模型：斜率 w 决定倾斜程度，截距 b 决定上下位置；“训练”就是找最贴合数据点的那条线

4.3 M--P 神经元：1943 年的“细胞”

原始资料　回到第 1 章的公式 (1)。M–P 模型把生物神经元抽象为：多个输入（树突）→ 加权求和 → 与阈值比较 → 输出 0 或 1（轴突是否发放信号）。

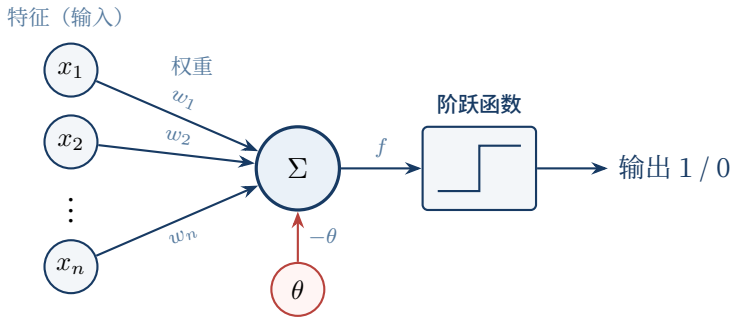


图 4.2　M–P 神经元：加权求和减去阈值，再经阶跃函数输出 1（激活）或 0

推导：阈值 θ 与偏置 b 是同一个东西 教学补全　M–P 模型写 $f = \sum w_i x_i - \theta$，速通课件的神经元图写 $y = g(\sum w_i x_i + b)$。令

$$b = -\theta,$$

则 $\sum w_i x_i - \theta = \sum w_i x_i + b$，两式完全相同。输出 1 的条件 $\sum w_i x_i - \theta \geq 0$ 等价于 $\sum w_i x_i \geq \theta$：**加权和“超过门槛”才激活**。所以“阈值”是从生物学角度的叫法，“偏置”是从直线截距角度的叫法。

例题 4.1　M--P 神经元判断西瓜

已知：三个特征 x_1 = 是否绿色条纹、x_2 = 是否个头很大、x_3 = 是否弯曲（是 = 1，否 = 0）；权重 $w = (0.6,\ 0.6,\ -1.0)$，阈值 $\theta = 1.0$。输入一个“绿色条纹、个头大、不弯曲”的水果 $\boldsymbol{x} = (1, 1, 0)$。

求：输出是 1（西瓜）还是 0（不是西瓜）？

第一步（加权和）： $0.6 \times 1 + 0.6 \times 1 + (-1.0) \times 0 = 1.2$。

第二步（减阈值）： $f = 1.2 - 1.0 = 0.2 \geq 0$。　**结果：**输出 1，判为西瓜。

检查：若换成香蕉 $\boldsymbol{x} = (0, 0, 1)$，$f = -1.0 - 1.0 = -2.0 < 0$，输出 0。

本题想说明：权重的**正负**表示特征是“支持”还是“反对”该结论（弯曲 $w_3 < 0$ 反对“西瓜”）；权重的**大小**表示影响有多强。

4.4　现代神经元：线性变换 + 非线性激活

原始资料　课件：在神经网络中，每个神经元的计算过程分为两步。

核心公式 神经元的两步计算

① 线性变换：　$z = \boldsymbol{w} \cdot \boldsymbol{x} + b$　　② 非线性激活：　$a = \text{activation}(z)$

输入 → 加权和 → 激活函数 → 输出

M–P 神经元是其特例：激活函数取阶跃函数。今天最常用的激活函数是 **ReLU**（笔记：$\text{ReLU}(x) = \max(0, x)$）。为了第 5 章的分类问题，这里一并补全 Sigmoid。

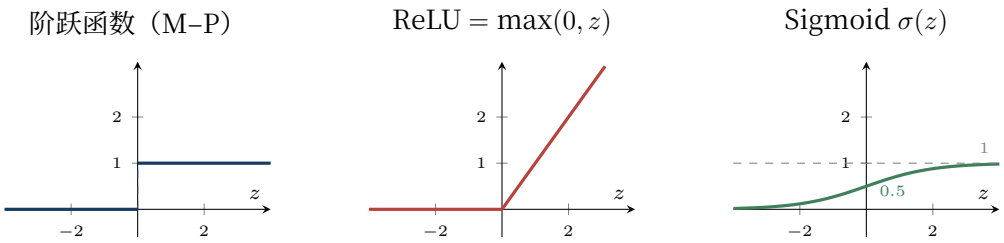


图 4.3　三种激活函数。三者都“弯折”了直线：阶跃在 0 处跳变，ReLU 在 0 处折弯，Sigmoid 把任意实数压到 $(0,1)$

激活函数	公式	输出范围	特点 / 用途
阶跃	1（$z \geq 0$），0（$z < 0$）	$\{0,1\}$	M–P 模型；不连续，导数几乎处处为 0，无法用梯度下降训练
ReLU	$\max(0,z)$	$[0,+\infty)$	计算简单；$z>0$ 时导数恒为 1，缓解深层网络训练困难（AlexNet 使用）
Sigmoid 教学补全	$\sigma(z)=\dfrac{1}{1+e^{-z}}$	$(0,1)$	输出可解释为“概率”，常用于二分类输出层；$\sigma(0)=0.5$

例题 4.2　手算一个神经元

已知： $\boldsymbol{x}=(1,2)$，$\boldsymbol{w}=(0.5,-1)$，$b=1$，激活函数 ReLU。　**求：** 输出 a。

第一步： $z=0.5\times1+(-1)\times2+1=-0.5$。　**第二步：** $a=\mathrm{ReLU}(-0.5)=\max(0,-0.5)=0$。

检查： $z<0$ 落在 ReLU 的“平台”区（图 4.3 中左半段），输出必为 0。若改用 Sigmoid，$a=\sigma(-0.5)=1/(1+e^{0.5})\approx0.378$。

本题想说明： 激活函数作用在 z 上，不能漏掉第二步，也不能把 z 当作最终输出。

4.5　为什么必须有非线性激活？

课件和笔记都写着：神经元计算中“非常多线性关系叠合 → 非线性”，并强调“非线性激活函数”。这里把背后的数学说清楚。

结论　线性层叠加仍是线性 教学补全

若每一层都只有线性变换（没有激活函数），那么无论堆叠多少层，整个网络都等价于一个线性模型。

证明 / 推导　**要证明：** 两层无激活网络 $\boldsymbol{h}=W_1\boldsymbol{x}+\boldsymbol{b}_1$，$\hat{y}=W_2\boldsymbol{h}+\boldsymbol{b}_2$ 可以写成 $\hat{y}=W\boldsymbol{x}+\boldsymbol{b}$ 的形式。

已知： W_1, W_2 是矩阵，$\boldsymbol{b}_1, \boldsymbol{b}_2$ 是向量，维度相容。

证明思路： 把第一层代入第二层，利用矩阵乘法的分配律与结合律。

详细证明：

$$\begin{aligned}
\hat{y} &= W_2\boldsymbol{h} + \boldsymbol{b}_2 && \text{（第二层定义）}\\
&= W_2(W_1\boldsymbol{x} + \boldsymbol{b}_1) + \boldsymbol{b}_2 && \text{（代入第一层）}\\
&= (W_2W_1)\boldsymbol{x} + (W_2\boldsymbol{b}_1 + \boldsymbol{b}_2) && \text{（分配律、结合律）}\\
&= W\boldsymbol{x} + \boldsymbol{b}, && \text{其中 } W = W_2W_1,\ \boldsymbol{b} = W_2\boldsymbol{b}_1 + \boldsymbol{b}_2.
\end{aligned}$$

结论：两层合并成了一层。对 k 层用数学归纳法重复这一步，结论对任意层数成立。■

一句话直观解释：直线套直线还是直线。例如 $h = 2x + 1$，$\hat{y} = 3h - 4$，合起来 $\hat{y} = 6x - 1$，仍是一条直线。

去掉“无激活”这个条件会怎样？只要中间加上 ReLU，就能表示折线。例如

$$\mathrm{ReLU}(x) + \mathrm{ReLU}(-x) = |x|,$$

两个 ReLU 神经元就拼出了一个 V 形——这是任何一条直线都做不到的。

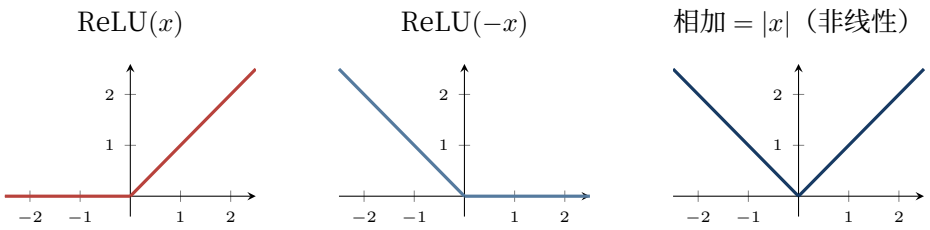


图 4.4　两个 ReLU 叠加得到 V 形折线；更多神经元可以拼出更复杂的曲线

4.6　从一个神经元到神经网络：层与“深度”

把很多神经元排成一层，再一层层连接起来，就是**神经网络**：第一层是**输入层**，最后一层是**输出层**，中间是**隐藏层**。笔记：深度 = 层数，深度学习 = 神经网络层数多。

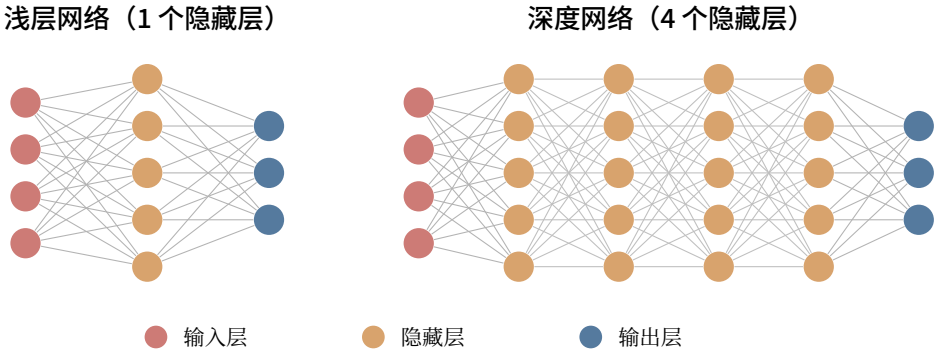


图 4.5　浅层与深度神经网络（依课件重绘）。每条连线代表一个权重

原始资料　为什么要“深”？课件用情绪识别举例：如果直接用像素判断，信息太多太乱（等于盯着每一个像素）。神经网络像一条**信息提炼流水线**：每一层都是一个“小模型”，把前一层的

输出继续处理，生成新的表示（representation），**每一层提取一个更高级的特征**；多层堆叠，就能从原始数据中逐步提取更抽象、更有用的特征。课件引用了 Lee 等人（2009）的可视化：图像识别网络的前几层学到的是边缘、线条，中间层是车轮、车窗等部件，更深层才是整辆汽车。

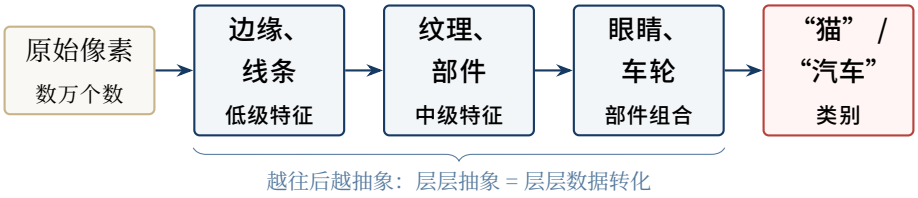


图 4.6　深度网络的“层层抽象”

例题 4.3　一个两层小网络的前向计算

已知：输入 $\boldsymbol{x}=(1,2)$。隐藏层 2 个 ReLU 神经元：$h_1=\mathrm{ReLU}(x_1+x_2-1)$，$h_2=\mathrm{ReLU}(x_1-x_2)$；输出层 $\hat{y}=2h_1+3h_2+1$（不加激活）。

第一步（隐藏层线性部分）：$z_1=1+2-1=2$，$z_2=1-2=-1$。

第二步（激活）：$h_1=\mathrm{ReLU}(2)=2$，$h_2=\mathrm{ReLU}(-1)=0$。

第三步（输出层）：$\hat{y}=2\times 2+3\times 0+1=5$。

矩阵写法：$\boldsymbol{h}=\mathrm{ReLU}(W_1\boldsymbol{x}+\boldsymbol{b}_1)$，$W_1=\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}$，$\boldsymbol{b}_1=\begin{bmatrix}-1\\ 0\end{bmatrix}$；$\hat{y}=W_2\boldsymbol{h}+b_2$，$W_2=[2\ \ 3]$，$b_2=1$。

本题想说明：网络的计算就是“线性 → 激活 → 线性 → 激活……”一层层往前算，这叫**前向传播**。$h_2=0$ 说明这个神经元对当前输入“沉默”，这正是 ReLU 带来的非线性。

4.7　常见模型家族与“模型是训练出来的”

原始资料　课件列举：线性回归、决策树、支持向量机（SVM）、随机森林、卷积神经网络（CNN）、循环神经网络（RNN）、Transformer。前四个属于“传统机器学习”，后三个属于深度学习。模型就是让机器像人一样**做判断（其实是预测、推测）**的工具（笔记：本质 = 预测 / 判断）。

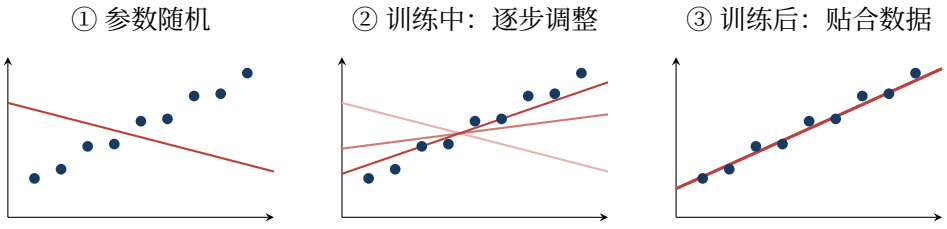


图 4.7　模型一开始是“空的”（参数随机），用数据“教它”，它会“调整自己”，越来越接近想要的输出

原始资料　课件与笔记都强调：**模型不是凭空得来的，是训练出来的。**模型一开始是“空的”，参数随机；我们用数据“教它”什么输入该对应什么输出；它会“调整自己”（优化参数 → 权重 w_i），越来越接近我们想要的输出。“怎样算接近”由第 5 章回答，“怎样调整”由第 6 章回答。

比较维度	M–P 神经元（1943）	现代神经元
计算	$f=\sum w_i x_i-\theta$，输出 0/1	$z=\boldsymbol{w}\cdot\boldsymbol{x}+b$，$a=\text{activation}(z)$
激活函数	阶跃函数	ReLU、Sigmoid 等（连续、可求导）
参数来源	人工设定	从数据中训练得到
能否用梯度下降	不能（阶跃函数导数几乎处处为 0）	能

易错提醒

1. 把 z 当成神经元的输出，漏掉激活函数这一步。
2. 以为“层数多就一定更强”——若没有非线性激活，100 层也只等于 1 层（本章定理）。
3. 把权重 w 和输入 x 混淆：x 是每个样本不同的“题目”，w 是所有样本共用、需要训练的“套路”。

学完这里，你应该能够回答

1. 写出线性模型的公式，并说明 w 和 b 在图像上分别控制什么。
2. M–P 模型中的阈值 θ 与偏置 b 是什么关系？
3. 神经元计算分哪两步？ReLU 的公式是什么？
4. 为什么没有激活函数的多层网络等价于一层？请写出两层的推导。
5. “深度”指什么？为什么深层网络能处理情绪识别这类复杂问题？

到这里，我们已经解决了什么？模型能把 $\boldsymbol{x}$ 变成 $\hat{y}$ 了，但一开始参数是随机的，$\hat{y}$ 多半是错的。**下一步：**需要一把“尺子”来量它“错了多少”——这就是目标函数与损失函数。

第 5 章　目标函数：怎样衡量“学得好不好”

本章回答三个问题：(1) 目标函数和损失函数是什么？(2) 回归用什么损失（MSE），分类用什么损失（交叉熵），为什么？(3) 损失低就一定学得好吗？什么是过拟合，怎么防止？

5.1　从“学习的目的”到目标函数

原始资料　课件：机器学习是“从经验中学习”。学习的目的是什么？提高、符合预期、达到期望。怎样才算真正提高？如何评估？标准是什么？

定义　目标函数与损失函数

原始资料

- **目标函数**（objective function）：模型优劣程度的度量；这个度量在大部分情况下是“可优化的”。
- **损失函数**（loss function）：实际值（期望值）和预测值之间的偏差。

模型训练不是“胡乱学”，而是不断让损失函数的值更好（通常更低）。

5.2 回归任务：均方误差（MSE）

核心公式 均方误差 Mean Squared Error

$$L = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

n　样本个数　y_i：第 i 个样本的**真实值**（标签）　$\hat{y}_i$：模型对第 i 个样本的**预测值**
$y_i - \hat{y}_i$　误差（残差），可正可负　平方：去掉正负号，并放大大误差　$\frac{1}{n}\sum$：取平均

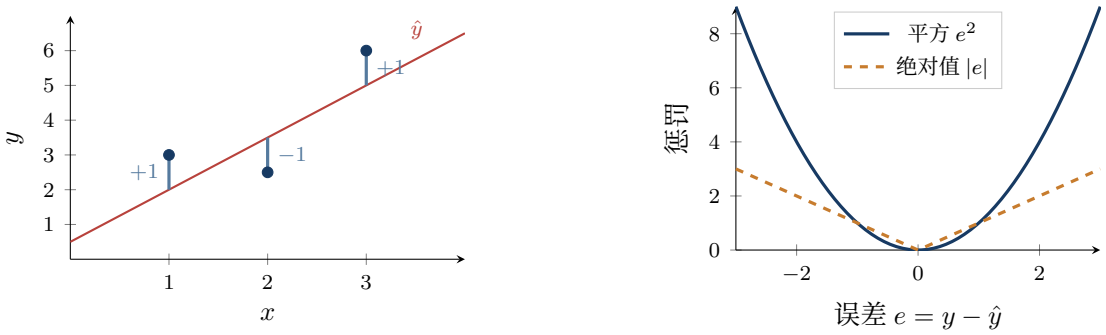


图 5.1　左：竖直蓝线段就是每个样本的误差；右：平方惩罚在误差大时增长得比绝对值快得多

原始资料　课件总结 MSE 的三个特点：(1) 每次错一点，就罚一点；错得越多，罚得更多（平方惩罚）——从图 5.1 右可以看到，误差为 3 时平方惩罚是 9，而误差为 1 时只有 1；(2) 数学上可导、可优化（平方函数处处光滑，而绝对值在 0 处有尖点）；(3) 输出连续数值时非常常用（回归任务）。

例题 5.1　计算 MSE

已知： 图 5.1 左中的三个点 $(1,3),(2,2.5),(3,6)$，模型 $\hat{y} = 1.5x + 0.5$。
第一步（预测）： $\hat{y}_1 = 2,\ \hat{y}_2 = 3.5,\ \hat{y}_3 = 5$。
第二步（误差）： $y_i - \hat{y}_i = 1,\ -1,\ 1$。
第三步（平方再平均）： $L = \frac{1}{3}(1 + 1 + 1) = 1$。
检查： 三条蓝线段长度都是 1，平方后都是 1，平均当然是 1。
本题想说明： 正负误差不会互相抵消（若直接平均误差会得到 $\frac{1}{3}$，掩盖了“每个点都有偏差”这一事实）。

原图纠错 4　笔记中 MSE 的下标

原始写法： 笔记 361 页 $L = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y})^2$。　**存在的问题：** $\hat{y}$ 缺少下标 i，看起来像所有样本都与同一个预测值比较。　**规范写法：** $(y_i - \hat{y}_i)^2$，每个样本与**自己的**预测比较（课件写法正确）。　**是否影响后续：** 不影响。

5.3 分类任务：交叉熵损失

原始资料　课件：当我们做“分类”（比如识别图片是猫还是狗）时，不再用 MSE，而常用**交叉熵损失**（Cross Entropy Loss），它衡量预测分布与真实标签分布之间的差距。二分类问题中：

核心公式 二分类交叉熵

$$\boxed{L = -\big[\, y \log \hat{y} + (1-y)\log(1-\hat{y}) \,\big]}, \qquad \hat{y} \in (0,1),\ y \in \{0,1\}$$

y：真实标签（1 = 是猫，0 = 不是猫）；$\hat{y}$：模型给出的“是猫”的概率（通常由 Sigmoid 输出）。log 取自然对数 ln（教学补全；换底只相差一个正常数倍，不影响哪个参数更好）。

把公式拆开看：因为 y 只取 0 或 1，公式中只会有一项起作用：

$$L = \begin{cases} -\ln \hat{y}, & y = 1 \ \text{（真的是猫）} \\ -\ln(1-\hat{y}), & y = 0 \ \text{（真的不是猫）} \end{cases}$$

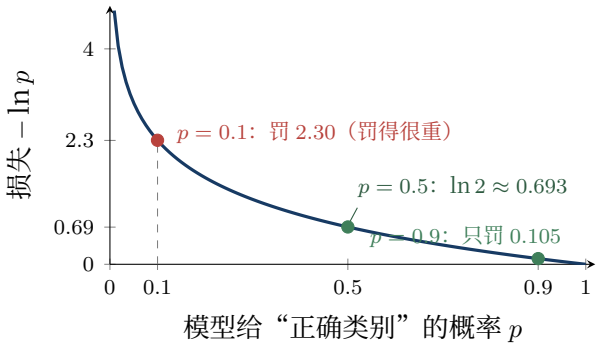


图 5.2　交叉熵的单样本损失 $-\ln p$：越自信地答错（$p \to 0$），惩罚越大，趋于无穷

原始资料　课件：“如果你预测‘它是猫’的概率只有 0.1，但它其实是猫，那你就罚得很重。”由图 5.2：$y = 1, \hat{y} = 0.1$ 时 $L = -\ln 0.1 \approx 2.303$；若 $\hat{y} = 0.9$，$L = -\ln 0.9 \approx 0.105$。

教学补全：交叉熵 + Sigmoid 的梯度为什么特别简单　设输出 $\hat{y} = \sigma(z)$，$\sigma(z) = \dfrac{1}{1+e^{-z}}$。

第 1 步（Sigmoid 的导数）： $\sigma'(z) = \dfrac{e^{-z}}{(1+e^{-z})^2} = \dfrac{1}{1+e^{-z}} \cdot \dfrac{e^{-z}}{1+e^{-z}} = \sigma(z)\big(1-\sigma(z)\big) = \hat{y}(1-\hat{y})$。

第 2 步（损失对 $\hat{y}$ 求导）： $\dfrac{\partial L}{\partial \hat{y}} = -\dfrac{y}{\hat{y}} + \dfrac{1-y}{1-\hat{y}} = \dfrac{\hat{y}-y}{\hat{y}(1-\hat{y})}$。

第 3 步（链式法则，见第 6 章）：

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} = \frac{\hat{y}-y}{\hat{y}(1-\hat{y})} \cdot \hat{y}(1-\hat{y}) = \boxed{\hat{y}-y}.$$

直观解释：梯度就是“预测概率 − 真实标签”，错得越多梯度越大、改得越猛；而若用 MSE 配 Sigmoid，梯度会多出一个 $\hat{y}(1-\hat{y})$ 因子，当模型**非常自信地答错**（$\hat{y} \approx 0$ 而 $y = 1$）时该因子接近 0，模型几乎“改不动”。这就是分类任务偏爱交叉熵的一个重要原因。

5.4　损失低 ≠ 学得好：泛化与过拟合

原始资料　课件：损失函数的值是模型预测与真实标签之间的差异，但这个“差异”是**在一组特定的数据集上计算的**，所以它依赖于数据集本身。你让模型背答案，它确实会“零错误”。训练集就像模拟题本，你天天做它；测试集就像期末考试题，你之前没见过。**损失函数计算的是“表现”，但表现好 ≠ 懂得好；只有在看不见的数据上也表现好，才是真的学会了。**

定义 过拟合与泛化

原始资料　一个模型在训练集上表现良好，但不能推广到测试集，这个模型被称为**过拟合**（overfitting）的，即模型的**泛化**（generalization）能力比较弱。

教学补全　与之相对，若模型在训练集上就表现很差（连模拟题都做不对），称为**欠拟合**（underfitting），通常是模型太简单或训练不足。

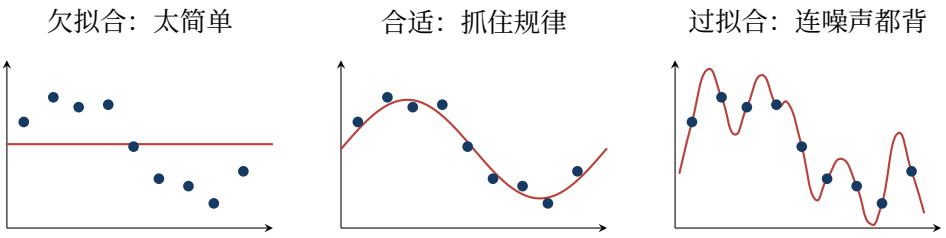


图 5.3　同一组数据的三种拟合。右图穿过了每一个训练点（训练损失为 0），但曲线剧烈摆动，对新数据的预测很差

课件用下表描述训练过程中两种损失的变化（笔记：“过拟合不是因为你太聪明，而是你太‘听话’——连错误的记忆都照单全收”）：

轮数	训练损失	验证 / 测试损失	表现
初期	降低	降低	学到规律
中期	继续降低	持平或略降	泛化极限
后期	很低	**开始上升**	背答案 → 过拟合

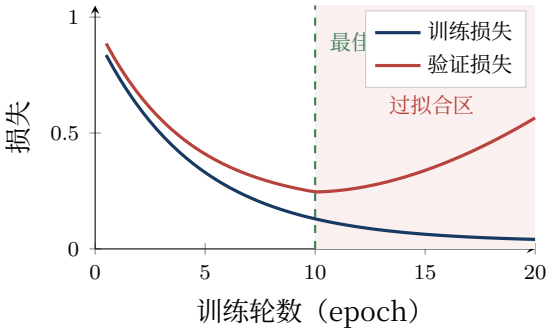


图 5.4　训练损失一直下降，验证损失先降后升；二者“分叉”的位置就是过拟合开始的地方（示意曲线）

5.5　如何防止过拟合

方法一：验证集 + 提前停止（Early Stopping）

原始资料　在训练过程中，用一部分未参与训练的数据（验证集）定期测试模型表现；如果发现验证集性能连续多轮不再提升，就停止训练。课件与笔记的例子：**模型训练第 10 轮时在验证集表现最好，到第 15 轮反而下降，我们就选第 10 轮的模型**（对应图 5.4 中的绿线）。

方法二：数据增强（Data Augmentation）

原始资料　对训练集的数据做随机变换或扰动，生成“新”数据，让模型“见多识广”，尤其适用于图像、语音、文本任务。常见变换：翻转、旋转、缩放、剪裁、亮度变化等（举一反三）。

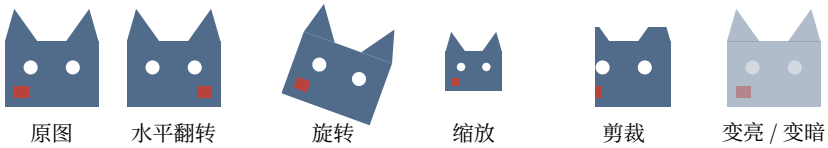


图 5.5　数据增强：一张训练图变成多张，标签不变（都仍是“猫”）

拓展联想　以下内容只用于建立知识联系，当前阶段不要求掌握：AlexNet 使用的 **Dropout**（训练时随机“关掉”部分神经元）、在损失中加入 $\lambda\sum w_i^2$ 的**正则化**，也都是防止过拟合的常用手段。

易错提醒

1. 训练损失很低 $\neq$ 模型好：必须看验证 / 测试损失。
2. 早停要看**验证集**，不能看测试集，否则测试集就“泄露”了。
3. 数据增强只对**训练集**做；增强后的样本标签必须仍然正确（把“6”旋转 180° 就变成了“9”，这种增强不可用）。

学完这里，你应该能够回答

1. 写出 MSE 公式，解释为什么要平方。
2. $y=1$、$\hat{y}=0.5$ 时二分类交叉熵是多少?
3. 分类任务为什么常用交叉熵而不是 MSE?
4. 在损失曲线上怎样认出过拟合？早停应该选哪一轮?
5. 列出三种数据增强方法，并说明为什么它们能缓解过拟合。

到这里，我们已经解决了什么? 我们有了一把尺子 $L(\boldsymbol{w})$ 来衡量模型错了多少。**下一步：**知道“错了多少”还不够，还要知道**每个参数该往哪个方向、改多少**，才能让 L 变小。这就是优化算法。

第 6 章　优化算法：怎样一步步把模型调好

本章回答三个问题：(1) 为什么沿“负梯度”走能让损失下降？梯度到底是什么？(2) 学习率怎么影响训练？BGD、SGD、小批量、Adam 有什么区别？(3) 神经网络有成千上万个参数，梯度怎么算？——反向传播。

本章知识路线： 前置速补（偏导、梯度、链式法则）→ 一维梯度下降 → 多维梯度与其几何意义（证明）→ 学习率与收敛（证明）→ 局部最小与鞍点 → 三种梯度下降 → Adam → 反向传播。

定义　优化算法

原始资料　优化算法的目的：找到一组最优的模型参数，使得损失函数最小化。笔记：优化算法 = 调整模型参数（权重）。用符号写：

$$\boldsymbol{w}^* = \arg\min_{\boldsymbol{w}} L(\boldsymbol{w}) \qquad \text{（读作：使 } L \text{ 最小的那个 } \boldsymbol{w}\text{）}$$

6.1　前置速补：偏导数、梯度、链式法则

教学补全　这三个工具在高等数学中会系统学习，这里只补到“够用”。

偏导数　多元函数 $L(w_1, w_2)$ 对 w_1 的**偏导数** $\dfrac{\partial L}{\partial w_1}$：把 w_2 看成常数，只对 w_1 求导。例如 $L = w_1^2 + 3w_1 w_2$，则 $\dfrac{\partial L}{\partial w_1} = 2w_1 + 3w_2$，$\dfrac{\partial L}{\partial w_2} = 3w_1$。含义：只动 w_1 一点点，L 变化的快慢。

链式法则　若 L 依赖 y，y 依赖 z，z 依赖 w（一条“传话链”），则

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial z} \cdot \frac{\partial z}{\partial w}.$$

例：$L = y^2$，$y = 3z$，$z = 2w$。$\frac{\partial L}{\partial y} = 2y$，$\frac{\partial y}{\partial z} = 3$，$\frac{\partial z}{\partial w} = 2$，故 $\frac{\partial L}{\partial w} = 2y \cdot 6 = 12y$。直接代入 $L = (6w)^2 = 36w^2$，$\frac{dL}{dw} = 72w = 12 \cdot (6w) = 12y$，两者一致。

6.2　一维梯度下降：沿着“下坡方向”走一步

原始资料　课件：梯度下降（Gradient Descent）是最核心、最常用的优化算法——每次往“损失函数下降最快的方向”走一步，直到找到最低点。

核心公式　梯度下降更新公式

$$\boxed{w := w - \eta \cdot \frac{\partial L(w)}{\partial w}}$$

$:=$	“更新为”：用右边算出的新值覆盖旧的 w（笔记：下一步更新）
$\dfrac{\partial L(w)}{\partial w}$	损失函数对参数的梯度（偏导）：当前位置的“坡度”
η	学习率（learning rate，读作 eta），控制“走多远”；$\eta > 0$
$\eta \cdot \dfrac{\partial L}{\partial w}$	这一步实际移动的量（**步长**）

笔记中“η → 步幅”的准确理解　笔记把 η 标注为“步幅”。更准确地说：η 是**学习率**，真正的一步移动量是 $\eta \times$ |梯度|。同样的 η，坡陡的地方一步走得远，坡缓的地方一步走得近。

为什么是“减去”梯度？——推导　教学补全　**直观：**若斜率 $L'(w) > 0$（右高左低），应该往左走（w 减小）；若 $L'(w) < 0$，应往右走。“$-\eta L'(w)$”恰好总是朝着下坡方向。

推导：由导数定义，当步子 Δ 很小时 $L(w + \Delta) \approx L(w) + L'(w)\,\Delta$（一阶近似，即切线）。取 $\Delta = -\eta L'(w)$，得

$$L(w_{\text{new}}) \approx L(w) - \eta\,[L'(w)]^2 \le L(w).$$

因为 $\eta > 0$、$[L'(w)]^2 \ge 0$，所以只要 η 足够小（一阶近似足够准），每一步都让损失不增加；只有在 $L'(w) = 0$（平坦处）时才停下。

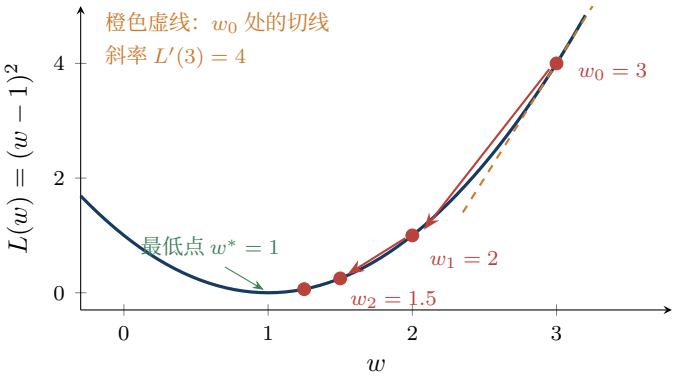


图 6.1　梯度下降在 $L(w)=(w-1)^2$ 上的前几步（$\eta=0.25$）：越接近谷底，坡越缓，步子自动变小

例题 6.1　手算梯度下降

已知： $L(w)=(w-1)^2$，$w_0=3$，$\eta=0.25$。　**求：** w_1,w_2,w_3 及对应损失。

导数： $L'(w)=2(w-1)$。

第 1 步： $L'(3)=4$，$w_1=3-0.25\times 4=2$，$L=1$。　**第 2 步：** $L'(2)=2$，$w_2=2-0.5=1.5$，$L=0.25$。　**第 3 步：** $w_3=1.5-0.25\times 1=1.25$，$L=0.0625$。

检查： 损失 $4\to 1\to 0.25\to 0.0625$ 单调减小，w 逐步逼近最低点 $w^*=1$（与图 6.1 一致）。每步与最低点的距离都减半：$2\to 1\to 0.5\to 0.25$。

本题想说明： 梯度下降不需要“一眼看出”最低点在哪里，只需要知道**当前位置的坡度**。

6.3　多维情况：梯度向量及其几何意义

原始资料　对于多元函数 $L(w_1,w_2,\dots,w_n)$，它在每个参数上的偏导数组成了**梯度向量**：

核心公式　梯度

$$\nabla L(\boldsymbol{w})=\left[\frac{\partial L}{\partial w_1},\frac{\partial L}{\partial w_2},\dots,\frac{\partial L}{\partial w_n}\right],\qquad \boldsymbol{w}:=\boldsymbol{w}-\eta\nabla L(\boldsymbol{w})$$

几何意义：**梯度指向函数增长最快的方向**；负梯度指向下降最快的方向。

证明：梯度方向是函数增长最快的方向 教学补全　**要证明：** 在所有单位方向 $\boldsymbol{u}$（$|\boldsymbol{u}|=1$）中，沿 $\boldsymbol{u}=\nabla L/|\nabla L|$ 走时 L 增长最快。

已知： L 可微，$\nabla L\neq\mathbf{0}$。

思路： 把“沿某方向的变化率”写成数量积，再利用 $\cos\theta\le 1$。

详细证明： 沿方向 $\boldsymbol{u}$ 走一小步 t，由多元函数的一阶近似

$$\begin{aligned}L(\boldsymbol{w}+t\boldsymbol{u})&\approx L(\boldsymbol{w})+t\left(\frac{\partial L}{\partial w_1}u_1+\cdots+\frac{\partial L}{\partial w_n}u_n\right) && \text{（各方向偏导的线性组合）}\\ &=L(\boldsymbol{w})+t\,\nabla L\cdot\boldsymbol{u}. && \text{（数量积定义）}\end{aligned}$$

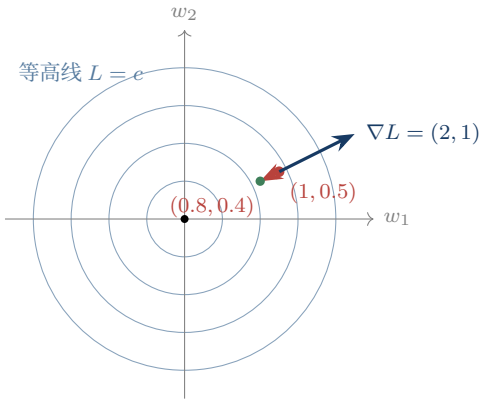
所以变化率（方向导数）为 $\nabla L\cdot\boldsymbol{u}=|\nabla L|\,|\boldsymbol{u}|\cos\theta=|\nabla L|\cos\theta$，其中 θ 是 $\boldsymbol{u}$ 与 ∇L 的夹角。由于 $-1\le\cos\theta\le 1$：

- $\theta=0$（沿梯度）时变化率取最大值 $|\nabla L|$：**上升最快**；

· $\theta = \pi$（沿负梯度）时变化率取最小值 $-|\nabla L|$：**下降最快**；

· $\theta = \pi/2$ 时变化率为 0：沿**等高线**方向走，L 不变。

结论：梯度是最陡上坡方向，负梯度是最陡下坡方向。■　**一句话：**梯度总是**垂直于等高线、指向高处**。



原始资料　课件例子：负梯度方向为 $[-2, -1]$，学习率 $\eta = 0.1$，则

$$w_1 := w_1 - 0.1\times 2 = w_1 - 0.2, \quad w_2 := w_2 - 0.1\times 1 = w_2 - 0.1.$$

教学补全　为了能画出来，取 $L = w_1^2 + w_2^2$（碗形），在 $(1, 0.5)$ 处 $\nabla L = (2w_1, 2w_2) = (2, 1)$，正是课件的数值。一步后到达 $(0.8, 0.4)$，L 从 1.25 降到 0.8。每次沿负梯度走一点，就像“往谷底滑下去”。

图 6.2　碗形损失 $L = w_1^2 + w_2^2$ 的等高线：蓝箭头（梯度）垂直于等高线指向外（上坡），红箭头（负梯度的一步）指向谷底

6.4　学习率：走多远才合适

原始资料　课件：学习率太大 → 容易跳过最低点，甚至发散；学习率太小 → 收敛很慢，训练时间长。通常使用动态调整学习率（如 warmup 预热、decay 衰减、scheduler 调度器）。

结论 学习率与收敛（以 $L = w^2$ 为例） 教学补全

对 $L(w) = w^2$ 做梯度下降，$w_{t+1} = (1 - 2\eta)\, w_t$，因此 $w_t = (1 - 2\eta)^t\, w_0$。

$$\text{收敛到 } 0 \iff |1 - 2\eta| < 1 \iff 0 < \eta < 1.$$

$0 < \eta < 0.5$：单调收敛；$\eta = 0.5$：一步到达；$0.5 < \eta < 1$：来回振荡着收敛；$\eta > 1$：振荡发散。

证明 / 推导　$L'(w) = 2w$，更新 $w_{t+1} = w_t - \eta \cdot 2w_t = (1 - 2\eta)w_t$。反复代入得等比数列 $w_t = q^t w_0$，公比 $q = 1 - 2\eta$。等比数列趋于 0 当且仅当 $|q| < 1$，即 $-1 < 1 - 2\eta < 1 \iff 0 < \eta < 1$。$q > 0$ 时各项同号（单调），$q < 0$ 时正负交替（振荡）。■

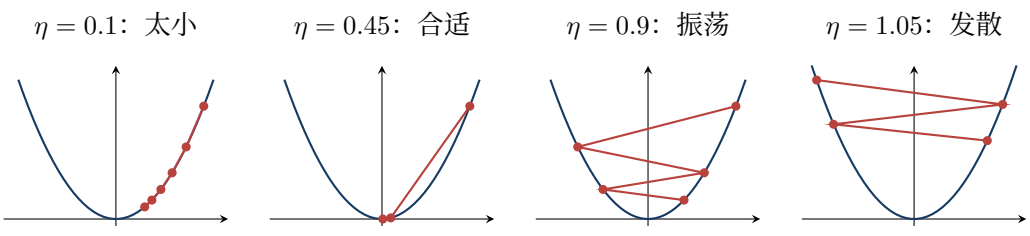


图 6.3　同一个碗 $L = w^2$、不同学习率下的轨迹（红点为逐步迭代的位置）

6.5　梯度下降不是完美的：局部最小值与鞍点

原始资料　课件：梯度下降可能陷入“局部最小值”或“鞍点”，导致训练卡住。教学补全 在这些点上梯度为 0（或非常小），更新公式 $w := w - \eta \cdot 0$ 不再移动：

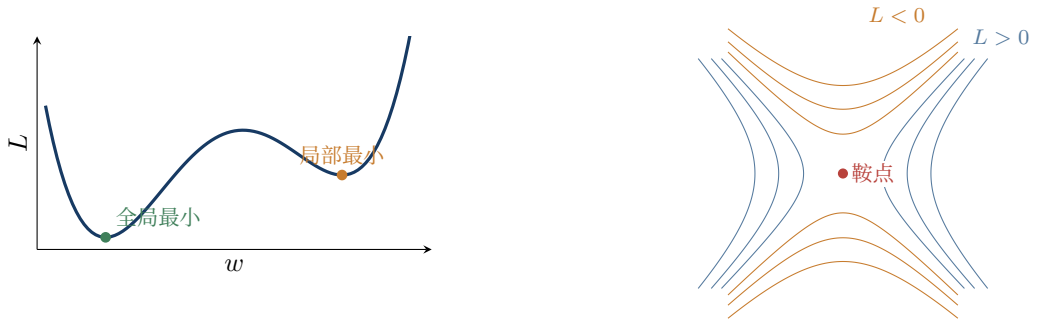


图 6.4　左：局部最小值——从右边出发的梯度下降会停在局部最小；右：$L = w_1^2 - w_2^2$ 的鞍点——沿 w_1 方向是谷底，沿 w_2 方向是山顶，梯度却为 0

6.6　三种梯度下降：一次用多少数据算梯度

训练集有 n 个样本时，总损失是各样本损失的平均：$L = \frac{1}{n}\sum_{i=1}^{n} \ell_i$，所以梯度也是平均：$\nabla L = \frac{1}{n}\sum_{i=1}^{n} \nabla \ell_i$。问题是：每更新一次，要不要把 n 个样本的梯度都算一遍？

方法	每次更新用的样本	优点	缺点
批量梯度下降 BGD	全部 n 个	梯度估计准确，更新方向稳定	每次计算代价大、训练慢，不适合大数据
随机梯度下降 SGD	1 个	每步计算量小、速度快，容易跳出局部最小值	更新方向不稳定，容易“抖动”，收敛不平稳
小批量 Mini-batch	一小批 B 个（如 32、64、128）	兼顾速度与稳定性，能用矩阵计算并行加速	需选择批大小 B；深度学习最常用

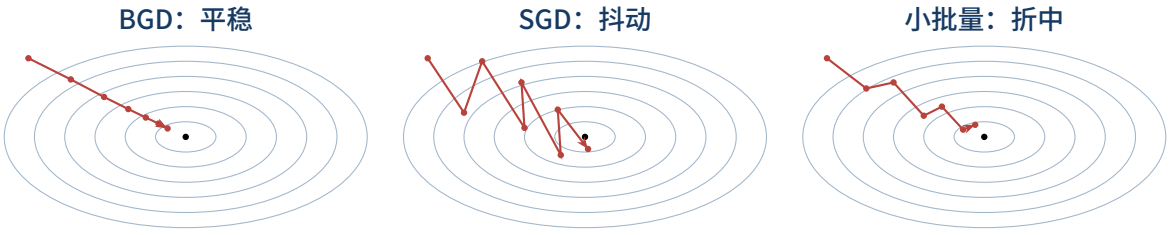


图 6.5　三种方法在同一损失等高线上的典型路径（示意）

例题 6.2　一轮（epoch）更新几次？

题目：训练集 1000 个样本，一轮（epoch）指把全部样本用一遍。三种方法各更新多少次？
结果：BGD：1 次；SGD：1000 次；小批量（$B = 50$）：$1000 \div 50 = 20$ 次。
本题想说明：每次用的样本越少，每轮更新次数越多、每次越便宜，但方向越“吵”。

6.7 Adam：会“记方向”又会“看地形”的梯度下降

原始资料　Adam（Adaptive Moment Estimation，自适应矩估计）是深度学习中最常用的优化器之一。设第 t 步的梯度为 g_t：

核心公式 Adam（含偏差修正）

① 梯度记忆（动量，一阶矩）：　$m_t = \beta_1 m_{t-1} + (1-\beta_1)\, g_t$

② 梯度平方的记忆（二阶矩）：　$v_t = \beta_2 v_{t-1} + (1-\beta_2)\, g_t^2$

③ 偏差修正 教学补全：　$\hat{m}_t = \dfrac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \dfrac{v_t}{1-\beta_2^t}$

④ 参数更新：

$$\boxed{w := w - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}}$$

常用默认值：$\beta_1 = 0.9$，$\beta_2 = 0.999$，$\epsilon = 10^{-8}$（防止除以 0），$m_0 = v_0 = 0$。

每一项在做什么

- m_t：最近梯度的**加权平均**（越近的权重越大），记录“平均方向”，像**惯性**——来回摆动的分量相互抵消，一致的方向越走越稳（笔记：记录每次的方向）。
- v_t：最近梯度**平方**的加权平均，衡量这个参数的梯度通常有多大、多“剧烈”（笔记：注意方差）。
- $\hat{m}/\sqrt{\hat{v}}$：用“典型梯度大小”去除，得到大小约为 1 的步子——梯度一贯很大的参数步子被缩小，梯度一贯很小的参数步子被放大（笔记：动态调整）。**每个参数有自己的步长。**

课件的比喻：Adam 像一个登山者——记录每次走的方向（动量），避免来回折返；注意地形陡峭程度（方差），避免冲太快；每只脚（参数）的步子大小都不一样；一边走一边调整节奏。

例题 6.3　Adam 的第一步

已知： $\beta_1 = 0.9$，$\beta_2 = 0.999$，$m_0 = v_0 = 0$，第 1 步梯度 $g_1 = 2$。

计算： $m_1 = 0.9 \times 0 + 0.1 \times 2 = 0.2$；$v_1 = 0.999 \times 0 + 0.001 \times 4 = 0.004$。

修正： $\hat{m}_1 = 0.2/(1-0.9) = 2$，$\hat{v}_1 = 0.004/(1-0.999) = 4$，步长 $\eta \cdot 2/(\sqrt{4}+\epsilon) \approx \eta$。

本题想说明： 若没有偏差修正，$m_1 = 0.2$ 被初值 0“拖小”了 10 倍；修正后恢复为真实梯度 2。并且第一步移动量约为 η，与梯度绝对大小无关——这正是“自适应”的含义。

原图纠错 5　课件对 Adam 的两处表述

原始写法 1： “Adam 会记录每个参数历史上的一阶梯度的‘平均方向’、二**阶梯度的‘方差’**”。

存在的问题： v_t 是**（一阶）梯度的平方**的指数移动平均，即梯度的“二阶矩”（未减去均值的方差），**不是**“二阶梯度”（二阶导数 / Hessian）。Adam 只使用一阶导数。

规范写法： 记录梯度的一阶矩（均值）m_t 与二阶矩（平方的均值）v_t。

原始写法 2：“99% 的深度学习模型默认都在用 Adam，无需精调学习率”。
存在的问题：这是夸张的口语说法，没有统计依据。Adam 及其变体（如 AdamW）确实非常常用，但仍需设置学习率，大模型训练通常还配合 warmup 与衰减；部分任务中带动量的 SGD 泛化更好。
是否影响后续：不影响公式与计算。课件公式省略了偏差修正步骤，本讲义已按原论文（Kingma & Ba, 2015）补全。

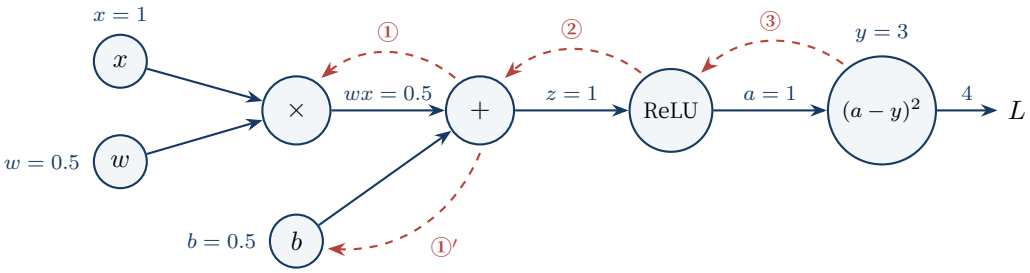
6.8　反向传播：成千上万个参数的梯度怎么算

原始资料　课件用三问引出：训练神经网络的目标是什么？——找到参数，使得损失函数最小。怎么找到让损失函数变小的参数？——先随机，然后沿梯度下降。怎么计算梯度？——需要 $\nabla L = \left[\frac{\partial L}{\partial w_1}, \ldots, \frac{\partial L}{\partial w_n}\right]$。

神经网络是一层套一层的函数；损失函数只有一个，在最后的输出处发挥作用。直观上，损失函数可以直接算出**最后一层**的梯度，那倒数第二层、倒数第三层呢？答案是**链式法则**：

$$\frac{\partial L}{\partial W} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial z} \cdot \frac{\partial z}{\partial W}.$$

从输出层开始，把“L 对本层输出的梯度”一层一层**往回传**，每层乘上本层的局部导数，就得到每一层参数的梯度——这就是**反向传播**（Backpropagation）。



反向（从右往左）：
③ $\partial L/\partial a = 2(a-y) = -4$
② $\partial L/\partial z = \partial L/\partial a \times \partial a/\partial z = -4 \times 1 = -4$　（$z>0$，ReLU 斜率 1）
① $\partial L/\partial w = \partial L/\partial z \times x = -4$　　①′ $\partial L/\partial b = \partial L/\partial z \times 1 = -4$

图 6.6　计算图：蓝色数字是前向传播的值（$x=1, w=0.5, b=0.5$，目标 $y=3$），红色虚线是反向传播的梯度

例题 6.4　一个神经元的反向传播 + 一次更新

已知：$z = wx + b$，$a = \mathrm{ReLU}(z)$，$L = (a-y)^2$；$x=1$，$w=0.5$，$b=0.5$，$y=3$，$\eta = 0.1$。
前向：$z = 0.5 \times 1 + 0.5 = 1$，$a = \mathrm{ReLU}(1) = 1$，$L = (1-3)^2 = 4$。
反向（从后往前）：$\frac{\partial L}{\partial a} = 2(a-y) = -4$；$\frac{\partial a}{\partial z} = 1$（因为 $z=1>0$，ReLU 此处斜率为 1）；$\frac{\partial z}{\partial w} = x = 1$，$\frac{\partial z}{\partial b} = 1$。于是

$$\frac{\partial L}{\partial w} = (-4) \times 1 \times 1 = -4, \qquad \frac{\partial L}{\partial b} = (-4) \times 1 \times 1 = -4.$$

更新：$w := 0.5 - 0.1 \times (-4) = 0.9$，$b := 0.5 - 0.1 \times (-4) = 0.9$。

检查：新的前向：$z = 0.9 + 0.9 = 1.8$，$a = 1.8$，$L = (1.8-3)^2 = 1.44 < 4$。损失确实下降了。
本题想说明：反向传播负责**算梯度**，梯度下降负责**用梯度改参数**，两者配合才完成一次训练。若 $z < 0$，ReLU 的斜率为 0，梯度传到这里就“断了”，该神经元这一步不会更新。

方法总结：一次完整的训练迭代

1. **取数据：**从训练集取一个小批量 $\{(\boldsymbol{x}_i, y_i)\}$；
2. **前向传播：**逐层计算 $z = \boldsymbol{w} \cdot \boldsymbol{x} + b$、$a = \text{activation}(z)$，得到预测 $\hat{y}$；
3. **算损失：**回归用 MSE，分类用交叉熵；
4. **反向传播：**用链式法则从输出层往回算出每个参数的梯度；
5. **更新参数：**梯度下降 / Adam；
6. **定期验证：**在验证集上看损失，决定是否早停。回到第 1 步。

易错提醒

1. 更新公式是**减**梯度，不是加；梯度方向是上坡方向。
2. 学习率不是越大越快：超过临界值会振荡甚至发散（图 6.3）。
3. **反向传播不是一种优化算法**，它是“高效计算梯度的方法”；优化算法（GD、SGD、Adam）使用它算出的梯度。
4. Adam 中的 v_t 是“梯度平方的平均”，不是二阶导数。

学完这里，你应该能够回答

1. 写出梯度下降的更新公式并解释每个符号；为什么是“减”？
2. 为什么说梯度指向函数增长最快的方向？
3. 对 $L = w^2$，学习率取多少时梯度下降收敛？取 0.9 会怎样？
4. BGD、SGD、小批量各用多少样本算一次梯度？一轮各更新几次？
5. Adam 的 m_t、v_t 分别记录什么？为什么要偏差修正？
6. 反向传播与梯度下降是什么关系？

第 7 章　总结与联系：把四个要素连成一张网

到这里，我们已经完整地走过了机器学习的四个要素。本章把它们串成一张网，并看看它们在现实系统和后续课程中出现在哪里。

7.1　本讲知识地图

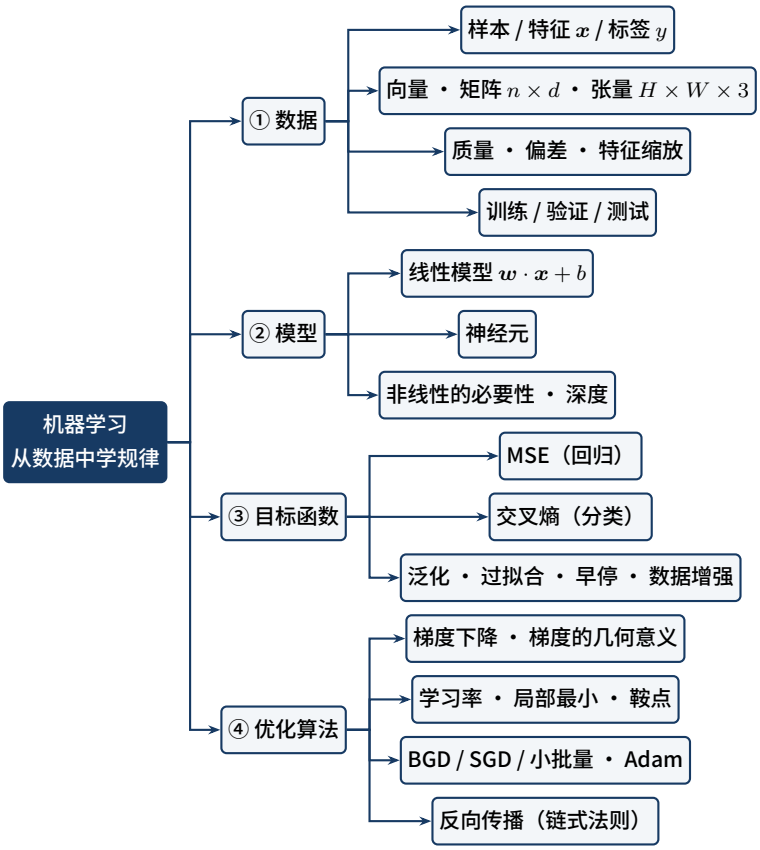


图 7.1　本讲知识地图：四个要素及其下属概念

7.2　相近概念总对比

容易混淆的一对	前者	后者
特征 vs. 标签	拿来预测的输入 $\boldsymbol{x}$	要预测的目标 y
参数 vs. 输入	$\boldsymbol{w}, b$：所有样本共用，要训练	$\boldsymbol{x}$：每个样本不同，不训练
验证集 vs. 测试集	训练过程中用来“选”，可反复使用	全部完成后“考”一次，不能用于调参
目标函数 vs. 损失函数	优劣的度量，可最大化或最小化	预测与真实的偏差，最小化
MSE vs. 交叉熵	回归（连续值）；平方惩罚	分类（概率）；自信答错罚得极重
过拟合 vs. 欠拟合	训练好、验证差（背答案）	训练就差（太简单或没练够）
BGD vs. SGD	全部样本，稳而慢	1 个样本，快而抖
梯度下降 vs. 反向传播	用梯度**改参数**的方法	**算梯度**的方法
阈值 θ vs. 偏置 b	M–P 模型中的“门槛”	线性模型的截距；$b = -\theta$
AI vs. ML vs. DL	AI 最大	ML 是 AI 的子集，DL 是 ML 的子集

7.3 高频易错点总表

	常见错误	正确理解
1	数据集形状写成“特征数 × 样本数”	通常为 $n \times d$：**行 = 样本**
2	灰度 0 = 白、255 = 黑	0 = 黑、255 = 白
3	神经元输出就是 $z = \boldsymbol{w} \cdot \boldsymbol{x} + b$	还要经过激活：$a = \text{activation}(z)$
4	层数越多越强（不管有无激活）	无非线性激活时多层 = 一层
5	MSE 中误差可以直接平均	要先平方再平均，否则正负抵消
6	训练损失低就说明模型好	要看验证 / 测试损失（泛化）
7	用测试集决定早停轮数	用验证集；测试集只考一次
8	梯度下降“加”梯度	“减”梯度：$w := w - \eta \nabla L$
9	学习率越大收敛越快	超过临界值会振荡或发散
10	反向传播是一种优化器	反向传播只算梯度
11	Adam 用到二阶导数	只用一阶梯度及其平方的移动平均
12	计算距离时直接用原始特征	量纲差异大时先做特征缩放

7.4 基础解题步骤总结

遇到计算题，先认清是哪一类

- **数形状 / 数个数：**样本数 × 特征数；灰度 $H \times W$；彩色 $H \times W \times 3$；拉平后维度 = 所有数的个数。
- **神经元前向：**① 算 $z = \sum w_i x_i + b$（M–P：$\sum w_i x_i - \theta$）；② 代入激活函数；③ 多层就逐层重复。
- **算损失：**MSE：预测 → 误差 → 平方 → 平均；交叉熵：看 y 取 1 还是 0，只算对应的一项 $-\ln(\cdot)$。
- **梯度下降：**① 求导（或偏导）；② 代入当前参数得梯度；③ $w := w - \eta \cdot$ 梯度；④ 回代检查损失是否下降。
- **反向传播：**先完整前向，记下每个中间值；再从损失往回，逐个乘局部导数；ReLU 处看 z 的正负。
- **读损失曲线：**找验证损失最低点 = 早停位置；训练降、验证升 = 过拟合；都高 = 欠拟合。

7.5 从课本到现实：这些知识到底用在哪里

从课本到现实

- **购物 / 视频推荐**。每个商品、每个用户都被表示成一个特征向量（第 3 章），系统在向量空间里找“离你喜欢的东西最近”的内容。真实系统的特征往往有几百上千维，并且会先做归一化，避免销量这类大数值特征“一家独大”。
- **手机人脸解锁**。摄像头拍到的人脸先变成像素张量，深度网络逐层提取特征（边缘 → 五官 → 整张脸），最后得到一个“人脸向量”，与录入时的向量比较距离。距离小于阈值就解锁——这里同时用到了第 3 章的距离和第 4 章 M–P 模型式的“超过门槛才激活”。

- **输入法联想**。根据你已经输入的字预测下一个最可能的词，这与 GPT-2 “根据前文预测下一个词”的训练目标本质相同，只是规模小得多；分类的损失正是交叉熵（第 5 章）。
- **导航软件估计到达时间**。输入是路段长度、实时车速、时段等特征，输出是一个连续的时间值——典型的回归任务，可用 MSE 类损失训练，并在历史行程数据上验证误差。

7.6 后续课程连接

这些知识以后在哪里还会出现

- **线性代数：**数据矩阵、矩阵乘法 $W\boldsymbol{x}$、“线性层叠加仍线性”的证明，都是矩阵运算。
- **高等数学（多元微积分）：**偏导数、梯度、方向导数、链式法则——本讲第 6 章的全部工具。
- **概率论与数理统计：**独立同分布、Sigmoid 输出的概率解释、交叉熵与极大似然估计。
- **最优化方法 / 运筹学：**梯度下降是无约束优化最基本的方法；局部最小与全局最小、步长选择都是该课程的核心问题。
- **自动控制原理：**梯度下降 $w_{t+1} = (1 - 2\eta)w_t$ 本身就是一个离散时间系统，“收敛条件 $|1 - 2\eta| < 1$”与离散系统“极点在单位圆内才稳定”是同一件事；Adam 的动量项类似一阶低通滤波；智能体“感知—决策—行动—观察”的闭环即反馈控制。
- **数据结构与算法（C++）：**图像以多维数组存储，按行优先展开成一维内存；神经网络的计算图是有向无环图，反向传播就是在这张图上按拓扑逆序遍历。

拓展联想　以下只用于建立联系，当前不要求掌握：卷积神经网络（CNN）把“同一组小权重在图像上滑动”作为一层，大幅减少参数；Transformer 的注意力本质上是“用数量积衡量两个词向量有多相关”，再按相关程度加权求和——仍然是本讲的向量、数量积、加权和与 Softmax（Sigmoid 的多类推广）。

正式练习（38 道）

练习分三层：**A. 基础巩固 25 道**（第一次学完即可完成）、**B. 中等偏下提升 10 道**（把 2–4 个相邻知识点连起来）、**C. 跨学科迁移 3 道**（把本讲知识放到相邻学科的简单情境中，所需背景已在题干给出）。请先独立完成，再查阅书末的答案速查与图解解析。题目中的图只呈现已知条件，不提示答案。

知识点—题目对应表

核心知识点	基础题	提升题	跨学科
K1 机器学习定义；AI / ML / DL	1, 2	—	—
K2 样本、特征、标签	11	—	36
K3 数据表示：向量 / 矩阵 / 张量	3, 4, 5, 16	—	38
K4 距离与特征缩放	21	28	—
K5 训练 / 验证 / 测试集	10, 18	29	—
K6 神经元、M–P、激活函数、非线性	6, 7, 19, 20, 24	26, 35	—
K7 MSE	8, 22	34	37
K8 交叉熵	17	33	—
K9 过拟合、早停、数据增强	12, 13, 25	29	—
K10 梯度下降、梯度、学习率	9, 14, 15, 23	27, 34	36
K11 BGD / SGD / 小批量 / Adam	—	30, 31	—
K12 反向传播（链式法则）	—	32, 35	—

A. 基础巩固训练（25 道）

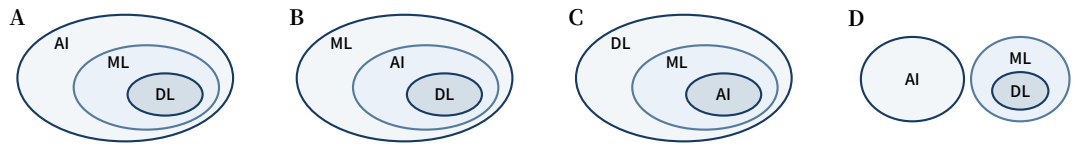
A1　单项选择题（10 道）

1. 下列哪一项最准确地描述了“机器学习”？　基础

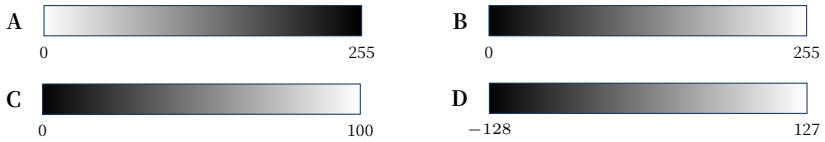


A. 程序员预先写好全部 if–else 规则，程序按规则输出答案
B. 程序从带答案的数据中自动总结规律，再用规律对新数据做预测
C. 程序把训练数据原样存下来，遇到问题就查表，查不到就不回答
D. 只要程序处理的是图像，就属于机器学习

2. 下列四幅图中，哪一幅正确表示了人工智能（AI）、机器学习（ML）、深度学习（DL）的关系？　基础

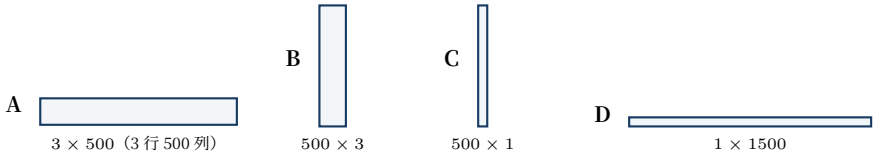


3. 8 位灰度图像中，像素值的取值范围与亮度的对应关系是（ ）。　基础



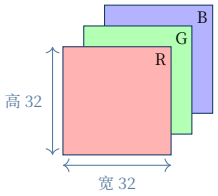
A. 0 表示白色，255 表示黑色　　**B.** 0 表示黑色，255 表示白色
C. 取值 $0 \sim 100$，0 黑、100 白　　**D.** 取值 $-128 \sim 127$

4. 某数据集记录了 500 名学生，每名学生有身高、体重、年龄 3 个特征。按“每行一个样本”的约定，特征矩阵 X 的形状是（ ）。　基础



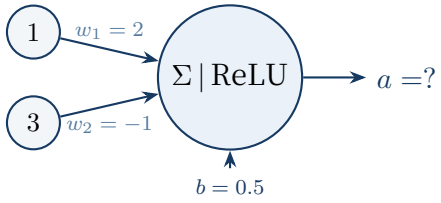
A. 3×500　　**B.** 500×3　　**C.** 500×1　　**D.** 1×1500

5. 一张 32×32 的 RGB 彩色图片（每个通道每个像素存 1 个数）一共包含多少个数值?　基础



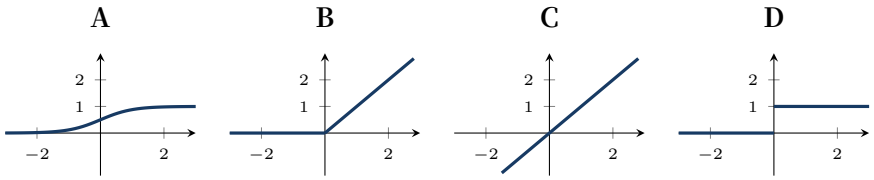
A. 1024　　**B.** 2048　　**C.** 3072　　**D.** 96

6. 一个神经元的输入 $\boldsymbol{x} = (1, 3)$，权重 $\boldsymbol{w} = (2, -1)$，偏置 $b = 0.5$，激活函数为 ReLU。它的输出 a 是（ ）。　基础

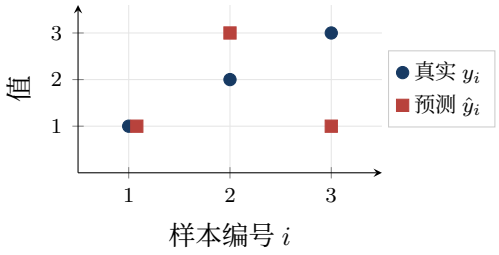


A. -0.5　　**B.** 0　　**C.** 0.5　　**D.** 5.5

7. 下列四个函数图像中，哪一个是 ReLU 激活函数 $\mathrm{ReLU}(z)=\max(0,z)$？（四幅图坐标范围相同）　基础

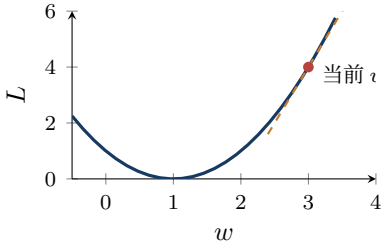


8. 三个样本的真实值 $\boldsymbol{y}=(1,2,3)$，模型预测值 $\hat{\boldsymbol{y}}=(1,3,1)$。均方误差 $L=\frac{1}{n}\sum(y_i-\hat{y}_i)^2$ 等于（ ）。　基础



A. 1　　**B.** $\frac{5}{3}$　　**C.** 5　　**D.** $\frac{1}{3}$

9. 损失函数 $L(w)=(w-1)^2$，当前 $w=3$，此处 $\frac{dL}{dw}=4$，学习率 $\eta=0.1$。执行一次梯度下降后 w 等于（ ）。　基础



A. 3.4　　**B.** 2.6　　**C.** -1　　**D.** 2.96

10. 训练过程中需要决定“训练到第几轮停止”（早停）。应该依据哪部分数据上的表现来决定？　基础



A. 训练集　　**B.** 验证集　　**C.** 测试集　　**D.** 三者任选其一，效果相同

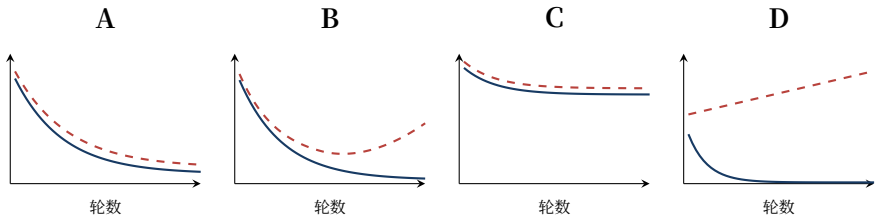
A2　多项选择题（5 道）

11. 下列各项中，哪些在所给任务中充当**标签**（而非特征）？　基础

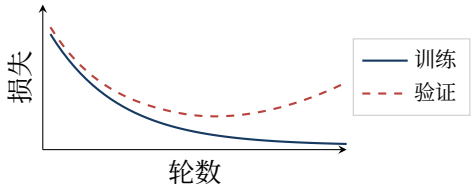


A. 房价预测任务中的“房价”　　**B.** 猫狗识别任务中的“图像像素值”
C. 疾病诊断任务中的“是否患病”　　**D.** “根据身高预测体重”任务中的“身高”

12. 下面四幅图是四个模型训练时的损失曲线（实线：训练损失；虚线：验证损失；坐标范围相同）。哪些图显示出了**过拟合**？　基础

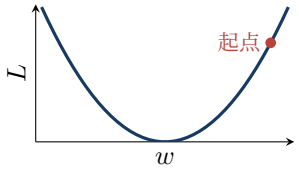


13. 某图像分类模型的训练曲线如图所示，验证损失在后期上升。下列哪些做法能**合理地**缓解这一问题？　基础



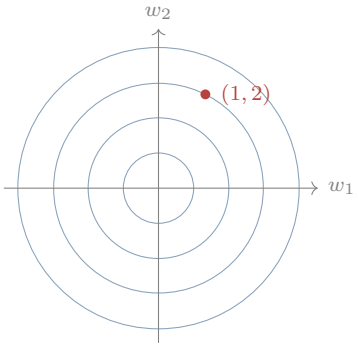
A. 使用验证集监控，并在验证损失不再下降时提前停止训练
B. 对训练图片做随机翻转、旋转、剪裁等数据增强
C. 用测试集反复调整超参数，直到测试损失最低
D. 继续增加训练轮数，直到训练损失变为 0

14. 关于梯度下降中的学习率 η，下列说法正确的有（ ）。（可借助碗形损失 $L = w^2$ 思考）　基础



A. 学习率过大，参数可能在最低点两侧来回跳动，甚至发散
B. 学习率过小，收敛很慢，训练时间长
C. 学习率越大，一定越快到达最低点
D. 每一步的移动量由学习率与该点梯度共同决定

15. 设 $L(w_1, w_2) = w_1^2 + w_2^2$，当前点为 $(1, 2)$（见等高线图）。下列说法正确的有（　）。 基础

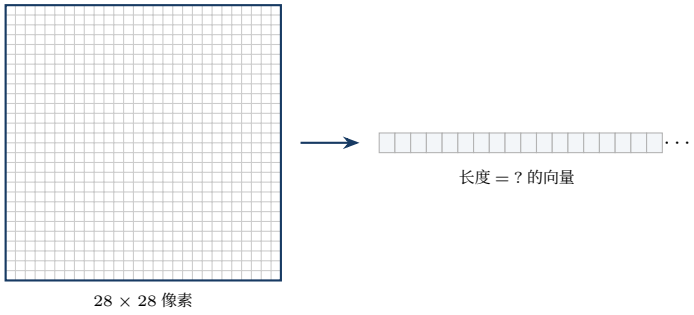


A. 该点梯度为 $\nabla L = (2, 4)$　　**B.** 梯度方向是 L 增加最快的方向

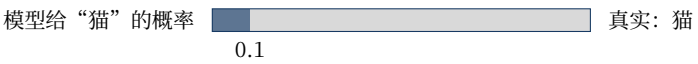
C. 沿 $(-2, -4)$ 方向 L 下降最快　　**D.** 梯度下降应沿梯度方向更新参数

A3　填空题（5 道）

16. 一张 28×28 的灰度手写数字图片按行拉平成一个向量，该向量的维度为 _____。 基础



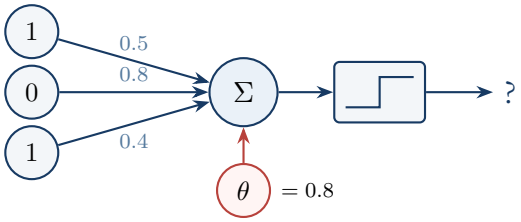
17. 一张图片实际是猫（$y = 1$），模型输出“是猫”的概率 $\hat{y} = 0.1$。用二分类交叉熵（自然对数）计算，该样本的损失 $L =$_____（保留两位小数）。 基础



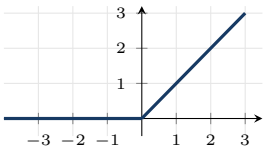
18. 共有 1000 个样本，按 70% / 10% / 20% 划分为训练集、验证集、测试集，则三者的样本数依次为 _____、_____、_____。 基础



19. M–P 神经元的输入 $\boldsymbol{x} = (1, 0, 1)$，权重 $\boldsymbol{w} = (0.5, 0.8, 0.4)$，阈值 $\theta = 0.8$，激活函数为阶跃函数（$f \geq 0$ 输出 1，否则输出 0）。则 $f = \sum w_i x_i - \theta =$_____，神经元输出为 _____。 基础



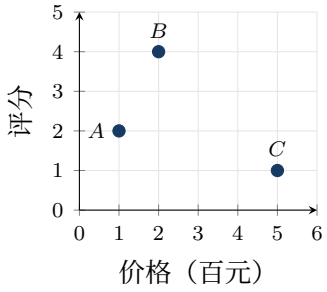
20. $\mathrm{ReLU}(-3)+\mathrm{ReLU}(2)=$_____。　基础



A4　解答题（5 道）

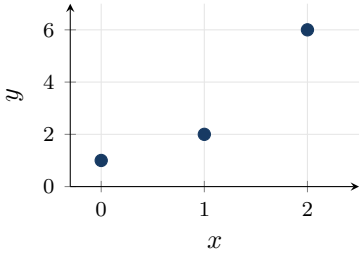
21.（特征空间与距离）三件商品用两个特征 [价格（百元），评分] 表示：$A=(1,2)$，$B=(2,4)$，$C=(5,1)$。用户喜欢商品 A。　基础

(1) 分别计算 A 与 B、A 与 C 的欧氏距离；(2) 按“推荐离 A 最近的商品”的规则，应推荐哪一件?



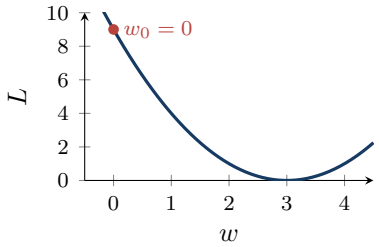
22.（线性模型与 MSE）三个样本 (x,y)：$(0,1)$，$(1,2)$，$(2,6)$。　基础

(1) 用模型 $\hat{y}=2x+1$ 计算三个预测值；(2) 计算该模型的 MSE；(3) 另一个模型 $\hat{y}=2.5x+0.5$ 的 MSE 是多少? 哪个模型更好?



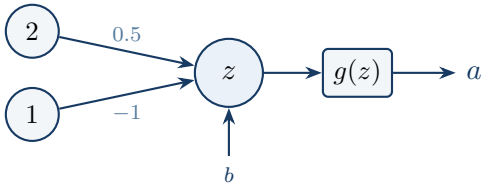
23.（梯度下降）损失函数 $L(w)=(w-3)^2$，初始 $w_0=0$，学习率 $\eta=0.25$。　基础

(1) 写出 $L'(w)$；(2) 计算 w_1、w_2；(3) 计算 $L(w_0)$、$L(w_1)$、$L(w_2)$，并说明损失的变化趋势。



24.（神经元计算）一个神经元输入 $\boldsymbol{x} = (2, 1)$，权重 $\boldsymbol{w} = (0.5, -1)$，偏置 $b = 1$。 基础

(1) 计算 z；(2) 若激活函数为 ReLU，输出是多少？若为 Sigmoid $\sigma(z) = \frac{1}{1+e^{-z}}$ 呢（保留三位小数）？(3) 若把偏置改为 $b = -1$，两种激活下的输出又各是多少？



25.（读损失表，早停）某模型每 2 轮记录一次损失： 基础

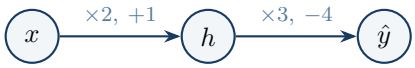
轮数	2	4	6	8	10	12	14	16
训练损失	0.80	0.55	0.40	0.30	0.22	0.16	0.11	0.08
验证损失	0.85	0.62	0.48	0.41	0.39	0.42	0.47	0.55

(1) 在同一坐标系中画出两条曲线的大致形状；(2) 按早停原则应选第几轮的模型？(3) 从第几轮之后出现过拟合迹象？为什么不能根据训练损失来选？

B. 中等偏下提升训练（10 道）

B1　单项选择题（3 道）

26. 一个两层网络：$h = 2x + 1$，$\hat{y} = 3h - 4$，中间**没有**激活函数。下列说法正确的是（ ）。 中等偏下



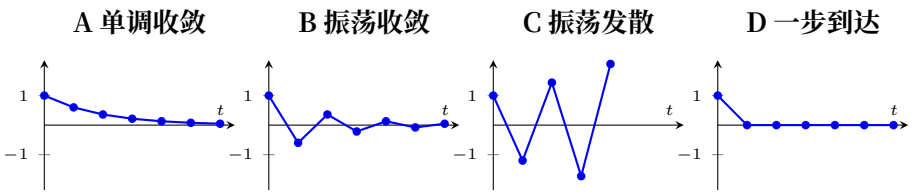
A. 该网络等价于 $\hat{y} = 6x - 1$，只能表示一条直线

B. 因为有两层，所以它能拟合 V 形折线

C. 该网络等价于 $\hat{y} = 5x - 3$

D. 若把 h 改为 $h = \mathrm{ReLU}(2x + 1)$，整个网络的图像仍然一定是一条直线

27. 对 $L(w) = w^2$ 做梯度下降，$w_0 = 1$，学习率 $\eta = 1.1$。下面四幅图是参数序列 w_t 的四种典型变化方式（横轴为迭代次数 t）。本题的参数序列属于哪一种？ 中等偏下



28. 商品用 [价格（元），评分（满分 5）] 表示：$A=(99,\ 4.8)$，$B=(109,\ 4.7)$，$C=(99,\ 2.0)$。用户喜欢 A。下列说法正确的是（ ）。　中等偏下

商品	A	B	C
价格 / 元	99	109	99
评分	4.8	4.7	2.0

A. 直接用原始数值算欧氏距离，B 离 A 更近

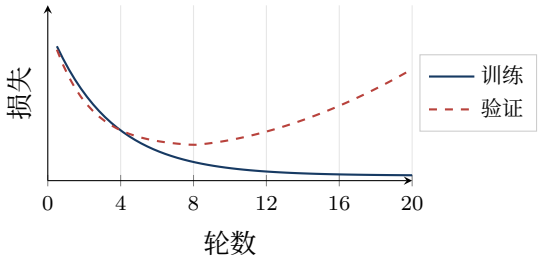
B. 直接用原始数值算欧氏距离，C 离 A 更近；这是因为价格的数值尺度远大于评分，距离被价格主导，这个结论并不合理

C. 直接用原始数值算，B、C 到 A 的距离相同

D. 特征缩放只改变距离的数值，不会改变“谁离 A 更近”

B2　多项选择题（2 道）

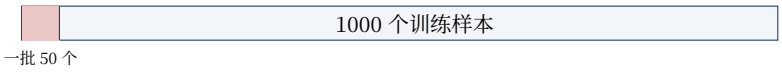
29. 某模型的训练、验证损失曲线如下（验证损失在第 8 轮最低）。下列说法正确的有（ ）。　中等偏下



A. 第 8 轮之后模型出现过拟合迹象　　**B.** 按早停原则应选第 8 轮附近的模型

C. 训练损失持续下降，说明模型的泛化能力越来越好　　**D.** 应该用测试集的损失来选择停止轮数

30. 训练集有 1000 个样本，小批量梯度下降的批大小为 50。下列说法正确的有（ ）。（一轮 = 全部样本用一遍）　中等偏下

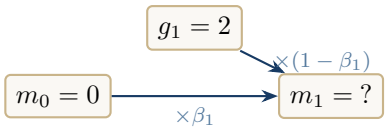


A. 小批量梯度下降每轮更新参数 20 次　　**B.** 批量梯度下降（BGD）每轮更新参数 1 次

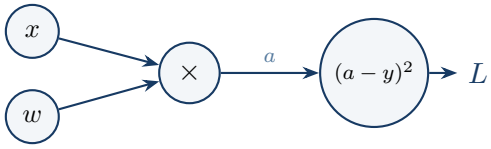
C. 随机梯度下降（SGD）每轮更新参数 1000 次　　**D.** SGD 每一次更新的方向都与 BGD 完全相同

B3　填空题（3 道）

31. Adam 优化器取 $\beta_1 = 0.9$，$\beta_2 = 0.999$，$m_0 = v_0 = 0$。第 1 步的梯度 $g_1 = 2$，则 $m_1 =$_____，$v_1 =$_____，偏差修正后 $\hat{m}_1 = \dfrac{m_1}{1-\beta_1^1} =$_____。 中等偏下



32. 模型 $a = wx$，损失 $L = (a-y)^2$。已知 $x = 2$，$w = 1.5$，$y = 2$。由链式法则，$\dfrac{\partial L}{\partial w} =$_____；若学习率 $\eta = 0.1$，更新一次后 $w =$_____。 中等偏下



33. 两个样本的二分类交叉熵（自然对数）：样本 1 真实 $y = 1$，预测 $\hat{y} = 0.8$；样本 2 真实 $y = 0$，预测 $\hat{y} = 0.4$。两个样本的平均损失约为 _____（保留三位小数）。 中等偏下



B4　综合大题（2 道）

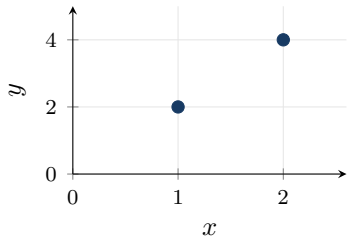
34.（从数据到一次梯度下降）两个样本 (x, y)：$(1, 2)$，$(2, 4)$。模型为不带偏置的线性模型 $\hat{y} = wx$，损失取 MSE：$L(w) = \frac{1}{2}\left[(w\cdot 1 - 2)^2 + (w\cdot 2 - 4)^2\right]$。 中等偏下

(1) 把 $L(w)$ 化简为 $k(w-2)^2$ 的形式，并求 $L(0)$；

(2) 求 $L'(w)$ 以及 $w = 0$ 处的梯度；

(3) 取 $w_0 = 0$，$\eta = 0.1$，做一次梯度下降，求 w_1 与 $L(w_1)$；

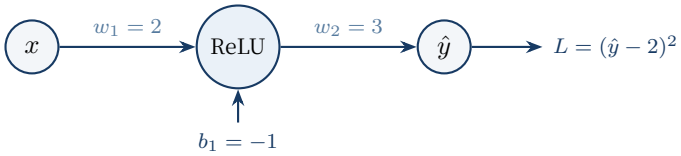
(4) 学习率取多少时，从 $w_0 = 0$ 出发恰好一步到达最优 $w^* = 2$？学习率在什么范围内梯度下降能收敛？



35.（小网络的前向、反向与更新）一个 1–1–1 的网络：$z_1 = w_1 x + b_1$，$h = \mathrm{ReLU}(z_1)$，$\hat{y} = w_2 h$，损失 $L = (\hat{y}-y)^2$。已知 $x = 1$，$y = 2$，$w_1 = 2$，$b_1 = -1$，$w_2 = 3$。 中等偏下

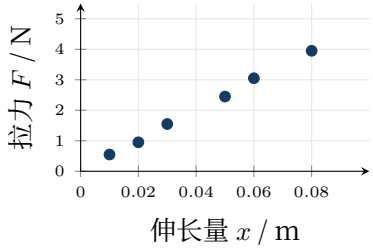
(1) 前向传播：求 z_1、h、$\hat{y}$、L；

(2) 反向传播：求 $\dfrac{\partial L}{\partial w_2}$、$\dfrac{\partial L}{\partial w_1}$、$\dfrac{\partial L}{\partial b_1}$；
(3) 取 $\eta = 0.05$ 更新三个参数，再做一次前向传播，验证损失是否下降。



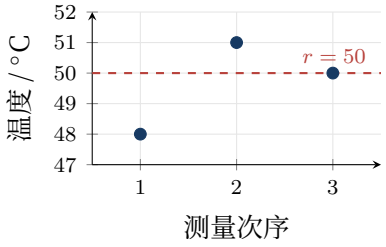
C. 跨学科迁移训练（3 道）

36.（大学物理 × 线性模型，单选）背景：胡克定律 $F = kx$，其中 F 为弹簧拉力（N），x 为伸长量（m），k 为劲度系数（N/m）。某同学测得多组 (x, F) 数据，用不带偏置的线性模型 $\hat{F} = w\,x$ 拟合，训练后得到 $w = 50$。下列说法正确的是（ ）。 跨学科



A. 当 $x = 0.04$ m 时，模型预测拉力为 2 N；参数 w 对应物理量劲度系数 k
B. 当 $x = 0.04$ m 时，模型预测拉力为 2 N；参数 w 对应弹簧的质量
C. 当 $x = 0.04$ m 时，模型预测拉力为 1250 N；参数 w 对应劲度系数 k
D. 当 $x = 0.04$ m 时，模型预测拉力为 0.0008 N；参数 w 对应劲度系数 k

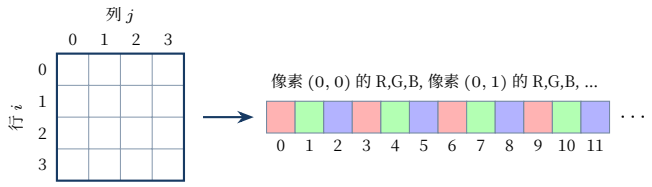
37.（自动控制 × 损失函数，多选）背景：恒温箱的目标温度 $r = 50\,^\circ$C，三次测量值 $y = 48,\ 51,\ 50\,^\circ$C。控制中常用误差 $e = r - y$ 的均方值 $J = \frac{1}{n}\sum e_i^2$ 作为性能指标。下列说法正确的有（ ）。 跨学科



A. $J = \dfrac{5}{3} \approx 1.67$　　**B.** 误差 $+1$ 与 -1 对 J 的贡献相同
C. 在该指标下，J 越小表示控制效果越好　　**D.** 误差为 2 的测量受到的惩罚是误差为 1 的 2 倍

38.（数据结构 / C++ × 图像张量，填空）背景：一张 $H \times W$ 的 RGB 图像在内存中常按“行优先、像素内 RGB 连续”存成一维数组 `unsigned char img[H*W*3]`，第 i 行、第 j 列像素的第 c 个通道（$c = 0, 1, 2$ 分别为 R、G、B，下标均从 0 开始）的下标 跨学科

为 $\mathrm{idx} = (i \cdot W + j) \cdot 3 + c$。对 $H = W = 4$ 的图像，像素 $(i, j) = (2, 1)$ 的 B 通道下标为 _____；整个数组共占 _____字节。



答案速查

本节只给结果，过程见后面的图解解析。

A. 基础巩固（25 道）

单选 1–10	1. B　2. A　3. B　4. B　5. C　6. B　7. B　8. B　9. B　10. B
多选 11–15	11. AC　12. BD　13. AB　14. ABD　15. ABC
填空 16–20	16. 784　17. ≈ 2.30　18. 700、100、200　19. 0.1；1　20. 2
解答 21–25	21. $d(A,B)=\sqrt{5}\approx 2.24$，$d(A,C)=\sqrt{17}\approx 4.12$，推荐 B
	22. 预测 1, 3, 5；MSE $=2/3\approx 0.667$；新模型 MSE $=0.5$，新模型更好
	23. $L'(w)=2(w-3)$；$w_1=1.5$，$w_2=2.25$；L：$9\to 2.25\to 0.5625$，逐步下降
	24. $z=1$；ReLU 输出 1，Sigmoid 输出 ≈ 0.731；$b=-1$ 时 $z=-1$，ReLU 输出 0，Sigmoid ≈ 0.269
	25. 选第 10 轮；第 10 轮之后（第 12 轮起验证损失上升）出现过拟合迹象

B. 中等偏下提升（10 道）

单选 26–28	26. A　27. C　28. B
多选 29–30	29. AB　30. ABC
填空 31–33	31. $m_1=0.2$，$v_1=0.004$，$\hat{m}_1=2$　32. $\partial L/\partial w=4$；$w=1.1$　33. ≈ 0.367
大题 34	$L=2.5(w-2)^2$，$L(0)=10$；$L'(w)=5(w-2)$，$L'(0)=-10$；$w_1=1$，$L(w_1)=2.5$；$\eta=0.2$；$0<\eta<0.4$
大题 35	前向 $z_1=1, h=1, \hat{y}=3, L=1$；$\partial L/\partial w_2=2$，$\partial L/\partial w_1=6$，$\partial L/\partial b_1=6$；更新后 $w_2=2.9, w_1=1.7, b_1=-1.3$，$L=0.7056<1$

C. 跨学科迁移（3 道）

36–38	36. A　37. ABC　38. 29；48 字节

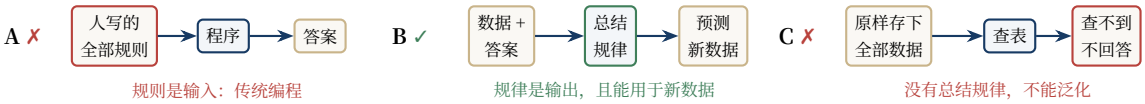
详细解析 · A. 基础巩固

第 1 题　机器学习的定义

答案：B　基础　**考查：**K1 机器学习定义

依据：机器学习 = 从数据（经验）中自动学习规律，并用规律预测或决策，而无需明确编程所有规则（第 2.2 节）。

逐项图解：



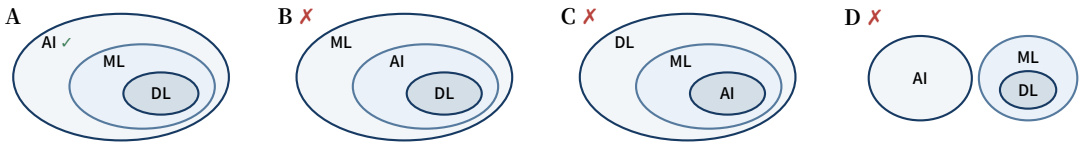
A 错：规则由人写死，性能不随经验提高（ELIZA 式）。B 对：箭头方向是“数据 + 答案 → 规律”，并把规律用于新数据。C 错：只是存储与查表，遇到没见过的输入就失效，这正是“背答案”，没有泛化。D 错：是否属于机器学习取决于“是否从数据中学习”，与数据类型无关（D 不涉及可画的结构，不配图）。

常见错误：把“处理图像 / 用了 AI 名称”误当成机器学习的判断标准。

一句话总结：看规则是“人写的”还是“从数据中学出来的”。

第 2 题　AI、ML、DL 的包含关系

答案：A　基础　**考查：**K1

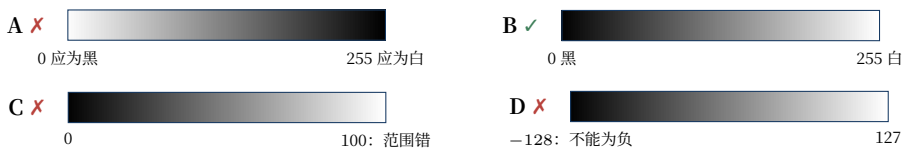


判断：AI 是最大的领域，ML 是 AI 的核心实现方式（子集），DL 是使用多层神经网络的 ML（子集的子集）。A 的三层嵌套顺序正确。B 把 AI 放进 ML 内部——但 ELIZA 这类规则系统是 AI 却不是 ML，说明 AI 不可能小于 ML。C 顺序完全颠倒。D 把 AI 与 ML 画成不相交，与“ML 是 AI 的实现方式”矛盾。

一句话总结：AI ⊃ ML ⊃ DL，最外圈最大。

第 3 题　灰度像素值

答案：B　基础　**考查：**K3 图像表示



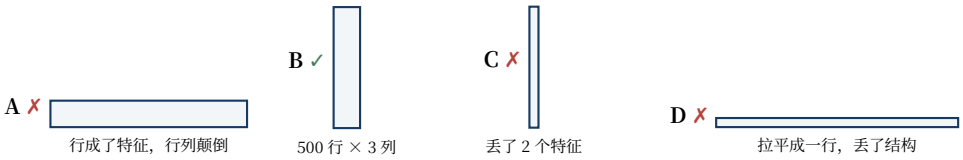
8 位灰度 $= 2^8 = 256$ 个等级，取 $0 \sim 255$，数值越大越亮。A 的渐变方向反了；C 的上限不对；D 出现负数（那是“有符号 8 位整数”的范围，不用于像素）。

常见错误：把 0 与“白纸”联想在一起。记忆：0 = 没有光 = 黑。

一句话总结：0 黑 255 白，一共 256 级。

第 4 题　数据集形状

答案：B　基础　**考查：**K3 数据集形状 $n \times d$

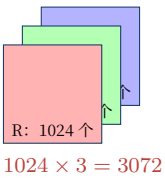


形状 = 样本数 × 特征维度 = 500 × 3。B 的“高而窄”块正是 500 行（每行一个学生）、3 列（身高、体重、年龄）。A 是转置；C 只剩一个特征；D 虽然数的个数也是 1500，但不再是“每行一个样本”的矩阵。

一句话总结：行 = 样本，列 = 特征。

第 5 题　彩色图像的数值个数

答案：C　基础　**考查：**K3 张量 $H \times W \times 3$



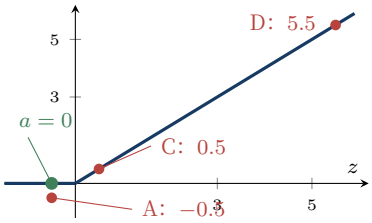
每个通道是 $32 \times 32 = 1024$ 个数，三个通道共 $1024 \times 3 = 3072$。A（1024）只算了一个通道——相当于灰度图；B（2048）只算了两个通道；D（96）是 32×3，把“面积”错当成“边长”。

常见错误：忘记乘 3，或者把 32×32 算成 $32 + 32$。

一句话总结：彩色图数值个数 $= H \times W \times 3$。

第 6 题　单个神经元的输出

答案：B　基础　**考查：**K6 神经元两步计算



第一步：$z = 2 \times 1 + (-1) \times 3 + 0.5 = -0.5$。

第二步：$a = \mathrm{ReLU}(-0.5) = \max(0, -0.5) = 0$。

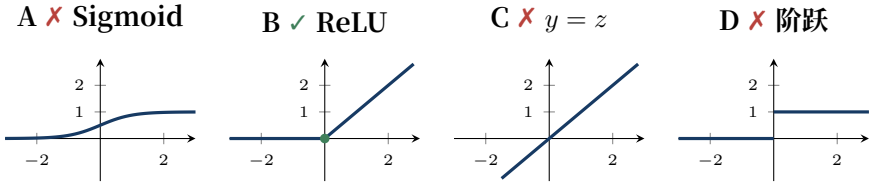
图上证据：$z = -0.5$ 落在 ReLU 左侧的水平段，输出必为 0（绿点）。

A（-0.5）：停在 z，漏了激活——红点 A 不在 ReLU 曲线上；C（0.5）：符号算反；D（5.5）：把 -1×3 算成 $+3$。

一句话总结：先算 z，再过激活；ReLU 把负数变 0。

第 7 题　识别 ReLU 图像

答案：B　基础　**考查：**K6 激活函数图像

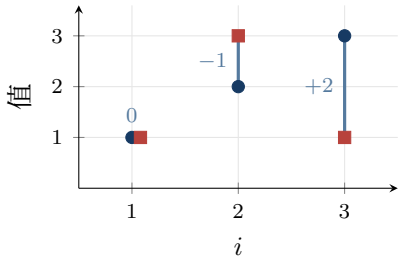


ReLU 的两个特征：$z<0$ 时恒为 0；$z>0$ 时等于 z（斜率 1 的射线），在原点折弯（B 图绿点）。A 在右侧趋于 1 而不是一直增大；C 在负半轴也是斜线，没有“截断”；D 在正半轴是水平线而不是 $y=z$。

一句话总结： ReLU = “负数砍成 0 + 正数原样通过”，图像是一条折线。

第 8 题　均方误差

答案：B　基础　**考查：** K7 MSE



误差 $y_i-\hat{y}_i=0,\,-1,\,2$（图中蓝线段），平方 $0,1,4$，平均 $L=\frac{0+1+4}{3}=\frac{5}{3}$。

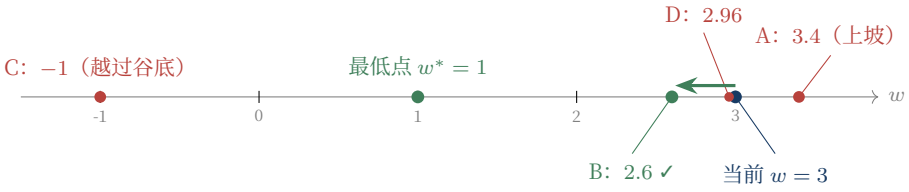
A（1）：是平均**绝对**误差 $\frac{0+1+2}{3}$，没有平方；C（5）：平方和，忘了除以 n；D（$\frac{1}{3}$）：误差直接平均 $\frac{0-1+2}{3}$，正负相互抵消。

常见错误： 漏掉“平方”或漏掉“除以 n”。

一句话总结： MSE = 误差 → 平方 → 求和 → 除以 n。

第 9 题　一次梯度下降

答案：B　基础　**考查：** K10 更新公式



$w:=w-\eta\cdot\frac{dL}{dw}=3-0.1\times4=2.6$，向最低点 $w^*=1$ 靠近了 0.4。A（3.4）：“加”了梯度，往上坡走，远离最低点；C（-1）：忘乘学习率，一步走了 4，越过最低点跑到另一侧；D（2.96）：把学习率当成 0.01。

一句话总结： 减去“学习率 × 梯度”，方向朝谷底。

第 10 题　早停依据哪部分数据

答案：B　基础　**考查：** K5 验证集的作用

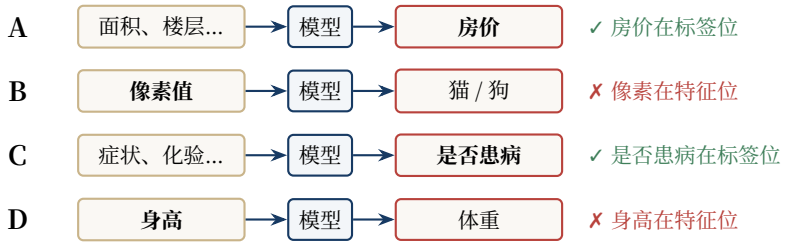


早停属于“选择模型”的决定，必须在验证集上做。A：训练损失几乎总在下降，用它永远不会“停”；C：用测试集做决定，测试结果就不再是“没见过的期末题”；D：三者用途不同，不能互换。

一句话总结： 学用训练集，选用验证集，考用测试集。

第 11 题　特征还是标签

答案：AC　基础　**考查：**K2 标签由任务决定

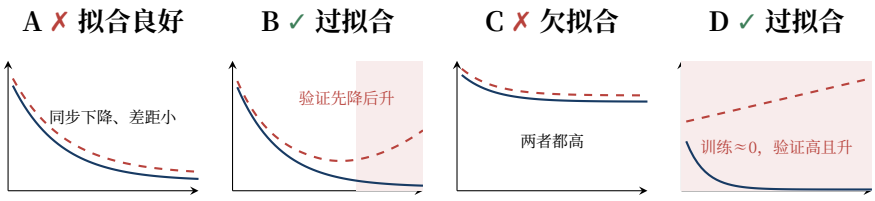


把每个选项放进“特征 → 模型 → 标签”的流程：要预测的是标签（A 房价、C 是否患病）；拿来预测的是特征（B 像素、D 身高）。D 的陷阱在于身高在“近视预测”里可以是特征、在“预测身高”任务里可以是标签——本题任务已明确是“根据身高预测体重”。

一句话总结：要预测的是标签，拿来预测的是特征。

第 12 题　识别过拟合曲线

答案：BD　基础　**考查：**K9 过拟合

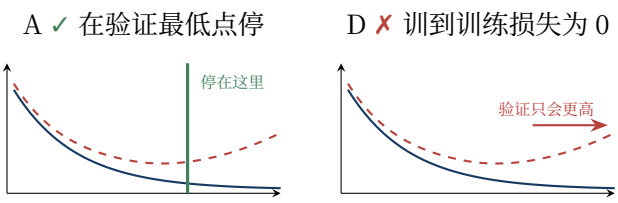


过拟合的图上证据是“训练损失低、验证损失明显更高且上升”（阴影区）。B：训练一直降，验证在中段后回升；D：训练几乎为 0，验证从一开始就高且越来越高。A 两条曲线同步下降、差距很小，是良好拟合；C 两条都停在高位，是**欠拟合**（模型太简单或训练不足）。

一句话总结：看两条曲线是否“分叉”：一降一升即过拟合。

第 13 题　缓解过拟合的做法

答案：AB　基础　**考查：**K9 早停、数据增强

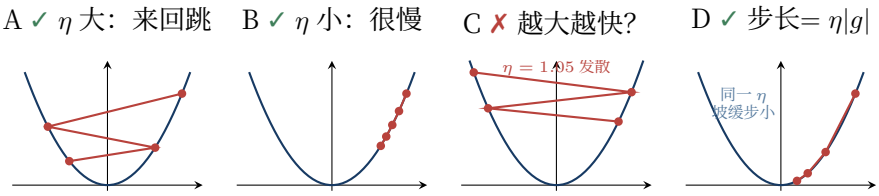


A 对：早停正是在验证损失最低处（绿线）停下。B 对：数据增强让模型见到更多变化（翻转、旋转后的猫仍是猫，见图 5.5），不再死记训练图片的细节。C 错：用测试集反复调参，测试集就“泄露”了，最终报告的测试损失会偏乐观，并不能真正提升泛化。D 错：图中训练损失越往后越低，验证损失却越来越高，继续训练只会加重过拟合。

一句话总结：早停看验证集，增强扩充训练集；测试集不能拿来调。

第 14 题　学习率

答案：ABD　基础　**考查：**K10 学习率

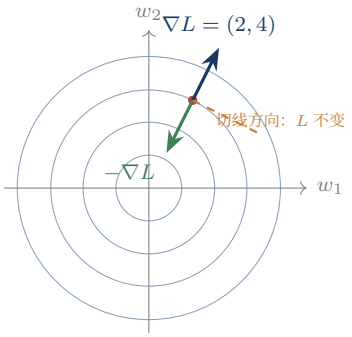


A、B 分别对应课件“太大 → 跳过最低点甚至发散”“太小 → 收敛很慢”。C 错：由第 6.4 节定理，对 $L = w^2$ 只要 $\eta > 1$ 就发散（第 3 幅图），并非越大越快。D 对：移动量 $= \eta \times$ 梯度，第 4 幅图中 $\eta = 0.2$ 固定，越接近谷底梯度越小，步子自动变小。

一句话总结：学习率要“适中”；真实步长还取决于梯度大小。

第 15 题　梯度及其方向

答案：ABC　基础　**考查：**K10 梯度的几何意义



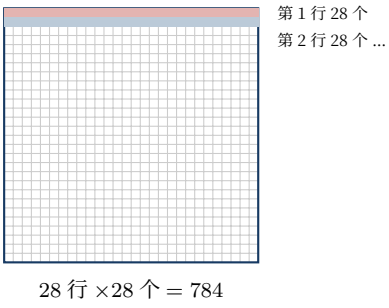
A 对：$\nabla L = (2w_1, 2w_2) = (2, 4)$。B 对：第 6.3 节的证明——方向导数 $= |\nabla L| \cos\theta$，$\theta = 0$ 时最大。图中蓝箭头垂直于圆形等高线、指向外（更高的等高线）。C 对：$(-2, -4)$ 是负梯度（绿箭头），指向圆心谷底，下降最快。D 错：沿梯度走是上坡，梯度下降要“减”梯度。

常见错误：把“梯度方向”和“更新方向”混为一谈。

一句话总结：梯度指向上坡，更新沿负梯度。

第 16 题　拉平后的维度

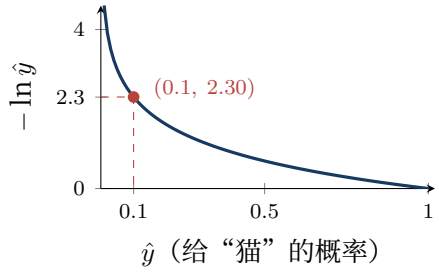
答案：784　基础　**考查：**K3



灰度图每像素 1 个数，拉平就是把 28 行首尾相接：$28 \times 28 = 784$。**单位：**无（维度是个数）。**易错：**写成 $28 + 28 = 56$，或误乘 3（那是彩色图）。

第 17 题　交叉熵计算

答案： ≈ 2.30（$= \ln 10$）　基础　**考查：** K8 交叉熵



$y = 1$，公式只剩第一项：$L = -\ln \hat{y} = -\ln 0.1 = \ln 10 \approx 2.30$。图上红点位于曲线陡升段：模型把真实类别的概率给得很低，惩罚很重。**可接受答案：** 2.30、2.303、$\ln 10$。

常见错误： 把 $\hat{y}$ 代入第二项 $-\ln(1-\hat{y}) = -\ln 0.9 \approx 0.105$——那是 $y=0$ 时才用的项。

第 18 题　数据集划分

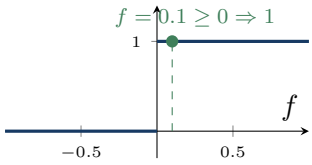
答案：700、100、200　基础　**考查：** K5

$1000 \times 70\% = 700$，$1000 \times 10\% = 100$，$1000 \times 20\% = 200$；检查：$700 + 100 + 200 = 1000$。



第 19 题　M--P 神经元

答案： $f = 0.1$；**输出 1**　基础　**考查：** K6 M–P 模型



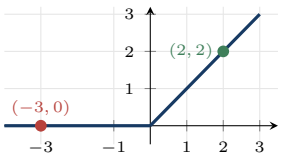
加权和：$0.5 \times 1 + 0.8 \times 0 + 0.4 \times 1 = 0.9$；$f = 0.9 - 0.8 = 0.1 \geq 0$，阶跃函数输出 1。

图上证据： $f = 0.1$ 在原点右侧，落在阶跃函数的“1”台阶上。

易错： 把 $x_2 = 0$ 对应的权重 0.8 也加进去（得 $f = 0.9$，结论碰巧也是 1，但数值错）；或忘记减阈值。

第 20 题　ReLU 求值

答案：2　基础　**考查：** K6 ReLU

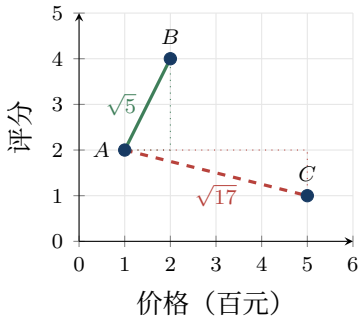


$\mathrm{ReLU}(-3) = \max(0, -3) = 0$（红点在水平段上），$\mathrm{ReLU}(2) = 2$（绿点在斜线上），和为 2。**易错：** 写成 $-3 + 2 = -1$，忘了负数被截成 0。

第 21 题　商品距离与推荐

答案：$\sqrt{5}\approx 2.24$，$\sqrt{17}\approx 4.12$，推荐 B　基础　**考查：**K4 欧氏距离

题意：在二维特征平面上找离 A 最近的点。**公式：**$d=\sqrt{(\Delta x_1)^2+(\Delta x_2)^2}$。



第一步：$d(A,B)=\sqrt{(2-1)^2+(4-2)^2}=\sqrt{1+4}=\sqrt{5}\approx 2.24$（绿色直角三角形，两直角边 1 与 2）。

第二步：$d(A,C)=\sqrt{(5-1)^2+(1-2)^2}=\sqrt{16+1}=\sqrt{17}\approx 4.12$（红色三角形，直角边 4 与 1）。

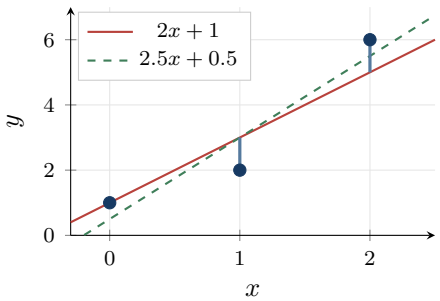
结果：$d(A,B)<d(A,C)$，推荐 B。**检查：**图上绿线明显短于红线。

易错：忘记开平方（比较大小时结论不变，但距离数值错）；把差值的绝对值直接相加（那是另一种距离“曼哈顿距离”）。

同类题：写坐标差 → 平方 → 相加 → 开方；特征量纲不同时先缩放（见第 28 题）。

第 22 题　线性模型与 MSE

答案：MSE $=\frac{2}{3}$ 与 0.5，后者更好　基础　**考查：**K7 MSE；线性模型



(1) $\hat{y}=2x+1$：$x=0,1,2$ 时预测 $1,3,5$。

(2) 误差 $y-\hat{y}=0,-1,1$（蓝线段），平方 $0,1,1$，MSE $=\frac{2}{3}\approx 0.667$。

(3) $\hat{y}=2.5x+0.5$：预测 $0.5,3,5.5$，误差 $0.5,-1,0.5$，平方 $0.25,1,0.25$，MSE $=\frac{1.5}{3}=0.5$。

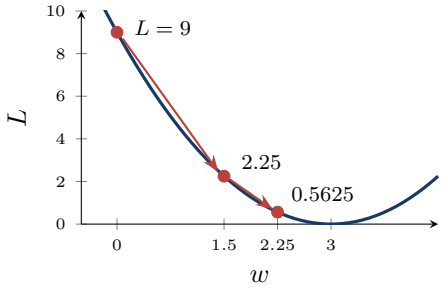
结论：$0.5<0.667$，新模型（绿虚线）更好。

检查：绿线更“照顾”了右上角的点 $(2,6)$。

易错：第 (3) 问第一个点的误差是 $1-0.5=0.5$，不是 0。**同类题：**“比较模型”就是比较同一数据上的损失，越小越好。

第 23 题　手算梯度下降

答案： $w_1 = 1.5$，$w_2 = 2.25$　基础　**考查：** K10



(1) $L'(w) = 2(w-3)$。

(2) $L'(0) = -6$，$w_1 = 0 - 0.25 \times (-6) = 1.5$；$L'(1.5) = -3$，$w_2 = 1.5 + 0.75 = 2.25$。

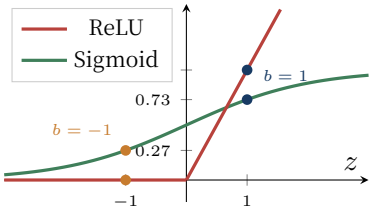
(3) $L(0) = 9$，$L(1.5) = 2.25$，$L(2.25) = 0.5625$，逐步下降，每次变为原来的 $\frac{1}{4}$。

检查： 到最低点 $w^* = 3$ 的距离 $3 \to 1.5 \to 0.75$，每步减半，与图一致。

易错： 梯度为负时，“减去负数”等于向右走，不要把符号弄反。**同类题：** 求导 → 代入 → 减去 $\eta\times$ 梯度 → 回代检查。

第 24 题　神经元计算：ReLU 与 Sigmoid

答案： $z = 1$；1 / 0.731；0 / 0.269　基础　**考查：** K6



(1) $z = 0.5 \times 2 + (-1) \times 1 + 1 = 1$。

(2) ReLU：$\max(0,1) = 1$；Sigmoid：$\frac{1}{1+e^{-1}} \approx \frac{1}{1.368} \approx 0.731$。

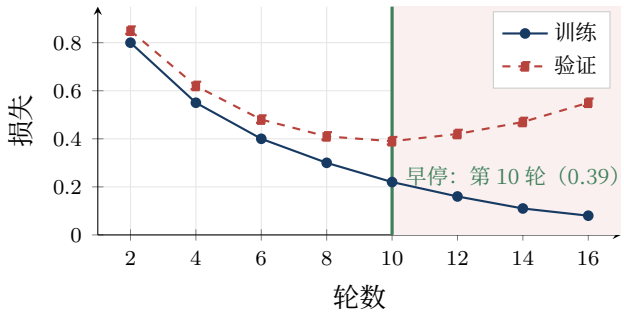
(3) $b = -1$ 时 $z = -1$：ReLU 输出 0；Sigmoid $\frac{1}{1+e} \approx 0.269$。

图上证据： 蓝点（$z = 1$）与橙点（$z = -1$）分别落在两条曲线上；Sigmoid 关于点 $(0, 0.5)$ 对称，所以 $0.731 + 0.269 = 1$。

易错： 偏置只改变 z，不改变激活函数的形状。**同类题：** 先 z 后激活；Sigmoid 可利用 $\sigma(-z) = 1 - \sigma(z)$ 检查。

第 25 题　读损失表，早停

答案：第 10 轮　基础　**考查：** K9 早停；K5 验证集



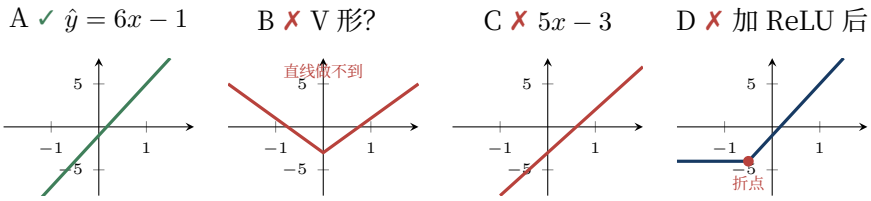
(1) 见图：训练损失单调下降；验证损失先降后升。**(2)** 验证损失最小值 0.39 出现在第 10 轮，选第 10 轮的模型。**(3)** 第 12 轮起验证损失回升（$0.39 \to 0.42 \to 0.47 \to 0.55$），而训练损失仍在下降——两条曲线分叉，说明模型开始“背答案”。训练损失一直下降，按它来选永远会选最后一轮，恰好是过拟合最严重的模型。

同类题： 找验证损失的最低点；看其后是否出现“训练降、验证升”。

详细解析 · B. 中等偏下提升

第 26 题　无激活的两层网络

答案：A　中等偏下　**考查：**K6 非线性的必要性

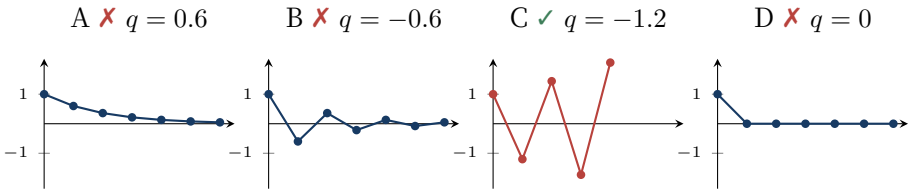


知识链：代入 → 合并 → 判断形状。$\hat{y}=3(2x+1)-4=6x+3-4=6x-1$，两层合并为一层，图像是直线（A）。B：只由直线组合而成、中间没有非线性，不可能出现折点。C：合并时把乘法当成加法（$2+3=5$）。D：加入 ReLU 后 $\hat{y}=3\,\mathrm{ReLU}(2x+1)-4$，当 $x<-0.5$ 时恒为 -4、$x>-0.5$ 时为 $6x-1$，在 $x=-0.5$ 处折弯（第 4 幅图红点），已经不是直线。

一句话总结：没有激活，层再多也是一条直线。

第 27 题　学习率过大时的轨迹

答案：C　中等偏下　**考查：**K10 学习率与收敛



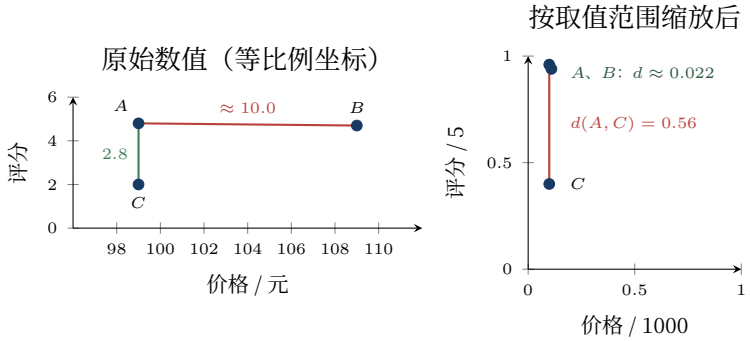
推导：$w_{t+1}=w_t-\eta\cdot 2w_t=(1-2\eta)w_t$，公比 $q=1-2\eta=1-2.2=-1.2$。于是 $w_0=1$，$w_1=-1.2$，$w_2=1.44$，$w_3=-1.728,\ldots$：符号正负交替（振荡），绝对值每次乘 1.2（发散）。四幅图分别对应公比 0.6，-0.6，-1.2，0（即 $\eta=0.2,\ 0.8,\ 1.1,\ 0.5$）：只有 $|q|>1$ 的 C 越跳越远。

常见错误：只看到“来回跳”就选 B；关键要看 $|q|$ 是否小于 1。

一句话总结：$L=w^2$ 上梯度下降收敛的充要条件是 $0<\eta<1$。

第 28 题　特征尺度与距离

答案：B　中等偏下　**考查：**K4 距离与特征缩放



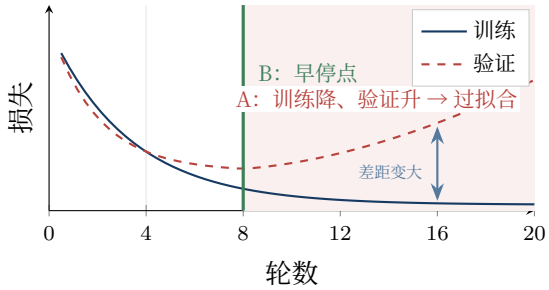
第一步（原始距离）： $d(A,B)=\sqrt{10^2+0.1^2}\approx 10.0$，$d(A,C)=\sqrt{0^2+2.8^2}=2.8$。按数值 C 更近——但 C 的评分只有 2.0，差得很远；B 只贵 10 元，评分几乎一样。距离被“数值大”的价格主导，结论不合理，所以 B 对、A 错。

第二步（缩放后）： 若按平台取值范围缩放（价格 0–1000 元，评分 0–5 分），$d(A,B)=\sqrt{0.01^2+0.02^2}\approx 0.022$，$d(A,C)=0.56$，$B$ 变得更近——“谁更近”发生了改变，所以 D 错。C 错：10.0 与 2.8 显然不等。

一句话总结： 不同量纲的特征先缩放，再谈“相似”。

第 29 题　读训练曲线（多选）

答案：AB　中等偏下　**考查：** K9 过拟合；K5 验证集



A 对：第 8 轮后验证损失上升而训练损失继续下降（阴影区）。B 对：早停选验证损失最低点。C 错：训练损失下降只说明“模拟题越做越熟”，图中训练与验证之间的差距反而越来越大（蓝色双箭头），泛化变差。D 错：停止轮数属于“选模型”，应由验证集决定。

一句话总结： 泛化看验证，不看训练。

第 30 题　三种梯度下降的更新次数

答案：ABC　中等偏下　**考查：** K11

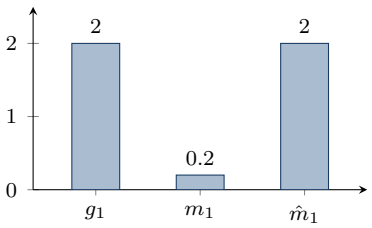


每轮更新次数 = 样本数 ÷ 每次使用的样本数：BGD $1000\div 1000=1$（B 对）；小批量 $1000\div 50=20$（A 对）；SGD $1000\div 1=1000$（C 对）。D 错：SGD 每次只用 1 个样本估计梯度，方向带有随机性，会“抖动”（图 6.5 中间），只是在平均意义上接近 BGD 的方向。

一句话总结： 每次用的样本越少：更新越频繁、越便宜、越抖。

第 31 题　Adam 的第一步

答案： $m_1 = 0.2$，$v_1 = 0.004$，$\hat{m}_1 = 2$　中等偏下　**考查：** K11 Adam



$m_1 = \beta_1 m_0 + (1-\beta_1) g_1 = 0.9 \times 0 + 0.1 \times 2 = 0.2$；

$v_1 = \beta_2 v_0 + (1-\beta_2) g_1^2 = 0.001 \times 4 = 0.004$；

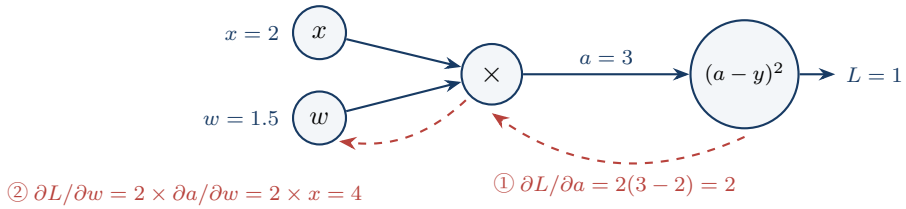
$\hat{m}_1 = \dfrac{0.2}{1-0.9} = 2$。

图上证据： 未修正的 m_1 只有真实梯度的 $\frac{1}{10}$（被初值 0 拖小），修正后恢复为 2。

易错： v_1 忘记平方（写成 0.002）；偏差修正分母写成 β_1 而不是 $1-\beta_1^t$。

第 32 题　链式法则

答案： $\partial L/\partial w = 4$；$w = 1.1$　中等偏下　**考查：** K12 反向传播

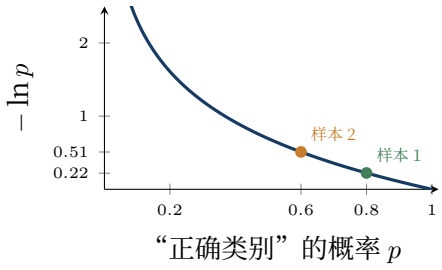


前向： $a = 1.5 \times 2 = 3$，$L = (3-2)^2 = 1$。**反向：** $\dfrac{\partial L}{\partial w} = \dfrac{\partial L}{\partial a} \cdot \dfrac{\partial a}{\partial w} = 2(a-y) \cdot x = 2 \times 2 = 4$。**更新：** $w = 1.5 - 0.1 \times 4 = 1.1$。**检查：** 新的 $a = 2.2$，$L = 0.04 < 1$。

常见错误： $\partial a/\partial w$ 写成 w（应为 x）；或者忘了损失求导的系数 2。

第 33 题　两个样本的平均交叉熵

答案： ≈ 0.367　中等偏下　**考查：** K8



样本 1：$y = 1$，$L_1 = -\ln 0.8 \approx 0.223$。

样本 2：$y = 0$，用第二项：$L_2 = -\ln(1-0.4) = -\ln 0.6 \approx 0.511$。

平均：$\frac{0.223+0.511}{2} \approx 0.367$。

关键： 样本 2 的“正确类别”是“不是猫”，其概率为 $1-0.4 = 0.6$；图中两点的横坐标都是“给正确答案的概率”。

易错： 样本 2 直接算 $-\ln 0.4 \approx 0.916$；或者求和后忘记除以 2。可接受答案 0.367、0.37。

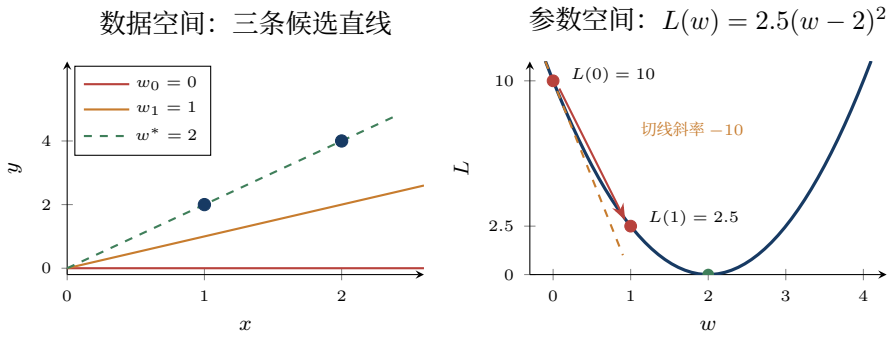
第 34 题　综合题：从数据到一次梯度下降

答案：见速查　中等偏下　**考查：**K7 MSE + K10 梯度下降 + 学习率条件

1. 题目在问什么：用两个数据点拟合一条过原点的直线 $\hat{y}=wx$，先写出损失，再用梯度下降走一步，最后讨论学习率。

2. 已知整理：数据 $(1,2),(2,4)$；$L(w)=\frac{1}{2}[(w-2)^2+(2w-4)^2]$；$w_0=0$，$\eta=0.1$。

3. 知识链：MSE 定义 → 化简 → 求导 → 更新公式 → 收敛条件（第 6.4 节）。



4. 第 (1) 问——为什么先化简：$(2w-4)^2=[2(w-2)]^2=4(w-2)^2$，所以 $L(w)=\frac{1}{2}[(w-2)^2+4(w-2)^2]=\frac{5}{2}(w-2)^2=2.5(w-2)^2$。化简后一眼看出最优 $w^*=2$（右图绿点），且 $L(0)=2.5\times4=10$。

5. 第 (2) 问：$L'(w)=5(w-2)$，$L'(0)=-10$（右图橙色切线斜率）。负号说明往右走（增大 w）损失下降。

6. 第 (3) 问：$w_1=0-0.1\times(-10)=1$，$L(1)=2.5\times1=2.5$。左图中直线从水平（红）转到斜率 1（橙），更靠近数据点。

7. 第 (4) 问：一般地 $w_1=0-\eta\cdot(-10)=10\eta$，令 $10\eta=2$ 得 $\eta=0.2$。收敛条件：$w_{t+1}-2=(w_t-2)-\eta\cdot5(w_t-2)=(1-5\eta)(w_t-2)$，需 $|1-5\eta|<1$，即 $\boxed{0<\eta<0.4}$。

8. 结果检查：$\eta=0.2$ 时公比 $1-5\eta=0$，一步到位，与第 6.4 节“$L=w^2$ 时 $\eta=0.5$ 一步到位”同理（那里公比为 $1-2\eta$）。

9. 最容易卡住：化简 $(2w-4)^2$ 时漏掉因子 4；或把 MSE 前的 $\frac{1}{2}$ 当作 $\frac{1}{3}$。

10. 条件变化：若 $\eta=0.3$，公比 -0.5，参数会在 2 的两侧振荡着收敛；若 $\eta=0.5$，公比 -1.5，发散。

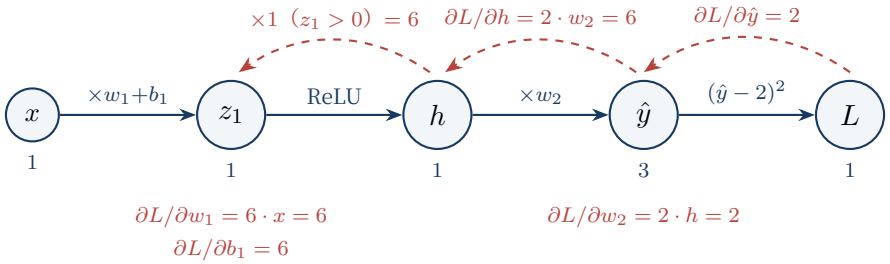
变式思考：若数据改为 $(1,2),(2,5)$，最优 w^* 还是 2 吗？（提示：令 $L'(w)=0$。）

第 35 题　综合题：小网络的前向、反向与更新

答案：见速查　中等偏下　**考查：**K6 神经元 + K12 反向传播 + K10 更新

1. 题目在问什么：完整走一遍“前向 → 反向 → 更新 → 再前向”的训练迭代。

2. 知识链：线性变换 → ReLU → MSE（单样本）→ 链式法则 → 梯度下降。



3. 第 (1) 问——前向（蓝色数字）：$z_1 = 2\times 1 - 1 = 1$，$h = \mathrm{ReLU}(1) = 1$，$\hat{y} = 3\times 1 = 3$，$L = (3-2)^2 = 1$。

4. 第 (2) 问——为什么从后往前：L 只直接依赖 $\hat{y}$，所以先算 $\frac{\partial L}{\partial \hat{y}} = 2(\hat{y}-y) = 2$，再逐层乘局部导数（红色）：

$$\frac{\partial L}{\partial w_2} = \frac{\partial L}{\partial \hat{y}}\cdot h = 2, \qquad \frac{\partial L}{\partial h} = \frac{\partial L}{\partial \hat{y}}\cdot w_2 = 6, \qquad \frac{\partial L}{\partial z_1} = 6\times \underbrace{1}_{\mathrm{ReLU}'(1)} = 6,$$

$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial z_1}\cdot x = 6, \qquad \frac{\partial L}{\partial b_1} = \frac{\partial L}{\partial z_1}\cdot 1 = 6.$$

5. 第 (3) 问——更新：$w_2 = 3-0.05\times 2 = 2.9$，$w_1 = 2-0.05\times 6 = 1.7$，$b_1 = -1-0.05\times 6 = -1.3$。

6. 再前向：$z_1 = 1.7-1.3 = 0.4$，$h = 0.4$，$\hat{y} = 2.9\times 0.4 = 1.16$，$L = (1.16-2)^2 = 0.7056 < 1$，损失下降。

7. 合理性检查：原来 $\hat{y} = 3$ 偏大，所有梯度都为正，更新后三个参数都朝“让 $\hat{y}$ 变小”的方向走，$\hat{y}$ 从 3 降到 1.16，方向正确（略微冲过了目标 2）。

8. 最容易卡住：$\frac{\partial L}{\partial h}$ 要乘的是 w_2（不是 h）；ReLU 处的导数要看 z_1 的正负。

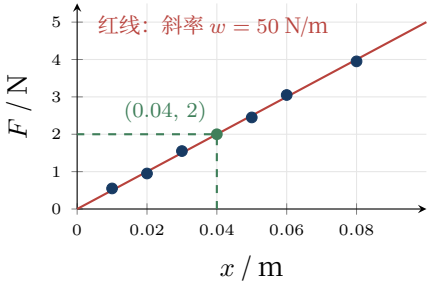
9. 条件变化：若取 $\eta = 0.1$：$w_2 = 2.8$，$w_1 = 1.4$，$b_1 = -1.6$，则 $z_1 = -0.2 < 0$，$h = 0$，$\hat{y} = 0$，$L = 4$——损失反而变大，而且该 ReLU 神经元输出为 0、梯度也为 0，暂时“不再学习”。这说明学习率过大在神经网络中同样危险。

变式思考：若 $y = 3$（与初始预测相同），各梯度是多少？训练还会改变参数吗？

详细解析 · C. 跨学科迁移

第 36 题　胡克定律 × 线性模型

答案：A　跨学科　**考查：**K2 特征 / 标签；线性模型参数的含义



当前专题知识：线性模型 $\hat{y} = wx$ 的参数 w 是直线斜率。

借用的外部情境：大学物理中弹簧的胡克定律。

为什么不超纲：题干已给出 $F = kx$ 及单位，只需把模型与公式逐项对照。

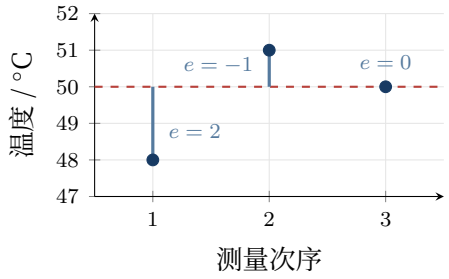
迁移点：“$\hat{y} = wx$”与“$F = kx$”形式完全相同，所以学到的 w 就是劲度系数 k，单位是 N/m。

计算：$\hat{F} = 50 \times 0.04 = 2$ N（图中绿点）。B 错：质量单位是 kg，与斜率 N/m 不符。C 错：$1250 = 50 \div 0.04$，把乘法算成了除法（$w \div x$）；图中 $x = 0.04$ 附近的数据点都在 2 N 左右，1250 N 明显不合理。D 错：$0.0008 = 0.04 \div 50$，同样是乘除颠倒（$x \div w$）。

一句话总结：机器学到的参数往往有物理意义：斜率 = 劲度系数。

第 37 题　恒温箱 × 均方误差

答案：ABC　跨学科　**考查：**K7 MSE 的计算与性质



当前专题知识：MSE 的计算及“平方惩罚”的性质。

借用的外部情境：自动控制中以误差平方为性能指标。

为什么不超纲：题干给出了 $e = r - y$ 与 J 的公式，无需控制理论知识。

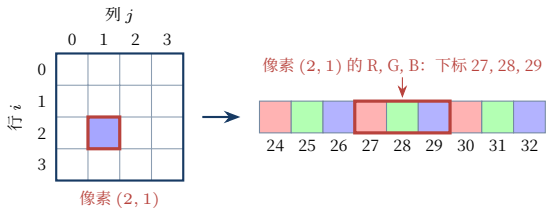
迁移点：控制中的 J 就是机器学习中的 MSE：r 相当于标签 y，测量值相当于预测 $\hat{y}$。

A 对：$e = 2, -1, 0$，$J = \frac{4+1+0}{3} = \frac{5}{3} \approx 1.67$。B 对：$(+1)^2 = (-1)^2 = 1$，平方使正负误差贡献相同（图中两段蓝线方向相反，惩罚相同）。C 对：J 是“偏离目标程度”的度量，越小越好。D 错：$2^2 = 4$ 是 $1^2 = 1$ 的 **4 倍**，不是 2 倍——这正是“错得越多、罚得更多”的平方惩罚。

一句话总结：机器学习的损失函数与控制中的性能指标是同一种“尺子”。

第 38 题　C++ 数组存储 × 图像张量

答案：29；48 字节　跨学科　**考查：**K3 张量与维度



当前专题知识：彩色图像是 $H \times W \times 3$ 的张量；数值个数 $= H \times W \times 3$。　**借用的外部情境：**C++ 一维数组、行优先存储。　**为什么不超纲：**下标公式已在题干给出，只需代入。

第一步：像素 $(2, 1)$ 前面有 2 整行（每行 $W = 4$ 个像素）再加 1 个像素，共 $2 \times 4 + 1 = 9$ 个

像素，每个像素占 3 个位置，所以它的 R 通道从下标 $9 \times 3 = 27$ 开始。

第二步： B 通道 $c = 2$，$\mathrm{idx} = 27 + 2 = 29$（图中红框第 3 格）。

第三步： 总字节数 $= 4 \times 4 \times 3 = 48$（`unsigned char` 每个 1 字节）。

迁移点： 第 3 章的“张量形状”在内存里就是一段连续数组；“拉平”（第 16 题）就是这里的行优先展开。**易错：** 下标从 1 开始数（得 30）；把 W 写成 H 在方阵中不影响，但在 $H \neq W$ 时会出错。

参考资料

原始教学依据

[1] 课件《第一节 神经网络入门（机器学习与人工智能）》，58 页。

[2] 课件《第一节 AI 发展速通（人工智能导论：AI 是怎么发展到今天这一步的）》，62 页。

[3] 课堂手写笔记，Memo No. 357–362，2026 年 9 月 18–19 日。

核心定义与公式核验

[4] T. M. Mitchell. Machine Learning. McGraw-Hill, 1997.（机器学习的形式化定义）

[5] I. Goodfellow, Y. Bengio, A. Courville. Deep Learning. MIT Press, 2016.（神经元、激活函数、交叉熵、梯度下降、反向传播）

[6] 周志华.《机器学习》. 清华大学出版社, 2016.（数据集划分、过拟合、M–P 神经元模型）

[7] D. P. Kingma, J. Ba. Adam: A Method for Stochastic Optimization. ICLR, 2015.（Adam 公式与偏差修正）

[8] D. E. Rumelhart, G. E. Hinton, R. J. Williams. Learning representations by back-propagating errors. Nature, 1986.（反向传播）

图像、历史节点与科普资料

[9] W. S. McCulloch, W. Pitts. A logical calculus of the ideas immanent in nervous activity. Bulletin of Mathematical Biophysics, 1943.

[10] A. M. Turing. Computing Machinery and Intelligence. Mind, 1950.

[11] A. L. Samuel. Some Studies in Machine Learning Using the Game of Checkers. IBM Journal of Research and Development, 1959.

[12] J. Weizenbaum. ELIZA—A Computer Program for the Study of Natural Language Communication between Man and Machine. Communications of the ACM, 1966.

[13] D. A. Pomerleau. ALVINN: An Autonomous Land Vehicle in a Neural Network. NIPS, 1989.

[14] N. Muscettola et al. Remote Agent: to boldly go where no AI system has gone before. Artificial Intelligence, 1998；NASA JPL Deep Space 1 任务资料。

[15] G. E. Hinton, S. Osindero, Y.-W. Teh. A fast learning algorithm for deep belief nets. Neural Computation, 2006.

[16] J. Deng et al. ImageNet: A Large-Scale Hierarchical Image Database. CVPR, 2009.

[17] A. Krizhevsky, I. Sutskever, G. E. Hinton. ImageNet Classification with Deep Convolutional Neural Networks. NIPS, 2012.

[18] H. Lee, R. Grosse, R. Ranganath, A. Y. Ng. Convolutional Deep Belief Networks for Scalable Unsupervised Learning of Hierarchical Representations. ICML, 2009.

[19] I. Goodfellow et al. Generative Adversarial Nets. NIPS, 2014.

[20] D. Silver et al. Mastering the game of Go with deep neural networks and tree search. Nature, 2016.

[21] A. Vaswani et al. Attention Is All You Need. NIPS, 2017；J. Devlin et al. BERT, 2018；A. Radford et al. GPT-2, 2019；T. Brown et al. Language Models are Few-Shot Learners, 2020.

[22] Anthropic. Claude Fable 5 and Claude Mythos 5（官方公告，2026 年 6 月 9 日）；OpenAI. GPT-6 Astra（官方发布页，2026 年 9 月）。