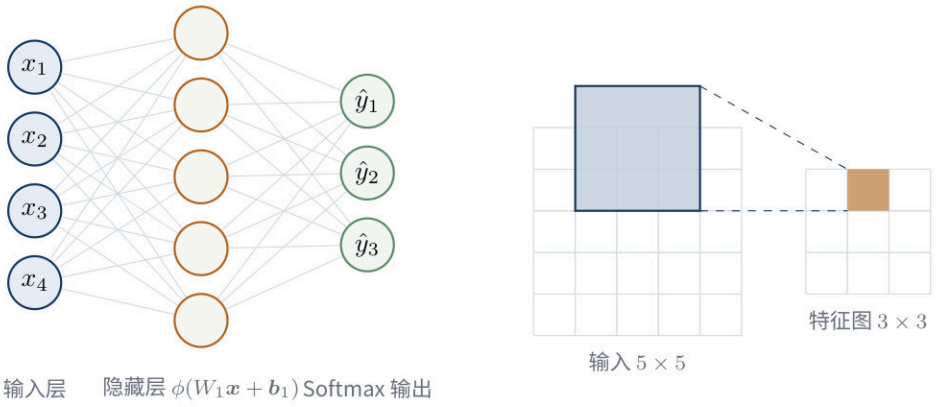
人工智能导论 · 基础学习讲义

机器学习入门

线性模型 · 多层感知机 · 卷积神经网络

从“超参数”到“YOLO 与 MediaPipe”：一条连续的知识链



覆盖内容	超参数；监督 / 无监督 / 在线 / 强化学习；线性回归与 R^2；Softmax、交叉熵、Sigmoid、BCE；多层感知机、激活函数、通用逼近定理、特征工程；卷积、池化、全连接；YOLO；OpenCV；MediaPipe
整理依据	382–386）；教学代码：sin 拟合网页演示、MNIST / Fashion-MNIST / CIFAR-10 笔记本、YOLO、OpenCV、MediaPipe 脚本
练习配置	25 道基础巩固 + 10 道中等偏下提升 + 3 道跨学科迁移 = 38 道正式练习（附完整解析）

2026 年 9 月　适用对象：第一次接触机器学习的本科生

阅读说明

这份讲义是对一次课（PPT“第二章 机器学习二入门”+“第三章 模型与算法”）的**教学重构**，而不是 PPT 的重新排版。课堂 PPT 为了节省时间，常常只给结论、只给例子的数字、只写“同理”，而本讲义的目标是：**只读这份 PDF，也不会因为课堂上口头略过的内容而断掉知识链。**

三种内容来源标记 为了让你知道每句话“从哪里来”，正文中用灰色小字标注来源：

- ［原始资料］：能从 PPT、笔记照片或课程代码中可靠识别的内容；
- ［教学补全］：原资料没有完整展示，但本科初学者理解所必需、依据标准教材与官方文档补充的内容（推导、证明、反例、公式细节等）；
- ［类比］：只帮助建立直觉的比喻，不能当作严格结论。

信息框的颜色含义 整本讲义颜色语义固定，看颜色就知道这是什么类型的内容：

定义、定理、核心公式（蓝）	易错点、原图纠错（红）
直观理解、推导、证明（蓝灰左线）	小结、方法、学习自检（绿）
例题、学科小史、科普（米色）	知识联系、跨学科（灰紫）

建议的阅读顺序 第 1 章给出全景与历史；第 2—6 章是正文，按“学习范式 → 线性模型 → MLP → CNN → 视觉应用”一步步“长出来”；第 7 章是 38 道练习（先独立做）；第 8 章答案速查；第 9 章逐题详细解析；第 10 章是总复习表。

关于数学基础 只需要：函数与图像、求和符号 $\sum$、指数与对数、向量与矩阵乘法、一元微积分中的求导与链式法则。遇到更高阶的工具时，正文会明确说“当前阶段只需理解思路”。

目　录

阅读说明 ii

1　全景导读：这一讲要解决什么问题 1

1.1　本讲学什么：一条主线，两条支线 1
1.2　在课程体系中的位置 1
1.3　学科小史：这些知识是怎样出现的? 2
1.4　从课本到现实：这些知识到底有什么用? 2
1.5　原始资料重编码：我们手里有什么 3
1.6　知识点总览与关系图 5

2　机器怎样学习：超参数与四种学习范式 5

2.1　参数与超参数：谁来决定? 6
2.2　监督学习：有“标准答案”的学习 7
2.3　无监督学习：没有标准答案，也要有“好坏标准” 9

2.4 离线学习与在线学习 9
2.5 环境六问：从预测器走向智能体 10
2.6 强化学习：在试错中学会行动 10

3 线性模型：线性回归、Softmax 回归与 Sigmoid 13
3.1 线性回归：用一条直线（超平面）做预测 13
3.2 决定系数 R^2：模型解释了多少变化? 15
3.3 Softmax 回归：从“打分”到“概率” 16
3.4 交叉熵损失：概率离真实答案有多远 18
3.5 多标签分类：Sigmoid 与二值交叉熵 19
3.6 统一视角、数据集与课程代码 21

4 多层感知机：让模型学会“非线性” 23
4.1 最小的反例：异或 XOR 23
4.2 加一个隐藏神经元：XOR 被解决了 24
4.3 为什么必须有激活函数 24
4.4 常见激活函数 25
4.5 多层感知机的结构、公式与参数量 26
4.6 反向传播：多层网络怎样求梯度 27
4.7 拟合 $\sin x$：通用逼近定理的直观 27
4.8 真实世界是非线性的：从房价说起 29
4.9 怎样确定网络结构 30

5 卷积神经网络：专门为“看图”设计的网络 31
5.1 MLP 看图有什么问题 31
5.2 核心思想：局部感知 + 参数共享 = 卷积 32
5.3 池化层：压缩并保留重要值 34
5.4 全连接层：把局部特征汇总成决策 34
5.5 完整的 CNN：以课程 Fashion-MNIST 笔记本为例 35

6 从分类到“看懂画面”：YOLO、OpenCV 与 MediaPipe 36
6.1 图像识别的三个层次 37
6.2 YOLO：只看一次 37
6.3 OpenCV：计算机眼中的图像 40
6.4 MediaPipe：已封装好的实时视觉 AI 工具箱 41
6.5 OpenCV、MediaPipe 与深度学习模型的关系 42

7 正式练习：38 道分层训练 **43**
知识点—题目对应表 43
7.1 A 层 基础巩固训练（25 道） 44
7.2 B 层 中等偏下提升训练（10 道） 50
7.3 C 层 跨学科迁移训练（3 道） 52

8 答案速查 **53**

9 详细解析 **54**
9.1 A 层解析：基础单选（1—10） 55
9.2 A 层解析：基础多选（11—15） 57
9.3 A 层解析：基础填空（16—20） 59
9.4 A 层解析：基础解答（21—25） 60
9.5 B 层解析：提升单选（26—28） 63
9.6 B 层解析：提升多选（29—30） 64
9.7 B 层解析：提升填空（31—33） 65
9.8 B 层解析：综合大题（34—35） 66
9.9 C 层解析：跨学科迁移（36—38） 68

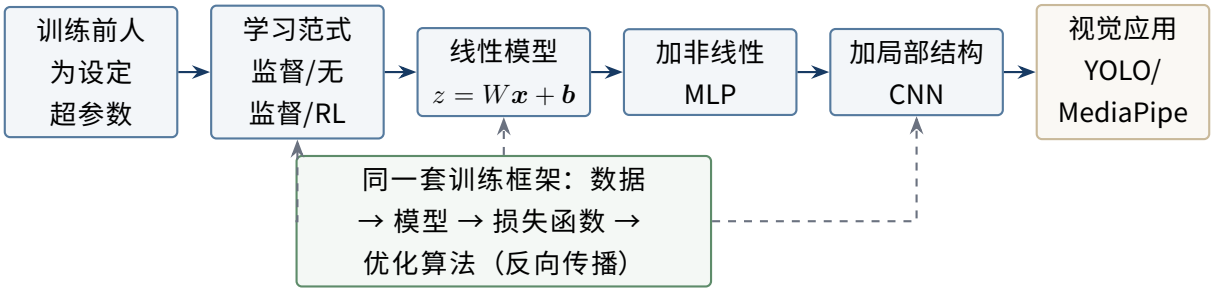
10 总复习：易错点、方法、概念对比与后续课程 **69**
10.1 高频易错点总表 69
10.2 基础解题步骤总结 69
10.3 相近概念总对比 70
10.4 后续课程连接 70
10.5 练习图解覆盖统计 70
10.6 参考资料 71

第 1 章　全景导读：这一讲要解决什么问题

本章回答三个问题：① 这一讲到底学什么？② 它在整个课程与大学知识体系中处于什么位置？③ 这些知识是怎样一步步发展出来、今天又用在哪里的？

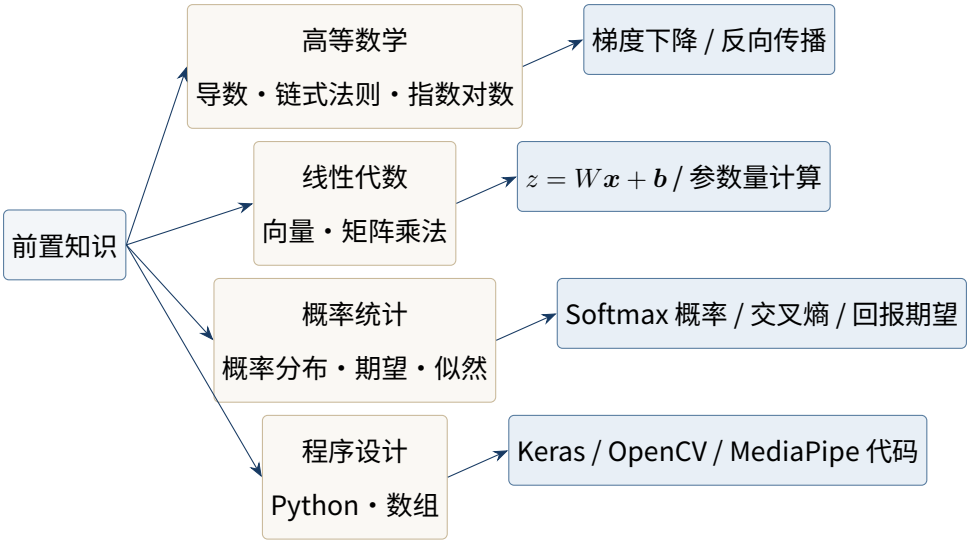
1.1　本讲学什么：一条主线，两条支线

课堂 PPT 由两部分组成［原始资料］：“第二章 机器学习二入门”讲**机器怎样学习**（学习范式），“第三章 模型与算法”讲**用什么模型来学**（从线性模型到 CNN，再到 YOLO、OpenCV、MediaPipe 的应用）。把它们串起来，就得到本讲的主线：



整讲反复出现的“四要素”是 PPT 在强化学习部分明确提出的分析框架［原始资料］：**数据、模型、目标函数（损失函数）、优化算法**。本讲义把它推广为全书的统一视角——无论是线性回归、Softmax、MLP 还是 CNN，都可以用这四个问题去拆解：数据长什么样？模型是什么函数？用什么衡量好坏？怎样调参数让它变好？

1.2　在课程体系中的位置

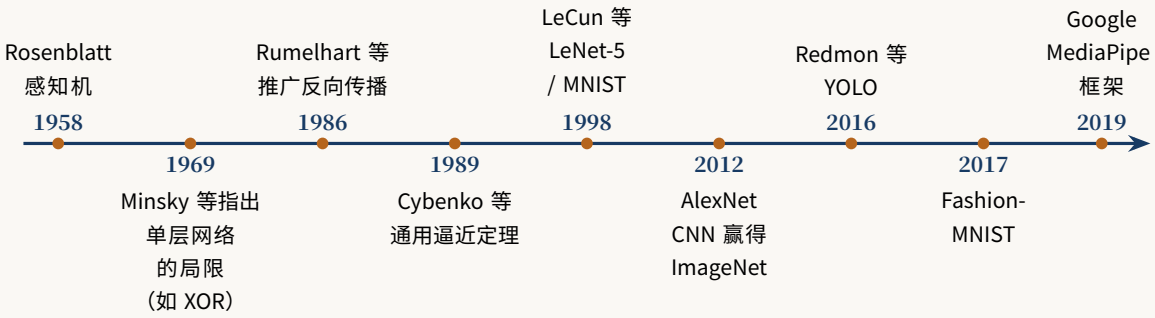


向后看，本讲的内容会在以下课程中再次出现：*模式识别与机器学习*（更系统的模型与理论）、*最优化方法*（梯度下降、Adam 的收敛性）、*数字图像处理*（卷积、滤波、边缘检测）、*计算机视觉*（目标检测、姿态估计）、*自动控制原理 / 最优控制*（强化学习与“策略”“回报”的联系），以及下一讲的*语言大模型与 RNN*（笔记 Memo 386 末尾“§ 3 语言大模型（RNN）”）［原始资料］。

1.3 学科小史：这些知识是怎样出现的？

学科小史：从“一个神经元”到“实时看懂画面”

人们最初遇到的问题是：**能不能让机器像人一样，从例子中学会判断？**下面是与本讲直接相关的几个关键节点（只列经可靠来源核验、且与正文直接相关的事件）：



- **单层模型的兴起与瓶颈**：1958 年 Rosenblatt 提出感知机，本质上就是本讲的“线性打分 + 阈值”。1969 年 Minsky 与 Papert 的著作系统分析了单层感知机的局限，其中最著名的例子就是无法表示**异或 XOR**——这正是本讲 PPT 第 58–59 页用来引出 MLP 的例子。
- **多层网络变得可训练**：1986 年 Rumelhart、Hinton、Williams 在 *Nature* 发表论文，使“反向传播训练多层网络”广为人知；1989 年 Cybenko 等人证明了**通用逼近定理**，从理论上说明“一个隐藏层 + 非线性激活”就有很强的表示能力。
- **卷积网络走向图像**：LeCun 等人把“局部连接 + 权重共享”用于手写数字识别，1998 年的 LeNet-5 论文与 MNIST 数据集成为经典；2012 年 AlexNet 在 ImageNet 竞赛中大幅领先，深度 CNN 从此成为视觉主流。
- **从“分类”到“实时理解画面”**：2016 年（arXiv 2015）Redmon 等提出 YOLO，把检测变成“看一次就输出所有框”；2019 年 Google 发布 MediaPipe 感知流水线框架，把手、脸、姿态等模型封装成可直接调用的工具。

今天仍要学习这些“老”知识，是因为：**大模型再复杂，其积木仍然是线性层、激活函数、Softmax、交叉熵与反向传播。**

1.4 从课本到现实：这些知识到底有什么用？

从课本到现实

① **工业质检与医学影像（监督学习 + CNN）**　产线相机拍下零件照片，CNN 判断“合格 / 划痕 / 缺角”；医学影像中判断病灶。这里立刻会遇到 PPT 讲的**样本不均衡**：缺陷品、罕见病的样本远少于正常样本。

② **手机与人机交互（MediaPipe）**　视频会议中的手势、美颜贴纸、健身 App 的动作计数，背后都是“先检测关键点、再根据几何关系判断”的流程，与课程提供的 `mp_hand.py`、`mp_body.py` 完全同构。

③ **巡检与智能车（YOLO）**　笔记中老师举的例子［原始资料］：智慧乡村（大创项目）、森林防火巡检、无人驾驶小车。无人机或小车上的摄像头每秒送来几十帧，YOLO 逐帧给出“什么东西、在哪里”，控制系统再据此决策。

④ **推荐与预测（在线学习与分布漂移）**　推荐系统、广告点击率、股票与量化模型需要不断用新数据更新模型；用户兴趣会随季节热点变化——这就是 PPT 所说的**分布漂移**。

1.5 原始资料重编码：我们手里有什么

1.5.1 资料清单与在讲义中的去向

资料	可靠识别到的核心内容	本讲义位置
PPT 第 1—27 页	超参数；监督学习（样本、特征、标签、任务表、四大挑战）；无监督学习；离线/在线学习；环境六问；强化学习（策略、回报、马尔可夫性）	第 2 章
PPT 第 28—54 页	线性回归、R^2、Graduate Admissions 数据集；Softmax 回归、交叉熵；Sigmoid、BCE；MNIST、Fashion-MNIST	第 3 章
PPT 第 55—80 页	MLP、XOR、激活函数、参数量、非线性现实问题、特征工程、通用逼近定理、网络结构选择	第 4 章
PPT 第 81—93 页	MLP 的缺陷；卷积层、池化层、全连接层	第 5 章
PPT 第 94—118 页	YOLO；OpenCV 图像处理；MediaPipe	第 6 章
手写笔记 Memo 382—386	课堂要点与老师口头补充（见下节逐页转录）	各章对应位置
`sin_nn_fitting_demo.html`	单隐藏层 ReLU 网络拟合 $\sin x$ 的 7 步演示，Adam 优化，MSE 损失	4.6 节
Softmax/Fashion-MNIST 笔记本	MLP（784→128→10 等）训练与测试结果	3.6、4.4 节
`cnn.zip`	Fashion-MNIST CNN、CIFAR-10 CNN（含 BN、数据增强）	5.6 节
`yolo / opencv / media_pipe`	图片/视频/摄像头检测；10 种 OpenCV 处理；手/脸/身体/全身关键点	第 6 章

1.5.2 手写笔记逐页转录（Memo 382—386，2026-09-26）

下面按笔记原顺序转录。红笔在原笔记中为老师强调或补充的内容，这里用“※”标出。

382　§2 二入门。一、超参数：训练前设置好，是人为设定。1.学习率 2.batch size 3.epoch（轮）4.optimizer（优化器）。二、监督学习：1.给定“输入特征”→预测“输出标签” 2.用于场景：① ［此处笔记只写了编号，后文空白，无法可靠辨认具体内容］ 3.缺点：①标注成本高 ②过拟合风险 ③样本不均衡：罕见病样本少 ④泛化能力差。※打算发论文：看顶刊，了解它们的模型，复现不出来就有机会。三、无监督学习：1.无人为标注的标签，模型自主分类 2.场景：①聚类 ②主成分分析..... 3.无监督学习有 Loss 函数与优化算法吗？※仍需优化，可构造一个目标函数→Loss 函数。※有无监督学习均为离线学习，不主动采集新样本。四、在线学习（股票/量化模型）1.模型逐步接收新数据 2.若环境“有记忆”则此前动作影响现在（部分马尔科夫）3.环境能否提供奖励或反馈机制（奖励信号设计）4.环境是否有自己的目标/敌人——博弈论 5.环境是否会变？——分布漂移

383　6.环境可否忽略？——agent。五、RL：1.通过与环境交互学习最优行为策略的学习方法 2.图示（动作、奖励、环境、观测、agent 的循环）3.公式 $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$，$\gamma$：折扣因子 $\gamma \in [0,1]$ 4.数据：①

监督 (x, y) ②RL：(s_t 当前，a_t 采取动作，r_t 奖励，s_{t+1} 下一) 5.模型（策略）：$\pi(a|s)$ 在 s 下选 a 的概率 6.目标函数：$\max_\pi \mathbb{E}_\pi[\gamma^k r_k]$ 7.马尔可夫性：过去对未来的状态仅依靠现在传递 $P(s_{t+1}|s_t, a_t, \dots)$。六、模型与算法 1.线性神经网络 ①线性回归 $y_i = w_i^\top x + b_i$（附散点与拟合直线草图）②决定系数 $R^2 = 1 - \frac{\sum(y_i-\hat{y}_i)^2}{\sum(y_i-\bar{y})^2}$ ③有多个输出怎么办？→多个回归 ※不要认为全是分类 2.softmax 回归（多分类）①图示

384 （4 输入 3 输出全连接图）②拓展：(1)输出形式：类别 (2)回归：softmax (3)激活函数 (4)Loss：交叉熵 ③归一化 $y_j = \frac{e^{z_j}}{\sum_{k=1}^{k} e^{z_k}}$ ※线性输出值→概率 ④为何用 softmax？(1)任意分数变成概率 (2)保留相对大小 (3)方便交叉熵 ⑤Loss 函数 $l = -\sum_{j=1}^{k} y_j \log(\hat{y}_j) = -\log(\hat{y}_k)$ ⑥过程 (1)$W \in \mathbb{R}^{k\times d}$，$b \in \mathbb{R}^k$ (2)$z = Wx+b$ (3)softmax→概率 (4)交叉熵 (5)反向传播。⑦Sigmoid（多标签分类）(1)$\sigma(x) = \frac{1}{1+e^{-x}}$ (2)Loss：二值交叉熵（BCE）(3)(a)MNIST：7 万张手写图像 (b)Fashion-MNIST。※$z = Wx + b$，线性回归：z→预测值

385 softmax / Sigmoid。3.多层感知机 ①单层网络能力有限，无法承担复杂任务，无法理解高层视觉特征 ②activation 函数：(1)ReLU (2)Sigmoid (3)Tanh；线性层：拉伸、旋转、平移；激活：使空间变弯 ③输入→隐藏层→输出，※隐藏层：原始输入→加工→中间特征。※层数多了→参数会急剧增长 ④参数多了模型就越强？参数越多越易过拟合 ⑤数学表示 $\hat{y} = \text{softmax}(W_2 \cdot \phi(W_1 x + b_1) + b_2)$，$\phi$ 激活函数。※房产是非线性过程：（边缘递减效应）⑥特征工程：非线性（人工设计）(1)多项式 (2)取对 (3)离散化 (4)One-hot..... ※更多在于数据本身的探索+研究 ⑦通用逼近定理（非线性）⑧自动搜索超参数组合 ※热门 (1)optuna (2)Raytune。4.卷积神经网络 ①MLP→全连接 ②局部感知能力→卷积

386 ③CNN (1)卷积核（3×3/5×5）(2)池化层：压缩并保留重要值 (3)全连接层。④YOLO（视觉相关）→视频 (1)智慧乡村（大创）(2)森林防火（巡检）(3)无人驾驶小车；只看一次整图→预测所有目标、位置和类别。⑤MediaPipe (1)OpenCV (a)图像处理 (2)mediapipe (a)骨骼 (b)人脸 (c)身体 (d)动作。§3 语言大模型（RNN）[下一讲预告，本讲义不展开]

1.5.3 原图纠错汇总

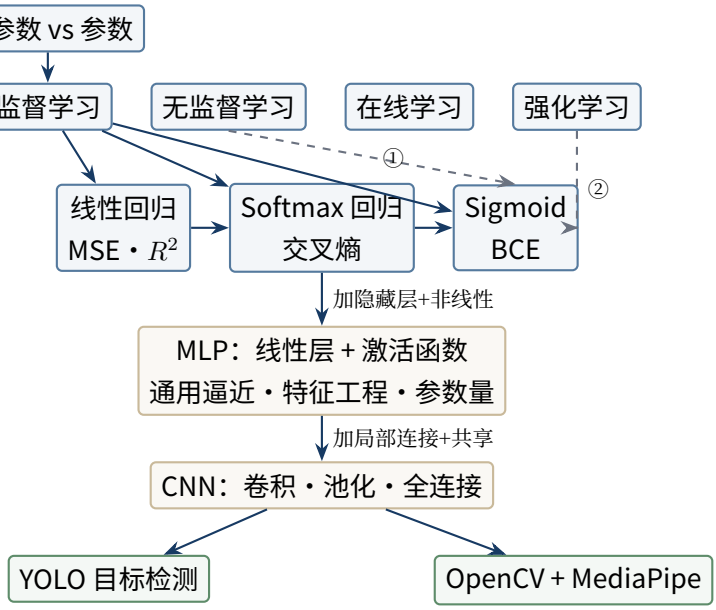
下列问题在正文对应位置还会再次标注。它们大多是简写或排版笔误，不影响课堂主线，但初学者若照抄会出错。 **原图纠错（共 8 处）**

位置	原始写法 → 存在的问题	规范写法与影响
PPT p.38	Softmax$([2.0, 1.0, 0.1])$ $\approx [0.65, 0.24, 0.11]$；第三项实际为 $1.105/11.212 \approx 0.0986$	应为 $\approx [0.66, 0.24, 0.10]$；三项之和才等于 1。不影响结论
PPT p.47—49 标题	“多标签分类（Single-label classification）”：中英文矛盾	应为 Multi-label classification。概念上必须区分（见 3.5 节）
PPT p.50—51	BCE：草地 0.2013、人 0.1266、均值 0.1255	精确计算为 0.2014、0.1269、0.1256。仅为舍入误差
PPT p.23；笔记 383	折扣因子 $\gamma \in [0, 1]$	无限步求和时通常取 $\gamma \in [0, 1)$，否则 G_t 可能发散；$\gamma = 1$ 只用于有终止的回合任务（见 2.5 节）
笔记 383	目标函数 $\max_\pi \mathbb{E}_\pi[\gamma^k r_k]$ 漏写求和号	应为 $\max_\pi \mathbb{E}_\pi\left[\sum_{t=0}^{\infty} \gamma^t r_t\right]$（PPT p.26 写法正确）
笔记 384	$y_j = \frac{e^{z_j}}{\sum_{k=1}^{k} e^{z_k}}$：求和上限与下标同为 k	上限应为类别数 K：$\sum_{k=1}^{K}$，否则式子无意义

位置	原始写法 → 存在的问题	规范写法与影响
笔记 385	“房产是非线性过程：（边缘递减效应）”	应为“边际递减效应”（diminishing marginal effect，PPT p.68 写法正确）
笔记 382	“若环境有记忆……（部分马尔科夫）”	规范术语是“部分可观测马尔可夫决策过程 POMDP”（PPT p.16），不是“部分马尔可夫”

另有两处需说明的表述　（不算错误，但易误解）① PPT p.70 在写出 $y = a\cdot\text{floor} + b\cdot\text{floor}^2 + c$ 后写“无法表达中间最贵”，指的是*原始线性模型* $y = w\cdot\text{floor} + b$ 无法表达；加入平方项（$b < 0$）后恰恰*可以*表达倒 U 型。② 课程代码 `mp_face.py` 与 PPT p.115 写人脸 468 个关键点，这是经典 Face Mesh 的数目；Google 当前 Face Landmarker 文档中模型输出 478 个点（多出 10 个虹膜点）。

1.6 知识点总览与关系图



图中实线箭头表示“后者建立在前者之上”，虚线表示“概念上的联系”：①无监督学习同样需要构造损失函数；②强化学习的策略 $\pi(a|s)$ 常用 Softmax 输出各动作的概率。可以看到：**Softmax 回归是全讲的枢纽**——向前承接线性回归，向后通过“加隐藏层”得到 MLP，再通过“换成卷积”得到 CNN。

第 2 章　机器怎样学习：超参数与四种学习范式

承上启下　第 1 章给出了全景。本章先解决一个最基本的问题：*“学习”到底指什么？* 我们会看到，所有机器学习都在做同一件事——**用数据调整模型参数，让某个目标函数变好**；而“数据从哪里来、有没有标签、模型会不会影响环境”，决定了不同的学习范式。

本章知识路线　参数与超参数 → 监督学习 → 无监督学习 → 离线 / 在线学习 → 环境六问 → 强化学习。

2.1 参数与超参数：谁来决定？

2.1.1 问题引入

训练一个模型时，有两类“数字”：一类是模型*自己*在训练中学出来的，另一类是*你*在训练开始前就要填好的。如果不区分这两类，就会出现“为什么调了半天学习率，模型里却找不到学习率这个参数”的困惑。

定义（超参数，Hyperparameter）

在机器学习或深度学习模型**训练前设置好**、并且**不会通过训练自动学习得到**的量，称为超参数。与之相对，**模型参数**（权重 $\boldsymbol{w}$、偏置 b）是通过训练（反向传播 + 优化算法）自动学出来的。［原始资料］

类别	超参数	含义	调得不当会怎样
优化相关	学习率 η	每一步参数更新的幅度	太大：震荡甚至发散；太小：收敛慢
优化相关	优化器 optimizer	参数更新规则，如 SGD、Adam、RMSprop	不同问题收敛速度差异大
训练策略	批次大小 batch size	一次参数更新使用多少个样本	太小噪声大，太大占内存
训练策略	轮数 epoch	整个训练集被完整使用多少遍	太少欠拟合，太多可能过拟合
模型结构	层数、每层宽度	网络的深度与宽度	太小表达力不足，太大易过拟合
数据增强	裁剪、旋转、翻转幅度	人为制造“变形样本”	太强会破坏标签含义

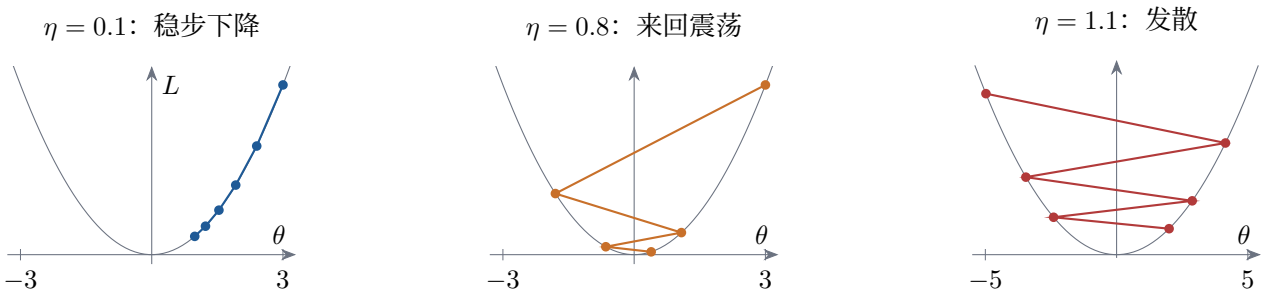
2.1.2 学习率：一张图看懂“太大”和“太小”

［教学补全］训练的本质是梯度下降：沿着损失函数下降最快的方向迈一步，

$$\theta_{\text{新}} = \theta_{\text{旧}} - \eta \frac{\partial L}{\partial \theta} \tag{2.1}$$

其中 θ 代表任一参数，$\eta > 0$ 是学习率，$\partial L/\partial \theta$ 是损失对该参数的导数（梯度）。以最简单的 $L(\theta) = \theta^2$ 为例，$\partial L/\partial \theta = 2\theta$，于是 $\theta_{\text{新}} = (1 - 2\eta)\theta_{\text{旧}}$：

- 若 $0 < \eta < 0.5$，则 $0 < 1 - 2\eta < 1$，θ 单调缩小到 0（稳定但可能慢）；
- 若 $0.5 < \eta < 1$，则 $-1 < 1 - 2\eta < 0$，θ 正负交替地收敛（震荡）；
- 若 $\eta > 1$，则 $|1 - 2\eta| > 1$，$|\theta|$ 越来越大——**发散**。



三幅图横轴是参数 θ，纵轴是损失 $L = \theta^2$；灰色抛物线是损失曲面，彩色折线是每一步参数所在位置。左图点沿曲线一步步滑到谷底；中图点在谷底两侧来回跳但幅度变小；右图幅度越跳越大，离谷底越来越远。

2.1.3 epoch、batch size 与“每轮多少步”

［教学补全］设训练集有 N 个样本，批次大小为 B，则一个 epoch 需要的参数更新次数（step 数）为

$$\text{每轮步数} = \left\lceil \frac{N}{B} \right\rceil, \tag{2.2}$$

$\lceil \cdot \rceil$ 表示向上取整：最后不足 B 个的样本也要组成一个（较小的）批次。

例 2.1　读懂课程笔记本里的“391/391”

已知：`softmax_mnist_demo.ipynb` 把 60000 张训练图拆成 50000 张训练 + 10000 张验证，`BATCH_SIZE = 128`，`EPOCHS = 8`［原始资料］。**求**：训练日志中每轮显示的步数，以及 8 轮一共更新多少次参数。

第一步：$50000/128 = 390.625$，向上取整得 **391**——这正是日志里每行开头的“391/391”。

第二步：总更新次数 $= 391 \times 8 = 3128$ 次。　**检查**：CIFAR-10 笔记本用 45000 张训练图、$B = 128$，$45000/128 = 351.6 \to 352$，与其日志“352/352”一致。

本题想说明：epoch 是“看完一遍数据”，step 是“更新一次参数”，两者差一个 $\lceil N/B \rceil$ 倍。

易错提醒　① **把超参数当成模型参数。** 学习率、batch size 不在模型里，保存的模型文件（如 `.keras`）中存的是权重和偏置。② **把 epoch 和 step 混为一谈。** “训练 8 轮”不是“更新 8 次”。

2.2 监督学习：有“标准答案”的学习

2.2.1 定义与基本术语

定义（监督学习，Supervised Learning）

在给定“输入特征”的前提下，预测相应的“输出标签”。训练数据由许多**输入—输出对**组成，每一对称为一个**样本**（example）；样本的输入称为**特征**（features），输出称为**标签**（label）。我们希望模型能“在给定输入特征的前提下估计标签（的概率）”，并能**泛化**到未见过的输入上。［原始资料］

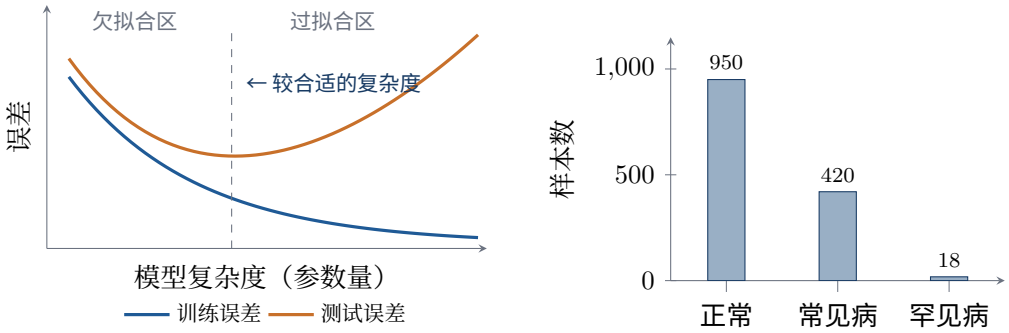
用符号写：训练集 $\mathcal{D} = \{(\boldsymbol{x}^{(i)}, y^{(i)})\}_{i=1}^{n}$，模型是一个带参数 θ 的函数 f_θ，目标是让 $f_\theta(\boldsymbol{x}) \approx y$，更一般地让模型输出的概率 $P_\theta(y \mid \boldsymbol{x})$ 接近真实情况。

问题类型	例子（输入 → 输出）	输出形式	本讲对应模型
二分类	邮件文本 → 是否垃圾邮件	是 / 否	Sigmoid（逻辑回归）
多分类	28 × 28 手写数字图 → 0~9	一个类别	Softmax 回归、MLP、CNN
线性回归	面积、房间数 → 房价	连续数值	线性回归
多标签分类	图片 → {风景, 夜景, ...}	标签集合	多个 Sigmoid 输出
目标检测	图片 → 每个物体的框与类别	框 + 类别	YOLO

表格节选自 PPT p.7 的 11 类问题［原始资料］。表中最后一列显示：本讲后面学到的每个模型，本质上都是**监督学习模型**。

2.2.2 监督学习的四大挑战

PPT p.8 与笔记 382 列出了四个问题［原始资料］。它们不是孤立的，下图把最重要的“过拟合”画出来：



左图横轴是模型复杂度，纵轴是误差：训练误差（蓝）随复杂度增加一直下降，测试误差（橙）先降后升。虚线左侧模型太简单，两种误差都大（**欠拟合**）；右侧模型把训练集“背”下来了，训练误差很小、测试误差反而变大（**过拟合**）。右图是一个示意性的样本分布：罕见病只有 18 例，模型若总猜“正常”也能有很高准确率，却完全没学会罕见病——这就是**样本不均衡**。

挑战	含义（原始资料）	为什么会发生 / 常见对策（教学补全）
标注成本高	标签需人工或专家标注，成本大	医学、工业缺陷需要专家；对策：半监督、主动学习、数据增强
过拟合风险	训练集表现好，测试集表现差	参数多、数据少；对策：更多数据、正则化、Dropout、早停
样本不均衡	一些标签（如罕见病）样本很少，模型偏向常见类	损失被多数类主导；对策：重采样、类别加权、看召回率而非只看准确率
泛化能力差	真实环境遇到新分布（分布漂移），模型可能失败	训练与部署数据不同分布；对策：持续收集数据、在线更新

> **老师的课堂补充**　笔记 382 的红笔写道：“打算发论文：看顶刊，了解它们的模型，复现不出来就有机会。”［原始资料］这句话的学术含义是：一个方法*在别人的数据上*表现好，*在你的数据上*却复现不出来，往往恰好暴露了**泛化能力或分布漂移**问题——而找出原因、改进方法，本身就是研究贡献。

2.3 无监督学习：没有标准答案，也要有“好坏标准”

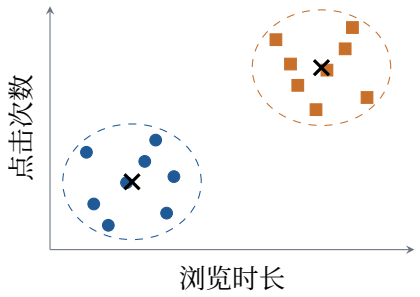
定义（无监督学习，Unsupervised Learning）

训练数据**没有人为标注的标签**，模型需要自己从数据中发现结构、模式或规律。常见任务：聚类、主成分分析（降维）、异常检测、生成模型、词嵌入、自编码器等。［原始资料］

PPT 用三个生活例子说明“没有标准答案”：学长给你 10 篇论文让你“自己研究吧”；“你觉得自己错在哪了？”；导师问“你觉得自己有什么问题？”［原始资料］——模型要*自己从数据中“学会看门道”*。

2.3.1 无监督学习有损失函数吗？

有。虽然没有“真实答案”，但仍要衡量模型的好坏，于是我们**构造一个目标函数来间接定义什么是好**，它就是损失函数［原始资料］。下面用聚类给一个具体例子［教学补全］：

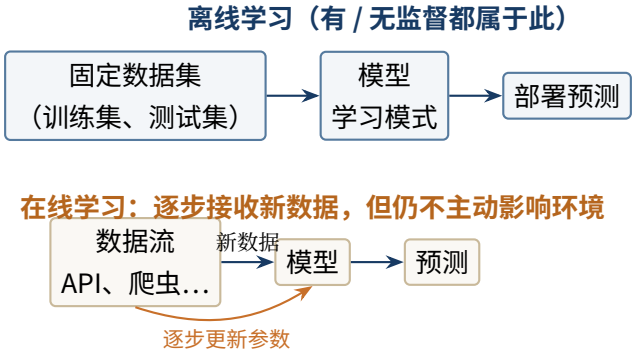


K-Means 聚类的目标函数是

$$J = \sum_{i=1}^{n} \left\| \boldsymbol{x}^{(i)} - \boldsymbol{\mu}_{c(i)} \right\|^2,$$

其中 $\boldsymbol{\mu}_{c(i)}$ 是样本 i 所属簇的中心（图中黑色 ×）。J 越小，说明每个点离自己的簇中心越近、“同类越抱团”。没有任何标签，但“抱团程度”就是**人为构造的“好”的标准**。

2.4 离线学习与在线学习



PPT 强调［原始资料］：无论有监督还是无监督，**本质上都是“离线学习”**——模型不会主动影响环境或采集新数据，所有数据已提前收集好；在线学习则逐步接收新数据（例：股票价格预测、广告点击率预估），**但仍然不主动影响环境**。

“但预测远远不够”——人工智能的目标不仅是识别与预测，而是能与环境*对话*和*作用*。当模

型从“预测器”（Predictive Model）变成“智能体”（Agent）时，就必须认真思考环境。

2.5 环境六问：从预测器走向智能体

PPT p.16—20 与笔记 382—383 提出了关于环境的一组问题［原始资料］。本讲义把它们整理为一张表，并为每一问补上对应的专业概念：

问题	例子（原始资料）	对应概念
① 环境记得我以前做过什么吗?	迷宫中走过的路线影响现在的位置；对话中前几句话影响对方回答	状态依赖历史；POMDP
② 环境能提供反馈吗?	自动驾驶刹车及时给正反馈；游戏得分；GPT 的用户点赞与偏好选择	奖励信号设计
③ 环境是我的“敌人”吗?	下围棋的对手；防火墙与不断变化的攻击者	博弈论、min-max、GAN
④ 环境会变吗?	疫情传播机制变化；用户兴趣随季节、热点变化	分布漂移（concept drift）
⑤ 环境可以忽略吗?	猫狗识别只看图片即可；自动驾驶不能忽略道路、行人、红绿灯	自主智能体必须建模环境

> **教学补全：什么是 POMDP?**　若智能体*每一步都能看到环境的完整状态* s_t，问题称为马尔可夫决策过程（MDP）；若只能看到*部分信息*（观测 o_t），比如对话中看不到对方心里在想什么，就只能“通过历史行为和观测来猜测当前环境”，这称为**部分可观测马尔可夫决策过程**（POMDP）。笔记中的“部分马尔科夫”是它的简写，规范术语以 PPT 为准。

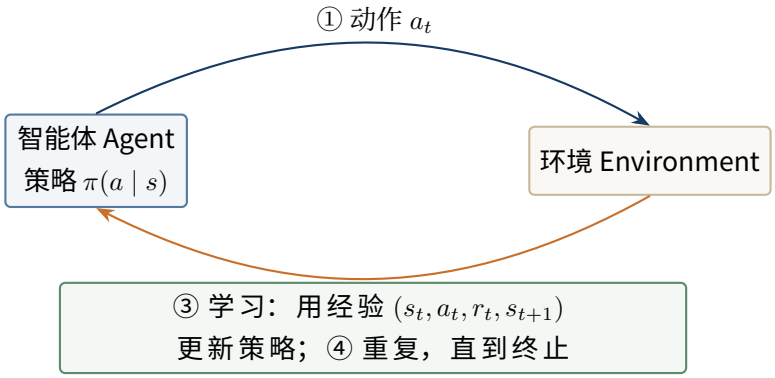
2.6 强化学习：在试错中学会行动

2.6.1 为什么需要强化学习

监督学习的每个样本都有“正确答案”，但下棋、开车、打游戏时，没有人能告诉你每一步的标准动作，只能在做完一串动作之后得到一个（可能延迟的）好坏反馈。强化学习就是为这种情况设计的。

定义（强化学习，Reinforcement Learning，RL）

强化学习是一类智能体（agent）通过与环境（environment）交互、学习**最优行为策略**（policy）的方法，其核心思想是“试错”：智能体在环境中采取动作（action），获得奖励（reward）或惩罚，以此指导未来的决策。与监督学习不同，RL 不直接提供“正确的标签”，而是提供稀疏或延迟的反馈信号。［原始资料］



上图对应 PPT p.23 的交互循环［原始资料］：智能体观察状态 s_t，按策略选择动作 a_t；环境执行动作后转移到新状态 s_{t+1} 并给出即时奖励 r_t；智能体用这组经验更新策略，如此循环。

2.6.2 用“四要素”理解强化学习

要素	监督学习	强化学习
数据	静态的 $(\boldsymbol{x}, y)$，全部可见	交互产生的经验四元组 (s_t, a_t, r_t, s_{t+1})
模型	$f_\theta(\boldsymbol{x})$ 或 $P_\theta(y \mid \boldsymbol{x})$	策略 $\pi(a \mid s)$：在状态 s 下选动作 a 的概率
目标函数	最小化预测误差（MSE、交叉熵）	最大化长期累计奖励的期望
优化	梯度下降 + 反向传播	策略梯度、Q-learning 等（后续课程）

2.6.3 回报与折扣因子

核心公式（折扣回报，Return）

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots \qquad \gamma \in [0, 1)$$

G_t：从时刻 t 开始获得的“打折后”的总奖励；r_{t+k}：第 $t+k$ 步的即时奖励；γ：折扣因子，衡量未来奖励的价值——越小越“短视”。［原始资料］（取值范围见下方纠错）

推导：为什么要打折？$\gamma < 1$ 保证回报有限　**要证明**：若每一步奖励都满足 $|r_{t+k}| \le R_{\max}$，且 $0 \le \gamma < 1$，则 $|G_t| \le \dfrac{R_{\max}}{1-\gamma}$。

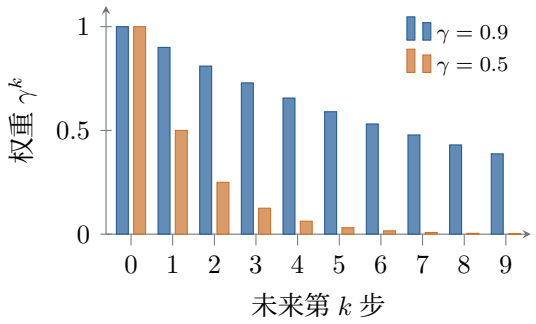
思路：把 G_t 与等比数列比较。　**证明**：由三角不等式与已知条件，

$$|G_t| \le \sum_{k=0}^{\infty} \gamma^k |r_{t+k}| \le R_{\max} \sum_{k=0}^{\infty} \gamma^k = R_{\max} \cdot \frac{1}{1-\gamma},$$

最后一步用了等比级数求和公式 $\sum_{k=0}^{\infty} \gamma^k = \frac{1}{1-\gamma}$（当 $|\gamma| < 1$ 时成立）。　□

条件为什么不能删：若 $\gamma = 1$ 且每步奖励都是 1，则 $G_t = 1 + 1 + 1 + \cdots = \infty$，“哪个策略更好”就无法比较。因此 $\gamma = 1$ 只适用于必定在有限步内结束的任务。

递推关系：把第一项单独拿出来，$G_t = r_t + \gamma\big(r_{t+1} + \gamma r_{t+2} + \cdots\big) = r_t + \gamma G_{t+1}$。它说明“现在的总价值 = 眼前奖励 + 打折后的未来总价值”，是后续课程中贝尔曼方程的起点。



左图横轴是“未来第几步”，纵轴是该步奖励在 G_t 中的权重 γ^k。$\gamma = 0.9$（蓝）时第 9 步奖励仍有约 0.39 的权重，智能体“有远见”；$\gamma = 0.5$（橙）时 3 步以后的奖励几乎被忽略，智能体“短视”。

例 2.2　计算一次回报

已知：$\gamma = 0.9$，某回合从 $t = 0$ 起依次获得奖励 $r_0 = 1$，$r_1 = 0$，$r_2 = 2$，之后结束（奖励为 0）。**求** G_0 与 G_1。

解：$G_0 = 1 + 0.9 \times 0 + 0.9^2 \times 2 = 1 + 0 + 1.62 = 2.62$；$G_1 = 0 + 0.9 \times 2 = 1.8$。　**检查（用递推）**：$G_0 = r_0 + \gamma G_1 = 1 + 0.9 \times 1.8 = 2.62$，一致。

2.6.4 策略、目标函数与价值函数

核心公式（RL 的模型与目标）

策略：$\pi(a \mid s)$ = 在状态 s 下选择动作 a 的概率；　**目标**：$\max_{\pi} \mathbb{E}_{\pi}\Big[\sum_{t=0}^{\infty} \gamma^t r_t\Big]$　［原始资料］

有时还引入 **状态—动作值函数** $Q^{\pi}(s,a) = \mathbb{E}\big[\text{未来的累计奖励} \,\big|\, s_t = s, a_t = a, \pi\big]$ 与 **状态值函数** $V^{\pi}(s) = \mathbb{E}_{a\sim\pi(\cdot|s)}\big[Q^{\pi}(s,a)\big]$。［原始资料］

原图纠错：目标函数与 γ 的范围

原始写法：笔记 383 写 $\max_{\pi} \mathbb{E}_{\pi}[\gamma^k r_k]$，并记 $\gamma \in [0,1]$（PPT p.23 亦写 $[0,1]$）。　**问题**：① 漏掉了求和号——目标是整条轨迹奖励之和的期望，而不是某一项；② 对无限长的任务，$\gamma = 1$ 可能使回报发散（见上面的证明）。　**规范写法**：$\max_{\pi} \mathbb{E}_{\pi}\big[\sum_{t=0}^{\infty} \gamma^t r_t\big]$，$\gamma \in [0,1)$；有限步回合任务可取 $\gamma = 1$。　**影响**：不影响后续章节，但做题时应按规范写法。

> **“期望”为什么出现？**　策略 π 是*概率*，环境转移也可能随机，所以同一策略每次玩出的轨迹不同、回报不同。我们比较的是策略的“平均表现”，这就是 $\mathbb{E}_{\pi}[\cdot]$。$V^{\pi}(s)$ 则是把“在 s 下各动作的价值 $Q^{\pi}(s,a)$”按策略给出的动作概率加权平均。

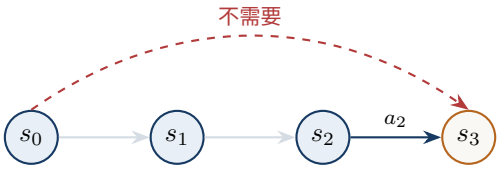
2.6.5 马尔可夫性

定义（马尔可夫性，Markov Property）

当前状态所包含的信息足以决定未来状态的转移概率，而与历史路径无关：

$$P(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \ldots, s_0, a_0) = P(s_{t+1} \mid s_t, a_t).$$

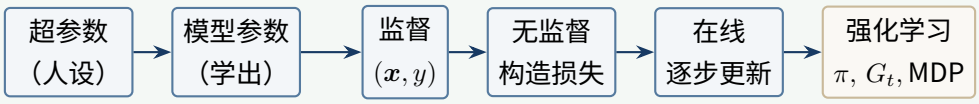
即“过去对未来的影响全部通过现在传递”（无记忆性假设）。满足该性质的决策问题称为马尔可夫决策过程 MDP。［原始资料］



正例：象棋——当前棋盘局面（状态）完全决定下一步可能的局面，不需要知道棋局是怎么走到这里的。

反例：只看一张静止照片判断球往哪飞——一帧图像里没有速度，必须结合前几帧；此时“单帧”不满足马尔可夫性。把最近几帧拼在一起作为状态，就能恢复马尔可夫性［教学补全］。

本章小结与知识地图



到这里，我们已经解决了什么？“学习”的共同框架（数据—模型—损失—优化），以及监督、无监督、在线、强化四种范式的区别。　**下一步还需要解决什么？**框架里的“模型”到底长什么样？下一章从最简单的模型——**线性模型**——开始。

学完这里，你应该能够回答

1. 学习率、权重、epoch、偏置中，哪些是超参数？
2. 训练集 30000 张、batch size 64，每轮多少步？
3. 监督学习的“样本、特征、标签”分别指什么？
4. 过拟合时训练误差与测试误差分别怎样？
5. 无监督学习没有标签，靠什么判断好坏？
6. 在线学习与强化学习的根本区别是什么？
7. 写出 G_t 的定义与递推式；γ 越小意味着什么？
8. 马尔可夫性说的是什么？举一个不满足的例子。

第 3 章　线性模型：线性回归、Softmax 回归与 Sigmoid

承上启下　上一章说明了“学习 = 用数据调参数让目标变好”。本章给出第一类具体模型——**线性模型**。PPT 第 54 页的一句话是本章的总纲［原始资料］：

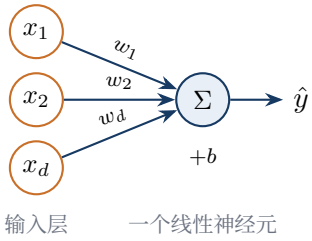
> 线性回归、Softmax 分类、Sigmoid 分类，本质上都是：**输入先经过一次线性计算 $\boldsymbol{z} = W\boldsymbol{x} + \boldsymbol{b}$，再得到输出**。
> 区别只是最后**怎么解释** $\boldsymbol{z}$：直接当预测值 / 转成多个类别概率 / 压缩到 $(0, 1)$。

本章知识路线　线性回归（MSE、最小二乘）→ 决定系数 R^2 → 多输出回归 → Softmax（多分类）→ 交叉熵 → Sigmoid 与 BCE（多标签）→ 统一视角与数据集。

3.1　线性回归：用一条直线（超平面）做预测

3.1.1　它解决什么问题

房价由面积、房间数、地段决定；研究生录取概率由 GRE、TOEFL、GPA 等决定。这类问题的输出是**连续数值**，最朴素的假设是：输出是各个特征的*加权和*再加一个常数。



核心公式（线性回归模型）

$$\hat{y} = \boldsymbol{w}^\top \boldsymbol{x} + b = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + b$$

$\boldsymbol{x} \in \mathbb{R}^d$：一个样本的 d 个特征；$\boldsymbol{w} \in \mathbb{R}^d$：权重，表示每个特征的“影响力”；$b$：偏置（截距）；$\hat{y}$：预测值。［原始资料］

左图就是 PPT p.30 中“三个圆圈连到一个圆圈”的含义：每条连线上有一个权重，神经元把加权和加上偏置后直接输出——**线性回归就是只有一个神经元、没有激活函数的神经网络**，这也是 PPT 把它归入“线性神经网络”的原因。

3.1.2 怎么衡量好坏：均方误差

核心公式（均方误差，MSE）

$$L(\boldsymbol{w}, b) = \frac{1}{n} \sum_{i=1}^{n} \left(y^{(i)} - \hat{y}^{(i)} \right)^2, \qquad \hat{y}^{(i)} = \boldsymbol{w}^\top \boldsymbol{x}^{(i)} + b.$$

$y^{(i)} - \hat{y}^{(i)}$ 称为**残差**，即图中数据点到直线的竖直距离。

为什么用平方？［教学补全］① 正负误差不会互相抵消；② 大误差被放大惩罚；③ 平方函数处处可导，便于求最小值。

3.1.3 公式从哪里来：一元最小二乘推导

推导：一元线性回归的最优 w, b（教学补全）　**要求**：对 $\hat{y} = wx + b$，求使 $S(w,b) = \sum_{i=1}^{n} (y_i - wx_i - b)^2$ 最小的 w, b（MSE 只差常数因子 $\frac{1}{n}$，最优点相同）。

思路：S 是 w, b 的二次函数，开口向上，最小值处两个偏导数都为 0。

第 1 步（对 b 求偏导）：$\dfrac{\partial S}{\partial b} = -2\sum_i (y_i - wx_i - b) = 0 \;\Rightarrow\; \sum y_i - w\sum x_i - nb = 0 \;\Rightarrow\; \boxed{b = \bar{y} - w\bar{x}}$，其中 $\bar{x}, \bar{y}$ 为平均值。它说明：**最优直线一定经过点** $(\bar{x}, \bar{y})$。

第 2 步（代回并对 w 求偏导）：把 $b = \bar{y} - w\bar{x}$ 代入，残差变为 $(y_i - \bar{y}) - w(x_i - \bar{x})$，于是

$$\frac{\partial S}{\partial w} = -2\sum_i (x_i - \bar{x})\left[(y_i - \bar{y}) - w(x_i - \bar{x}) \right] = 0 \;\Rightarrow\; \boxed{w = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}}$$

（第二步中把 $\partial / \partial w$ 作用于 $[(y_i - \bar{y}) - w(x_i - \bar{x})]^2$ 用了链式法则。）要求分母 $\sum (x_i - \bar{x})^2 \neq 0$，即 x *不能全相等*——否则所有点在一条竖线上，斜率无法确定。　□

一句话：斜率 = “x 与 y 一起变化的程度” ÷ “x 自身变化的程度”。

多元情形与神经网络中，一般不求解析解，而是用梯度下降(2.1)，需要的偏导数为（对 MSE 用链式法则）

$$\frac{\partial L}{\partial w_j} = -\frac{2}{n} \sum_{i=1}^{n} \left(y^{(i)} - \hat{y}^{(i)} \right) x_j^{(i)}, \qquad \frac{\partial L}{\partial b} = -\frac{2}{n} \sum_{i=1}^{n} \left(y^{(i)} - \hat{y}^{(i)} \right).$$

例 3.1　三个点的最小二乘直线

已知：数据 $(1,2),(2,3),(3,5)$。**求**最小二乘直线。

第一步：$\bar{x}=2$，$\bar{y}=\frac{10}{3}$。

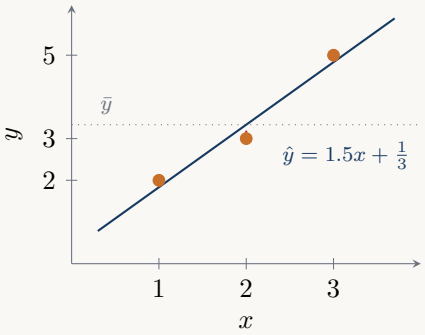
第二步：$\sum(x_i-\bar{x})(y_i-\bar{y})=(-1)(-\frac{4}{3})+0+(1)(\frac{5}{3})=3$，

$\sum(x_i-\bar{x})^2=1+0+1=2$，故 $w=\frac{3}{2}$。

第三步：$b=\bar{y}-w\bar{x}=\frac{10}{3}-3=\frac{1}{3}$。

结果：$\hat{y}=1.5x+\frac{1}{3}$。

检查：直线过 $(\bar{x},\bar{y})=(2,\frac{10}{3})$ √；残差 $\frac{1}{6},-\frac{1}{3},\frac{1}{6}$ 之和为 0 √（这正是第 1 步 $\partial S/\partial b=0$ 的含义）。



图的读法：橙点是数据，深蓝直线是拟合结果，红色虚线是残差（MSE 就是它们长度平方的平均），灰色点线是平均值 $\bar{y}$——下一节 R^2 要用到它。

3.2　决定系数 R^2：模型解释了多少变化?

MSE 的数值大小依赖单位（房价用“元”还是“万元”差 10^8 倍），很难直接判断“好不好”。我们需要一个**无量纲的、与基准比较的**指标。

核心公式 （决定系数，R^2，拟合优度）

$$R^2=1-\frac{\sum_{i=1}^{n}(y_i-\hat{y}_i)^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2}=1-\frac{\mathrm{RSS}}{\mathrm{TSS}}$$

y_i：真实值；$\hat{y}_i$：预测值；$\bar{y}$：真实值的平均。分子 RSS（残差平方和）表示模型的预测误差；分母 TSS（总平方和）表示数据本身的变动性。若 $R^2=0.8$，表示模型解释了约 80% 的目标变量变化。［原始资料］

为什么这样定义？——与“最笨的模型”比较　最笨的模型不看任何特征，永远预测平均值 $\bar{y}$，它的误差平方和恰好是 TSS。于是 RSS/TSS 是“你的模型误差 ÷ 最笨模型误差”，R^2 就是*相对于“只猜平均”，误差减少的比例*。在图 3.1 的例子中，红色残差比“点到 $\bar{y}$ 点线的距离”小得多，所以 R^2 接近 1。

三个关键取值［教学补全］：

- $R^2=1$：RSS $=0$，所有点恰好在预测线上（完美拟合）；
- $R^2=0$：模型与“只猜平均值”一样好（一样差）；
- $R^2<0$：**可以出现！**模型比只猜平均还差。反例：真实值 $2,3,5$，模型永远预测 10，RSS $=64+49+25=138$，TSS $=\frac{14}{3}$，$R^2=1-138\cdot\frac{3}{14}\approx-28.6$。所以“$R^2$ 一定在 0 到 1 之间”是**错误说法**；它只在“带截距的最小二乘线性回归、在训练集上计算”时才保证 ≥ 0。

例 3.2　计算例 3.1 的 R^2

$\mathrm{RSS}=(\frac{1}{6})^2+(\frac{1}{3})^2+(\frac{1}{6})^2=\frac{1}{36}+\frac{4}{36}+\frac{1}{36}=\frac{1}{6}$；$\mathrm{TSS}=(\frac{4}{3})^2+(\frac{1}{3})^2+(\frac{5}{3})^2=\frac{42}{9}=\frac{14}{3}$。

$R^2=1-\dfrac{1/6}{14/3}=1-\dfrac{1}{28}=\dfrac{27}{28}\approx 0.964$。**解释**：这条直线解释了约 96.4% 的 y 的变化。

3.2.1 案例数据集与多输出回归

PPT p.32 使用 Kaggle 的 Graduate Admissions 数据集［原始资料］：7 个特征（GRE 满分 340、TOEFL 满分 120、学校评级 1–5、SOP 1–5、LOR 1–5、CGPA 满分 10、是否有科研经历 0/1），目标是录取概率 Chance of Admit（0–1 之间）；Serial No. 只是编号，**不应作为特征**。于是 $d = 7$，$\hat{y} = \boldsymbol{w}^\top \boldsymbol{x} + b$ 中 $\boldsymbol{w} \in \mathbb{R}^7$。

如果标签有多个值（多个输出）怎么办？　笔记 383 写道：“多个回归。※不要认为全是分类”［原始资料］。即对每个输出 j 各做一个线性回归 $\hat{y}_j = \boldsymbol{w}_j^\top \boldsymbol{x} + b_j$，把它们叠在一起就是矩阵形式

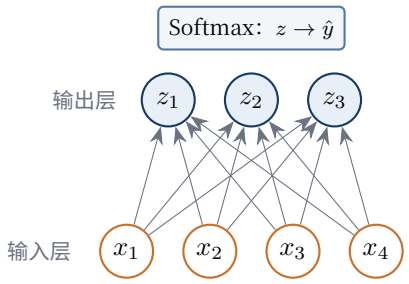
$$\hat{\boldsymbol{y}} = W\boldsymbol{x} + \boldsymbol{b}, \qquad W \in \mathbb{R}^{m\times d}\ (\text{第 } j \text{ 行是 } \boldsymbol{w}_j^\top),\ \boldsymbol{b} \in \mathbb{R}^m.$$

例如同时预测明天的最高温与最低温（$m = 2$），输出仍是连续数值，这是**多输出回归，不是分类**。

3.3 Softmax 回归：从“打分”到“概率”

3.3.1 为什么线性回归不够用

给一张图判断是“鞋子、衣服、裤子”中的哪一类（多分类）［原始资料］。若用一个输出 $\hat{y} \in \{1, 2, 3\}$ 做回归，会暗含“裤子(3) 比衣服(2) 更大”“鞋子和裤子的平均是衣服”这种*无意义的顺序关系*。正确做法是：**每个类别一个输出**，各自给一个“像这一类的程度”打分。



左图对应 PPT p.35 与笔记 384 的“4 输入 3 输出”全连接图［原始资料］：每个输出 $z_j = \boldsymbol{w}_j^\top \boldsymbol{x} + b_j$ 都连接全部输入，共有 $4 \times 3 = 12$ 个权重和 3 个偏置。输出 z_j 称为 **logit**（线性打分）。一般地：

$$\boldsymbol{z} = W\boldsymbol{x} + \boldsymbol{b}, \quad W \in \mathbb{R}^{K\times d},\ \boldsymbol{b} \in \mathbb{R}^K.$$

K 为类别数，d 为特征数。

PPT p.37 的例子［原始资料］：某张图的打分为 $z_{\text{鞋子}} = 1.2,\ z_{\text{衣服}} = 2.5,\ z_{\text{裤子}} = 0.9$。这些分数“代表模型觉得图像属于该类的可能性有多大，但这是线性变换，还不代表真正的概率”——它们可以是负数、加起来也不等于 1，无法直接当概率使用。

3.3.2 Softmax 函数

核心公式（Softmax）

$$\hat{y}_j = \operatorname{softmax}(\boldsymbol{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}}, \qquad j = 1, \dots, K.$$

两步理解［原始资料］：① 取指数 e^{z_j}，“让所有类别的线性打分都变成正数”；② 除以总和，“让所有指数值相加作为总值，每一个类别占多少比例”。

例 3.3　鞋子—衣服—裤子（PPT p.39–40 数据）

第一步（取指数）：$e^{1.2} \approx 3.32$，$e^{2.5} \approx 12.18$，$e^{0.9} \approx 2.46$。

第二步（求和）：$3.32 + 12.18 + 2.46 = 17.96$。

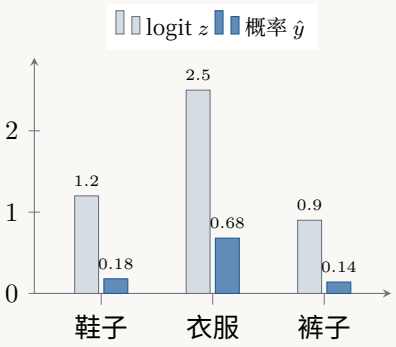
第三步（归一化）：

$p_{\text{鞋子}} = 3.32/17.96 \approx 0.18$，

$p_{\text{衣服}} = 12.18/17.96 \approx 0.68$，

$p_{\text{裤子}} = 2.46/17.96 \approx 0.14$。

检查：$0.18 + 0.68 + 0.14 = 1.00$ √；排序“衣服 > 鞋子 > 裤子”与打分排序相同 √。



本题想说明：Softmax 把一组任意实数变成“非负、和为 1、保持大小顺序”的概率分布。

原图纠错：PPT p.38 数值

原始写法：$\text{softmax}([2.0, 1.0, 0.1]) \approx [0.65, 0.24, 0.11]$。　**问题**：$e^{2.0} = 7.389$，$e^{1.0} = 2.718$，$e^{0.1} = 1.105$，和为 11.212，第三项 $1.105/11.212 = 0.0986 \approx 0.10$，原写法三项之和为 1.00 只是巧合地由 0.65 的舍入“补”上的。　**规范写法**：$\approx [0.659, 0.242, 0.099] \approx [0.66, 0.24, 0.10]$。

影响：无，仅数值精度。

3.3.3 Softmax 的性质：为什么它成为流行方法

PPT p.41 与笔记 384 给出三条理由［原始资料］：① 将任意分数变成概率（0~1，且加起来 = 1）；② 保留相对大小（原本得分高的，概率也大）；③ 方便用于交叉熵计算。下面给出前两条的证明，并补充两条重要性质［教学补全］。

证明：Softmax 的四条性质　**性质 1（是概率分布）**：因为 $e^z > 0$ 对任意实数成立，分子分母都为正，故 $\hat{y}_j > 0$；又分子 $\le$ 分母，且当 $K \ge 2$ 时分母还多出其他正项，故 $\hat{y}_j < 1$。求和：$\sum_j \hat{y}_j = \frac{\sum_j e^{z_j}}{\sum_k e^{z_k}} = 1$。

性质 2（保序）：若 $z_i > z_j$，由 e^x 严格递增得 $e^{z_i} > e^{z_j}$，两者除以同一个正数，得 $\hat{y}_i > \hat{y}_j$。所以**概率最大的类 = logit 最大的类**，预测时 $\arg\max_j \hat{y}_j = \arg\max_j z_j$。

性质 3（平移不变）：对任意常数 c，$\frac{e^{z_j + c}}{\sum_k e^{z_k + c}} = \frac{e^c e^{z_j}}{e^c \sum_k e^{z_k}} = \hat{y}_j$。所以只有打分的*差*有意义——这就是 PPT 提示“打分大小是自己和自己比”的数学含义。实际编程常取 $c = -\max_k z_k$，避免 e^{1000} 溢出。

性质 4（与 Sigmoid 的关系）：当 $K = 2$ 时，$\hat{y}_1 = \frac{e^{z_1}}{e^{z_1} + e^{z_2}} = \frac{1}{1 + e^{-(z_1 - z_2)}} = \sigma(z_1 - z_2)$。即**二分类的 Softmax 就是 Sigmoid**（下一节）。　□

易错提醒　**Softmax 不是“按比例归一化”**。$[1, 2]$ 按比例是 $[\frac{1}{3}, \frac{2}{3}]$，Softmax 是 $[0.27, 0.73]$；$[10, 20]$ 按比例仍是 $[\frac{1}{3}, \frac{2}{3}]$，Softmax 却是 $[0.00005, 0.99995]$——差距被指数放大，且*缩放*打分会改变结果（只有*平移*不会）。

3.4 交叉熵损失：概率离真实答案有多远

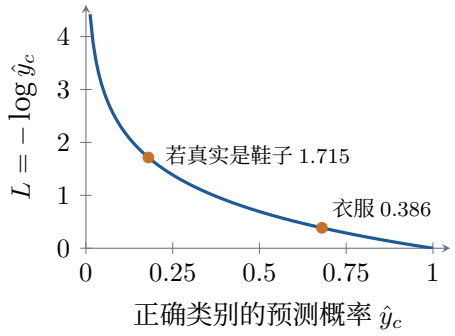
3.4.1 定义与 one-hot 化简

有了预测概率 $\hat{\boldsymbol{y}} = [\hat{y}_1, \ldots, \hat{y}_K]$，还需要衡量“模型预测的概率分布距离真实标签有多远” ［原始资料］。真实标签用 **one-hot 向量**表示：若真实类别为第 c 类，则 $\boldsymbol{y} = [0, \ldots, 0, \underset{c}{1}, 0, \ldots, 0]$。

核心公式 （交叉熵损失，Cross-Entropy）

$$L = -\sum_{j=1}^{K} y_j \log \hat{y}_j = -\log \hat{y}_c$$

因为 one-hot 中只有 $y_c = 1$，其余项都乘以 0 消失。含义：**只看模型给“正确类别”的概率** $\hat{y}_c$——$\hat{y}_c$ 越大，损失越小。 ［原始资料］ （本讲义 log 均指自然对数 ln）



左图横轴是正确类别的预测概率，纵轴是交叉熵损失。曲线在 $\hat{y}_c \to 1$ 时趋于 0，在 $\hat{y}_c \to 0$ 时趋于无穷——“**预测正确类别的概率越大，损失就越小；预测错误，损失就越大**” ［原始资料］。以例 3.3 为例：若真实类别是“衣服”，$L = -\ln 0.68 \approx 0.386$；若真实类别是“鞋子”，$L = -\ln 0.18 \approx 1.715$，模型被重罚。

3.4.2 公式从哪里来：最大似然

推导：交叉熵 = 负对数似然（教学补全）　**思路**：好的模型应该让“训练集中真实出现的标签”具有尽可能大的概率。

对 n 个独立样本，模型给出“全部标签都正确”的概率（似然）为 $\prod_{i=1}^{n} \hat{y}_{c_i}^{(i)}$。连乘不便求导，取对数变成求和（log 单调递增，不改变最大值位置），再加负号把“最大化”变成“最小化”：

$$\max \prod_i \hat{y}_{c_i}^{(i)} \iff \max \sum_i \log \hat{y}_{c_i}^{(i)} \iff \min \frac{1}{n} \sum_{i=1}^{n} \left(-\log \hat{y}_{c_i}^{(i)} \right).$$

括号里正是每个样本的交叉熵。所以**最小化交叉熵 = 最大化正确标签的概率**。 □

3.4.3 一个漂亮的梯度：$\partial L / \partial z_j = \hat{y}_j - y_j$

推导：Softmax + 交叉熵的梯度（教学补全）　**第 1 步**：$\log \hat{y}_k = z_k - \log \sum_m e^{z_m}$，对 z_j 求导：$\dfrac{\partial \log \hat{y}_k}{\partial z_j} = \delta_{kj} - \dfrac{e^{z_j}}{\sum_m e^{z_m}} = \delta_{kj} - \hat{y}_j$，其中 $\delta_{kj} = 1$（当 $k = j$）否则为 0。

第 2 步：$\dfrac{\partial L}{\partial z_j} = -\sum_k y_k (\delta_{kj} - \hat{y}_j) = -y_j + \hat{y}_j \sum_k y_k = \hat{y}_j - y_j$（因为 $\sum_k y_k = 1$）。

第 3 步（链式法则到参数）：由 $z_j = \boldsymbol{w}_j^{\top} \boldsymbol{x} + b_j$，$\dfrac{\partial L}{\partial \boldsymbol{w}_j} = (\hat{y}_j - y_j)\, \boldsymbol{x}$，$\dfrac{\partial L}{\partial b_j} = \hat{y}_j - y_j$。 □

直观：梯度 = “预测概率 − 真实概率”。预测衣服 0.68、真实是衣服（1）时，$\partial L / \partial z_{\text{衣服}} = -0.32 < 0$，梯度下降会*增大* $z_{\text{衣服}}$；对错误类别鞋子，$0.18 - 0 = 0.18 > 0$，会*减小* $z_{\text{鞋子}}$。这正

> 是“反向传播更新参数”的具体内容。

方法总结：Softmax 回归的训练过程（PPT p.43、笔记 384）

1. 初始化参数 $W \in \mathbb{R}^{K\times d}$，$\boldsymbol{b} \in \mathbb{R}^K$；
2. 对每个样本：计算 logit $\boldsymbol{z} = W\boldsymbol{x} + \boldsymbol{b}$ → Softmax 得预测概率 $\hat{\boldsymbol{y}}$ → 计算交叉熵 $L = -\log \hat{y}_c$；
3. 对损失反向传播（梯度 $\hat{y}_j - y_j$），用优化器更新 $W, \boldsymbol{b}$；重复直到收敛。

项目	线性回归	Softmax 回归
输出形式	连续实数	类别（概率最大对应的类别）
输出层	1 个（或 m 个）神经元	K 个神经元（每类一个）
激活函数	无	Softmax
损失函数	均方误差 MSE	交叉熵 Cross-Entropy
优化目标	最小化 MSE	最小化交叉熵（= 最大化正确类别概率）

3.5 多标签分类：Sigmoid 与二值交叉熵

3.5.1 为什么这时不能用 Softmax

一张图里既有“狗”也有“草地”［原始资料］：标签 $\boldsymbol{y} = [1, 0, 1, 0]$（狗、猫、草地、人），这称为**多标签分类**——一个样本可以同时属于多个类别。Softmax 的概率*和为 1*，各类别“互相竞争”：狗的概率上升，草地的概率必然下降，无法同时给两者都接近 1 的概率。PPT p.45 的预测 $\hat{\boldsymbol{y}} = [0.9, 0.1, 0.8, 0.3]$ 之和为 2.1，本身就不可能是 Softmax 的输出。所以“这个时候就不能用 Softmax 了！要用 Sigmoid！”［原始资料］——**每个类别独立做一次“是 / 否”的二分类**。

原图纠错：PPT p.47—49 标题

原始写法：“Sigmoid 用于多标签分类（Single-label classification）”。　**问题**：中文“多标签”与英文“Single-label（单标签）”矛盾。　**规范写法**：多标签分类（Multi-label classification）；Softmax 对应单标签多分类（Single-label, multi-class）。　**影响**：概念层面必须区分，这是考试高频点。

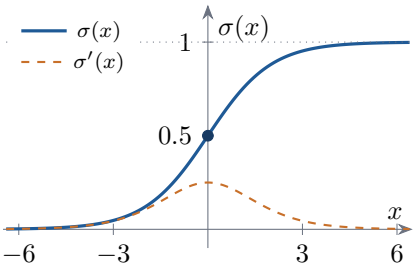
3.5.2 Sigmoid 函数

核心公式（Sigmoid）

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

输入 $x \in (-\infty, +\infty)$，输出 $\in (0,1)$；x 越大越接近 1，表示“该类别更可能是正类”。可理解为“这个类别的置信度”。［原始资料］

x	-10	0	10
$\sigma(x)$	≈ 0.00005	0.5	≈ 0.99995



图中蓝色实线是 Sigmoid：S 形、在 $x=0$ 处等于 0.5、两端分别贴近 0 和 1（灰色点线是渐近线 $y=1$）。橙色虚线是它的导数，最大值 0.25 出现在 $x=0$，两端几乎为 0——这就是后面 MLP 中 Sigmoid 容易“梯度消失”的原因。

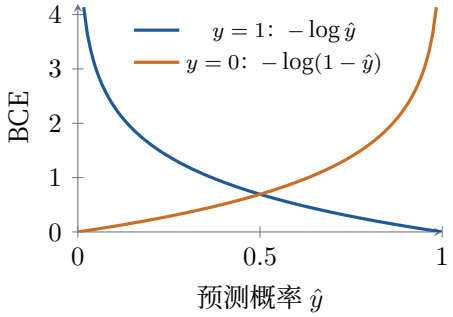
> **证明：Sigmoid 的两条性质（教学补全）**　**对称性** $\sigma(-x) = 1-\sigma(x)$：$1-\sigma(x) = \dfrac{1+e^{-x}-1}{1+e^{-x}} = \dfrac{e^{-x}}{1+e^{-x}} = \dfrac{1}{e^{x}+1} = \sigma(-x)$（分子分母同乘 e^{x}）。
> **导数** $\sigma'(x) = \sigma(x)\big(1-\sigma(x)\big)$：$\sigma'(x) = \dfrac{e^{-x}}{(1+e^{-x})^2} = \dfrac{1}{1+e^{-x}}\cdot\dfrac{e^{-x}}{1+e^{-x}} = \sigma(x)\big(1-\sigma(x)\big)$。由于 $\sigma(1-\sigma) \le \frac{1}{4}$（当 $\sigma=\frac{1}{2}$ 时取等），导数最大为 0.25。 □

3.5.3 二值交叉熵 BCE

核心公式（二值交叉熵，Binary Cross Entropy）

$$\mathrm{BCE} = -\big[\,y\log\hat{y} + (1-y)\log(1-\hat{y})\,\big], \qquad y\in\{0,1\},\ \hat{y}=\sigma(z)\in(0,1).$$

真实标签为 1 时希望 $\hat{y}\to 1$，损失变小；真实标签为 0 时希望 $\hat{y}\to 0$，损失也变小；预测越偏离真实值，损失越大。［原始资料］多标签时对每个类别各算一个 BCE 再取平均。



公式从哪里来［教学补全］：把 $\hat{y}$ 看作“$y=1$ 的概率”，则单个样本标签出现的概率是 $\hat{y}^{y}(1-\hat{y})^{1-y}$（$y=1$ 时为 $\hat{y}$，$y=0$ 时为 $1-\hat{y}$）。取负对数即得 BCE——与交叉熵完全同源。

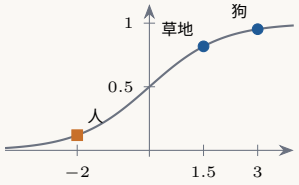
梯度：可以验证 $\dfrac{\partial\,\mathrm{BCE}}{\partial z} = \hat{y}-y$，与 Softmax 交叉熵形式相同。

例 3.4　狗—草地—人（PPT p.49—51，数值已精确复核）

真实标签 $[1,1,0]$（图中有狗和草地、没有人），模型 logits 为 $[3.0,\ 1.5,\ -2.0]$。

类别	真实 y	logit z	$\hat{y}=\sigma(z)$	BCE	计算
狗	1	3.0	0.9526	0.0486	$-\ln 0.9526$
草地	1	1.5	0.8176	0.2014	$-\ln 0.8176$
人	0	-2.0	0.1192	0.1269	$-\ln(1-0.1192)=-\ln 0.8808$
平均 BCE $=(0.0486+0.2014+0.1269)/3$				**0.1256**	模型预测得还不错

本题想说明：三个类别的概率 $0.95+0.82+0.12=1.89\neq 1$，它们互不竞争；每个类别分别用自己的 BCE 惩罚。 **纠错说明**：PPT 中草地 0.2013、人 0.1266、均值 0.1255 为舍入误差，精确值如上表（不影响结论）。

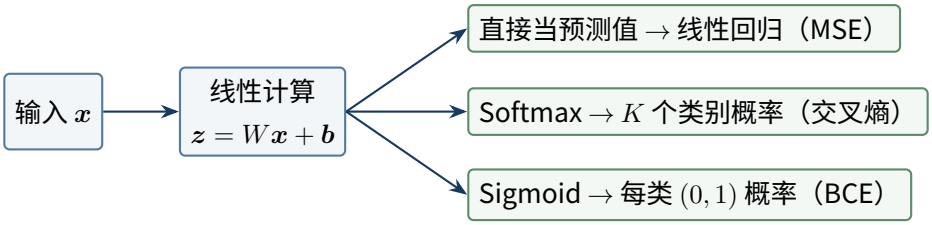


3.5.4 相近概念辨析：Softmax vs Sigmoid

比较维度	Softmax + 交叉熵	Sigmoid + BCE
任务	单标签多分类：每个样本恰属于一类	二分类，或多标签分类：可同时属于多类
输出之间	互相竞争，和为 1	相互独立，和不必为 1
函数	$\hat{y}_j=e^{z_j}/\sum_k e^{z_k}$	$\hat{y}_j=1/(1+e^{-z_j})$，逐个作用
损失	$-\log \hat{y}_c$	$-[y\log\hat{y}+(1-y)\log(1-\hat{y})]$，逐类平均
预测规则	取概率最大的一类	每类 $\hat{y}_j>0.5$（或设定阈值）即判为“有”
关系	$K=2$ 时 Softmax 退化为 $\sigma(z_1-z_2)$	

3.6 统一视角、数据集与课程代码

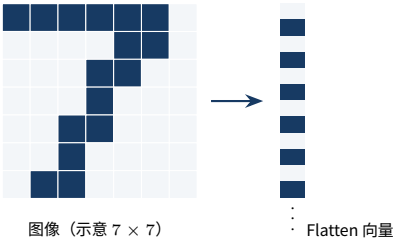
3.6.1 同一个 z，三种解释



记号提醒：$Wx+b$ 与 $xW+b$　PPT p.43 与笔记写 $\boldsymbol{z}=W\boldsymbol{x}+\boldsymbol{b}$（$\boldsymbol{x}$ 为列向量，$W\in\mathbb{R}^{K\times d}$）；PPT p.54 与 Keras 代码写 $\boldsymbol{z}=\boldsymbol{x}W+\boldsymbol{b}$（$\boldsymbol{x}$ 为行向量，$W\in\mathbb{R}^{d\times K}$）。两者只是转置约定不同，**参数个数完全相同**（都是 $dK+K$）。做题时先看清矩阵的形状。

3.6.2 MNIST 与 Fashion-MNIST

	MNIST	Fashion-MNIST
内容	手写数字 0~9	10 类服饰（T 恤、裤子、套衫、连衣裙、外套、凉鞋、衬衫、运动鞋、包、短靴）
规模	共 7 万张：60000 训练 + 10000 测试	同样 7 万张：60000 训练 + 10000 测试
图像	28×28 灰度，像素值 0~255	28×28 灰度，格式与 MNIST 相同
定位	分类算法的入门练习数据集	用于替代 MNIST，更复杂（由 Zalando Research 于 2017 年发布）



线性模型只能接收向量，所以代码中先用 `Flatten` 把 28×28 的图像按行拉平成 784 维向量（左图用 7×7 示意），再送入全连接层。这一步会**丢掉“哪些像素彼此相邻”的空间信息**——第 5 章 CNN 要解决的正是这个问题。

例 3.5　纯 Softmax 回归有多少参数？

已知：MNIST，$d = 784$，$K = 10$。**求**参数量。　**解**：W 有 $784 \times 10 = 7840$ 个，$\boldsymbol{b}$ 有 10 个，共 **7850** 个（PPT p.65“单层参数量”）［原始资料］。　**检查**：每个输出神经元连 784 个输入 + 1 个偏置，$785 \times 10 = 7850$ √。

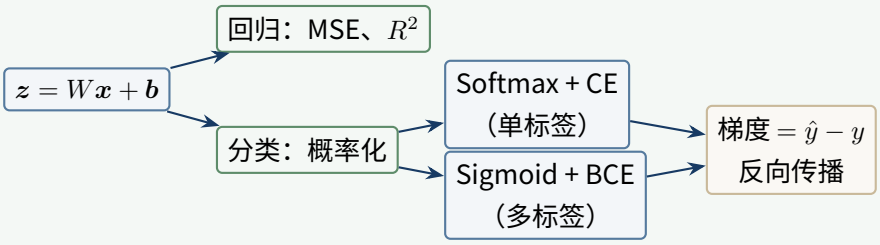
课程代码阅读：笔记本里的模型真的是“Softmax 回归”吗？　`softmax_mnist_demo.ipynb` 的模型结构为［原始资料］

```
model = keras.Sequential([
    layers.Input(shape=(28, 28)),
    layers.Flatten(),                       # 28x28 -> 784
    layers.Dense(128, activation="relu"),   # 隐藏层：这一层让它变成了 MLP
    layers.Dropout(0.2),                    # 训练时随机丢弃 20% 神经元，防过拟合
    layers.Dense(10, activation="softmax"),  # 10 类概率
])
model.compile(optimizer="adam", loss="sparse_categorical_crossentropy",
              metrics=["accuracy"])
```

逐段解释：`Flatten` 拉平；`Dense(128, relu)` 是*带激活函数的隐藏层*；`Dense(10, softmax)` 是输出层；`sparse_categorical_crossentropy` 就是交叉熵，只是标签直接用整数 c 而非 one-hot 向量（与 $-\log \hat{y}_c$ 等价）；`adam` 是优化器（超参数）。

注意：因为有一个 ReLU 隐藏层，这个笔记本严格说演示的是 **MLP（第 4 章）**，参数量 101770，测试准确率 0.9755；去掉 `Dense(128)` 与 `Dropout` 才是 PPT 所说的纯 Softmax 回归（7850 个参数，准确率约 90%，见 PPT p.57）。这一点对应笔记本名称与内容的差异，读代码时要留意。

本章小结与知识地图



到这里，我们已经解决了什么？ 用一次线性计算完成回归、多分类、多标签分类，并知道每种情况用什么损失、梯度是什么。　**下一步还需要解决什么？** 线性模型“只能从像素值中线性地拼接出模式”，Softmax 回归在 MNIST 上只能到约 90%，它学不会“8 中间两个圆”这样的结构。下一章加入**隐藏层与非线性激活函数**——多层感知机。

学完这里，你应该能够回答

1. 线性回归的模型、损失分别是什么？最优直线必过哪一点？
2. R^2 的分子分母各表示什么？R^2 能否为负？
3. 多输出回归和多分类有什么不同？
4. 写出 Softmax，并说明它为什么保序、为什么平移不变。
5. 交叉熵为什么可以化简为 $-\log \hat{y}_c$？
6. Softmax + 交叉熵对 z_j 的梯度是什么？
7. 多标签分类为什么不能用 Softmax？
8. $\sigma(0)$、$\sigma'(0)$ 各是多少？BCE 在 $y = 0$ 时是什么？

第 4 章　多层感知机：让模型学会“非线性”

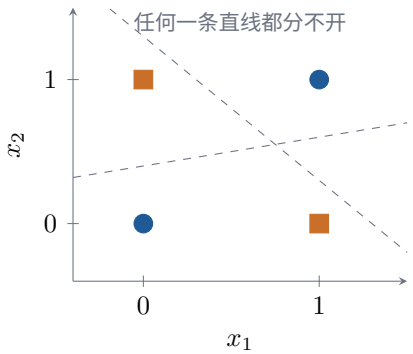
承上启下　第 3 章的所有模型都只有一次线性计算。PPT p.57 指出［原始资料］：用 Softmax 回归做 MNIST 大约能得到 90% 准确率，但“它无法学习到像 2 的弯曲形状或 8 中间两个圆之间的层次结构，只能从像素值中‘线性地拼接’出模式”。本章回答：*线性模型到底差在哪里？加什么就能补上？代价是什么？*

本章知识路线　XOR：线性模型的反例 → 隐藏层解决 XOR → 为什么必须有激活函数 → 常见激活函数 → MLP 的结构、公式与参数量 → 反向传播 → 拟合 $\sin x$：通用逼近定理 → 现实中的非线性与特征工程 → 如何确定网络结构。

4.1　最小的反例：异或 XOR

x_1	x_2	输出 y
0	0	0
0	1	1
1	0	1
1	1	0

异或真值表［原始资料］



右图把四个输入画成平面上的点：蓝色圆点输出 0，橙色方块输出 1。两类点分布在正方形的对

角线上，无论怎样画一条直线（灰色虚线是两次尝试），总有一侧混入另一类。下面把这个直觉变成严格证明。

> **证明：不存在线性分类器能实现 XOR（教学补全）**　**要证明**：不存在 w_1, w_2, b，使得“$w_1x_1 + w_2x_2 + b > 0$ 时输出 1，否则输出 0”对四个点都正确。
> **思路**：反证法——假设存在，推出矛盾。　**证明**：若存在，则由四行真值表分别得到
>
> $$(0,0):\ b \le 0; \qquad (0,1):\ w_2 + b > 0; \qquad (1,0):\ w_1 + b > 0; \qquad (1,1):\ w_1 + w_2 + b \le 0.$$
>
> 把中间两式相加：$w_1+w_2+2b > 0$，即 $w_1+w_2+b > -b$。由第一式 $-b \ge 0$，故 $w_1+w_2+b > 0$，与第四式矛盾。　□
> **一句话**：XOR 的正类在“对角”，而线性分类器的决策边界只能是一条直线，把平面切成两个*凸*的半平面。这正是 1969 年 Minsky 与 Papert 分析单层感知机局限时的经典例子。

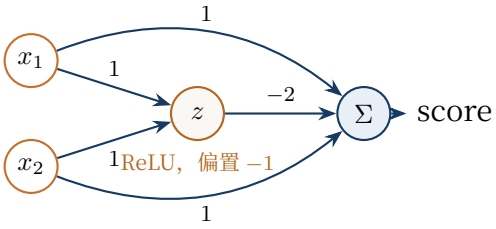
4.2　加一个隐藏神经元：XOR 被解决了

PPT p.59 给出了一个“魔法公式”［原始资料］：score $= x_1 + x_2 - 2z$，其中 z 在 $(1,1)$ 时为 1、其他情况为 0。PPT 没有说明 z 从哪里来，这里补全［教学补全］：取一个带 ReLU 的隐藏神经元

$$z = \mathrm{ReLU}(x_1 + x_2 - 1) = \max(0,\ x_1 + x_2 - 1).$$

点	$x_1 + x_2 - 1$	z	score
(0,0)	-1	0	0
(0,1)	0	0	1
(1,0)	0	0	1
(1,1)	1	1	0

score 列与 XOR 输出完全一致 √



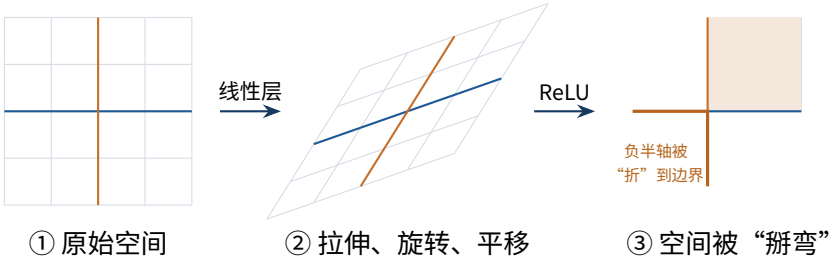
> **为什么隐藏神经元有用？——换一个空间看问题**　隐藏神经元 z 只在 $(1,1)$ “亮起来”，它相当于*自动造出了一个新特征*“两个输入同时为 1”。在新特征的帮助下，输出层又可以用线性计算（$x_1 + x_2 - 2z$）得到答案。换言之：**隐藏层把原问题变换到一个线性可分的新空间**。这就是 PPT p.64 所说“隐藏层负责把原始输入加工成更有用的中间特征”的最小例子。

4.3　为什么必须有激活函数

如果把隐藏层的 ReLU 去掉，还能解决 XOR 吗？不能。PPT p.61 给出结论：“如果没有激活函数，多层线性层叠加起来，仍然等价于一层线性模型。”［原始资料］下面补全证明。

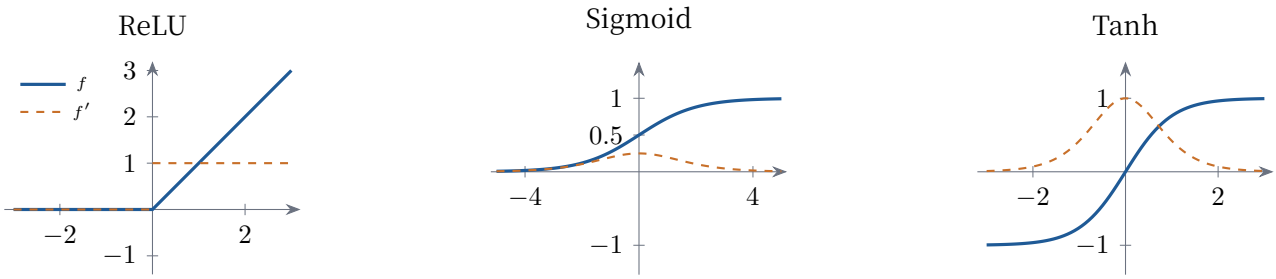
> **证明：线性层的复合仍是线性层**　设第一层 $\boldsymbol{h} = W_1\boldsymbol{x} + \boldsymbol{b}_1$，第二层 $\boldsymbol{z} = W_2\boldsymbol{h} + \boldsymbol{b}_2$。代入得
>
> $$\boldsymbol{z} = W_2(W_1\boldsymbol{x} + \boldsymbol{b}_1) + \boldsymbol{b}_2 = \underbrace{(W_2W_1)}_{W}\boldsymbol{x} + \underbrace{(W_2\boldsymbol{b}_1 + \boldsymbol{b}_2)}_{\boldsymbol{b}},$$
>
> 用到了矩阵乘法对加法的分配律与结合律。它与单层 $\boldsymbol{z} = W\boldsymbol{x} + \boldsymbol{b}$ 形式完全相同；由归纳法，任意多层线性层的复合都是一层线性层。　□　“只是把一条直线换成了另一条直线，模型能

> 力没有本质提升。” [原始资料]



上图对应 PPT p.62 与笔记 385 的比喻 [原始资料]：“线性层负责拉伸、旋转、平移空间；激活函数负责掰弯空间。”①是原始坐标网格；②线性变换后网格仍是平行直线（只被拉伸、错切）；③ReLU 把所有负坐标变成 0，整个平面被“折叠”进第一象限，直线在原点处出现折角——这就是**非线性**。多层网络反复“拉伸 + 掰弯”，就能形成复杂的分类边界。

4.4 常见激活函数



三幅图使用相同的颜色约定：蓝色实线是函数本身，橙色虚线是导数。ReLU 在正半轴导数恒为 1、负半轴为 0；Sigmoid 与 Tanh 都是 S 形，但 Sigmoid 输出在 $(0,1)$、导数最大 0.25，Tanh 输出在 $(-1,1)$、导数最大 1。

函数	表达式	值域	特点（教学补全）
ReLU	$\max(0,x)$	$[0,+\infty)$	计算最简单；正半轴梯度不衰减，深层网络默认首选；负半轴梯度为 0
Sigmoid	$\frac{1}{1+e^{-x}}$	$(0,1)$	适合输出层表示概率；在隐藏层中两端饱和、梯度小，深层易“梯度消失”
Tanh	$\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$	$(-1,1)$	以 0 为中心；$\tanh x = 2\sigma(2x)-1$，本质是平移缩放后的 Sigmoid

易错提醒 ①**“激活函数只是为了把输出压到 0~1”——错。** 隐藏层激活函数的根本作用是**引入非线性**，ReLU 的输出根本没有上界。②**“ReLU 是分段线性的，所以不算非线性”——错。** ReLU 在 0 处有折角，$\mathrm{ReLU}(a+b) \neq \mathrm{ReLU}(a)+\mathrm{ReLU}(b)$（例如 $a=1, b=-1$：左边 0，右边 1），它不满足线性函数的可加性，所以是非线性函数。

4.5 多层感知机的结构、公式与参数量

定义（多层感知机，MLP）

至少包含输入层、一个或多个**隐藏层**、输出层的前馈全连接网络。每一层依次做：线性变换 $\boldsymbol{h} = W\boldsymbol{x} + \boldsymbol{b}$ → 激活函数（非线性）→ 送入下一层。［原始资料］　**隐藏层**不是故意藏起来的层，而是它*不直接对应最终答案*，负责把原始输入加工成更有用的中间特征。［原始资料］

核心公式（单隐藏层 MLP 用于分类，PPT p.67、笔记 385）

$$\hat{\boldsymbol{y}} = \operatorname{softmax}\left(W_2\,\phi(W_1\boldsymbol{x} + \boldsymbol{b}_1) + \boldsymbol{b}_2\right)$$

$\boldsymbol{x} \in \mathbb{R}^d$；$W_1 \in \mathbb{R}^{H\times d}$，$\boldsymbol{b}_1 \in \mathbb{R}^H$（$H$ 为隐藏层宽度）；ϕ：逐元素作用的激活函数（如 ReLU）；$W_2 \in \mathbb{R}^{K\times H}$，$\boldsymbol{b}_2 \in \mathbb{R}^K$。与 Softmax 回归相比，**只多了一个隐藏层和非线性变换 ϕ**。

例 4.1　手算一次前向传播

已知：$\boldsymbol{x} = (1, 2)^\top$，$\boldsymbol{b}_1 = (0, -1)^\top$，$\boldsymbol{b}_2 = \boldsymbol{0}$，$\phi = \mathrm{ReLU}$，

$$W_1 = \begin{bmatrix} 1 & -1 \\ 0.5 & 0.5 \end{bmatrix}, \qquad W_2 = \begin{bmatrix} 1 & 2 \\ -1 & 1 \end{bmatrix}. \qquad \text{求 } \hat{\boldsymbol{y}}.$$

第一步（隐藏层线性）：$W_1\boldsymbol{x} + \boldsymbol{b}_1 = \begin{bmatrix} 1\cdot 1 + (-1)\cdot 2 + 0 \\ 0.5\cdot 1 + 0.5\cdot 2 - 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 0.5 \end{bmatrix}$

第二步（ReLU）：$\boldsymbol{h} = \mathrm{ReLU}\begin{bmatrix} -1 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.5 \end{bmatrix}$　（负数被截为 0）

第三步（输出层）：$\boldsymbol{z} = W_2\boldsymbol{h} + \boldsymbol{b}_2 = \begin{bmatrix} 1\cdot 0 + 2\cdot 0.5 \\ -1\cdot 0 + 1\cdot 0.5 \end{bmatrix} = \begin{bmatrix} 1 \\ 0.5 \end{bmatrix}$

第四步（Softmax）：$\hat{\boldsymbol{y}} = \left[\frac{e^1}{e^1+e^{0.5}}, \frac{e^{0.5}}{e^1+e^{0.5}}\right] = \left[\frac{2.718}{4.367}, \frac{1.649}{4.367}\right] \approx [0.622,\ 0.378]$

本题想说明：第一个隐藏神经元被 ReLU“关掉”了，对输出毫无贡献——**不同输入会激活不同的神经元组合**，这正是非线性的来源。

4.5.1 参数量：层数多了会“史诗级增长”

核心公式（全连接层参数量）

一层输入 n_{in} 个、输出 n_{out} 个神经元的全连接层，参数量为

$$\boxed{n_{\text{in}} \times n_{\text{out}} + n_{\text{out}}}\ \text{（权重 + 偏置）}, \qquad \text{整个 MLP 参数量} = \sum_{\ell} \left(n_{\ell-1}n_\ell + n_\ell\right).$$

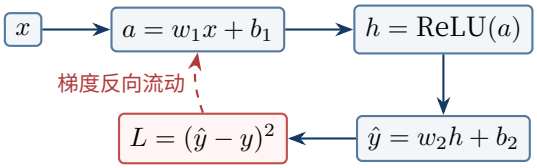
模型	结构	计算	参数量
Softmax 回归	$784 \to 10$	$784 \times 10 + 10$	7850
单隐藏层 MLP（PPT p.65）	$784 \to 128 \to 10$	$(784 \times 128 + 128) + (128 \times 10 + 10) = 100480 + 1290$	101770
Fashion 笔记本 MLP	$784 \to 256 \to 128 \to 10$	$200960 + 32896 + 1290$	235146

PPT 原式写作“$100352 + 128 + 1280 + 10 = 101770$”［原始资料］，与上表等价。只加一个 128 宽的隐藏层，参数就增加了约 13 倍。“参数越多，模型可以调节的‘旋钮’越多，能够表示的形状越复杂”，但**“参数越多，也越容易过拟合”**［原始资料］。课程笔记本中 `Dropout(0.2)`、`Dropout(0.3)` 就是为抑制过拟合而加的（训练时随机让一部分神经元输出 0）。

课程笔记本	模型	测试准确率	说明
`softmax_mnist_demo`	784→128→10（MLP）	0.9755	8 轮，Adam，batch 128
`fashion_mnist_teaching_case`	784→256→128→10（MLP）	0.8744	10 轮；Fashion-MNIST 比 MNIST 难得多

4.6 反向传播：多层网络怎样求梯度

PPT 多次提到“对损失函数反向传播，更新参数”［原始资料］，但没有展开。这里用最简单的网络说明它只是**链式法则的系统化使用**［教学补全］。



前向（黑箭头）逐层算出 $a, h, \hat{y}, L$；反向（红虚线）从 L 出发，依次乘上每一步的局部导数：

$$\frac{\partial L}{\partial \hat{y}} = 2(\hat{y} - y), \qquad \frac{\partial L}{\partial w_2} = \frac{\partial L}{\partial \hat{y}}\, h,$$
$$\frac{\partial L}{\partial a} = \frac{\partial L}{\partial \hat{y}}\, w_2\, \mathrm{ReLU}'(a),$$
$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial a}\, x, \qquad \frac{\partial L}{\partial b_1} = \frac{\partial L}{\partial a}.$$

其中 $\mathrm{ReLU}'(a) = 1$（$a > 0$）或 0（$a < 0$）。这与 `sin_nn_fitting_demo.html` 中 `trainStep()` 的代码逐行对应［原始资料］：`d = 2*(yhat-y)/n` 是 $\partial L/\partial \hat{y}$（对 n 个样本取平均），`ga[j] += d*h[j]` 是 $\partial L/\partial a_j$（输出权重），`dz = d*a[j]*reluGrad(z[j])` 是 $\partial L/\partial z_j$，`gw[j] += dz*x`、`gb[j] += dz` 是隐藏层权重与偏置的梯度。深度学习框架（Keras、PyTorch）会*自动*完成这一过程（自动微分）。

4.7 拟合 $\sin x$：通用逼近定理的直观

4.7.1 课程网页演示在做什么

`sin_nn_fitting_demo.html` 设定真实规律 $y = \sin x$，在 $[-2\pi, 2\pi]$ 上均匀取 72 个样本，用一个*隐藏层*的 ReLU 网络去拟合［原始资料］：

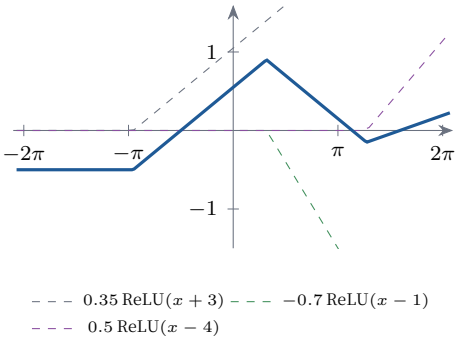
$$f(x) = c + \sum_{i=1}^{H} a_i\, \mathrm{ReLU}(w_i x + b_i), \qquad \mathrm{Loss} = \frac{1}{n} \sum \big(f(x) - y\big)^2,$$

默认 $H = 24$ 个神经元、学习率 0.006、Adam 优化器，并做了梯度裁剪（防止曲线飞出画面）。页面的 7 步依次是：真实规律 → 采集样本 → 随机初始化“小线段” → 叠加得到预测曲线 → 计算误差与损失 → 反向传播调参 → 多次迭代后完成拟合。

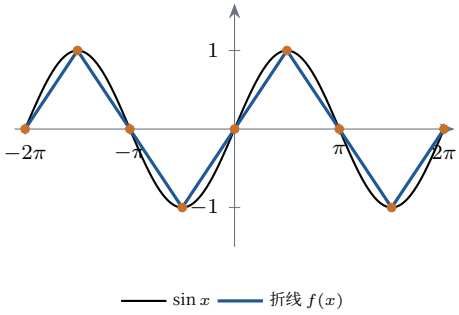
4.7.2 为什么“一堆小折线”能拼出正弦曲线

每一项 $a_i\,\mathrm{ReLU}(w_i x + b_i)$ 是一条“铰链”：在 $x = -b_i/w_i$ 之前为 0，之后以斜率 $a_i w_i$ 直线增长（$w_i < 0$ 时方向相反）。把许多铰链相加，就得到一条**分段线性（折线）函数**，每个铰链贡献一个“折点”。

三个 ReLU 铰链与它们的和



8 个折点即可粗略拼出 $\sin x$



左图中三条虚线是三个铰链（灰、绿、紫），它们各自在 $x = -3, 1, 4$ 处“开始起作用”；蓝色实线是它们的和再减 0.5，是一条有 3 个折点的折线。右图黑线是 $\sin x$，蓝色折线在 9 个橙点处与 $\sin x$ 相等，由 c 加 8 个铰链构成［教学补全］：在第 k 个折点 x_k，铰链系数等于“右侧斜率 − 左侧斜率”，这里斜率在 $\pm\frac{2}{\pi}$ 之间切换，所以第一个铰链系数为 $\frac{2}{\pi}$，其余 7 个为 $\pm\frac{4}{\pi}$。**神经元越多，折点越多，折线就越贴近** $\sin x$——训练的过程，就是自动寻找每个折点的位置（$-b_i/w_i$）与高度（a_i）。

4.7.3 通用逼近定理

通用逼近定理（Universal Approximation Theorem，非正式表述）

一个包含非线性激活函数的前馈神经网络，只要隐藏层神经元足够多，就可以以任意精度逼近*定义在有界闭区间（或有界闭集）上的*任意连续函数。［原始资料］（斜体条件为教学补全：Cybenko 1989 对 Sigmoid 型函数证明；后续工作推广到 ReLU 等非多项式激活函数。）

> **严格证明需要后续课程工具**　严格证明需要实分析与泛函分析。当前阶段只需理解上面的折线构造：连续函数在有界区间上可以被折线任意逼近，而每段折线都能由 ReLU 铰链拼出。注意定理只保证*存在*这样的网络，**不保证训练一定找得到、也不告诉你需要多少神经元**。

PPT p.75—76 讨论了两个课堂提问［原始资料］：

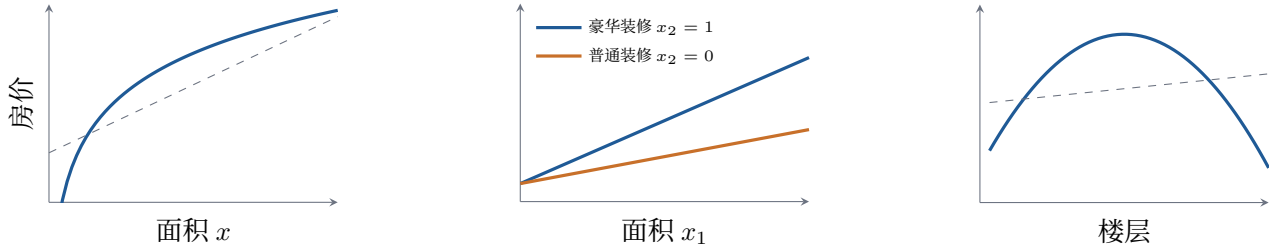
- **真实模型是 $y = \sin x + \log x$，是不是第一个隐藏层学 $\sin x$、第二个学 $\log x$？**——不是。隐藏层内部学到的是许多“构成它”的函数片段和变换模式，最终拼出完整的模型，而不是一层学一个函数（参考上面的折线：每个神经元只是一个“折点”）。
- **既然一层就能逼近任何函数，为什么还要多层？**——“说的没错！但不实际！”原因见下表。

问题	原因解释（PPT p.76）
需要的神经元数可能非常大	有些函数需要成百上千个神经元才能在一层中拟合好，非常浪费
训练难度大	网络太宽 → 梯度传播不稳定，容易震荡或收敛困难
参数量大，易过拟合	表达能力强但泛化能力差
缺乏分层语义结构	语言、图像、策略具有层级结构，一层很难有效建模“组合语义”
不易迁移 / 解释	多层可以抽象出“边缘 → 形状 → 物体”的通用特征层级，便于迁移与解释

4.8 真实世界是非线性的：从房价说起

PPT p.68—70 用房价说明：看似能用线性回归解决的问题，本质上有很多非线性关系［原始资料］。

① 边际递减：$w \log x + b$　② 交互：$c x_1 x_2$　③ 倒 U：$a f + b f^2 + c$



三幅图中蓝色是真实关系、灰色虚线是纯线性模型：①面积越大房价越高，但每增加 $1\,\mathrm{m}^2$ 的涨幅递减（**边际递减效应**）；②“装修对大房子价值提升更明显”：两条线斜率不同，是特征之间的**交互作用**，$y = ax_1 + bx_2 + cx_1x_2 + d$，线性叠加 $ax_1 + bx_2$ 画不出两条不平行的线；③中间楼层最贵，价格对楼层是**非单调**的。

原图纠错：笔记 385 用词与 PPT p.70 表述

① 笔记“边缘递减效应”应为“**边际**递减效应”（PPT p.68 写法正确）。② PPT p.70 在 $y = a \cdot \mathrm{floor} + b \cdot \mathrm{floor}^2 + c$ 下方写“无法表达‘中间最贵’的非单调非线性模”，应理解为*原线性模型* $y = w \cdot floor + b$ 无法表达；加入平方项且 $b < 0$ 时，抛物线开口向下，恰好*可以*表达倒 U 型（顶点在 $\mathrm{floor} = -\frac{a}{2b}$）。

4.8.1 特征工程：人工设计非线性

定义（特征工程，Feature Engineering）

将原始数据通过一系列技术手段转换为更容易被模型利用的“特征”的过程。它是“**人工设计非线性**”的过程，目的是帮助（线性）模型从原始数据中获得更有效的表达能力。［原始资料］

类型	举例	作用
多项式扩展	加入 x^2, x^3	拟合弯曲关系（如倒 U）
取对数 / 开方	$\log x$，$\sqrt{x}$	处理指数或幂次增长、边际递减
离散化	面积分成“小、中、大”	连续变量转为类别变量
One-hot 编码	装修：普通 $\to [1,0]$，高档 $\to [0,1]$	表示类别型变量，避免虚假大小关系
交叉特征	面积 $\times$ 装修质量	模拟特征间的协同效应
时间 / 地理特征	时间戳 → 年、月、节假日；经纬度 → 距商圈距离	提取隐含结构

难点在哪？“在真实的研究中，我们只有输入特征和输出结果，并不知道变量之间是否存在交互效应，更不知道要不要构造面积 × 装修质量这样的项”，所以“特征工程其实更多的工作量在对数据本身的探索和研究上”［原始资料］。两条路线：**理论驱动**（来自专家直觉或文献，可解释、与论文“理论假设”对齐，但依赖经验、易遗漏）与**数据驱动**（枚举两两甚至三三组合构造交叉项，无需先验、能挖掘高阶特征，但组合爆炸、易过拟合、可解释性差）。

> **MLP 与特征工程的关系**　特征工程是人来设计 $\log x$、$x_1 x_2$、x^2；MLP 的隐藏层是让*网络自己*学出这些非线性特征（XOR 中的 z 就是网络自己造出的“x_1 且 x_2”）。所以 PPT 说：给 MLP 足够的容量、数据和训练时间，“它就能自动学习出任何复杂的映射关系”。

4.9 怎样确定网络结构

“没有通用公式，但有一套实用策略：启发式经验 + 学习曲线观察 + 超参数搜索。”［原始资料］

层数的经验选择	每层宽度的经验选择（回归任务为例）
简单回归（$\sin x$、$\log x$、多项式）：1~2 层	第一层：约 2~10 倍输入维度
表格数据分类 / 回归：2~4 层	后续层：通常逐层递减，如 128 → 64 → 32
图像任务：用 CNN 替代 MLP；文本任务：用 RNN / Transformer	输出层：分类 = 类别数；回归 = 1（或输出个数）
不确定时：从 1 层开始逐步加深，观察训练效果	目标是拟合能力强 → 加宽加深；要泛化 → 减小并加正则

自动搜索超参数组合（笔记标注“热门”［原始资料］）：GridSearchCV / RandomizedSearchCV（sklearn，小规模最方便）、**Optuna**（自动剪枝、并行）、**Ray Tune**（分布式、工业级）、Keras Tuner（深度学习友好）。一个 Optuna 的最小框架如下［教学补全］：

```
import optuna

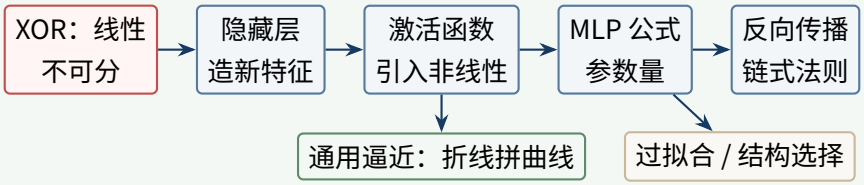
def objective(trial):
    units = trial.suggest_int("units", 32, 256, log=True)       # 隐藏层宽度
    lr = trial.suggest_float("lr", 1e-4, 1e-2, log=True)        # 学习率
    model = build_model(units, lr)     # 自己写的函数：按参数搭建并 compile 模型
    history = model.fit(x_train, y_train, epochs=5, verbose=0,
```

```
                        validation_data=(x_val, y_val))
    return max(history.history["val_accuracy"])                # 要最大化的指标

study = optuna.create_study(direction="maximize")
study.optimize(objective, n_trials=20)                         # 自动尝试 20 组
print(study.best_params)
```

`trial.suggest_*` 让 Optuna 在给定范围内挑一组超参数；`objective` 用这组超参数训练并返回验证集准确率；`optimize` 重复 20 次，并根据已有结果智能地选择下一组。注意用**验证集**而不是测试集来挑超参数，否则测试结果会被“偷看”而偏乐观。

本章小结与知识地图



到这里，我们已经解决了什么？ 非线性从哪里来、MLP 怎样计算与训练、为什么它理论上能逼近任意连续函数。　**下一步还需要解决什么？** MLP 对图像要先 Flatten，丢掉了像素的空间关系，参数量又极大（784×100 就有 78400 个权重）。能否设计一种“专门看图”的网络？——卷积神经网络。

学完这里，你应该能够回答

1. 用反证法说明线性分类器为何不能实现 XOR。
2. 为什么没有激活函数时多层等价于一层？
3. ReLU、Sigmoid、Tanh 的值域与导数最大值？
4. 784→64→10 的 MLP 有多少参数？
5. 反向传播本质上用了哪条求导法则？
6. ReLU 网络的输出为什么是折线？
7. 通用逼近定理保证了什么、没保证什么？
8. 特征工程与隐藏层分别由谁来“设计非线性”？

第 5 章　卷积神经网络：专门为“看图”设计的网络

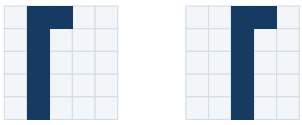
承上启下　MLP 能逼近任意函数，但处理图像时既“笨”又“贵”。本章先说清 MLP 看图的问题，再从“局部连接 + 参数共享”推出卷积，最后把卷积层、池化层、全连接层拼成完整的 CNN，并用课程笔记本的真实结果验证。

本章知识路线　MLP 看图的四个问题 → 局部感知与参数共享 → 卷积运算与输出尺寸 → 卷积层参数量 → 池化层 → 全连接层 → 完整 CNN 与实验结果。

5.1　MLP 看图有什么问题

MLP 是“全连接神经网络”：每一层的每个神经元都连接到上一层所有神经元，对输入没有任何结构假设，适合表格数据或特征向量，不擅长图像、文本等结构化数据［原始资料］。

问题	说明（PPT p.82）
参数量极大	一张 28×28 灰度图 = 784 个像素，接入 100 个神经元的隐藏层就有 $784 \times 100 = 78400$ 个权重；若是 $224 \times 224 \times 3$ 的彩色图，一层就超过 1500 万个
空间结构无法保留	图像中“相邻像素”具有空间关系，Flatten 后 MLP 把这些邻接信息完全打乱
无法局部建模	物体往往由局部组合而成，MLP 无法专注于局部区域，只能“全局一刀切”
难以处理平移 / 缩放 / 旋转	缺乏对“局部不变性”的建模能力



平移的例子［教学补全］：左图同一个笔画右移一格。对 MLP 而言，Flatten 后亮像素的编号全变了（第 1 列变成第 2 列），相当于换了一个完全不同的输入向量，必须重新学习；而人眼一看就知道是同一个形状。

5.2 核心思想：局部感知 + 参数共享 = 卷积

PPT p.83 列出三种需要的能力［原始资料］：**局部感知能力**（local receptive field）、**参数共享能力**（一个模板扫描多个区域）、**保持空间结构的能力**。“核心思想就是：卷积——使用一个小的‘滤波器’（也叫卷积核），在输入图像上滑动，在每个位置提取局部特征。”

定义（二维卷积运算，深度学习中的约定）

输入图像 I、大小为 $k \times k$ 的卷积核 K、偏置 b，输出特征图 S 在位置 (i, j) 的值为

$$S(i,j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} I(i+m,\ j+n)\, K(m,n) + b$$

即：把卷积核盖在图像的一个 $k \times k$ 窗口上，**对应位置相乘再求和**，然后滑到下一个位置。［教学补全］

> **记号说明**　数学与信号处理中的“卷积”要先把卷积核翻转 180°；深度学习框架（Keras、PyTorch）实际计算的是上式（数学上叫互相关），但习惯上仍称“卷积”。由于卷积核是学出来的，翻不翻转不影响模型能力。本讲义统一用上式。

例 5.1　一个会找“竖直边缘”的卷积核

10	10	10	0	0
10	10	10	0	0
10	10	10	0	0
10	10	10	0	0
10	10	10	0	0

输入 I（5×5）

$*$

1	0	-1
1	0	-1
1	0	-1

卷积核 K

$=$

0	30	30
0	30	30
0	30	30

特征图 S（3×3）

已知：左边 3 列亮（10）、右边 2 列暗（0）；卷积核每行为 $[1, 0, -1]$，$b = 0$。

左上角（深蓝框）：每行 $10 \cdot 1 + 10 \cdot 0 + 10 \cdot (-1) = 0$，三行共 0。

第 2 列：窗口覆盖第 1—3 列，每行 $10 - 0 = 10$，共 30。

第 3 列：窗口覆盖第 2—4 列，每行 $10 - 0 = 10$，共 30。

本题想说明：卷积核 $[1, 0, -1]$ 计算“左边减右边”，在亮度均匀处输出 0，在明暗交界处输出大值——特征图中亮的两列正好指出了**竖直边缘的位置**。“每个卷积核学会了识别一种模式，比如垂直边缘、颜色渐变、斑点纹理”［原始资料］，只不过在 CNN 中，这些数值不是人设计的，而是训练学出来的。

5.2.1 输出尺寸公式

核心公式（卷积 / 池化输出尺寸）

输入边长 n，卷积核边长 k，四周补零 p 圈（padding），每次滑动 s 格（stride），则输出边长

$$\boxed{o = \left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1}$$

推导（教学补全）　补零后边长为 $n + 2p$。卷积核左边缘可以放在位置 $0, s, 2s, \ldots$，但右边缘不能超出，所以左边缘最大为 $n + 2p - k$。可放位置个数 = $\{0, s, 2s, \ldots\}$ 中不超过 $n + 2p - k$ 的数的个数 $= \lfloor (n + 2p - k)/s \rfloor + 1$（“+1”是因为从 0 开始数）。 □

验证：例 5.1 中 $n = 5, k = 3, p = 0, s = 1$，$o = \frac{5-3}{1} + 1 = 3$ √。课程 CNN 代码用 `padding="same"`（$k = 3$ 时 $p = 1$），$o = \frac{28+2-3}{1} + 1 = 28$，尺寸不变；$2 \times 2$ 池化 $k = s = 2$，$o = \lfloor \frac{28-2}{2} \rfloor + 1 = 14$，尺寸减半。

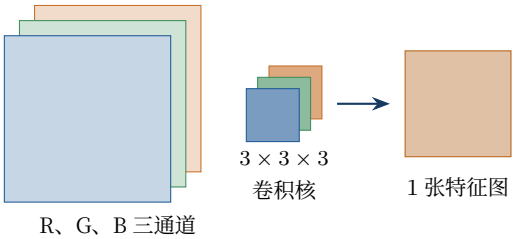
5.2.2 参数共享：参数量与图像大小无关

核心公式（卷积层参数量）

输入 C_{in} 个通道，使用 C_{out} 个 $k \times k$ 卷积核（每个卷积核深度等于 C_{in}，各带 1 个偏置）：

$$\boxed{\text{参数量} = (k \times k \times C_{\text{in}} + 1) \times C_{\text{out}}}$$

PPT p.86 的例子［原始资料］：输入 28×28 灰度图（$C_{\text{in}} = 1$），用 10 个 3×3 卷积核，“只需要 $10 \times 3 \times 3 = 90$ 个权重参数”——加上 10 个偏置共 100 个。对比 MLP 的 78400 个，相差近 800 倍。“虽然一个卷积核会‘滑动’在整个图像上计算很多位置的输出值，但它的权重组是共享的，真正需要训练的参数数量只取决于卷积核的大小和数量，**与图像大小无关**。”［原始资料］



多通道［教学补全］：彩色图有 R、G、B 三个通道，一个卷积核也要有 3 层（深度 = 输入通道数），三层分别与对应通道做乘加，再把三层结果*相加*成一张特征图。C_{out} 个卷积核就输出 C_{out} 张特征图，它们又成为下一层的 C_{out} 个输入通道。

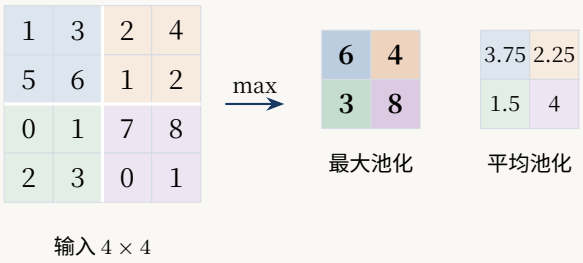
易错提醒　① **算卷积参数量时忘记乘输入通道数**。第二个卷积层 `Conv2D(64, 3×3)` 的输入是上一层的 32 张特征图，参数量是 $(3 \cdot 3 \cdot 32 + 1) \times 64 = 18496$，不是 $(9 + 1) \times 64 = 640$。② **把“输出特征图的像素数”当成参数量**。特征图大小影响*计算量*，不影响参数量。

5.3 池化层：压缩并保留重要值

定义（池化，Pooling）

在每个窗口内用一个统计量代替整个窗口：**最大池化**取最大值（强调最显著特征，最常用）；**平均池化**取平均值（平滑）；**全局池化**每个通道只取一个值（常用于连接全连接层之前）。池化的目的是**压缩并保留重要性，而不是发现模式**。［原始资料］

例 5.2　2×2 池化，步长 2（PPT p.89 数据）



输入 4×4　　最大池化　　平均池化

四种颜色标出四个 2×2 区域：区域 1 $\{1,3,5,6\}$：max 6，均值 3.75；区域 2 $\{2,4,1,2\}$：max 4，均值 2.25；区域 3 $\{0,1,2,3\}$：max 3，均值 1.5；区域 4 $\{7,8,0,1\}$：max 8，均值 4。

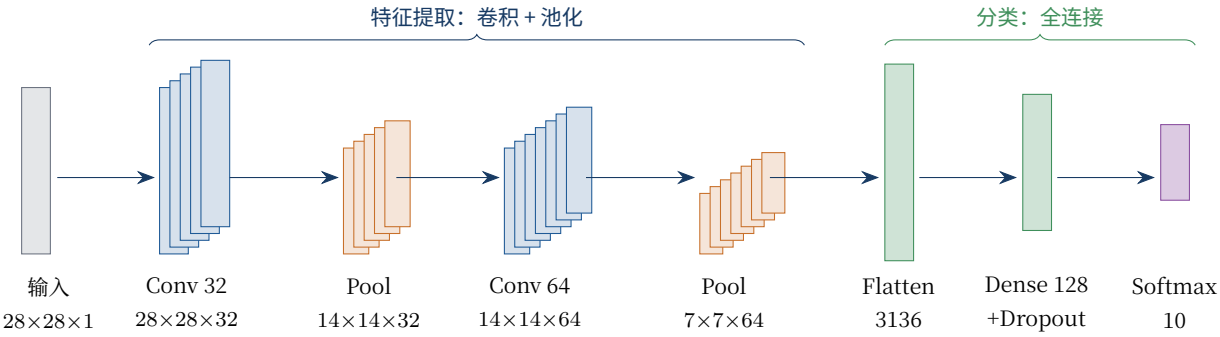
检查：由尺寸公式 $o=\lfloor\frac{4-2}{2}\rfloor+1=2$ √；最大池化结果 $[[6,4],[3,8]]$ 与 PPT 一致。**注意**：池化层**没有需要训练的参数**，它只是一个固定的规则。

作用（PPT p.88、p.90）	为什么
降低计算量	尺寸减半 → 后续卷积 / 全连接的计算量约减为 1/4
降低过拟合	去除小幅扰动和不重要的细节
增加感受野	后续神经元的一个像素对应原图更大的区域
增强平移不变性	窗口内的最大值往哪个角落挪一格，结果都不变（如区域 1 中 6 的位置变化不影响输出），提升鲁棒性

5.4 全连接层：把局部特征汇总成决策

“CNN 中前几层通过卷积和池化提取的是局部空间特征图，但最终任务（分类、回归等）是对整个图像做决策。”［原始资料］全连接层（FC）把特征图“摊平”后像 MLP 一样处理：融合全局信息、学习组合特征做判断、最后一层输出分类概率或数值。可以这样分工理解：**卷积 + 池化 = 自动的“特征工程”；全连接 = 在好特征上做分类**。

5.5 完整的 CNN：以课程 Fashion-MNIST 笔记本为例



上图是 `fashion_mnist_cnn_teaching_case.ipynb` 的结构［原始资料］（蓝色为 3×3、ReLU 激活的卷积层，橙色为 2×2 最大池化层，绿色为全连接层，紫色为输出层）。每经过一次池化，尺寸减半（$28 \to 14 \to 7$），而卷积核个数（通道数）加倍（$32 \to 64$）。PPT p.84 展示的 VGG 风格大网络也遵循同样的规律：**越往后，图越小、通道越多**——空间细节逐渐被压缩成更抽象的“特征”。

例 5.3　逐层计算形状与参数量

层	输出形状	参数量计算	参数量
Conv2D(32, 3×3, same)	$28 \times 28 \times 32$	$(3 \cdot 3 \cdot 1 + 1) \times 32$	320
MaxPooling2D(2×2)	$14 \times 14 \times 32$	无参数	0
Conv2D(64, 3×3, same)	$14 \times 14 \times 64$	$(3 \cdot 3 \cdot 32 + 1) \times 64$	18496
MaxPooling2D(2×2)	$7 \times 7 \times 64$	无参数	0
Flatten	3136	$7 \times 7 \times 64$	0
Dense(128)	128	$3136 \times 128 + 128$	401536
Dense(10, softmax)	10	$128 \times 10 + 10$	1290
合计			**421642**

本题想说明：两个卷积层合计不到 1.9 万个参数，**95% 的参数集中在 Flatten 之后的第一个全连接层**。这也是后来的网络常用“全局池化”替代大全连接层的原因［教学补全］。

5.5.1 实验结果：CNN 真的更好吗？

笔记本	模型	测试准确率	观察
Fashion-MNIST	MLP 784→256→128→10	0.8744	235146 个参数
Fashion-MNIST	CNN（上图）	**0.9104**	12 轮；末轮训练 0.948、验证 0.911，差距拉大是轻度过拟合的信号
CIFAR-10（32×32 彩色）	6 层卷积 CNN + BN + 数据增强	0.7583	25 轮；彩色自然图像比服饰灰度图难得多

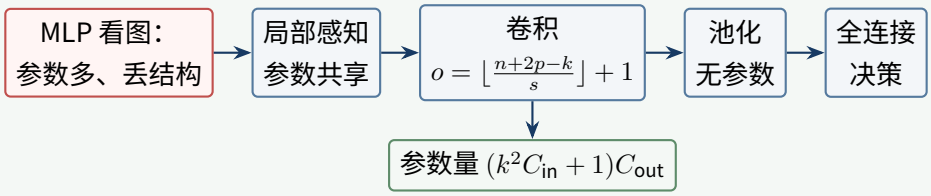
同样的数据，CNN 比 MLP 高约 3.6 个百分点，且参数中真正“看图”的卷积部分极少——这正是局部感知与参数共享的威力。

> **拓展联想**　CIFAR-10 笔记本中还用到了三种本讲未展开的技巧：`BatchNormalization`（对每层输出做标准化，使训练更稳定）、`RandomFlip/RandomRotation/RandomZoom`（数据增强，即第 2 章表中的“数据增强”超参数）、逐层增大的 `Dropout`。它们都属于后续课程内容，当前只需知道“作用是让训练更稳、泛化更好”。

5.5.2 相近概念辨析：MLP vs CNN

维度	MLP（全连接）	CNN（卷积）
连接方式	每个神经元连接上一层全部神经元	每个输出只连接一个局部窗口
参数	每个连接一个独立权重	同一卷积核在所有位置共享
输入形式	先 Flatten 成向量	保持 $H \times W \times C$ 的空间结构
参数量与图像大小	随图像大小成正比增长	卷积层与图像大小无关
擅长	表格数据、特征向量	图像、视频等网格结构数据

本章小结与知识地图



到这里，我们已经解决了什么？怎样用少量共享参数从图像中提取局部特征，并完成“整张图是什么”的分类。　**下一步还需要解决什么？**现实中一张图里往往有多个物体，我们还想知道“*每个东西在哪里*”，并且要在摄像头画面中实时完成。下一章：YOLO、OpenCV 与 MediaPipe。

学完这里，你应该能够回答

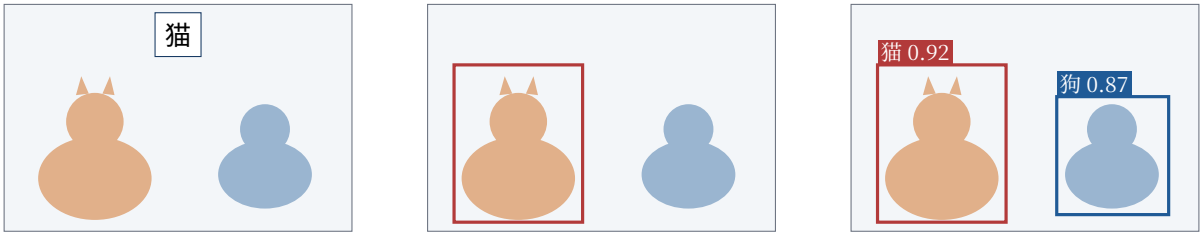
1. MLP 处理图像的四个问题是什么？
2. 写出卷积运算的定义；它和“矩阵乘法”有何不同？
3. 32×32 输入、5×5 核、$p = 0$、$s = 1$，输出多大？
4. 输入 3 通道，16 个 3×3 卷积核，参数多少？
5. 最大池化有没有可训练参数？它的作用有哪些？
6. 为什么说卷积层参数量与图像大小无关？
7. 全连接层在 CNN 中起什么作用？
8. 课程实验中 CNN 与 MLP 的准确率各是多少？

第 6 章　看懂画面：YOLO、OpenCV 与 MediaPipe

承上启下　第 5 章的 CNN 能回答“这张图是什么”。但摄像头画面里往往有多个物体，我们还想知道“每个东西在哪里”，甚至“这个人的手指是否伸出”。本章沿着“检测 → 图像处理 → 关键点”展开，这些内容对应 PPT 第 94—118 页、笔记 Memo 386 与三个代码压缩包。

本章知识路线　分类 / 定位 / 检测 → YOLO 的思想与输出 → IoU、置信度阈值与 NMS → YOLO 训练与代码 → 图像的本质与 OpenCV 基本处理 → MediaPipe 关键点 → 三者分工。

6.1 图像识别的三个层次



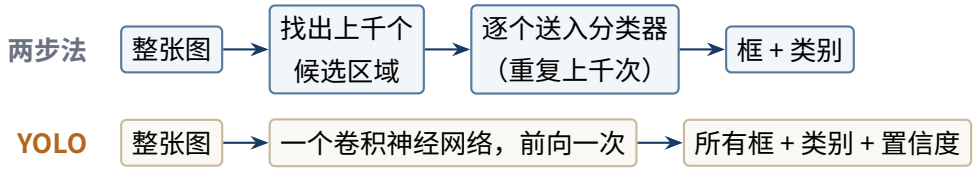
① 图像分类：“猫”　② 目标定位：猫在哪里　③ 目标检测：有哪些、各在哪

PPT p.96 的表格［原始资料］：图像分类回答“这张图是什么？”（输出：猫）；目标定位回答“猫在哪里？”（输出：一个框）；目标检测回答“图里有哪些东西？分别在哪里？”（输出：猫、狗、人、车以及每个物体的位置框）。**YOLO 属于目标检测，包含定位与分类**。

6.2 YOLO：只看一次

6.2.1 YOLO 之前的“两步走”

在 YOLO 之前，很多目标检测方法可以粗略理解成两步［原始资料］：第一步先找出图中可能有物体的区域；第二步对这些区域逐个分类（“这块区域可能有东西 → 放进分类器 → 是猫”）。它比较直观，但**候选区域很多、每个区域都要处理、速度较慢、不太适合实时摄像头**。



定义（YOLO，You Only Look Once）

把**整张图片输入神经网络**，网络**一次性输出所有检测框**：“只看一次整张图片，就直接预测所有目标的位置和类别”。输入：一张图片；输出：一堆候选框 + 每个框的类别 + 每个框的置信度［原始资料］，例如

```
[ [x1, y1, x2, y2, "person", 0.92],
  [x1, y1, x2, y2, "car",    0.87],
  [x1, y1, x2, y2, "dog",    0.76] ]
```

其中 (x_1, y_1) 是框的左上角、(x_2, y_2) 是右下角（像素坐标），最后一个数是置信度。

6.2.2 框的表示与 IoU（教学补全）

框有两种常用表示：角点式 (x_1, y_1, x_2, y_2)（课程代码 `box.xyxy` 即此格式）与中心式 (c_x, c_y, w, h)，互相转换为

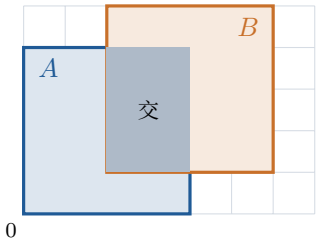
$$c_x = \frac{x_1 + x_2}{2}, \quad c_y = \frac{y_1 + y_2}{2}, \quad w = x_2 - x_1, \quad h = y_2 - y_1.$$

易错：图像坐标系的 y 轴向下　图像的原点在**左上角**，x 向右增大，y **向下**增大。所以 $y_1 < y_2$ 表示“上边在上、下边在下”，“位置越高 y 越小”——这一点在后面 MediaPipe 判断手指时非常关键。

核心公式（交并比，Intersection over Union）

$$\mathrm{IoU}(A,B)=\frac{\text{面积}(A\cap B)}{\text{面积}(A\cup B)}=\frac{\text{面积}(A\cap B)}{\text{面积}(A)+\text{面积}(B)-\text{面积}(A\cap B)}\in[0,1]$$

衡量两个框的重合程度：完全不重叠为 0，完全重合为 1。它用于评价预测框准不准（和真实框比），也用于下面的 NMS。



例：$A=(0,0,4,4)$，$B=(2,1,6,5)$（单位：格）。交集为 $x\in[2,4]$、$y\in[1,4]$，面积 $2\times 3=6$；两框面积均为 16；并集 $16+16-6=26$。

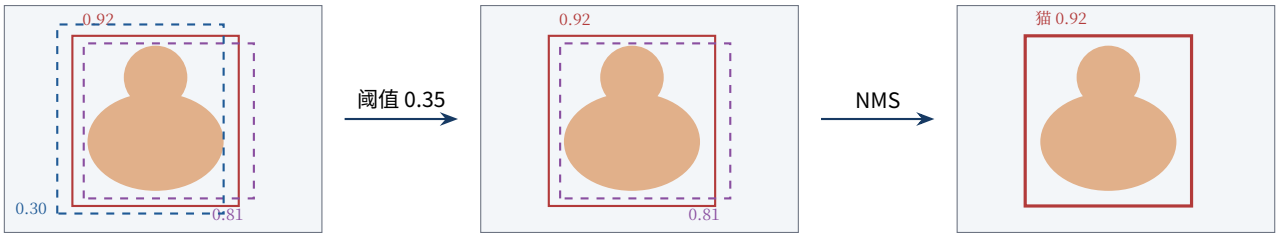
$$\mathrm{IoU}=\frac{6}{26}\approx 0.23.$$

交集的左边界取两框左边界的*较大者*，右边界取右边界的*较小者*；若算出宽或高为负，说明不相交，交集面积记为 0。（左图按网格示意，y 轴朝向不影响面积与 IoU。）

6.2.3 置信度阈值与非极大值抑制（教学补全）

网络会输出大量候选框，需要两步筛选：

1. **置信度阈值**：只保留置信度 ≥ 阈值的框。课程代码中 `CONFIDENCE_THRESHOLD = 0.35` [原始资料]，README 提示“检测框太少就调低，误识别太多就调高”。
2. **非极大值抑制（NMS）**：同一个物体常被多个框重复框住。对每个类别：按置信度从高到低排序 → 保留最高的框 → 删除与它 IoU 超过某个阈值（常取 0.45~0.5）的其他框 → 对剩下的框重复。



① 网络原始输出　② 删去 0.30 的框　③ 只留一个框

图中三个框都框住同一只猫：①置信度 0.30 的蓝框低于阈值被删；②剩下两个框高度重叠（IoU 大），③NMS 保留置信度最高的红框（0.92），删去紫框（0.81）。

6.2.4 YOLO 训练时在学什么

“输入数据需要：图片，标注框（在哪 + 是什么）；训练时，模型会不断比较：自己预测的框 − 真实标注的框。” [原始资料] 这仍然是**监督学习**，只不过标签从“一个类别”变成“一组框 + 类

别”。损失函数由四部分组成：

损失项（PPT p.99）	惩罚什么	与前面知识的联系（教学补全）
位置损失	框的位置不准（框画歪了）	类似回归的误差（MSE 或基于 IoU 的损失）
尺寸损失	框的宽高不准（太大或太小）	同上，是对 w, h 的回归
置信度损失	有没有物体判断不准（背景被误判成物体）	类似二分类，常用 BCE
分类损失	物体类别判断不准（狗被识别成猫）	多分类交叉熵或逐类 BCE

> **YOLO 把本讲的知识全部串起来了**　它的骨干是 CNN（第 5 章）；框的坐标是*回归*、类别是*分类*（第 3 章）；总损失是几项损失的加权和，用反向传播训练（第 4 章）；本质上仍是*监督学习*（第 2 章）。

6.2.5 读懂课程 YOLO 代码

```python
from ultralytics import YOLO
import cv2

model = YOLO("yolov8n.pt")                    # 加载预训练的小模型（n = nano）
image = cv2.imread("test.jpg")                # OpenCV 读图：高 x 宽 x 3 的数组（BGR）
results = model.predict(source=image, conf=0.35, verbose=False)
result = results[0]                           # 一张图对应一个结果
for box in result.boxes:                      # 每一个检测框
    class_id = int(box.cls[0])                # 类别编号
    name = result.names[class_id]             # 编号 -> 类别名，如 "person"
    confidence = float(box.conf[0])           # 置信度
    x1, y1, x2, y2 = box.xyxy[0].tolist()     # 左上角、右下角坐标
    print(name, round(confidence, 2), x1, y1, x2, y2)
annotated = result.plot()                     # 把框画到图上
cv2.imwrite("image_result.jpg", annotated)
```

这段代码根据 `01_yolo_image_detect.py` 精简而来［原始资料］：`predict` 完成“看一次”，`conf` 是置信度阈值，`boxes` 中每个框都带类别、置信度和 `xyxy` 坐标。视频与摄像头版本（`02`、`03`）只是把它放进循环：“**视频其实就是很多张连续图片**”，逐帧读取 → 送入 YOLO → 画框 → 写入新视频或显示；画面左上角的 FPS 表示每秒处理多少帧。模型 `yolov8n` 最快、精度较低，`yolov8s`、`yolov8m` 依次更准但更慢——这是**速度与精度的权衡**。

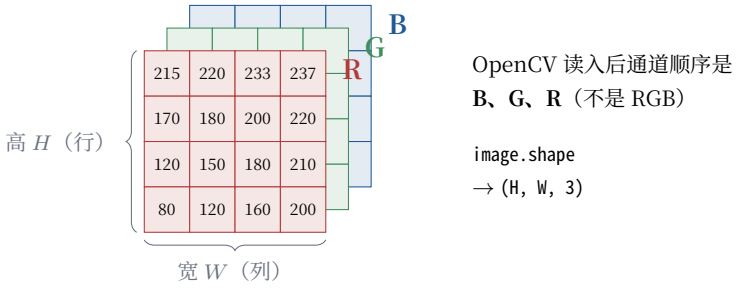
从课本到现实：老师举的 YOLO 应用（笔记 386）

(1) **智慧乡村**（大创项目）：识别农田中的作物、牲畜、车辆与行人；(2) **森林防火巡检**：无人机拍摄画面中检测烟雾、火点；(3) **无人驾驶小车**：检测道路上的行人、车辆、交通标志，再交给控制系统决策。三者的共同点是“视频流 + 实时性”，正是 YOLO“只看一次、速度快”的优势所在。PPT p.100 的足球比赛画面演示了在一帧中同时框出数十名球员。

6.3 OpenCV：计算机眼中的图像

6.3.1 图像的本质：像素 + 矩阵 + 通道

“计算机看到的不是‘西瓜’，而是数字。”［原始资料］一张彩色图片是一个 $H \times W \times C$ 的数组：H 行（高）、W 列（宽）、C 个通道（彩色图 $C = 3$）；每个数字表示一个像素在某个通道上的亮度，范围 0~255。



> **OpenCV 默认顺序是 BGR**　PPT p.107 与代码 README 都强调［原始资料］：OpenCV 读入的彩色图通道顺序是 **B、G、R**。而 MediaPipe、Matplotlib 等大多数库使用 RGB，所以课程 MediaPipe 代码中有一行必不可少的 `cv2.cvtColor(frame, cv2.COLOR_BGR2RGB)`——“颜色顺序不转换会影响模型输入”。

6.3.2 课程 OpenCV 实验台的 10 种处理

`opencv_rich_teaching_case.py` 在一个窗口中同时展示 10 种处理［原始资料］。下表给出每种处理的函数与原理（原理为教学补全）：

处理	代码中的函数与参数	原理与作用
BGR 通道拆分	`cv2.split(image)`	拆成 3 个单通道图；某通道越亮，该颜色成分越强
灰度化	`cvtColor(..., COLOR_BGR2GRAY)`	$Y = 0.299R + 0.587G + 0.114B$，去掉颜色只保留亮度
高斯模糊	`GaussianBlur(image,(15,15),0)`	用高斯卷积核做加权平均，降噪但损失细节
Canny 边缘	`Canny(blur, 80, 160)`	先模糊，再求亮度梯度，保留梯度大且连续的像素
阈值分割	`threshold(gray,150,255, THRESH_BINARY_INV)`	灰度 > 150 的变 0（黑），否则变 255（白）
形态学闭运算	`morphologyEx(..., MORPH_CLOSE, 5×5)`	先膨胀再腐蚀，填补小断裂、连通区域
轮廓与计数	`findContours`、`boundingRect`	找出白色区域边界，按面积筛选并计数、画框
HSV 颜色提取	`inRange(hsv,[35,50,50],[85,255,255])`	在 HSV 空间按色相 H 选出绿色区域
直方图均衡化	`equalizeHist(gray)`	把集中的灰度拉开，提高对比度

（第 10 种为原图显示本身。）PPT p.111 的总结是：**“阈值分割负责‘区分’，形态学处理负责‘优化’”**；p.110 的总结是：**“边缘 = 变化剧烈的位置”**。

例 6.1　高斯模糊就是一次卷积

PPT p.109 的高斯核（权重和为 1，保证整体亮度不变）与一块中心有噪点的 3×3 区域为

$$K=\frac{1}{16}\begin{bmatrix}1&2&1\\2&4&2\\1&2&1\end{bmatrix},\qquad P=\begin{bmatrix}10&10&10\\10&90&10\\10&10&10\end{bmatrix}.$$

按卷积定义“对应位置相乘再求和”：

$$\text{中心新值}=\frac{1}{16}\big(\underbrace{4\times 10}_{\text{四角}\times 1}+\underbrace{2\times 4\times 10}_{\text{四边}\times 2}+\underbrace{4\times 90}_{\text{中心}\times 4}\big)=\frac{40+80+360}{16}=30.$$

本题想说明：噪点从 90 被“摊平”到 30，更接近周围的 10——这就是“降噪”；同理真实的细小纹理也会被摊平——这就是“损失细节”。更重要的是，**它和第 5 章的卷积运算完全相同**，区别只在于：高斯核是人设计好的，CNN 的卷积核是学出来的。

例 6.2　纯红色像素变成多灰?

OpenCV 中纯红色像素为 $(B,G,R)=(0,0,255)$。灰度 $Y=0.299\times 255+0.587\times 0+0.114\times 0\approx 76$，是一个偏暗的灰。**想说明**：人眼对绿色最敏感，所以绿色权重最大（0.587）；同样亮度的红、蓝在灰度图中会显得更暗。

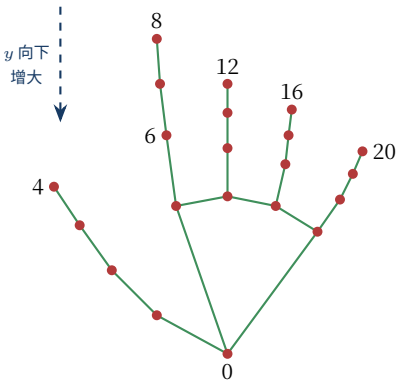
6.4　MediaPipe：已封装好的实时视觉 AI 工具箱

定义（MediaPipe）

Google 推出的多媒体 AI 感知工具框架，可以让程序快速理解摄像头画面中“手、脸、身体、动作”等信息，适合做实时识别、交互演示和入门 AI 应用。一句话：**MediaPipe = 已封装好的实时视觉 AI 工具箱**。［原始资料］

任务	课程脚本	关键点数	能做什么
手部 Hand	`mp_hand.py`	21 / 只手	手掌、手指、手势
人脸 Face	`mp_face.py`	468*	人脸结构、表情、AR 效果
人体姿态 Pose	`mp_body.py`	33	站姿、动作、运动姿态
全身综合 Holistic	`mp_holistic.py`	543	同时分析脸、手、身体：$33+468+2\times 21=543$

*PPT 与代码采用经典 Face Mesh 的 468 点；Google 当前 Face Landmarker 文档说明模型输出 478 点（另含 10 个虹膜点）。



左图是手部 21 个关键点的示意：0 是手腕，每根手指 4 个点（如食指 5—8，8 为指尖、6 为第二关节），拇指为 1—4。MediaPipe 输出的坐标是**归一化坐标**：$x = 0.25$ 表示在画面宽度的 25% 处［原始资料］。要画到画面上，需换算为像素：

$$x_{\text{px}} = \lfloor x \cdot W \rfloor, \qquad y_{\text{px}} = \lfloor y \cdot H \rfloor.$$

例 6.3　“食指是否伸出”怎么判断？

PPT p.117 的提示［原始资料］：“食指尖高于关节 → 可能表示‘食指伸出’。”

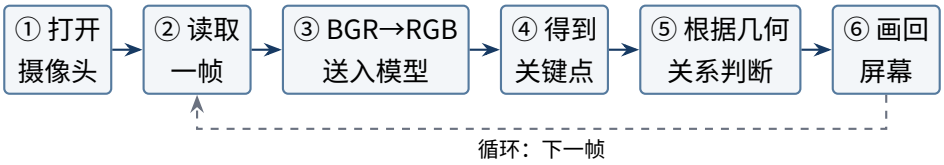
已知：画面 1280×720，关键点 8（食指尖）归一化坐标 $(0.52, 0.30)$，关键点 6（食指第二关节）为 $(0.50, 0.42)$。

第一步（换算像素）：8 号点 $y_{\text{px}} = 0.30 \times 720 = 216$；6 号点 $y_{\text{px}} = 0.42 \times 720 \approx 302$。

第二步（比较高低）：图像坐标 y 向下增大，“更高”意味着 y *更小*。$216 < 302$，指尖在关节上方。

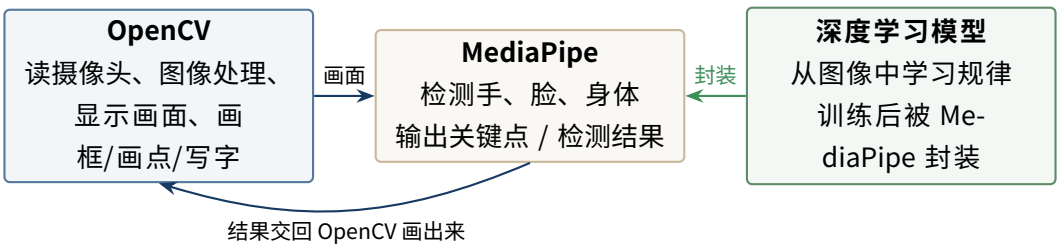
结果：判定“食指伸出”。**易错**：若写成 $y_8 > y_6$ 就判“伸出”，结论正好相反。

6.4.1 MediaPipe 的工作流程与代码要点



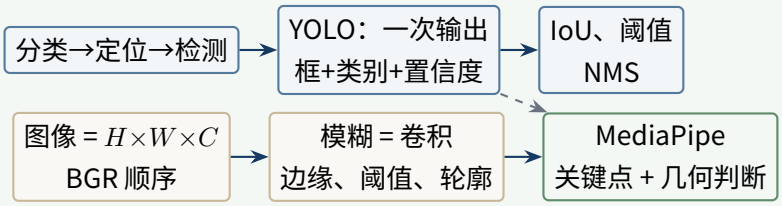
课程脚本 `mp_hand.py` 的关键设置［原始资料］：模型文件 `hand_landmarker.task`；`running_mode=VIDEO` 表示逐帧处理视频，此模式下 `detect_for_video()` *必须传入递增的时间戳*；`num_hands=2`；检测、存在与跟踪置信度均为 0.55；画面先 `cv2.flip(frame, 1)` 镜像翻转，“让学生举左手时屏幕左侧也动”。推荐学习顺序：Hand → Face → Pose → Holistic → 小项目实战［原始资料］。

6.5 OpenCV、MediaPipe 与深度学习模型的关系



“它们不是对立，而是分工合作”；一句话：“**OpenCV 负责‘看见画面’，MediaPipe 负责‘理解画面’**”［原始资料］。YOLO 在课程代码中的角色与 MediaPipe 相同：由 OpenCV 读帧、显示，由深度学习模型完成“理解”。

本章小结与知识地图



到这里，我们已经解决了什么？从“认出一张图”走到“在实时画面中找出多个物体、识别身体关键点”，并看清了课程代码的完整流程。　**下一步还需要解决什么？**图像是网格结构，CNN 很合适；但语言是*序列*，前后文有依赖——下一讲“语言大模型（RNN）”将讨论如何处理序列数据（笔记 386 预告）。

学完这里，你应该能够回答

1. 分类、定位、检测的输出分别是什么？
2. YOLO 相比“两步法”快在哪里？
3. 写出 IoU 的定义；不相交时 IoU 是多少？
4. 置信度阈值调高会怎样？NMS 解决什么问题？
5. YOLO 损失由哪四部分组成？
6. OpenCV 的通道顺序是什么？为什么要转 RGB？
7. 高斯模糊与 CNN 卷积有何异同？
8. 在图像坐标中，“更高”对应 y 更大还是更小？

第 7 章　正式练习：38 道分层训练

本章共 38 道正式练习：**A 层** 25 道基础巩固（单选 10、多选 5、填空 5、解答 5），**B 层** 10 道中等偏下提升（单选 3、多选 2、填空 3、综合大题 2），**C 层** 3 道跨学科迁移（单选、多选、填空各 1）。**请先独立完成，再查第 8 章答案与第 9 章解析。**题目中的图只呈现已知条件，不含答案提示。多选题每题至少有两个正确选项。

知识点—题目对应表

核心知识点	A 基础巩固	B 中等偏下提升	C 跨学科迁移
超参数、epoch 与 batch（2.1）	1, 2		
学习范式与过拟合（2.2—2.4）	3, 4		
强化学习：回报、折扣、马尔可夫性（2.6）	11, 21		36, 38
线性回归与最小二乘（3.1）	16, 22	34	
决定系数 R^2（3.2）	5, 22	32, 34	
Softmax 与交叉熵（3.3—3.4）	6, 12, 17, 23	26, 35	

核心知识点	A 基础巩固	B 中等偏下提升	C 跨学科迁移
Sigmoid、BCE 与多标签（3.5）	7, 12, 18	29	
XOR、激活函数、线性叠加（4.1—4.4）	8, 14, 24		
MLP 结构与参数量（4.5）	14, 19	31, 35	
ReLU 折线与特征工程（4.6—4.7）		27, 34	
卷积运算、尺寸与参数（5.2）	9, 13, 25	28, 31	37
池化与全连接（5.3—5.4）	13, 20	28	
YOLO：IoU、阈值、NMS（6.2）	15	30	
OpenCV 与 MediaPipe（6.3—6.4）	10, 15	33	37

7.1 A 层　基础巩固训练（25 道）

一、单项选择题（每题只有一个正确选项）

1 下列量中，属于**超参数**的是（　）。

A. 全连接层的权重 W　　B. 全连接层的偏置 $\boldsymbol{b}$

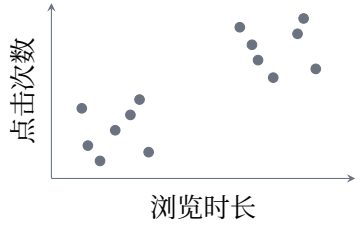
C. 学习率 η　　D. 卷积核中的数值

2 训练集有 12000 个样本，batch size 为 64，则训练 1 个 epoch 需要更新参数的次数是（　）。

A. 188　　B. 187

C. 64　　D. 12000

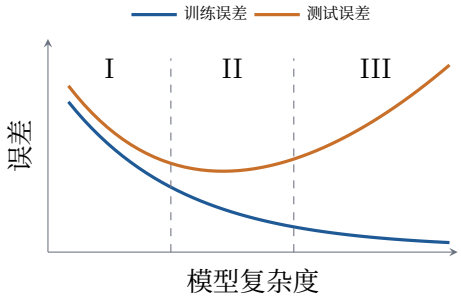
3 某电商只有用户的浏览时长与点击次数数据，没有任何“用户类型”标签，希望把用户自动分成若干群体（下图每个点是一个用户）。这属于（　）。



A. 监督学习中的多分类　　B. 强化学习

C. 监督学习中的回归　　D. 无监督学习中的聚类

4 下图是某模型的训练误差与测试误差随模型复杂度变化的曲线，横轴分为 I、II、III 三个区域。**过拟合**最明显的是（　）。



A. 区域 I　　B. 区域 II

C. 区域 III　　D. 三个区域都没有过拟合

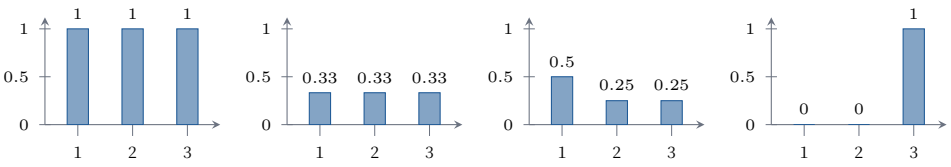
5 某回归模型在测试集上的残差平方和 RSS = 20，总平方和 TSS = 100（见下图，条形长度表示平方和大小）。该模型的 R^2 为（　）。



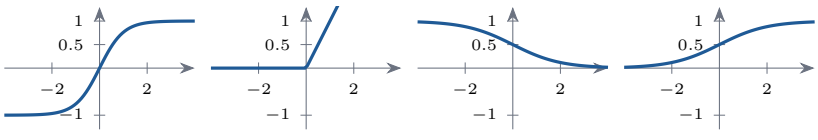
A. 0.2　　B. 1.25

C. -0.8　　D. 0.8

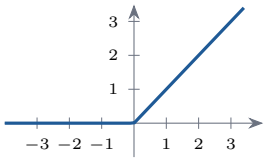
6 三个类别的 logit 为 $\boldsymbol{z} = [1, 1, 1]$。下列四幅条形图中（横轴为类别 1、2、3，纵轴为数值），能表示 softmax($\boldsymbol{z}$) 的是（　）。



7 下列四幅图的横轴为 x、纵轴为函数值，坐标范围完全相同。其中表示 Sigmoid 函数 $\sigma(x) = 1/(1 + e^{-x})$ 的是（　）。



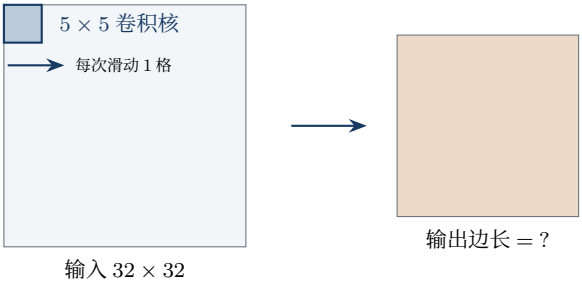
8 下图是 ReLU 函数的图像。$\mathrm{ReLU}(-3)+\mathrm{ReLU}(2)$ 的值为（　）。



A. 2　　B. -1

C. 5　　D. 0

9 如下图，输入为 32×32 的单通道图像，使用 5×5 的卷积核，不补零（$p=0$），步长 $s=1$。输出特征图的边长为（　）。



A. 27　　B. 28

C. 30　　D. 32

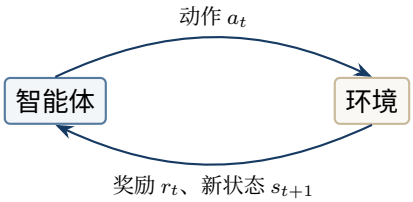
10 用 `cv2.imread()` 读入一张彩色图片后，每个像素三个通道的默认存储顺序是（　）。

A. R、G、B　　B. H、S、V

C. B、G、R　　D. G、R、B

二、多项选择题（每题至少两个正确选项）

11 关于强化学习，下列说法正确的是（　）。



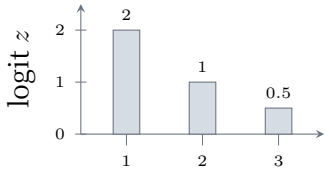
A. 强化学习的一条经验数据可以写成 (s_t, a_t, r_t, s_{t+1})

B. 强化学习要求环境在每一步都给出“正确动作”的标签

C. 折扣因子 γ 越小，智能体越“短视”（越看重眼前奖励）

D. 当 $\gamma=1$ 时，任意无限长任务的回报 G_t 都一定是有限值

12 关于 Softmax 与 Sigmoid，下列说法正确的是（　）。下图为某样本三个类别的 logit。



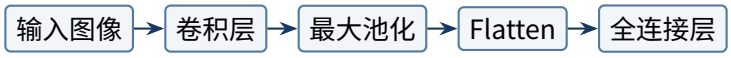
A. 对该样本做 Softmax 后，三个概率之和等于 1

B. Softmax 保序：logit 最大的类别 1，其 Softmax 概率也最大

C. 多标签分类中，对各类别分别做 Sigmoid 后，输出之和也必须等于 1

D. 类别数 $K = 2$ 时，Softmax 给出的第 1 类概率等于 $\sigma(z_1 - z_2)$

13 关于卷积神经网络，下列说法正确的是（　）。



A. 卷积层的参数量只取决于卷积核的大小、个数和输入通道数，与输入图像的长宽无关

B. 最大池化层没有需要训练的参数

C. 2×2、步长为 2 的池化把 28×28 的特征图变为 14×14

D. 卷积核中的数值由人工设定，训练过程中保持不变

14 关于多层感知机与激活函数，下列说法正确的是（　）。

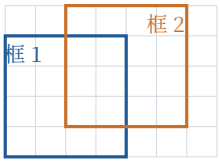
A. 若去掉所有激活函数，多层全连接网络等价于一层线性模型

B. 隐藏层越多，模型在测试集上的表现一定越好

C. ReLU 虽由两段直线组成，但它是非线性函数

D. 单个线性分类器无法实现异或（XOR）

15 关于目标检测与关键点检测，下列说法正确的是（　）。下图为同一物体上的两个检测框。



A. 两个框的 IoU 可以大于 1

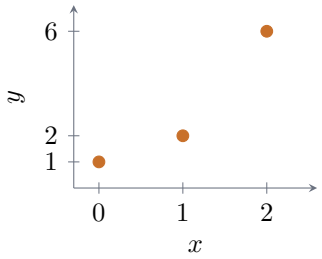
B. 把 YOLO 的置信度阈值调高，保留下来的检测框数量不会增加

C. YOLO 的训练属于监督学习，需要带标注框的图片

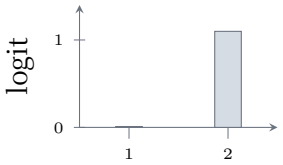
D. MediaPipe 输出的归一化坐标乘以画面宽、高才得到像素坐标

三、填空题

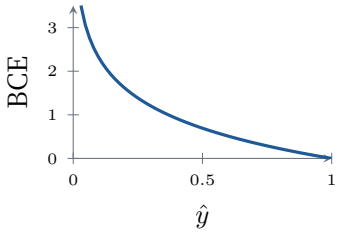
16　用最小二乘法拟合下图中的三个数据点 $(0,1)$，$(1,2)$，$(2,6)$。
所得直线为 $\hat{y} =$ _____。



17　两个类别的 logit 为 $\boldsymbol{z} = [0,\ \ln 3]$（如下图），则 $\mathrm{softmax}(\boldsymbol{z}) =$ _____。



18　某样本真实标签 $y = 1$，模型预测概率 $\hat{y} = 0.5$，则该样本的二值交叉熵 BCE = _____（保留 3 位小数，log 为自然对数）。下图为真实标签 $y = 1$ 时 BCE 随 $\hat{y}$ 变化的曲线。



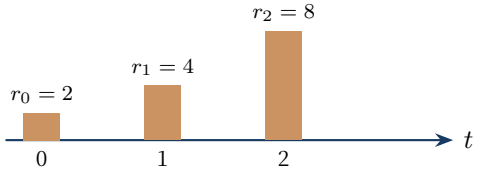
19　输入层 784、一个隐藏层 64、输出层 10 的全连接网络（含偏置）共有 _____个参数。

20　对下图 4×4 特征图做 2×2、步长为 2 的**最大池化**，结果为 _____。

2	0	1	5
4	3	2	1
0	1	6	2
7	2	3	4

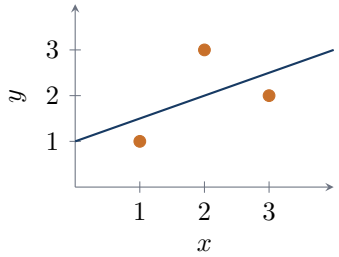
四、解答题

21　一个回合共 3 步，折扣因子 $\gamma = 0.5$，智能体在 $t = 0, 1, 2$ 依次获得奖励 $r_0 = 2$、$r_1 = 4$、$r_2 = 8$，之后回合结束（奖励为 0），如下图。



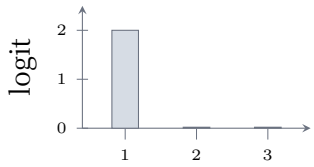
(1) 求 G_0、G_1、G_2；　(2) 用递推式 $G_t = r_t + \gamma G_{t+1}$ 验证 (1) 的结果。

22　数据点 $(1,1)$、$(2,3)$、$(3,2)$，某模型为 $\hat{y} = 0.5x + 1$（下图直线）。



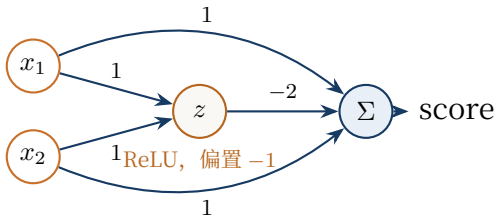
(1) 求该模型的残差平方和 RSS；(2) 求总平方和 TSS；(3) 求 R^2 并解释其含义。

23　三分类问题中，某样本的 logit 为 $\boldsymbol{z} = [2, 0, 0]$（如下图），真实类别为第 1 类。



(1) 求 Softmax 概率 $\hat{\boldsymbol{y}}$（保留 3 位小数）；(2) 求交叉熵损失；(3) 求损失对 logit 的梯度 $\partial L / \partial \boldsymbol{z}$，并说明梯度下降会使 z_1 增大还是减小。

24　下图网络中，隐藏神经元 $z = \mathrm{ReLU}(x_1 + x_2 - 1)$，输出 score $= x_1 + x_2 - 2z$。



(1) 列表计算四个输入 $(0,0), (0,1), (1,0), (1,1)$ 的 z 与 score，并说明它实现了什么逻辑运算；(2) 若把 ReLU 去掉（$z = x_1 + x_2 - 1$），score 变成什么表达式？还能实现该运算吗？

25　对下图 4×4 输入 I 用 2×2 卷积核 K 做卷积（深度学习约定：对应相乘再求和），步长 1，不补零，偏置为 0。

1	2	0	1
3	1	2	2
0	2	1	0
1	0	3	1

输入 I

1	0
0	-1

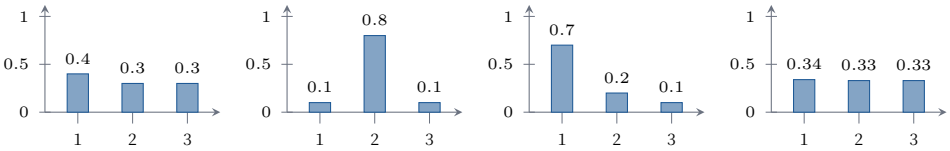
卷积核 K

(1) 求输出特征图的尺寸；(2) 求完整的输出特征图；(3) 若该层有 1 个这样的卷积核且带偏置，参数量是多少？

7.2 B 层　中等偏下提升训练（10 道）

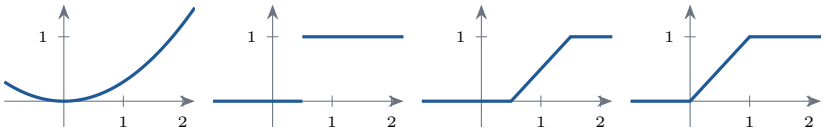
一、单项选择题

26　三分类问题中真实类别为第 1 类。四个模型给出的预测概率如下（横轴为类别 1、2、3）。**交叉熵损失最小**的是（　）。



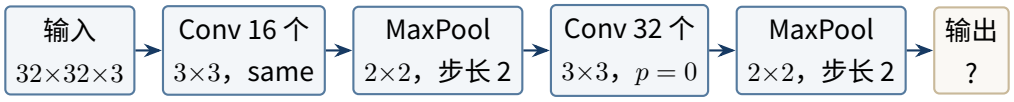
A　　B　　C　　D

27　形如 $f(x)=a\ \mathrm{ReLU}(x)+b\ \mathrm{ReLU}(x-1)+c$（$a,b,c$ 为任意实数）的单隐藏层网络，能**精确**表示下列哪个函数的图像（　）？四幅图坐标范围相同。



A　　B　　C　　D

28　输入 $32\times32\times3$ 的彩色图像依次经过下图各层，最终输出的形状为（　）。

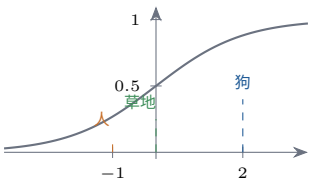


A. $8\times8\times32$　　B. $7\times7\times32$

C. $6\times6\times32$　　D. $7\times7\times16$

二、多项选择题

29　一张图中有狗和草地、没有人，标签为 $[1,1,0]$（狗、草地、人）。模型对三类输出的 logit 为 $[2,\ 0,\ -1]$，每类分别使用 Sigmoid，如下图。下列说法正确的是（　）。



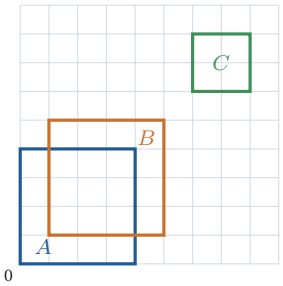
A. 模型给“草地”的概率为 0.5

B. 以 0.5 为阈值，模型判断图中“没有人”

C. 三个类别的概率之和等于 1

D. “草地”一项的 BCE 等于 $\ln 2$

30 如下图，YOLO 对同一类别输出三个框：框 $A=(0,0,4,4)$，置信度 0.9；框 $B=(1,1,5,5)$，置信度 0.8；框 $C=(6,6,8,8)$，置信度 0.7（坐标为左上角、右下角，单位为格）。NMS 的 IoU 阈值为 0.5（IoU 大于阈值的低分框被删除）。下列说法正确的是（　）。



A. $\mathrm{IoU}(A,B)\approx 0.39$

B. NMS 后框 B 被删除

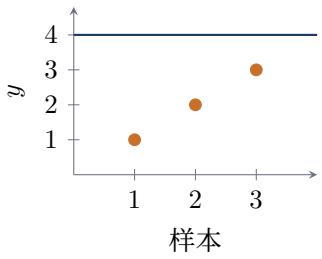
C. 框 C 与 A、B 都不重叠，因此 NMS 后框 C 被保留

D. 若把 NMS 阈值改为 0.3，框 B 会被删除

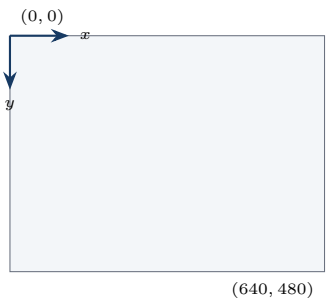
三、填空题

31 对 $32\times 32\times 3$ 的彩色图像：
(1) 使用 8 个 3×3 卷积核（带偏置）的卷积层，参数量为 _____；
(2) 若改为先 Flatten 再接 8 个神经元的全连接层（带偏置），参数量为 _____。

32 真实值为 $1,2,3$，某“模型”无论输入是什么都预测 4（下图水平线）。该模型的 $R^2=$ _____。

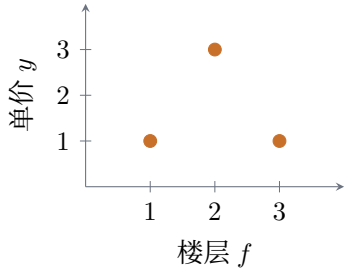


33 摄像头画面大小为 640 × 480（宽 × 高）。MediaPipe 输出关键点 P 的归一化坐标为 (0.25, 0.60)，关键点 Q 为 (0.30, 0.50)。则 P 的像素坐标为 _____；P、Q 中在画面上**位置更高**的是 _____。



四、综合大题

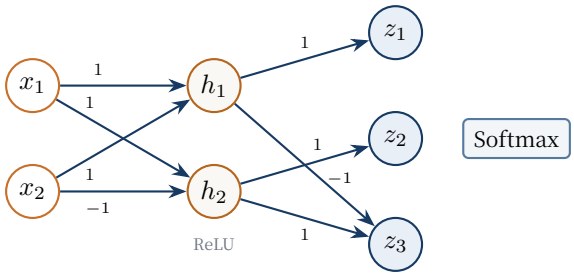
34　（特征工程与 R^2）某小区中楼层 f 与单价 y（单位：万元每平方米）有三组数据，如下图所示：$(1,1)$，$(2,3)$，$(3,1)$。



(1) 用最小二乘法拟合直线 $\hat{y} = wf + b$，求 w、b；
(2) 求 (1) 中直线的 R^2，并解释结果；
(3) 加入特征 f^2，用 $\hat{y} = af + bf^2 + c$ 拟合，求使三点完全吻合的 a, b, c，此时 R^2 为多少？单价最高的楼层是多少？
(4) 用一句话说明本题与多层感知机隐藏层的关系。

35　（MLP 前向传播与交叉熵）下图网络的输入为 $\boldsymbol{x} = (1, -1)^\top$，隐藏层使用 ReLU，输出层后接 Softmax 输出 3 个类别的概率，偏置 $\boldsymbol{b}_1 = \boldsymbol{b}_2 = \boldsymbol{0}$，真实类别为第 2 类。权重矩阵为

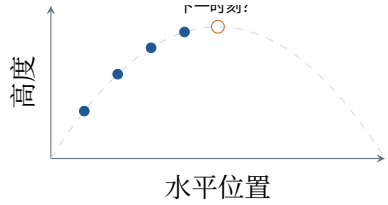
$$W_1 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \qquad W_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ -1 & 1 \end{bmatrix}.$$



（图中未画出的连接权重为 0。）(1) 求隐藏层输出 $\boldsymbol{h}$；(2) 求 logit $\boldsymbol{z}$ 与 Softmax 概率 $\hat{\boldsymbol{y}}$（保留 3 位小数）；(3) 求交叉熵损失；(4) 求该网络的参数总数（含偏置）。

7.3　C 层　跨学科迁移训练（3 道）

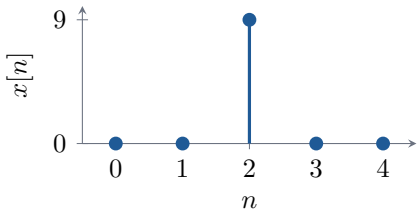
36　（大学物理 × 马尔可夫性）忽略空气阻力时，抛体在极短时间 Δt 后的位置与速度满足 $\boldsymbol{r}_{t+1} = \boldsymbol{r}_t + \boldsymbol{v}_t \Delta t$，$\boldsymbol{v}_{t+1} = \boldsymbol{v}_t + \boldsymbol{g}\Delta t$（$\boldsymbol{g}$ 为恒定的重力加速度）。 我们想用一个“状态”预测下一时刻的状态，并希望它满足马尔可夫性。下图中实心点为已观测到的位置。下列关于“状态”选择的说法中，正确的是（　）。



A. 以“当前位置和当前速度” $(\boldsymbol{r}_t, \boldsymbol{v}_t)$ 为状态即可满足马尔可夫性　B. 只以“当前位置” $\boldsymbol{r}_t$ 为状态即可满足马尔可夫性

C. 必须把从抛出开始的全部历史轨迹作为状态　D. 该过程具有随机性，不可能满足马尔可夫性

37　（信号处理 × 卷积）传感器采样得到离散信号 $x[n]$，其中出现一个尖峰噪声：$x = [0,\ 0,\ 9,\ 0,\ 0]$。用“三点滑动平均”滤波：$y[n] = \frac{1}{3}\big(x[n-1] + x[n] + x[n+1]\big)$（只计算 $n = 1, 2, 3$ 三个内部位置）。下列说法正确的是（　）。



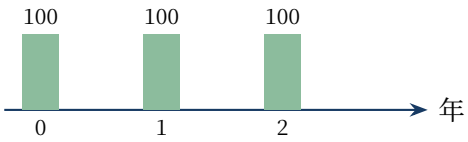
A. 该滤波等价于用卷积核 $[\frac{1}{3}, \frac{1}{3}, \frac{1}{3}]$ 在信号上做一维卷积

B. 滤波后 $y[1] = y[2] = y[3] = 3$

C. 滤波后尖峰高度由 9 降为 3，起到平滑降噪作用

D. 与 CNN 相同，这个卷积核的三个数值需要通过训练数据学习得到

38　（经济学 × 折扣回报）一项投资在今后三年年初分别带来 100 元收入（第 0 年、第 1 年、第 2 年各 100 元），以后不再有收入。若把未来 1 年后的 1 元只看作现在的 $\gamma = 0.9$ 元（折扣因子），则这三笔收入折算到现在的总价值（“现值”）为 _____元。



第 8 章　答案速查

本章只列结果，不讲过程；过程见第 9 章。

题型	答案
A 层 基础巩固	
单选 1—10	1. C　2. A　3. D　4. C　5. D　6. B　7. D　8. A　9. B　10. C
多选 11—15	11. AC　12. ABD　13. ABC　14. ACD　15. BCD

题型	答案
填空 16—20	16. $2.5x+0.5$　17. $[0.25,\ 0.75]$　18. $\ln 2 \approx 0.693$　19. 50890　20. $\begin{bmatrix}4 & 5\\ 7 & 6\end{bmatrix}$
解答 21	$G_0=6$，$G_1=8$，$G_2=8$；递推验证成立
解答 22	RSS $=1.5$，TSS $=2$，$R^2=0.25$（模型只解释了 25% 的变化）
解答 23	$\hat{\boldsymbol{y}} \approx [0.787, 0.107, 0.107]$；$L \approx 0.240$；梯度 $\approx [-0.213, 0.107, 0.107]$，$z_1$ 增大
解答 24	score 依次为 0,1,1,0，实现异或 XOR；去掉 ReLU 后 score $=2-x_1-x_2$，不能实现
解答 25	输出 3×3：$\begin{bmatrix}0 & 0 & -2\\ 1 & 0 & 2\\ 0 & -1 & 0\end{bmatrix}$；参数量 5
B 层 中等偏下提升	
单选 26—28	26. C　27. D　28. B
多选 29—30	29. ABD　30. ACD
填空 31—33	31. 224；24584　32. -6　33. $(160,\ 288)$；Q
大题 34	(1) $w=0,\ b=\frac{5}{3}$；(2) $R^2=0$；(3) $a=8,\ b=-2,\ c=-5$，$R^2=1$，第 2 层最贵
大题 35	(1) $\boldsymbol{h}=[0,2]$；(2) $\boldsymbol{z}=[0,2,2]$，$\hat{\boldsymbol{y}} \approx [0.063, 0.468, 0.468]$；(3) $L \approx 0.759$；(4) 15
C 层 跨学科迁移	
单选 36	A
多选 37	ABC
填空 38	271 元

第 9 章　详细解析

每题解析依次给出：答案与难度 → 考查知识点 → 思路 → 过程（含解析图）→ 逐项 / 逐步判断 → 常见错误 → 一句话总结。解析图与题目图功能不同：**解析图上会加入辅助标注，帮助你“看见”推理过程**。难度标签：★ 基础，★★ 中等偏下。

9.1 A 层解析：基础单选（1—10）

第 1 题 答案 C ★ 知识点：参数与超参数（2.1）

思路 判断标准只有一条：*训练前由人设定、训练中不自动更新*的是超参数。

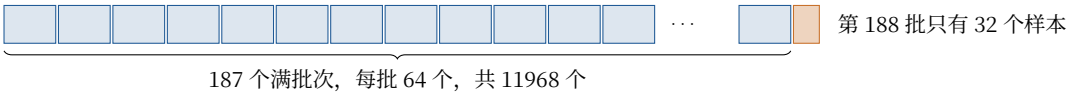
逐项 A、B：权重和偏置由反向传播学习得到，是**模型参数**，**错误**。C：学习率在 `compile`/优化器中由人设定，控制每一步更新幅度，**正确**。D：CNN 的卷积核数值同样是训练学到的参数（5.2 节），**错误**。

常见错误 以为“卷积核大小 3×3”与“卷积核中的数值”是一回事：前者是超参数，后者是参数。

一句话 人定的是超参数，学出的是参数。

第 2 题 答案 A ★ 知识点：epoch 与 batch（2.1.3）

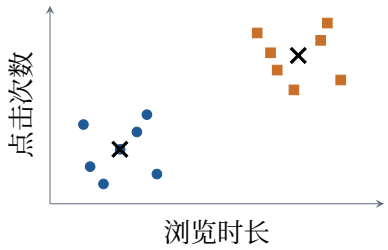
思路与过程 每轮步数 $=\lceil N/B\rceil=\lceil 12000/64\rceil=\lceil 187.5\rceil=188$。



逐项 B 187：直接向下取整，漏掉了剩下的 $12000-187\times64=32$ 个样本；C 把 batch size 当成步数；D 把样本数当成步数。

一句话 一轮步数 = 样本数 ÷ 批大小，**向上取整**。

第 3 题 答案 D ★ 知识点：无监督学习、聚类（2.3）



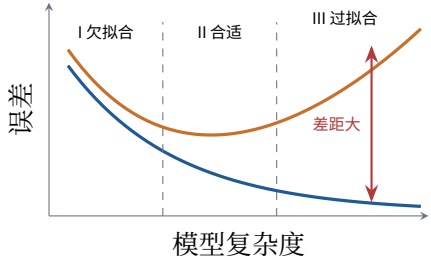
思路 关键词是“**没有任何标签**”与“**分成若干群体**”。

解析图 左图是聚类后的结果：同一数据自然分成蓝、橙两簇，× 为簇中心。算法只用“点与点的远近”，从未见过任何“类型”标签——这就是无监督学习。

逐项 A、C：监督学习需要标签，**错误**；B：强化学习需要与环境交互并获得奖励，本题只是分析固定数据，**错误**；D **正确**。

一句话 没标签、找结构 → 无监督；分群 → 聚类。

第 4 题 答案 C ★ 知识点：过拟合（2.2.2）



思路 过拟合 = 训练误差小、测试误差大，两条曲线之间的“缝”越来越宽。

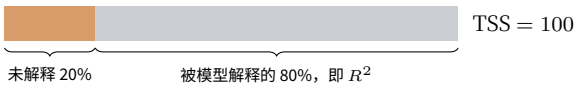
图上证据 区域 III 中蓝线（训练）已接近 0，橙线（测试）却向上翘，红色双箭头标出的差距最大。区域 I 两线都高，是*欠拟合*；区域 II 测试误差最低，是较合适的复杂度。

常见错误 看到区域 I 误差最大就选 A——误差大不等于过拟合，要看训练与测试是否“一好一坏”。

一句话 训练好、测试差才叫过拟合。

第 5 题 答案 D ★ 知识点：决定系数（3.2）

过程 $R^2 = 1 - \dfrac{\text{RSS}}{\text{TSS}} = 1 - \dfrac{20}{100} = 0.8$。

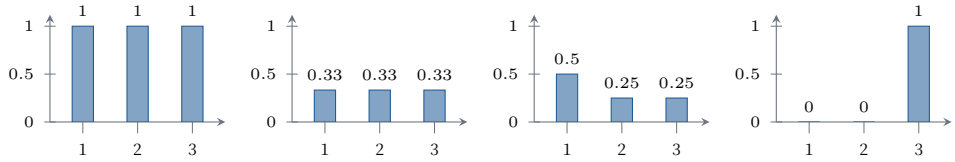


逐项 A 0.2 是 RSS/TSS 本身（未解释部分），忘了“1−”；B 1.25 是 TSS/RSS 倒数的误用；C -0.8 是符号错误。

一句话 R^2 = 1 − “没解释掉的比例”。

第 6 题 答案 B ★ 知识点：Softmax 的性质（3.3）

过程 e^1 三项相等，$\hat{y}_j = \dfrac{e}{3e} = \dfrac{1}{3}$。**logit 相等 → 概率相等**（由保序性与和为 1 立即得到）。

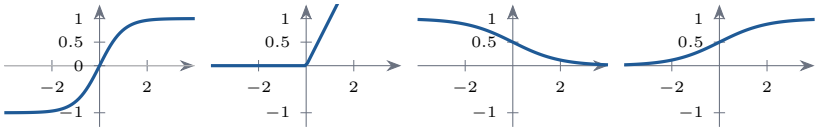


A　　B　　C　　D

逐项图解 A：三条柱都为 1，和为 3，**错误**——违反“和为 1”，这是把 logit 原样画出。B：三条柱均为 $\frac{1}{3}$，和为 1、彼此相等，**正确**。C：和为 1，但三类 logit 相同，概率却不同，违反保序（相等输入应得相等输出），**错误**。D：一类为 1，是“one-hot”形状，只有 logit 差距趋于无穷时才接近，**错误**。

一句话 Softmax 输出和为 1，且只由 logit 之间的差决定。

第 7 题 答案 D ★ 知识点：Sigmoid 图像（3.5.2）



A　　B　　C　　D

逐项图解 判断 Sigmoid 只需三条证据：值域 $(0,1)$、$\sigma(0) = 0.5$、单调递增。

A（Tanh）：左侧趋于 -1，在 0 处取 0，**错误**（值域是 $(-1,1)$）。

B（ReLU）：左半为 0、右半是斜线且无上界，不是 S 形，**错误**。

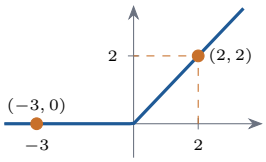
C：过 $(0, 0.5)$、值域 $(0,1)$，但*单调递减*，它是 $\sigma(-x) = 1 - \sigma(x)$，**错误**。

D：S 形、过 $(0, 0.5)$、从 0 增到 1，**正确**。

常见错误 只看“S 形”就选 A 或 C：Tanh 与 $\sigma(-x)$ 也都是 S 形。

一句话 Sigmoid：过 $(0, 0.5)$、上升、夹在 0 与 1 之间。

第 8 题　答案 A　★　知识点：ReLU（4.4）



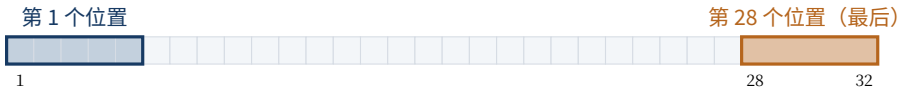
过程 $\mathrm{ReLU}(-3)=\max(0,-3)=0$，$\mathrm{ReLU}(2)=2$，和为 2。图中两个橙点即对应位置。

逐项 B -1：误把 ReLU 当成恒等函数 $(-3)+2$；C 5：取了绝对值 $3+2$；D 0：误以为 ReLU 把所有值都置 0。

一句话 ReLU：负数变 0，正数不变。

第 9 题　答案 B　★　知识点：卷积输出尺寸（5.2.1）

过程 $o=\dfrac{n+2p-k}{s}+1=\dfrac{32+0-5}{1}+1=28$。



解析图 一行 32 个像素中，5 宽的窗口左端只能放在第 1—28 格（放在第 29 格时右端会越界），所以每行有 28 个位置。

逐项 A 27：忘了“+1”；C 30：误用 $32-3+1$（把核当成 3）；D 32：那是 `padding="same"` 时的结果。

一句话 不补零时，每用 $k\times k$ 核卷积一次，边长减少 $k-1$。

第 10 题　答案 C　★　知识点：OpenCV 通道顺序（6.3.1）

思路 OpenCV 默认按 **B、G、R** 存储，这是课程 PPT p.107 与 README 专门强调的“坑”。A 是 Matplotlib、MediaPipe 等使用的顺序；B 是另一种颜色空间，需 `cvtColor(..., COLOR_BGR2HSV)` 转换；D 不是常用顺序。

常见错误 把 OpenCV 读入的图直接交给 MediaPipe 或 Matplotlib 显示，导致红蓝颠倒。

一句话 OpenCV 是 BGR，交给别的库前先转 RGB。

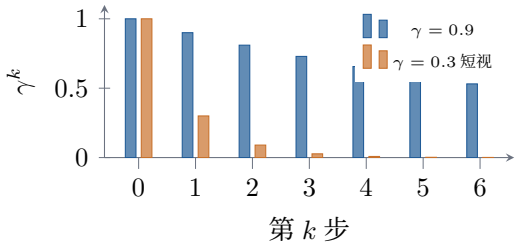
9.2　A 层解析：基础多选（11—15）

第 11 题　答案 AC　★　知识点：强化学习数据、折扣因子（2.6）

A 正确。智能体在 s_t 下做动作 a_t，得到奖励 r_t 并转移到 s_{t+1}，这四个量就是一条经验（PPT p.24）。

B 错误。RL 的特点恰恰是不提供正确动作标签，只给（可能延迟的）奖励。

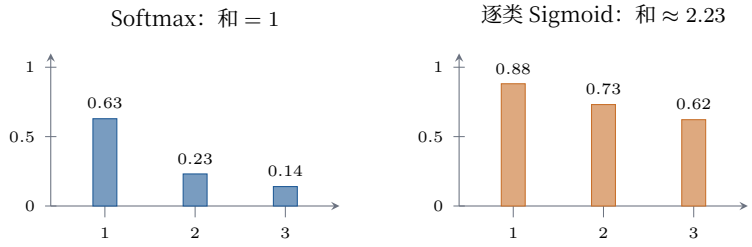
C 正确。见下图：γ 越小，远期奖励的权重 γ^k 衰减越快。



D 错误。反例：每步奖励都是 1、$\gamma = 1$，则 $G_t = 1 + 1 + 1 + \cdots = \infty$。只有 $\gamma < 1$ 才能保证 $|G_t| \le R_{\max}/(1-\gamma)$。
一句话 RL 没有标签只有奖励；γ 决定“多有远见”，且必须 < 1 才能保证无限长回报有限。

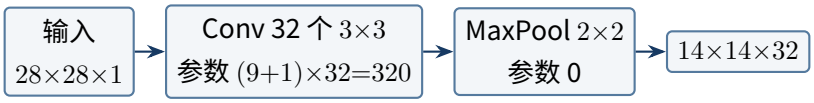
第 12 题　答案 ABD　★　知识点：Softmax 与 Sigmoid（3.3、3.5）

计算 $e^2 = 7.389$，$e^1 = 2.718$，$e^{0.5} = 1.649$，和为 11.756，故 Softmax $\approx [0.629, 0.231, 0.140]$；若逐类做 Sigmoid，则为 $[\sigma(2), \sigma(1), \sigma(0.5)] \approx [0.881, 0.731, 0.622]$。



A 正确：$0.629 + 0.231 + 0.140 = 1$。　**B 正确**：左图最高柱在类别 1，与 logit 最大者一致（保序）。
C 错误：右图三柱之和约 2.23，多标签中各类独立，不要求和为 1。　**D 正确**：$\frac{e^{z_1}}{e^{z_1}+e^{z_2}} = \frac{1}{1+e^{-(z_1-z_2)}} = \sigma(z_1 - z_2)$（3.3 节性质 4）。
一句话 Softmax“互相竞争、和为 1”，Sigmoid“各管各的”。

第 13 题　答案 ABC　★　知识点：卷积、池化、全连接（第 5 章）

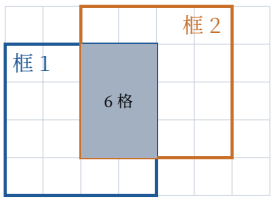


A 正确：公式 $(k^2 C_{\text{in}} + 1)C_{\text{out}}$ 中没有图像的长宽（上图中 320 与 28 无关）。
B 正确：最大池化只是“取窗口最大值”这一固定规则，没有权重。
C 正确：$o = \lfloor \frac{28-2}{2} \rfloor + 1 = 14$。
D 错误：卷积核数值是*训练学到的*参数；人工设计固定卷积核的是 OpenCV 的高斯模糊等传统方法（例 6.1）。
一句话 卷积有参数且共享，池化无参数只压缩。

第 14 题　答案 ACD　★　知识点：MLP 与激活函数（第 4 章）

A 正确：$W_2(W_1\boldsymbol{x} + \boldsymbol{b}_1) + \boldsymbol{b}_2 = (W_2 W_1)\boldsymbol{x} + (W_2\boldsymbol{b}_1 + \boldsymbol{b}_2)$。
B 错误：层数增加使参数增多，可能过拟合（见第 4 题的区域 III），“一定更好”错误。
C 正确：反例 $\text{ReLU}(1 + (-1)) = 0 \neq \text{ReLU}(1) + \text{ReLU}(-1) = 1$，不满足可加性。
D 正确：4.1 节反证法已证明；几何上两类点位于正方形的两条对角线，任何直线都分不开。
一句话 非线性来自激活函数；模型变大不等于泛化变好。

第 15 题　答案 BCD　★　知识点：IoU、置信度阈值、MediaPipe 坐标（第 6 章）



A 错误：交集是并集的一部分，$0 \le \text{IoU} \le 1$。以题图为例：交集 6 格（深色），并集 $16+16-6=26$ 格，$\text{IoU} \approx 0.23$。

B 正确：阈值调高只会让更多框“不合格”被删，保留框数不增加。

C 正确：训练数据是“图片 + 标注框”，模型比较预测框与真实框，属于监督学习。

D 正确：$x_{\text{px}} = x \cdot W$，$y_{\text{px}} = y \cdot H$。

一句话 IoU 在 0 到 1 之间；阈值越高越严格；YOLO 是监督学习。

9.3 A 层解析：基础填空（16—20）

第 16 题　答案 $\hat{y} = 2.5x + 0.5$　★　知识点：最小二乘（3.1.3）

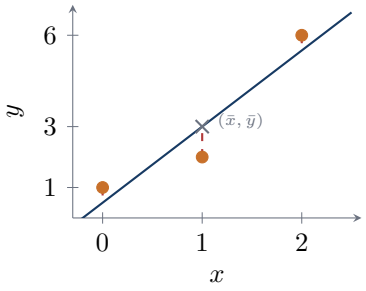
公式 $w = \dfrac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$，$b = \bar{y} - w\bar{x}$。

第一步 $\bar{x} = 1$，$\bar{y} = \frac{1+2+6}{3} = 3$。

第二步 分子 $= (-1)(-2) + 0 \cdot (-1) + 1 \cdot 3 = 5$；分母 $= 1 + 0 + 1 = 2$；$w = 2.5$。

第三步 $b = 3 - 2.5 \times 1 = 0.5$。

检查 直线过 $(\bar{x}, \bar{y}) = (1, 3)$ √；残差 $0.5, -1, 0.5$，和为 0 √。



等价答案 $\frac{5}{2}x + \frac{1}{2}$。

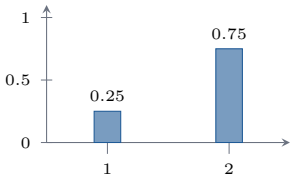
易错 把 $\bar{y}$ 算成 $\frac{1+2+6}{2}$；或只用两个端点连线（$y = 2.5x + 1$，这不是最小二乘解）。

第 17 题　答案 $[0.25,\ 0.75]$　★　知识点：Softmax 计算（3.3）

过程 $e^0 = 1$，$e^{\ln 3} = 3$，总和 4，故 $\text{softmax}(\boldsymbol{z}) = [\frac{1}{4}, \frac{3}{4}]$。

另一种看法 二分类时 $\hat{y}_2 = \sigma(z_2 - z_1) = \sigma(\ln 3) = \frac{1}{1+\frac{1}{3}} = \frac{3}{4}$，与性质 4 一致。

易错 写成 $[0, \ln 3]$ 归一化后的 $[0, 1]$——Softmax 先取指数，不是按比例归一化。

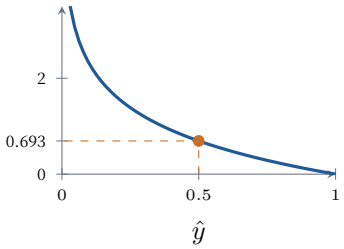


第 18 题　答案 $\ln 2 \approx 0.693$　★　知识点：BCE（3.5.3）

过程 $y = 1$ 时 $\text{BCE} = -[1 \cdot \ln 0.5 + 0 \cdot \ln 0.5] = -\ln 0.5 = \ln 2 \approx 0.693$。

含义 $\hat{y} = 0.5$ 表示模型“完全拿不准”；右图蓝线（$y = 1$ 分支）上的橙点正对应这个损失。若 $\hat{y} \to 1$，损失趋于 0。

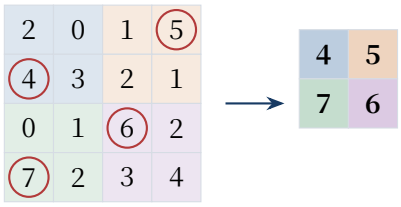
易错 用常用对数得 0.301；本讲义与课程代码均使用自然对数。



第 19 题 答案 50890　★　知识点：MLP 参数量（4.5.1）

过程 第一层：$784\times 64+64=50176+64=50240$；第二层：$64\times 10+10=650$；合计 50890。
检查 与 784→128→10 的 101770 相比，隐藏层宽度减半，参数约减半 √。
易错 漏掉偏置得 50816；或把每层的“神经元数”相加得 858。

第 20 题 答案 $\begin{bmatrix}4 & 5\\ 7 & 6\end{bmatrix}$　★　知识点：最大池化（5.3）

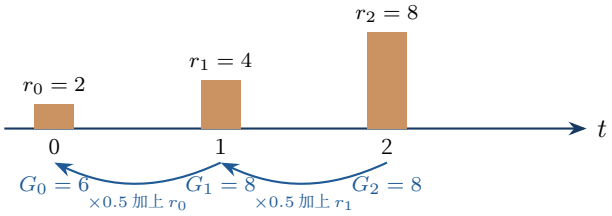


过程 四个颜色区域（左上、右上、左下、右下）分别为
$\{2,0,4,3\}\to 4$；$\{1,5,2,1\}\to 5$；
$\{0,1,7,2\}\to 7$；$\{6,2,3,4\}\to 6$。
红圈标出各区域的最大值。
易错 窗口重叠滑动（步长 1）会得到 3×3 的结果；步长 2 时窗口互不重叠。

9.4 A 层解析：基础解答（21—25）

第 21 题 ★　知识点：折扣回报与递推（2.6.3）

题意 求从不同时刻出发的“打折总奖励”。　**已知** $\gamma=0.5$；$r_0=2, r_1=4, r_2=8$，之后为 0。
公式 $G_t=\sum_{k\ge 0}\gamma^k r_{t+k}$；$G_t=r_t+\gamma G_{t+1}$。
第一步 $G_2=r_2=8$（之后没有奖励）。
第二步 $G_1=r_1+\gamma r_2=4+0.5\times 8=8$。
第三步 $G_0=r_0+\gamma r_1+\gamma^2 r_2=2+0.5\times 4+0.25\times 8=2+2+2=6$。
递推验证 $G_1=r_1+\gamma G_2=4+0.5\times 8=8$ √；$G_0=r_0+\gamma G_1=2+0.5\times 8=6$ √。



解析图 橙色柱是即时奖励，蓝色数字是回报；蓝色箭头表示递推“从后往前算”：每往前一步，先把后面的回报乘 γ，再加上当步奖励。
结果检查 奖励越来越大但被越打越折，三项在 G_0 中的贡献恰好都是 2。
易错 把 γ^k 的指数从 1 开始（写成 $0.5\times 2+0.25\times 4+\cdots$）。
同类题 从最后一步往前用递推式，最不容易出错。

第 22 题 ★ 知识点：RSS、TSS 与 R^2（3.2）

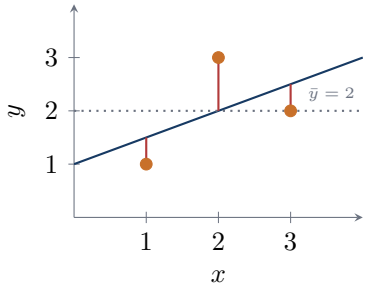
已知 $(1,1),(2,3),(3,2)$；$\hat{y}=0.5x+1$。

第一步（预测值） $\hat{y}=1.5,\ 2,\ 2.5$；残差 $y-\hat{y}=-0.5,\ 1,\ -0.5$。

第二步（RSS） $0.25+1+0.25=1.5$。

第三步（TSS） $\bar{y}=2$，$(1-2)^2+(3-2)^2+(2-2)^2=2$。

第四步 $R^2=1-\frac{1.5}{2}=0.25$。



解析图 红色竖线是残差（RSS 来源），灰色点线是 $\bar{y}$（TSS 衡量点到它的距离）。第 2 个点离模型线的距离（1）与离 $\bar{y}$ 线的距离（1）相同，模型在这里毫无改进，所以总体只改进了 25%。

结果含义 模型只解释了 y 变化的 25%，比“只猜平均值”好一点但很有限。

易错 TSS 用 $\hat{y}$ 的平均值代替 y 的平均值。　**同类题** 先列表算残差，再分别求两个平方和。

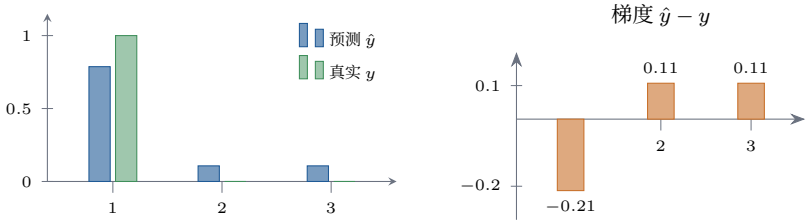
第 23 题 ★ 知识点：Softmax、交叉熵、梯度（3.3—3.4）

第一步（Softmax） $e^2=7.389$，$e^0=1$，总和 $7.389+1+1=9.389$，

$$\hat{\boldsymbol{y}}=\left[\frac{7.389}{9.389},\ \frac{1}{9.389},\ \frac{1}{9.389}\right]\approx[0.787,\ 0.107,\ 0.107].$$

第二步（交叉熵） 真实类别为 1，$L=-\ln\hat{y}_1=-\ln 0.787\approx 0.240$。

第三步（梯度） $\dfrac{\partial L}{\partial z_j}=\hat{y}_j-y_j$，$\boldsymbol{y}=[1,0,0]$，故梯度 $\approx[-0.213,\ 0.107,\ 0.107]$。



解析图 左图：预测柱（蓝）比真实柱（绿）在类别 1 矮 0.213，在类别 2、3 各高 0.107；右图的梯度正是二者之差。

结论 更新 $z_1\leftarrow z_1-\eta\cdot(-0.213)$，$z_1$ **增大**；z_2,z_3 减小。梯度下降把概率“挪向”正确类别。

检查 三个梯度之和 $=-0.213+0.107+0.107\approx 0$，这是因为 $\sum\hat{y}_j=\sum y_j=1$。

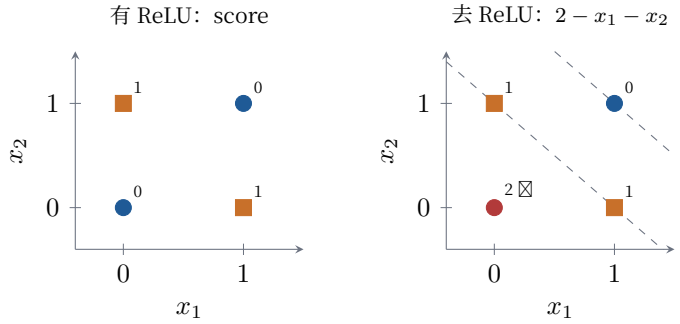
易错 把梯度写成 $y-\hat{y}$，导致更新方向相反。

第 24 题 ★ 知识点：XOR 与激活函数的作用（4.1—4.3）

(x_1,x_2)	x_1+x_2-1	z	score	去 ReLU
(0,0)	-1	0	0	2
(0,1)	0	0	1	1
(1,0)	0	0	1	1
(1,1)	1	1	0	0

(1) score 列为 $0,1,1,0$，与异或 XOR 真值表相同：两输入*不同*时输出 1。关键在于 z 只在 $(1,1)$ 处为 1，它把 $(1,1)$ 的 score 从 2 “拉回”到 0。

(2) 去掉 ReLU：score $= x_1 + x_2 - 2(x_1 + x_2 - 1) = 2 - x_1 - x_2$，是一个*线性函数*，四点的值为 $2, 1, 1, 0$（表中最后一列），$(0,0)$ 输出 2 而不是 0，不能实现 XOR。这印证了“没有激活函数，多层线性等价于单层线性”，而第 14 题 D 已说明单层线性不能实现 XOR。



解析图 右图灰色虚线是线性函数 $2 - x_1 - x_2$ 的等值线，score 沿对角方向单调变化，$(0,0)$ 与 $(1,1)$ 两个“应输出 0”的点落在最高与最低两端，线性函数无法让它们同时为 0。
同类题 判断能否实现某个运算：先列真值表，再检查去掉非线性后是否退化为线性函数。

第 25 题 ★ 知识点：卷积计算与参数量（5.2）

(1) $o = \frac{4-2}{1} + 1 = 3$，输出 3×3。

(2) 卷积核 $\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ 使每个输出等于“窗口左上角 − 窗口右下角”：$S(i,j) = I(i,j) - I(i+1, j+1)$。

1	2	0	1
3	1	2	2
0	2	1	0
1	0	3	1

输入 I

$$2 \cdot 1 + 2 \cdot 0 + 1 \cdot 0 + 0 \cdot (-1) = 2$$

0	0	-2
1	0	2
0	-1	0

输出 S

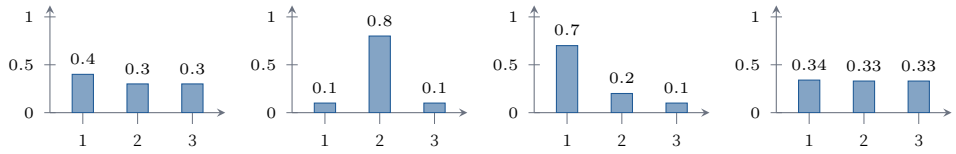
逐项：第 1 行 $1-1=0,\ 2-2=0,\ 0-2=-2$；第 2 行 $3-2=1,\ 1-1=0,\ 2-0=2$；第 3 行 $0-0=0,\ 2-3=-1,\ 1-1=0$。 **解析图** 深蓝框展示第 2 行第 3 列：窗口 $\begin{bmatrix} 2 & 2 \\ 1 & 0 \end{bmatrix}$ 与卷积核对应相乘求和，得到输出中深蓝框的 2。

(3) $(2 \times 2 \times 1 + 1) \times 1 = 5$ 个参数（4 个权重 + 1 个偏置）。
易错 按矩阵乘法计算；或把输出尺寸算成 4×4（那需要补零）。

9.5 B 层解析：提升单选（26—28）

第 26 题　答案 C　★★　知识点：Softmax 输出与交叉熵（3.4）

思路 交叉熵只看*正确类别*的概率：$L=-\ln \hat{y}_1$。$\hat{y}_1$ 越大，损失越小——其余类别怎么分配不影响本题损失。



A　　B　　C　　D

逐项图解（只看每幅图的第 1 根柱）

A：$\hat{y}_1=0.4$，$L=-\ln 0.4\approx 0.916$，**错误**。

B：$\hat{y}_1=0.1$，$L=-\ln 0.1\approx 2.303$，损失最大，**错误**——模型把最高概率给了错误的第 2 类。

C：$\hat{y}_1=0.7$，$L=-\ln 0.7\approx 0.357$，最小，**正确**。

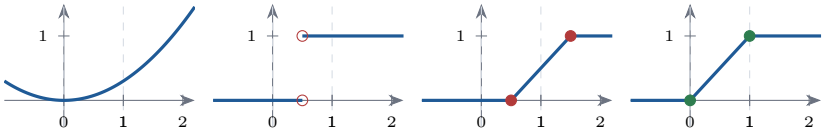
D：$\hat{y}_1=0.34$，$L\approx 1.079$，接近“瞎猜”（$\ln 3\approx 1.099$），**错误**。

常见错误 选 B，因为它的“最高柱最高”——但最高柱在错误类别上。

一句话 交叉熵只关心“正确类别那根柱有多高”。

第 27 题　答案 D　★★　知识点：ReLU 网络的折线表示（4.6）

思路 $a\,\mathrm{ReLU}(x)+b\,\mathrm{ReLU}(x-1)+c$ 由两个铰链组成：折点*只能*出现在 $x=0$ 和 $x=1$；函数处处连续；$x<0$ 时两项都为 0，函数为常数 c。



A　　B　　C　　D

逐项图解（灰色虚线标出允许的折点位置 $x=0,1$）

A：光滑抛物线处处在弯，没有“直线段 + 折点”的结构，**错误**（只能用很多铰链*近似*，不能精确表示）。

B：在 $x=0.5$ 处*跳跃*（红圈），而 ReLU 之和处处连续，**错误**。

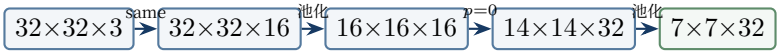
C：是折线，但折点（红点）在 0.5 和 1.5，不在允许的位置，**错误**。

D：折点（绿点）恰在 0 和 1：$x<0$ 为 0、$0\le x\le 1$ 斜率 1、$x>1$ 斜率 0。取 $a=1$、$b=-1$、$c=0$，即 $f(x)=\mathrm{ReLU}(x)-\mathrm{ReLU}(x-1)$，**正确**。

验证 $x=0.5$：$0.5-0=0.5$ √；$x=2$：$2-1=1$ √；$x=-1$：0 √。

一句话 每个 ReLU 铰链贡献一个固定位置的折点；ReLU 网络画出的是连续折线。

第 28 题　答案 B　★★　知识点：卷积与池化的形状变化（5.2—5.5）



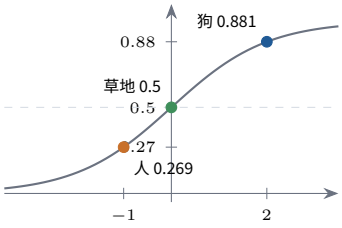
过程 ① same 卷积尺寸不变，通道变为卷积核个数 16；② 池化：$\lfloor \frac{32-2}{2} \rfloor + 1 = 16$；③ 不补零：$\frac{16-3}{1} + 1 = 14$，通道 32；④ 池化：$\lfloor \frac{14-2}{2} \rfloor + 1 = 7$。

逐项 A $8 \times 8 \times 32$：第 ③ 步误当作 same（$16 \to 16 \to 8$）；C $6 \times 6 \times 32$：第 ③ 步多减了 2；D 通道数错写成第一层的 16——**输出通道数 = 最后一个卷积层的卷积核个数**。

一句话 尺寸看 k, p, s，通道看卷积核个数，池化不改通道。

9.6　B 层解析：提升多选（29—30）

第 29 题　答案 ABD　★★　知识点：多标签 Sigmoid 与 BCE（3.5）



计算 $\sigma(2) \approx 0.881$，$\sigma(0) = 0.5$，$\sigma(-1) \approx 0.269$（左图三点）。灰色虚线为阈值 0.5。

A 正确：$\sigma(0) = 0.5$。

B 正确：人的点在阈值线下方，判为“没有人”，与标签一致。

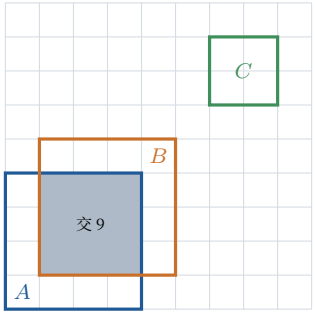
C 错误：$0.881 + 0.5 + 0.269 \approx 1.65 \neq 1$，多标签的各类概率独立。

D 正确：草地 $y = 1$，$\text{BCE} = -\ln 0.5 = \ln 2$。

延伸 三类平均 $\text{BCE} = \frac{1}{3}(-\ln 0.881 - \ln 0.5 - \ln 0.731) \approx \frac{1}{3}(0.127 + 0.693 + 0.313) \approx 0.378$；草地的损失最大，因为模型对它“拿不准”。

一句话 多标签：每类一条 Sigmoid、一个 BCE，概率互不相加。

第 30 题　答案 ACD　★★　知识点：IoU 与 NMS（6.2.2—6.2.3）



第一步（IoU） $A \cap B$：$x \in [1, 4]$、$y \in [1, 4]$，面积 9（深色）；并集 $16 + 16 - 9 = 23$；$\text{IoU}(A, B) = \frac{9}{23} \approx 0.391$。

第二步（NMS，阈值 0.5） 按置信度排序 $A(0.9) > B(0.8) > C(0.7)$。保留 A；$\text{IoU}(A, B) = 0.39 < 0.5$，$B$ 保留；C 与 A、B 都不相交，IoU 为 0，保留。

A 正确。　**B 错误**：0.39 没有超过 0.5。　**C 正确**：见第二步。　**D 正确**：阈值改为 0.3 后，$0.39 > 0.3$，B 被视为与 A 重复而删除。

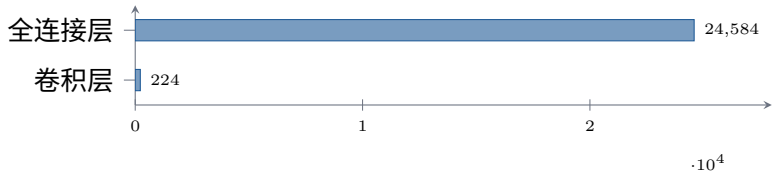
条件变化 NMS 阈值*越低*越“严格”，删除越多重叠框；密集人群场景阈值太低会误删相邻的不同目标。

一句话 NMS：从最高分开始，删掉和它重叠太多（IoU 超阈值）的框。

9.7 B 层解析：提升填空（31—33）

第 31 题　答案 224；24584　★★　知识点：卷积与全连接参数量对比（4.5、5.2）

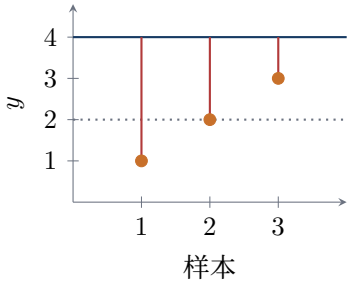
(1) 每个卷积核为 $3\times3\times3$（深度 = 输入通道 3），加 1 个偏置：$(27+1)\times8=224$。
(2) Flatten 后 $32\times32\times3=3072$ 维，$3072\times8+8=24584$。



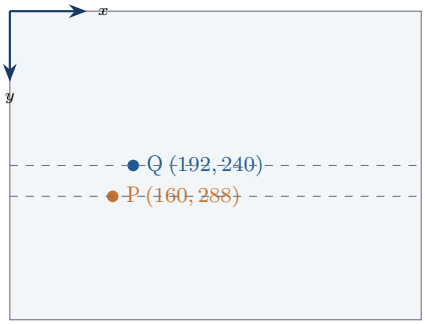
结论 同样输出 8 个“特征”，全连接层参数是卷积层的约 110 倍；且图像越大差距越大（卷积层参数不随图像大小变化）。
易错 (1) 忘记乘输入通道数得 80；(2) 忘了彩色图有 3 个通道得 8200。

第 32 题　答案 -6　★★　知识点：R^2 可以为负（3.2）

过程 $\mathrm{RSS}=(1-4)^2+(2-4)^2+(3-4)^2=9+4+1=14$；$\bar{y}=2$，$\mathrm{TSS}=1+0+1=2$；$R^2=1-\frac{14}{2}=-6$。
解析图 红色竖线（到预测线 $y=4$ 的距离）明显长于点到灰色 $\bar{y}$ 线的距离：这个模型比“只猜平均值 2”差得多，所以 $R^2<0$。
易错 认为 R^2 必在 $[0,1]$ 而填 0。



第 33 题　答案 (160, 288)；Q　★★　知识点：归一化坐标与图像坐标系（6.4）



第一步 P：$x=0.25\times640=160$，$y=0.60\times480=288$。　Q：$x=192$，$y=240$。
第二步 图像坐标 y 向下增大，y 越小越靠上。$240<288$，所以 **Q 更高**（左图中 Q 的虚线在 P 上方）。
易错 ① 把宽、高乘反，得 $(120,384)$；② 按数学坐标习惯认为 y 大的更高而填 P。

9.8 B 层解析：综合大题（34—35）

第 34 题 ★★ 知识链：最小二乘 → R^2 → 特征工程 → MLP

1. 题目在问什么 先用“直线”拟合一组“中间高、两边低”的数据，看它失败在哪里；再通过人工加入 f^2 特征让线性模型成功；最后联系 MLP。

2. 已知 $(1,1),(2,3),(3,1)$。　**3. 知识链** 最小二乘公式 → R^2 定义 → 多项式特征（线性方程组）→ 隐藏层自动造特征。

(1) 为什么先求平均 最小二乘直线必过 $(\bar f,\bar y)$。$\bar f=2$，$\bar y=\frac{5}{3}$。

$$w=\frac{(-1)(1-\frac{5}{3})+0\cdot(3-\frac{5}{3})+(1)(1-\frac{5}{3})}{1+0+1}=\frac{\frac{2}{3}-\frac{2}{3}}{2}=0,\qquad b=\bar y-w\bar f=\frac{5}{3}.$$

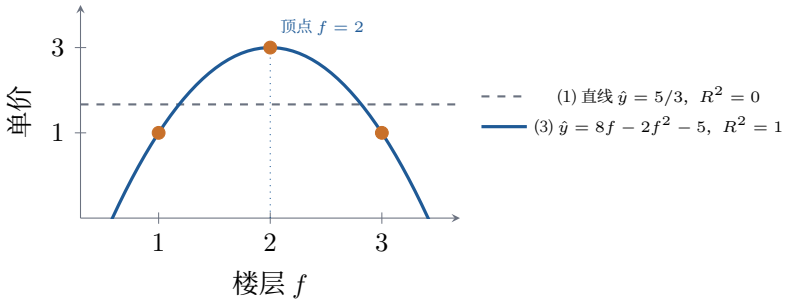
直线是水平线 $\hat y=\frac{5}{3}$。原因：数据左右对称，“上升”与“下降”恰好抵消，最好的直线只能取平均。

(2) 预测值恒为 $\frac{5}{3}=\bar y$，于是 RSS 与 TSS 完全相同：$\text{RSS}=\frac{4}{9}+\frac{16}{9}+\frac{4}{9}=\frac{8}{3}=\text{TSS}$，$R^2=1-1=0$。**直线模型与“只猜平均”一样，没有解释任何变化**——这不是因为楼层与单价无关，而是因为关系是*非单调*的，直线表达不了。

(3) 加入 f^2 后仍是“参数的线性模型”，三点代入得方程组：

$$\begin{cases}a+b+c=1\\2a+4b+c=3\\3a+9b+c=1\end{cases}\xrightarrow{②-①,\ ③-②}\begin{cases}a+3b=2\\a+5b=-2\end{cases}\Rightarrow\ b=-2,\ a=8,\ c=1-8+2=-5.$$

得 $\hat y=8f-2f^2-5$，三点完全吻合，RSS $=0$，$R^2=1$。二次函数开口向下（$b<0$），顶点 $f=-\frac{a}{2b}=-\frac{8}{2\times(-2)}=2$，即**第 2 层单价最高**。



(4) f^2 是人工设计的非线性特征（特征工程）；MLP 的隐藏层可以*自动*学出类似的非线性特征（如用两个 ReLU 铰链拼出“先升后降”），不需要事先知道要加 f^2。

合理性检查 $f=1$：$8-2-5=1$ √；$f=3$：$24-18-5=1$ √。

最容易卡住 看到 $w=0$ 以为算错；其实“水平线”正是对称数据的最小二乘解。

条件变化 若 3 层单价为 2（不对称），直线斜率将不为 0，但 R^2 仍会远小于 1，二次模型依然更好。

变式思考 若只有两组数据 $(1,1),(2,3)$，直线就能完全拟合（$R^2=1$）。这说明什么？（提示：数据太少时“完美拟合”并不可靠，与过拟合有关。）

第 35 题 ★★ 知识链：矩阵乘法 → ReLU → Softmax → 交叉熵 → 参数量

1. 题目在问什么 完整走一遍 MLP 的前向传播，并算出损失和参数量。 **2. 知识链** $\boldsymbol{h} = \mathrm{ReLU}(W_1\boldsymbol{x}) \to \boldsymbol{z} = W_2\boldsymbol{h} \to \hat{\boldsymbol{y}} = \mathrm{softmax}(\boldsymbol{z}) \to L = -\ln \hat{y}_2$。

(1)

$$W_1\boldsymbol{x} = \begin{bmatrix} 1\cdot 1 + 1\cdot(-1) \\ 1\cdot 1 + (-1)\cdot(-1) \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \qquad \boldsymbol{h} = \mathrm{ReLU}(W_1\boldsymbol{x}) = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \text{（0 与 2 都不小于 0，保持不变）.}$$

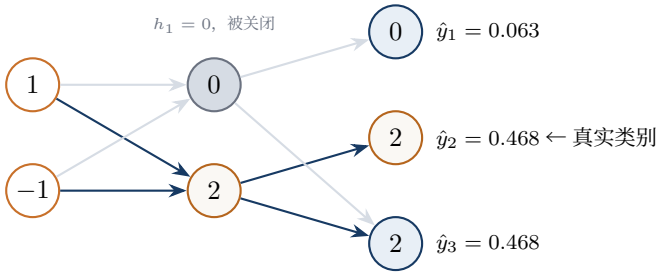
(2)

$$\boldsymbol{z} = W_2\boldsymbol{h} = \begin{bmatrix} 1\cdot 0 + 0\cdot 2 \\ 0\cdot 0 + 1\cdot 2 \\ -1\cdot 0 + 1\cdot 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \\ 2 \end{bmatrix},$$

$$\hat{\boldsymbol{y}} = \frac{[e^0,\ e^2,\ e^2]}{1 + 2\times 7.389} = \frac{[1,\ 7.389,\ 7.389]}{15.778} \approx [0.063,\ 0.468,\ 0.468].$$

(3) $L = -\ln 0.468 \approx 0.759$。

(4) W_1：4，$\boldsymbol{b}_1$：2，W_2：6，$\boldsymbol{b}_2$：3，共 **15** 个参数（偏置为 0 也是参数，只是当前取值为 0）。



解析图 圆圈内是前向传播得到的数值：$h_1 = 0$（灰色）意味着它的所有出边对本样本不起作用（灰色箭头），实际参与计算的只有 h_2 这条通路。

合理性检查 三个概率之和 $0.063 + 0.468 + 0.468 \approx 1$ √；$z_2 = z_3$ 所以 $\hat{y}_2 = \hat{y}_3$ √。

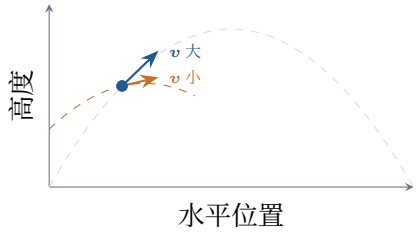
最容易卡住 W_2 是 3×2 矩阵，行数 = 输出个数 3、列数 = 隐藏层宽度 2，不要把矩阵转置。

条件变化 若 W_2 的第三行改为 $[-1,\ 0]$，则 $z_3 = 0$，$\hat{y}_2 = \frac{e^2}{e^2+2} \approx 0.787$，损失降为约 0.240——模型不再把概率“分给”第 3 类。

变式思考 若输入改为 $\boldsymbol{x} = (-1, 1)^\top$，哪个隐藏神经元会被关闭?

9.9 C 层解析：跨学科迁移（36—38）

第 36 题 答案 A　★★　当前专题知识：马尔可夫性（2.6.5）　外部情境：大学物理·抛体运动



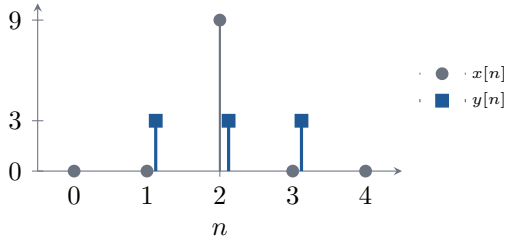
思路 马尔可夫性要求：*当前状态*足以决定下一状态。题干给出的更新式中，$\boldsymbol{r}_{t+1}$ 需要 $\boldsymbol{r}_t$ 和 $\boldsymbol{v}_t$，$\boldsymbol{v}_{t+1}$ 需要 $\boldsymbol{v}_t$。

解析图 同一位置（蓝点）若速度不同（蓝、橙箭头），下一时刻位置完全不同——只知道位置不够。

A 正确：$(\boldsymbol{r}_t, \boldsymbol{v}_t)$ 已包含更新式所需的全部信息。　**B 错误**：见解析图反例。　**C 错误**：历史轨迹中能用的信息（速度）已被 $\boldsymbol{v}_t$ 概括，不需要全部历史。　**D 错误**：题干描述的是确定性过程；而且马尔可夫性本来就允许随机转移，只要概率只依赖当前状态。

为什么不超纲 两个更新式在题干中给出，无需预先会推导抛体公式。　**迁移点** “单帧图像不满足马尔可夫性、需拼接多帧”（2.6.5 反例）在物理中就是“状态必须包含速度”。

第 37 题 答案 ABC　★　当前专题知识：卷积（5.2、例 6.1）　外部情境：信号处理·滑动平均



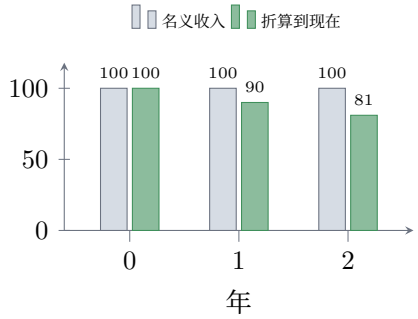
计算 $y[1]=\frac{0+0+9}{3}=3$，$y[2]=\frac{0+9+0}{3}=3$，$y[3]=\frac{9+0+0}{3}=3$。

解析图 灰色是原信号（一个高 9 的尖峰），蓝色是滤波后信号：尖峰被“摊平”成三个高 3 的点。

A 正确：$y[n]=\sum_{m=-1}^{1}\frac{1}{3}x[n+m]$ 正是“卷积核对应相乘再求和”的一维形式。　**B 正确**：见计算。　**C 正确**：尖峰由 9 降为 3，与例 6.1 高斯模糊的“降噪”完全同理。　**D 错误**：这里的卷积核是人为*设计*的固定滤波器；CNN 的卷积核才需要训练。

为什么不超纲 滤波公式在题干中已给出，只需按公式计算。　**迁移点** 二维图像卷积 ↔ 一维信号卷积：同一个“滑动窗口加权求和”。

第 38 题 答案 271 元　★　当前专题知识：折扣回报（2.6.3）　外部情境：经济学·现值



对应关系 奖励 r_k ↔ 第 k 年收入；折扣因子 γ ↔ 未来 1 年的 1 元值现在 0.9 元；回报 G_0 ↔ 现值。

计算 $G_0=100+0.9\times100+0.9^2\times100=100+90+81=271$（元）。

易错 从第 0 年就开始打折，得 $90+81+72.9=243.9$。第 0 年的收入“现在就拿到”，权重 $\gamma^0=1$。

为什么不超纲 “折扣”的含义在题干中已定义，只用到 G_t 的定义。　**迁移点** 强化学习的“折扣回报”与经济学的“现值”是同一个数学结构：**越远的收益，今天看来越不值钱**。

第 10 章　总复习：易错点、方法、概念对比与后续课程

10.1　高频易错点总表

主题	错误说法 / 做法	正确理解
超参数	学习率、batch size 是模型参数	人为设定、训练中不更新；权重和偏置才是参数
epoch	训练 8 个 epoch = 更新 8 次	每个 epoch 更新 $\lceil N/B \rceil$ 次
过拟合	误差大就是过拟合	训练误差小、测试误差大才是过拟合
无监督	没有标签就没有损失函数	仍需构造目标函数（如 K-Means 的簇内距离和）
折扣因子	$\gamma \in [0,1]$ 都能保证回报有限	无限长任务需 $\gamma < 1$；目标函数要对整条轨迹求和
R^2	R^2 一定在 $[0,1]$	模型比“只猜平均”差时 $R^2 < 0$
Softmax	按比例归一化；缩放 logit 不影响结果	先取指数；只有平移不影响，缩放会改变结果
交叉熵	需要把所有类别的误差都加起来	one-hot 下只剩 $-\log \hat{y}_c$
多标签	多标签也用 Softmax	各类独立用 Sigmoid + BCE；PPT 标题中 Single-label 应为 Multi-label
激活函数	只是把输出压到 0~1	核心作用是引入非线性；去掉后多层等价于一层
MLP 参数	漏掉偏置；只数神经元个数	每层 $n_{\text{in}} n_{\text{out}} + n_{\text{out}}$
卷积参数	忘乘输入通道数	$(k^2 C_{\text{in}} + 1) C_{\text{out}}$，与图像长宽无关
池化	池化层有可训练参数	无参数；只压缩，不发现模式
图像坐标	y 越大位置越高	原点在左上角，y 向下增大
OpenCV	图像通道是 RGB	默认 BGR，交给 MediaPipe 前需转 RGB

10.2　基础解题步骤总结

六类基础题的通用步骤

1. **算回报**：从最后一步往前，用 $G_t = r_t + \gamma G_{t+1}$ 递推。
2. **最小二乘 / R^2**：求 $\bar{x}, \bar{y}$ → 求 w 再求 b → 列表算残差 → RSS、TSS → $R^2 = 1 - \text{RSS}/\text{TSS}$。
3. **Softmax / 交叉熵**：取指数 → 求和 → 归一化 → 只取正确类别算 $-\ln \hat{y}_c$ → 梯度 $\hat{\boldsymbol{y}} - \boldsymbol{y}$。
4. **Sigmoid / BCE**：逐类 $\sigma(z)$ → 按 $y = 1$ 或 0 选分支 → 平均。
5. **参数量**：全连接 $n_{\text{in}} n_{\text{out}} + n_{\text{out}}$；卷积 $(k^2 C_{\text{in}} + 1) C_{\text{out}}$；池化、Flatten 为 0。
6. **形状变化**：尺寸用 $o = \lfloor \frac{n+2p-k}{s} \rfloor + 1$，通道 = 卷积核个数，池化不改通道。

10.3 相近概念总对比

概念对	前者	后者
参数 / 超参数	训练学出（$W, \boldsymbol{b}$、卷积核数值）	训练前人设（η、batch、epoch、层数）
监督 / 无监督	有标签 $(\boldsymbol{x}, y)$，拟合标签	无标签，自己找结构，但仍有损失
在线学习 / 强化学习	逐步接收新数据，不影响环境	主动行动、影响环境、靠奖励学习
回归 / 分类	输出连续值，MSE	输出类别，交叉熵
多输出回归 / 多分类	多个连续输出（“不要认为全是分类”）	多个类别概率，和为 1
单标签 / 多标签	Softmax，互斥	Sigmoid，可并存
线性层 / 激活函数	拉伸、旋转、平移空间	掰弯空间，引入非线性
特征工程 / 隐藏层	人工设计非线性特征	网络自动学习非线性特征
MLP / CNN	全连接、不保留空间结构	局部连接、参数共享、保留空间结构
卷积层 / 池化层	有参数，发现模式	无参数，压缩并保留重要值
分类 / 检测	整图一个类别	多个框 + 类别 + 置信度
OpenCV / MediaPipe	“看见画面”：读取、处理、显示	“理解画面”：输出关键点与检测结果

10.4 后续课程连接

本讲知识以后会在哪里再出现

- **最优化方法**：梯度下降、学习率与收敛条件（本讲 $L = \theta^2$ 的例子就是最简单的收敛分析），Adam 等自适应优化器。
- **概率论与数理统计**：最大似然估计——交叉熵与 BCE 的来源；期望——强化学习目标 $\mathbb{E}_{\pi}[\cdot]$。
- **数字图像处理 / 信号与系统**：卷积、滤波、边缘检测（高斯模糊、Canny 与第 37 题的滑动平均）。
- **自动控制原理 / 最优控制**：状态、马尔可夫性与“策略”——控制律的现代说法；折扣回报对应带折扣的性能指标。
- **计算机视觉 / 机器人**：目标检测、姿态估计、视觉伺服；YOLO 与 MediaPipe 是实际项目（如智能小车、巡检）的常用起点。
- **下一讲：语言大模型与 RNN**：从“网格结构（图像）”走向“序列结构（语言）”。

10.5 练习图解覆盖统计

按“题意能否画图、条件能否上图、选项是否具有图形含义、过程是否有中间状态”四项判定，38 道练习中 32 道为**可视化适配题**；其余 6 道（1、2、10、14、19、31）为纯概念辨析或一步算术，题目区不强行配图（其中 2、31 的解析仍配有辅助图）。

项目	说明	结果
可视化适配题	3–9、11–13、15–18、20–30、32–38	32 / 38
题目区配图率	适配题中题目含题意图的比例	100%
解析区配图率	适配题中解析含解析图的比例	100%
选项级图解	第 6、7、26、27 题共 16 个图形选项在题目区与解析区均逐项绘制；第 11、12、15 题中具有图形含义的选项在解析中配图	100%

10.6 参考资料

原始教学依据

- 课程 PPT《第二节 线性回归、MLP 与 CNN》（机器学习与人工智能，118 页）；课堂手写笔记 Memo 382—386（2026-09-26）。
- 课程代码：`sin_nn_fitting_demo.html`；`softmax_mnist_demo.ipynb`；`fashion_mnist_teaching_case.ipynb`；`cnn/`（Fashion-MNIST 与 CIFAR-10 CNN 笔记本）；`yolo/`；`opencv/`；`media_pipe/`。

核心定义与公式核验

- I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. MIT Press, 2016（第 5—6、9 章：机器学习基础、前馈网络、卷积网络）。
- A. Zhang, Z. C. Lipton, M. Li, A. J. Smola.《动手学深度学习》（Dive into Deep Learning），线性神经网络、多层感知机、卷积神经网络章节。
- R. S. Sutton, A. G. Barto. *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, 2018（回报、折扣与 MDP）。
- G. Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989。

图像、工程工具核验

- J. Redmon, S. Divvala, R. Girshick, A. Farhadi. You Only Look Once: Unified, Real-Time Object Detection. CVPR 2016（arXiv:1506.02640）。
- OpenCV 官方文档：`cvtColor` 颜色空间转换（灰度加权公式）、`GaussianBlur`、`Canny`、形态学操作。
- Google AI Edge MediaPipe 文档：Hand / Face / Pose Landmarker（关键点数量与归一化坐标）。
- Ultralytics YOLO 文档：`predict` 结果中 `boxes.xyxy`、`conf`、`cls` 的含义。

学科史与数据集

- D. E. Rumelhart, G. E. Hinton, R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986。
- Y. LeCun, L. Bottou, Y. Bengio, P. Haffner. Gradient-based learning applied to document recognition. *Proc. IEEE*, 86(11), 1998。
- H. Xiao, K. Rasul, R. Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747, 2017。
- C. Lugaresi et al. MediaPipe: A Framework for Building Perception Pipelines. arXiv:1906.08172, 2019。