Near-Optimal Sensor Placements in Gaussian Processes

从手写标题与摘要，走向概率建模、信息量化与近似优化

原论文信息

Andreas Krause, Ajit Singh, Carlos Guestrin

Near-Optimal Sensor Placements in Gaussian Processes: Theory, Efficient Algorithms and Empirical Studies

JMLR, 9:235–284, 2008

这份讲义解决什么

不是逐句翻译论文，而是建立一条可学习的主线：

传感器选址 → GP → 熵/互信息 → 次模性 → 贪心近似 → 加速与鲁棒 → 实验阅读。

阅读定位 第一次接触本方向的本科生 · 公式来源可追踪 · 图形辅助理解 · 区分“理论保证”与“实验结果”

隐含的概率论、线性代数、信息论与组合优化背景补齐。排版采用连续章节而非“每章强制另起一页”，优先保证知识前后衔接、图文对应与页面信息密度。

目录

阅读说明 1

1 原始手写笔记：准确重构与纠错 2
- 1.1 你这页笔记实际抓住了什么 2
- 1.2 摘要中的六步逻辑链 2
- 1.3 手写词汇的规范化 3

2 先理解研究问题：传感器为什么不能随便放 4
- 2.1 从“测量”到“空间预测” 4
- 2.2 为什么简单“覆盖半径”模型不够 4
- 2.3 组合优化从哪里出现 4
- 2.4 在进入 GP 之前：先把“相关性”写成矩阵 . 5

3 高斯过程：为什么它能“预测 + 告诉你有多不确定” 5
- 3.1 一句正式定义 5
- 3.2 为什么核函数很重要 5
- 3.3 后验预测的两个核心量 6
- 3.4 和本文的连接 7

4 熵与互信息：怎样把“位置好不好”变成一个数 7
- 4.1 熵：不确定性有多大 7
- 4.2 为什么只追求“高熵位置”会出问题 7
- 4.3 互信息：知道 A 后，B 少了多少不确定性 . . 7
- 4.4 高斯情形下为什么特别好算 8

5 次模性：为什么贪心算法突然有了理论底气 8
- 5.1 先不看定义，先看“边际收益递减” 8
- 5.2 正式定义 9
- 5.3 为什么本文的互信息目标关键地满足次模性 . 9
- 5.4 经典贪心保证 9
- 5.5 这篇论文为什么不能简单写成“就是 63.2%” 10

6 论文算法主线：从难问题到可用算法 10
- 6.1 为什么精确最优太难 10
- 6.2 核心贪心算法 10
- 6.3 复杂度痛点：为什么“理论可行”还不等于“工程可用” 11

7 鲁棒性：真实传感器会坏，模型也会错 . . . 12
- 7.1 节点失效 12
- 7.2 模型参数不确定 12

8 实验：论文到底证明了什么，没证明什么 . 13
- 8.1 两个真实数据集 13
- 8.2 论文主要比较了什么 13
- 8.3 最值得记住的经验结论 13

9 标题与摘要的英文精读法 14
- 9.1 标题不是逐词翻译，而是研究结构 14
- 9.2 摘要里最该抓的不是生词，而是功能句 . . . 14
- 9.3 高频表达 14
- 9.4 把摘要读成“动作链”，而不是逐词翻译 . . 15

10 知识网络：这篇论文与你后续课程怎样连接 15
- 10.1 前置知识地图 16
- 10.2 与本科课程的自然连接 16
- 10.3 后续研究方向 16
- 10.4 学完这里，你应该能自检 17

11 正式基础练习（24 题） 17
- 11.1 单项选择题（10 题） 17
- 11.2 多项选择题（5 题） 18
- 11.3 填空题（5 题） 19
- 11.4 基础解答题（4 题） 19
- 11.5 答案速查 20

12 详细解析 20
- 12.1 单选题解析 20
- 12.2 多选题解析 21
- 12.3 填空题解析 21
- 12.4 解答题解析 21
- 12.5 高频易错点总表 22

13 下一步学习路线 23
- 13.1 最小前置知识清单 23

参考资料 23

制作与核验说明 24

阅读说明



第一遍怎么读

如果你目前只认得几个关键词，先不要追证明。每遇到一个公式，优先回答两件事：**它在解决什么问题？图上对应什么？**把整篇论文先读成“问题—建模—目标—困难—方法—证据”的连续故事。

第二遍怎么读

第二遍再补：条件高斯、熵/互信息、次模定义与贪心保证。推导不要求一次全记住，但要能说清**每个符号、使用条件与结论层级**。

本专题结束后，你应该能回答

1. sensor placement 为什么不是简单均匀布点?
2. GP 为什么能同时给预测与不确定性?
3. 熵与互信息分别衡量什么?
4. 为什么互信息最大化会变成组合优化?
5. 次模性的“边际收益递减”是什么意思?
6. 为什么贪心不再只是经验启发式?
7. near-optimal 在本文究竟“近”在哪里?
8. lazy/local/robust 各解决什么工程痛点?

阅读时始终区分三种证据

定义/公式回答“是什么”；　**定理/近似保证**回答“最坏情况下能保证什么”；　**实验结果**回答“在这些数据上实际表现怎样”。

蓝色：核心定义 / 公式　浅红：纠错 / 易错　浅绿：总结 / 自检　米白：直观例子

CHAPTER 01

原始手写笔记：准确重构与纠错

1.1 你这页笔记实际抓住了什么

你在手写页中把论文阅读分成了两层：**标题**和**摘要**。这是非常合理的第一遍阅读方式，因为标题告诉你研究对象和方法风格，摘要则告诉你完整的“问题—困难—方法—结果”链条。

手写笔记中的标题拆解

英文片段	你的笔记含义	更规范的理解
sensor placements	传感器布置	选择一组传感器应放置的位置
near-optimal	近最优的	有理论近似保证，且实证上常接近最优
Gaussian processes	高斯过程	一类对函数/空间场进行概率建模的非参数模型
efficient algorithms	高效算法	不只“能算”，还强调规模化计算与加速
empirical studies	实证研究	真实数据上的系统实验验证

你还补充了一句对高斯过程的直观认识：**“可以预测某个位置的数值，还可以告知这个预测有多么不确定。”**这句话作为直觉是对的，而且恰好抓住了本文为什么适合用 GP 的关键。

原图纠错 1：论文完整标题中有一个词容易漏掉

你红笔记录了一个常见标题模板“XXX Theory, Algorithms and Empirical Studies”。这个模板本身可以作为英语标题记忆，但**这篇论文的正式标题**是：

Theory, **Efficient** Algorithms and Empirical Studies

也就是说，*Efficient* 不是可有可无的修饰词，它对应论文第 5 节中专门讨论的扩展：懒惰求值、局部核等加速方法。[1]

1.2 摘要中的六步逻辑链

手写页对摘要的逻辑压缩非常准确，可以规范整理为下面六步：

1. **问题：**传感器数量有限，究竟应该放在哪里?
2. **建模：**用高斯过程描述空间位置之间的统计相关性和不确定性。
3. **目标：**用互信息衡量“已选位置对未选位置的解释/预测能力”。
4. **困难：**寻找互信息最大的 k 个位置是 NP-complete 的组合优化问题。
5. **理论：**利用互信息目标的次模性，用贪心算法得到近似最优保证。
6. **工程化：**继续加速算法，并考虑节点失效和模型不确定性，再用真实数据验证。

一句话压缩摘要

> **先用 GP 把空间信息变成“可计算的不确定性”，再用互信息定义“好位置”，用次模性把一个难解的组合问题变成有理论保证的贪心近似，最后解决效率与鲁棒性问题。**

1.3 手写词汇的规范化

表达	更自然的中文	学术语境提示
tackle a problem	着手解决 / 处理一个问题	比 *solve* 更强调“面对并处理”，不保证完全解出
combinatorial optimization problem	组合优化问题	决策变量往往是离散选择，例如“选哪 k 个位置”
mutual information	互信息	衡量两个随机变量共享的信息量，也可理解为知道一个变量后另一个变量不确定性的减少
submodularity	次模性	集合函数的“边际收益递减”性质
greedy algorithm	贪心算法	每一步选择当前边际收益最大的候选位置
empirical study	实证/实验研究	用真实或系统数据验证理论与算法表现

CHAPTER 02

先理解研究问题：传感器为什么不能随便放

2.1　从“测量”到“空间预测”

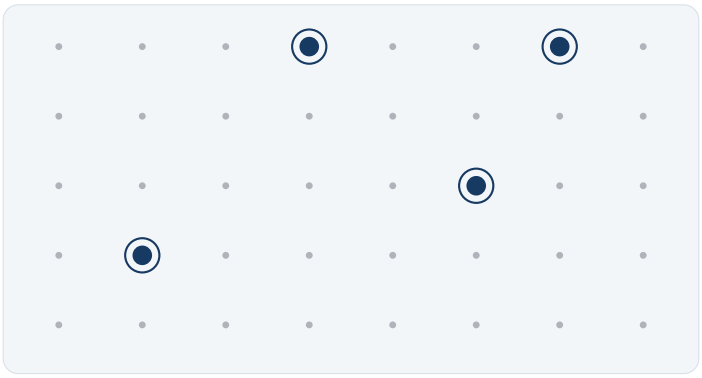
设想你要监测一个房间里的温度场。你当然可以在每个位置都放一个传感器，但现实中传感器有成本、供电、通信和维护限制，因此只能选择少数位置。

真正的目标通常不是“知道这几个传感器位置的温度”，而是：

利用少量测点，尽可能准确地推断整个区域中未测位置的状态。

这就意味着“传感器位置好不好”不能只由几何距离判断，还要考虑**不同位置的数据相关性**。

灰点：候选位置　　蓝色：最终布置的传感器



问题不是“蓝点之间离得尽量远”，而是“这些蓝点的观测能否尽量减少对其余灰点的预测不确定性”。

2.2　为什么简单“覆盖半径”模型不够

论文开篇指出，固定感知半径的几何模型对真实环境往往过强：传感器测量存在噪声，相关性不一定是规则圆盘，而且多个传感器的联合信息可能比任何单个传感器都重要。[1]

最容易产生的误解

> “离得近”通常意味着相关性可能更强，但**不是数学上必然的等价关系**。在真实空间场中，墙体、气流、地形、降水带等结构都可能造成非平稳（nonstationary）相关性。因此，本文的核心不是几何覆盖，而是**数据驱动的统计相关结构**。

2.3　组合优化从哪里出现

假设共有 n 个候选位置，只允许放 k 个传感器。那就要从 n 个位置中选 k 个：

$$\#\text{候选方案} = \binom{n}{k}.$$

例如 $n = 100,\ k = 10$ 时，组合数已经非常大。只要目标函数不是特殊结构，暴力枚举通常不可行。

一个微型例子

如果只有 5 个候选点 $\{1,2,3,4,5\}$，要求放 2 个传感器，则有

$$\binom{5}{2} = 10$$

种布置。你还可以逐个算。但当候选位置达到几百、几千甚至连续空间离散化后，这种思路会迅速失效。

2.4　在进入 GP 之前：先把“相关性”写成矩阵

假设只看两个候选位置 x_1, x_2，把它们的随机测量记为 X_1, X_2。最简单的相关结构可以写成协方差矩阵

$$\boldsymbol{K} = \begin{bmatrix} \mathrm{Var}(X_1) & \mathrm{Cov}(X_1, X_2) \\ \mathrm{Cov}(X_2, X_1) & \mathrm{Var}(X_2) \end{bmatrix}.$$

对角线告诉我们“每个位置自己有多不确定”，非对角线则告诉我们“两个位置一起变化得有多强”。因此，传感器选址真正需要利用的不是一串独立方差，而是**整张位置相关网络**。

为什么下一章自然要引入高斯过程

如果候选位置从 2 个扩展到几十、几百个，我们就需要一种统一规则，根据任意两点 x, x' 自动给出协方差 $k(x, x')$，并在观测部分位置后更新其余位置的预测均值和不确定性。**高斯过程正好把“相关性规则 + 条件预测”放进同一个概率模型里**。

CHAPTER 03

高斯过程：为什么它能“预测 + 告诉你有多不确定”

3.1　一句正式定义

Gaussian Process（高斯过程）

一个高斯过程是随机变量的集合，其中任意有限个随机变量都服从联合高斯分布。常写为

$$\boxed{f(\boldsymbol{x}) \sim \mathcal{GP}\big(m(\boldsymbol{x}), k(\boldsymbol{x}, \boldsymbol{x}')\big)}.$$

其中 $m(\boldsymbol{x})$ 是均值函数，$k(\boldsymbol{x}, \boldsymbol{x}')$ 是协方差（核）函数。该定义与经典教材 *Gaussian Processes for Machine Learning* 一致。[2]

一句话直观理解

普通高斯分布描述“一个随机向量可能落在哪里”；高斯过程进一步描述“**一整条未知函数/一整个空间场可能是什么样**”。

3.2　为什么核函数很重要

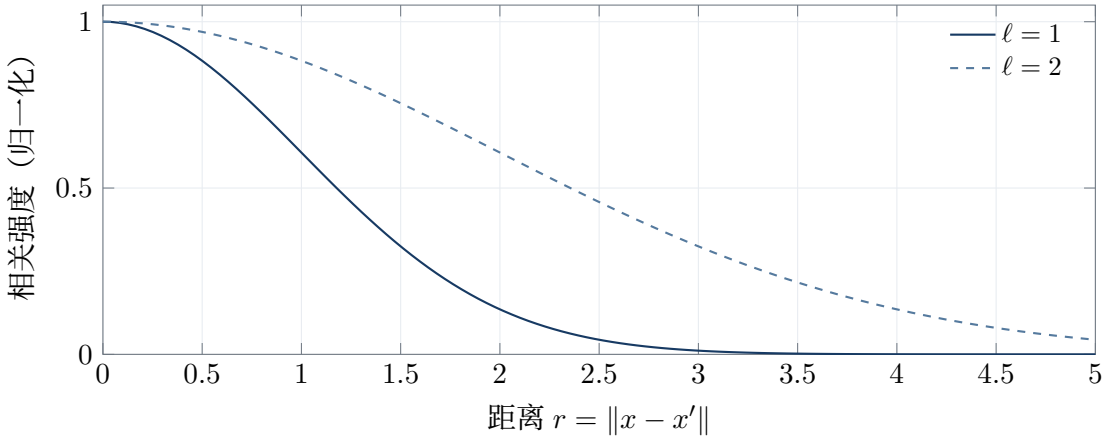
核函数

$$k(\boldsymbol{x}, \boldsymbol{x}') = \mathrm{Cov}\big(f(\boldsymbol{x}), f(\boldsymbol{x}')\big)$$

告诉模型两个位置之间“应该有多相关”。典型平方指数核为

$$\boxed{k(\boldsymbol{x},\boldsymbol{x}') = \sigma_f^2 \exp\left(-\frac{\|\boldsymbol{x}-\boldsymbol{x}'\|^2}{2\ell^2}\right)}.$$

ℓ 是长度尺度：ℓ 大，相关性衰减慢；ℓ 小，只有邻近位置强相关。



3.3　后验预测的两个核心量

设训练观测为

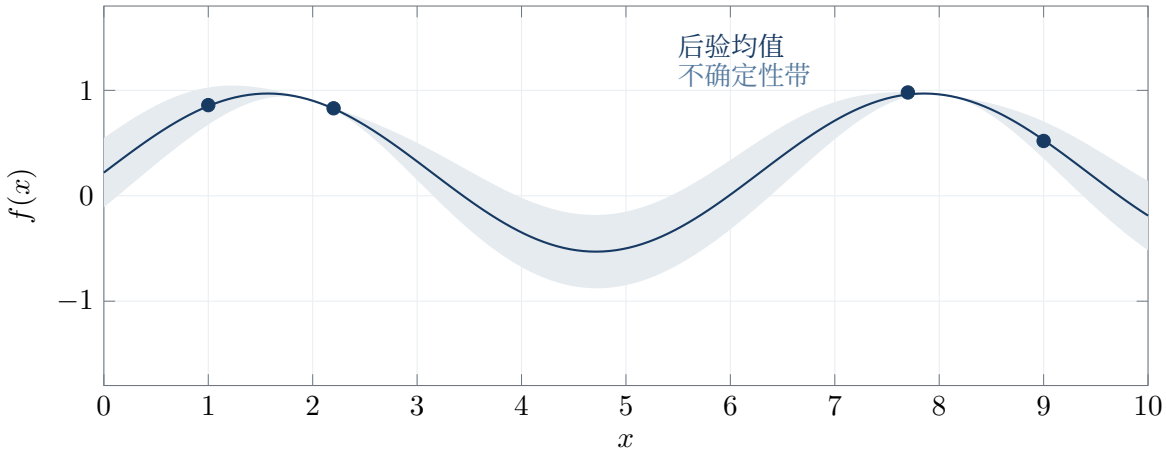
$$\boldsymbol{y} = \boldsymbol{f} + \boldsymbol{\varepsilon}, \qquad \boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{0}, \sigma_n^2 I).$$

对于新位置 $\boldsymbol{x}_*$，GP 回归给出后验均值和方差：

GP 后验均值与方差

$$\mu_* = \boldsymbol{k}_*^\top (K + \sigma_n^2 I)^{-1} \boldsymbol{y},$$
$$\sigma_*^2 = k(\boldsymbol{x}_*, \boldsymbol{x}_*) - \boldsymbol{k}_*^\top (K + \sigma_n^2 I)^{-1} \boldsymbol{k}_*.$$

其中 K 是训练位置之间的协方差矩阵，$\boldsymbol{k}_*$ 是新位置与训练位置之间的协方差向量。



图像和公式怎么对应

观测点附近，$\boldsymbol{k}_*$ 与已有观测的相关性较强，第二项 $\boldsymbol{k}_*^\top (K + \sigma_n^2 I)^{-1} \boldsymbol{k}_*$ 较大，因此后验方差会被“扣掉”更多；远离观测或相关性弱的位置，方差保持较大。这就是“传感器放在哪里会影响整个

> 空间的不确定性”的数学入口。

3.4　和本文的连接

论文并不是为了单纯做 GP 回归，而是反过来利用 GP 的**后验不确定性结构**决定在哪里采样。换句话说：

> GP 不只是预测器，也是传感器选址的评价模型。

CHAPTER 04

熵与互信息：怎样把“位置好不好”变成一个数

4.1　熵：不确定性有多大

对于一维高斯变量 $X \sim \mathcal{N}(\mu, \sigma^2)$，微分熵是

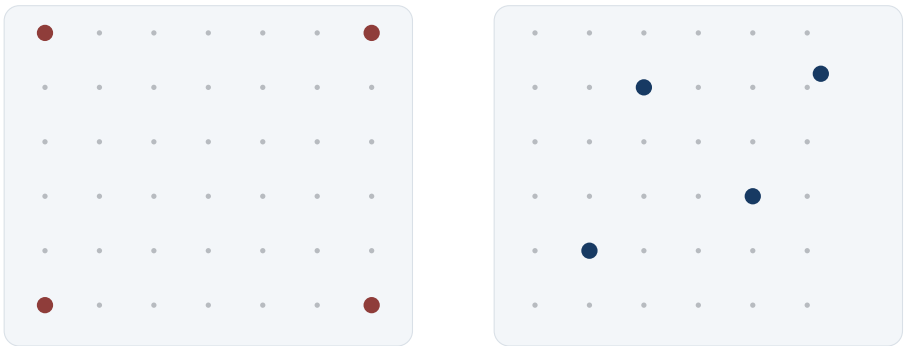
高斯变量的熵

$$H(X) = \frac{1}{2}\log(2\pi e\sigma^2).$$

所以对高斯变量而言，**方差越大，熵越大，不确定性越强**。这也是“最大熵选点”策略为何等价于倾向选择当前预测方差大的位置。[3, 1]

4.2　为什么只追求“高熵位置”会出问题

如果每次都选“当前最不确定的点”，算法容易把传感器推向空间边界。因为边界点离已有测点远，方差常常很大；但一台放在边缘的传感器，可能只对很少一片区域有帮助。



只看高熵：容易偏向边界　　互信息：兼顾自身不确定性与对未选区域的代表性

4.3　互信息：知道 A 后，B 少了多少不确定性

Mutual Information（互信息）

对随机变量 X, Y，互信息可写为

$$\boxed{I(X;Y) = H(X) - H(X \mid Y) = H(Y) - H(Y \mid X)}.$$

它衡量一个变量中包含了多少关于另一个变量的信息。[3]

对于传感器布置，论文定义：选择位置集合 A 后，希望它与未选位置 $V \setminus A$ 之间共享的信息最多：

论文的核心目标

$$\boxed{\mathrm{MI}(A) = I\big(X_A; X_{V\setminus A}\big)}.$$

这非常贴合真实目标：**我们测到的地方，应该尽量帮助我们理解没测到的地方**。

4.4　高斯情形下为什么特别好算

若 $\boldsymbol{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$，则

$$H(\boldsymbol{X}) = \frac{1}{2} \log \Big((2\pi e)^d \det \Sigma \Big).$$

因此互信息最终可转化为协方差矩阵行列式或条件方差的计算。对于贪心加入一个候选点 y，论文推导出边际收益：

加入一个新传感器的互信息增量

设 $\bar{A} = V \setminus (A \cup \{y\})$，则

$$\boxed{\mathrm{MI}(A \cup \{y\}) - \mathrm{MI}(A) = H(y \mid A) - H(y \mid \bar{A}).}$$

在高斯情形下等价于

$$\boxed{\Delta(y \mid A) = \frac{1}{2} \log \frac{\sigma^2_{y|A}}{\sigma^2_{y|\bar{A}}}.}$$

这个公式真正说了什么

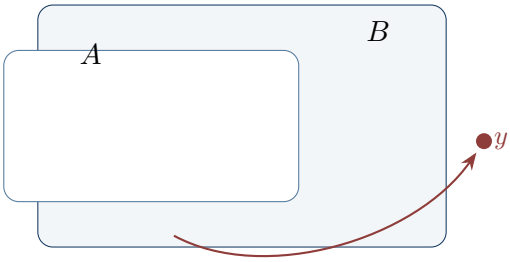
第一项 $H(y \mid A)$ 希望新点 y 不要和已选点过度重复；第二项 $-H(y \mid \bar{A})$ 又希望 y 能被未选区域很好“解释”，也就是它对未选区域具有代表性。两者合在一起，就形成“**既不重复，又要中央/代表性强**”的选点原则。[1]

CHAPTER 05

次模性：为什么贪心算法突然有了理论底气

5.1　先不看定义，先看“边际收益递减”

假设你已经放了很多彼此靠近的传感器，再在同一区域加一个新传感器，新增信息通常不大；如果你此前一个传感器都没有，同一个位置可能非常有价值。这就是“边际收益递减”的直觉。



$A \subseteq B$。在信息已经很多的集合 B 上再加入 y，通常不如在较小集合 A 上加入 y 有价值。

5.2　正式定义

Submodular set function（次模集合函数）

若对任意 $A \subseteq B \subseteq V$ 和 $y \in V \setminus B$，都有

$$\boxed{F(A \cup \{y\}) - F(A) \geq F(B \cup \{y\}) - F(B),}$$

则称 F 是次模函数。

左边是在“小集合”上加入 y 的边际收益，右边是在“大集合”上加入 y 的边际收益。定义本身就是边际收益递减。

5.3　为什么本文的互信息目标关键地满足次模性

论文证明 $A \mapsto \mathrm{MI}(A)$ 是次模的。[1] 这一步是整篇论文的理论转折点：没有次模性，“每次选当前最好的点”只是一个启发式；有了次模性，它就能继承经典的近似保证。

5.4　经典贪心保证

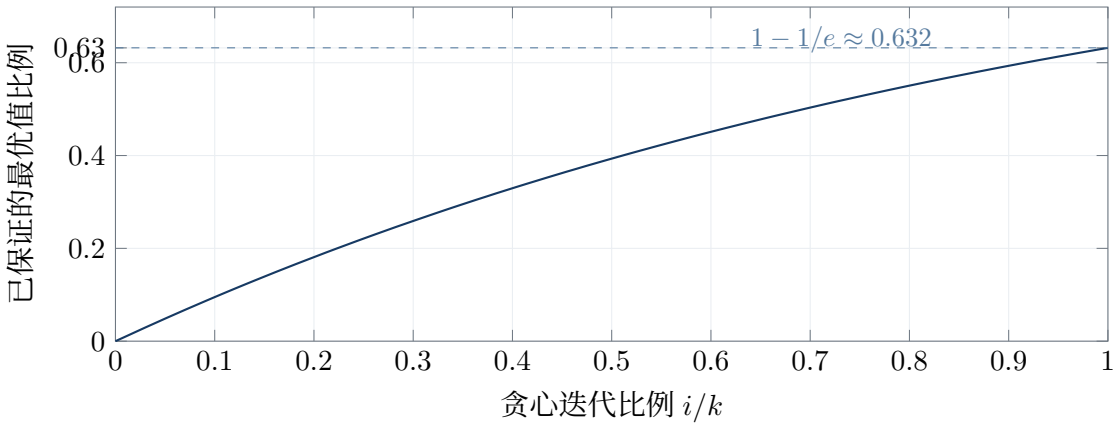
对非负、单调、次模函数 F，在“最多选 k 个元素”的约束下，经典 Nemhauser–Wolsey–Fisher 结果给出：

经典 $1 - 1/e$ 近似保证

设 S_k 为贪心算法选出的 k 元集合，S^* 为最优 k 元集合，则

$$\boxed{F(S_k) \geq \left(1 - \frac{1}{e}\right) F(S^*) \approx 0.632 F(S^*).}$$

这个结论在多份算法课程讲义中以“单调次模函数的基数约束贪心近似”出现。[4, 5]



5.5　这篇论文为什么不能简单写成“就是 63.2%”

这里有一个很重要的严谨性细节。论文讨论的是离散化后的空间互信息，目标在其条件下是**近似单调**的，因此给出的形式带有一个离散化误差项：

$$\mathrm{MI}(A_{\mathrm{greedy}}) \geq (1-1/e)\,\mathrm{OPT} - k\varepsilon$$

（论文给出更精确的条件与形式）。[1]

最常见误读

> **“near-optimal”不等于“理论上保证离最优值只差 5%”**。论文的通用理论保证本质上是 $1-1/e$ 级别，并带离散化误差；“小问题上贪心解不超过最优解 5% 的差距”是论文在一个可精确求最优的小规模实验中的**经验观察**。两者不能混在一起。

CHAPTER 06

论文算法主线：从难问题到可用算法

6.1　为什么精确最优太难

论文证明：最大化上述互信息目标的传感器选择问题是 NP-complete。[1] 直观上，困难来自两个层面：

- 选择变量是离散集合，而非普通连续参数；
- 每个候选点的价值依赖于“已经选了谁”，候选之间强耦合。

所以本文不是“再想一个更聪明的精确算法”，而是转向：**能不能构造一个多项式时间、可证明接近最优的算法？**

6.2　核心贪心算法

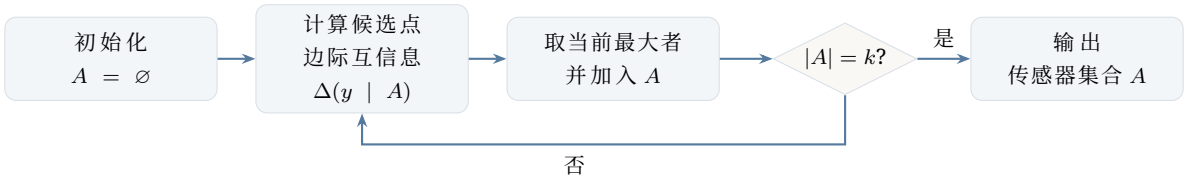
贪心传感器选址

输入：候选位置集合 S、总空间位置集合 V、协方差矩阵、预算 k。
初始化：$A \leftarrow \varnothing$。

重复 k 次：

$$y^* = \arg\max_{y \in S \setminus A} \big[\mathrm{MI}(A \cup \{y\}) - \mathrm{MI}(A)\big],$$

然后令 $A \leftarrow A \cup \{y^*\}$。



6.3　复杂度痛点：为什么“理论可行”还不等于“工程可用”

标准贪心每一轮都要对大量候选点重新计算条件熵/条件方差。论文分析指出，在其直接实现中，互信息贪心可能达到很高的计算复杂度，因此第 5 节专门讨论 *Scaling Up*。[1]

6.3.1　加速 1：Lazy Evaluation（懒惰求值）

次模性意味着某个候选点的边际收益随着已选集合增长不会变大。因此旧的边际收益值可以作为一个**上界**。算法把候选点放进优先队列，不再每轮把所有候选都完整重算，而是只在“这个点看起来可能成为第一名”时刷新它。

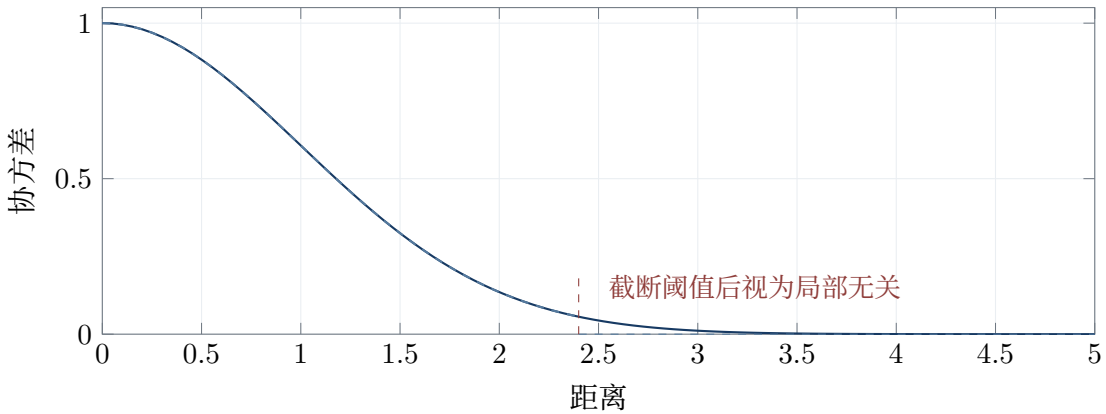
为什么这很聪明

普通贪心：**每轮全班重新考试，再选第一名。**
Lazy Greedy：**先保留上次成绩作为上界，只对有机会争第一的学生补考。**由于次模性保证成绩只会下降，不会突然上升，所以这种“偷懒”仍然能得到同一个贪心选择。

论文实验中，在一个 50 个传感器的降水数据选择任务上，互信息计算次数从 7125 次降到 1172 次，计算时间从 41.3 s 降到 8.7 s（论文当时的硬件环境）。[1]

6.3.2　加速 2：Local Kernels（局部核/截断）

若远距离位置之间的协方差非常小，就可以把足够小的相关项截断为 0，仅在局部邻域中更新。这样做牺牲少量精度，换取更显著的速度提升。



准确理解“高效算法”

“高效”不是说原始组合问题被彻底变成了一个简单问题，而是：**先用次模性取得近似保证，再利用同一结构减少无谓计算，同时利用 GP 的局部相关结构进一步缩小计算范围**。

CHAPTER 07

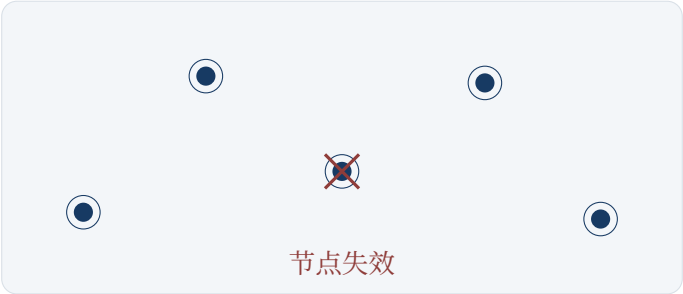
鲁棒性：真实传感器会坏，模型也会错

7.1　节点失效

物理传感器可能电池耗尽、通信丢包或硬件故障。论文把每个节点是否工作写成随机变量 Z_i，并考虑“真正工作的子集”上的互信息期望。其鲁棒互信息目标可以写成一种期望形式：

$$\mathrm{MI}_R(A) = \mathbb{E}_Z\big[\mathrm{MI}(A_Z)\big].$$

由于次模函数对期望运算保持封闭，这个鲁棒目标仍保留可利用的次模结构。[1]



鲁棒布置不是要求“永不失败”，而是让部分节点失效后系统仍保留较高的信息价值。

7.2　模型参数不确定

GP 的长度尺度、方差等超参数也可能估错。论文采用贝叶斯思想，把参数 θ 本身视为有分布的随机变量，然后对不同 θ 下的互信息取期望：

$$\mathrm{MI}_M(A) = \mathbb{E}_\theta\left[I(A; V \setminus A \mid \theta)\right].$$

这说明“鲁棒性”不仅是硬件可靠性，也包括**模型认知不完备**。

这一章与机器人/自主系统的自然联系

移动机器人、无人机、环境监测机器人经常面临同类问题：传感器会掉线、通信会受干扰、环境统计特性会随时间变化。因此“信息驱动的选点 + 鲁棒优化”是这篇论文最容易延伸到主动感知、主动采样和机器人探索的部分。论文也把这类工作与 active learning / spatial learning 联系起来。[1]

CHAPTER 08

实验：论文到底证明了什么，没证明什么

8.1　两个真实数据集

论文使用两个真实数据集进行系统实验：

- **Intel Berkeley Lab 温度数据：**论文实验部分使用 46 个传感器位置的数据，训练样本来自连续 3 天、每 30 秒一次的测量，测试为随后 2 天。[1]
- **美国华盛顿州与俄勒冈州降水数据：**包含 167 个区域，区域间距约 50 km，数据年份为 1949–1994，并做了适合 GP 建模的预处理。[1]

8.2　论文主要比较了什么

比较对象	核心问题	论文总体观察
几何 disk model vs GP	数据驱动相关性是否优于固定半径假设	数据驱动布置更能改善预测
Entropy vs Mutual Information	只选高方差点还是直接考虑未选区域	MI 通常更优，熵更容易偏向边界
A/D/E-optimal design vs MI	经典实验设计准则如何比较	结果依数据与目标而异，MI 在多项实验中具有竞争力
标准贪心 vs 其他启发式	简单贪心是否实用	小规模可精确求解时，贪心非常接近最优；大规模也与复杂启发式有竞争力
标准计算 vs lazy/local	加速是否真的有效	显著减少互信息计算与运行时间

8.3　最值得记住的经验结论

论文在一个 16 个候选位置的小问题上比较了贪心与最优解；选 1–5 个传感器时，贪心结果始终在最优值的 95% 以内。[1] 这比最坏情况下的理论保证要好得多，但它是**特定实验**，不能升级为普适定理。

证据层级提醒：**定理保证**回答“最坏情况下至少能怎样”，**实验结果**回答“这些数据上实际上怎样”。因此，$1-1/e$ 一类近似保证不能和“小规模实验达到最优值的 95% 以内”混成同一条结论。

CHAPTER 09

标题与摘要的英文精读法

9.1　标题不是逐词翻译，而是研究结构

正式标题：

Near-Optimal Sensor Placements in Gaussian Processes:
Theory, Efficient Algorithms and Empirical Studies

可以拆成：

$$\underbrace{\text{Near-Optimal Sensor Placements}}_{\text{研究任务 + 性能目标}} \quad \text{in} \quad \underbrace{\text{Gaussian Processes}}_{\text{建模框架}}$$

$$\underbrace{\text{Theory}}_{\text{理论}} + \underbrace{\text{Efficient Algorithms}}_{\text{算法工程化}} + \underbrace{\text{Empirical Studies}}_{\text{实验验证}}.$$

可以迁移到其他论文的标题模板

> **[核心问题/对象] : Theory, [Efficient/Scalable/Robust] Algorithms and Empirical Evaluation**
> 这种标题往往暗示论文不仅提出方法，还要给理论保证、算法实现与实验验证三个层次。

9.2　摘要里最该抓的不是生词，而是功能句

读摘要时给每句话贴“功能标签”：

1. **Background / Problem：**这个问题为什么重要?
2. **Gap：**现有方法哪里不够?
3. **Formulation：**作者把问题写成什么数学目标?
4. **Difficulty：**为什么不能直接做?
5. **Method：**作者用了什么核心结构?
6. **Guarantee：**理论上保证到什么程度?
7. **Acceleration / Extension：**怎样变快、变稳?
8. **Evidence：**在哪些数据上验证?

9.3　高频表达

表达	中文理解	阅读时注意
fundamental task	基础而关键的任务	常用于强调问题重要性
common strategy	常见策略	后面通常会转折指出不足
tackle the problem	着手处理该问题	不等于“精确解决”

表达	中文理解	阅读时注意
maximize mutual information	最大化互信息	这是数学问题定义, 不只是口头目标
NP-complete	NP 完全	指精确解的一般计算困难
polynomial-time approximation	多项式时间近似算法	用可计算性换取近似而非精确
within $(1-1/e)$ of optimum	达到与最优值相关的常数因子保证	不是“误差为 36.8%”这么机械理解
exploit submodularity	利用次模性	*exploit* 在论文里常指“利用某种结构性质”
yield significant speedups	带来显著加速	后面应找实验时间或复杂度证据
robust against failures	对故障具有鲁棒性	不是“不会坏”，而是坏后性能仍可控
extensive empirical study	大规模/系统实证研究	要继续找数据集、基线、指标

9.4　把摘要读成“动作链”，而不是逐词翻译

对初学者最有效的做法，是先圈出每句话的**动作动词**，再判断它在研究链条中的功能。例如本文摘要可以被压缩为四层动作：

1. **formulate**：把“传感器放哪里”写成互信息最大化；
2. **prove / exploit**：识别组合困难，并利用次模结构建立近似保证；
3. **accelerate / robustify**：减少计算量，并考虑故障和模型不确定性；
4. **evaluate**：在真实环境数据上验证预测质量与运行效率。

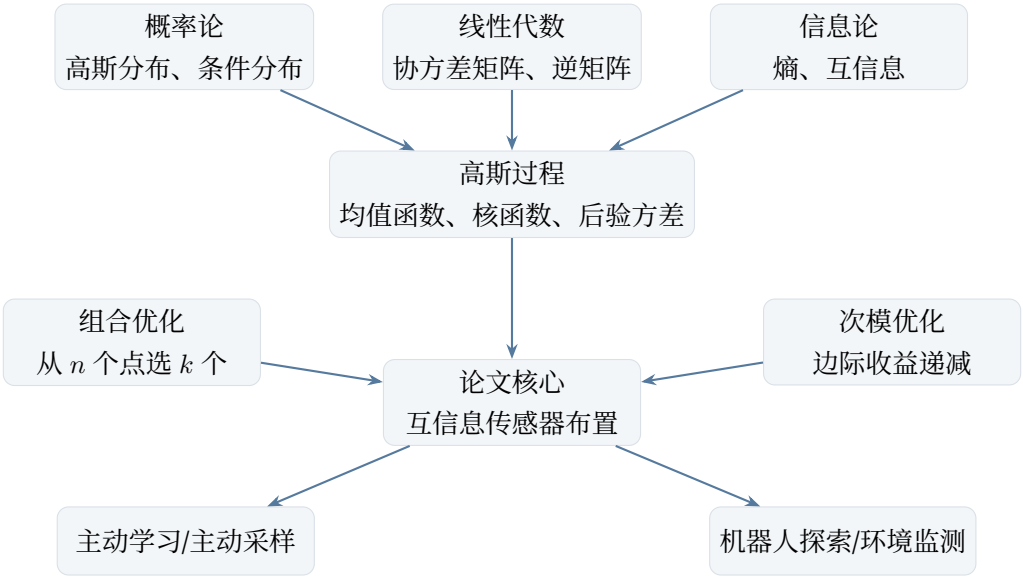
英文阅读时的一个实用判断

> 如果一句话里出现 *we formulate / we prove / we exploit / we develop / we evaluate*，优先把它当作“作者做了什么”的骨架词。生词可以后补，但这些动作词一旦抓住，摘要的结构通常已经不会丢。

CHAPTER 10

知识网络：这篇论文与你后续课程怎样连接

10.1　前置知识地图



10.2　与本科课程的自然连接

课程	在本文中对应什么
线性代数	协方差矩阵、分块矩阵、条件高斯分布、矩阵求逆、行列式
概率论	高斯随机变量、条件分布、期望、方差、随机失效
数值计算	大矩阵求解、复杂度、稳定性
运筹学/优化	组合优化、预算约束、贪心近似、Branch and Bound
数据结构	优先队列是 lazy greedy 加速的直接工程工具
机器学习	GP 回归、核方法、贝叶斯建模、active learning
机器人学	主动感知、探索、环境建图、移动传感器路径规划

为什么“数据结构”也会突然出现

你可能会觉得这是一篇概率/机器学习论文，为什么还出现优先队列？因为论文第 5 节的 lazy evaluation 正是在做“总是快速取当前上界最大的候选点”。这就是最大堆/优先队列的典型场景。算法思想与数据结构在这里真正接上了。

10.3　后续研究方向

从这篇论文继续往前走，可以自然进入：

- Informative Path Planning：传感器不再固定，而是机器人沿路径主动采样；
- Active Learning / Bayesian Optimization：选择“下一个最值得采样的位置”；
- Multi-robot sensing：多机器人协同覆盖与信息采集；
- Spatiotemporal GP：从静态空间场扩展到时空动态场；
- Sparse / scalable GP：候选点和历史数据大规模增长后的近似推断。

10.4　学完这里，你应该能自检

概念自检

不看前文，尝试口头回答：

1. 为什么传感器选址是“组合优化”而不是普通回归问题？
2. GP 的均值函数和核函数分别控制什么？
3. 为什么 GP 后验方差能用来衡量哪里“不确定”？
4. 熵最大化选点为什么容易偏向边界？
5. 互信息为什么比“只看被选点自身的不确定性”更直接？
6. 写出次模性的边际收益递减不等式。
7. $1-1/e$ 保证需要哪些经典前提？
8. 论文中为什么还会出现 $-k\varepsilon$ 一类项？
9. lazy evaluation 为什么依赖次模性？
10. 鲁棒目标为什么可以写成期望？

CHAPTER 11

正式基础练习（24 题）

11.1　单项选择题（10 题）

1. 本文中 *sensor placement* 最直接指的是（　）。

A. 设计传感器电路

B. 从候选位置中选择传感器放置位置

C. 提高传感器采样频率

D. 给传感器更换电池

2. 高斯过程最核心的概率特征是（　）。

A. 所有样本值相同

B. 任意有限个函数值联合服从高斯分布

C. 只能描述一维数据

D. 不需要协方差函数

3. 在高斯变量中，若其他条件不变，方差增大，则微分熵通常（　）。

A. 增大

B. 减小

C. 不变

D. 一定变为 0

4. $I(X;Y)=H(X)-H(X\mid Y)$ 的直观意义最接近（　）。

A. Y 的均值

B. 知道 Y 后 X 不确定性减少了多少

C. X 与 Y 的欧氏距离

D. X 的方差

5. 论文用互信息做传感器布置目标，核心希望（　）。

A. 让已选位置彼此完全独立

B. 让已选位置尽量解释未选位置

C. 让所有传感器位于边界

D. 让所有方差变为 0

6. 次模性最典型的直观解释是（　）。

A. 边际收益递增

B. 边际收益递减

C. 目标函数线性

D. 所有元素价值恒定

7. 对单调次模函数的基数约束最大化，经典贪心最坏情况保证约为最优值的（　）。

A. 10%

B. 36.8%

C. 63.2%

D. 100%

8. Lazy evaluation 的主要目的是什么（　）。

A. 改变互信息定义

B. 减少每轮不必要的边际收益重算

C. 使 GP 变成线性模型

D. 增加候选位置数量

9. 论文中的局部核/截断思想主要利用（　）。

A. 远距离相关性足够小时可忽略

B. 传感器必须规则排布

C. 所有协方差都相等

D. 互信息恒为 0

10. “贪心在一个小实验中距最优不超过 5%”应被理解为（　）。

A. 普适定理

B. 特定数据上的实证结果

C. NP 完全性的定义

D. 高斯过程定义

11.2　多项选择题（5 题）

1. 下列属于论文摘要主线的有（　）。

A. 用 GP 建模空间现象

B. 最大化已选与未选位置之间的互信息

C. 利用次模性构造近似算法

D. 研究节点失效与模型不确定性

2. 高斯过程在本文中重要，是因为它可以提供（　）。

A. 空间相关结构

B. 后验预测均值

C. 后验预测方差

D. 条件熵计算所需的概率结构

3. 关于次模性，下列正确的是（　）。

A. 描述集合函数的边际收益递减

B. 可为某些贪心算法提供近似保证

C. 与优先队列 lazy greedy 的正确性有关

D. 意味着精确最优一定容易求

4. 下列哪些属于论文“Scaling Up”的思路（　）。

A. Lazy evaluation

B. Priority queue

C. Local kernels / truncation

D. 暴力枚举所有 $\binom{n}{k}$ 方案

5. 关于理论与实验，下列说法正确的是（　）。

A. 理论保证描述最坏情况底线

B. 实验表现可以显著好于最坏情况保证

C. 一个数据集上的 95% 结果不能直接当成普适定理

D. 论文同时使用真实温度和降水数据验证方法

11.3　填空题（5 题）

1. 对 $X \sim \mathcal{N}(\mu, \sigma^2)$，其微分熵为 $H(X) =$ _____。

2. 互信息恒等式 $I(X;Y) = H(X) -$ _____。

3. 次模性要求当 $A \subseteq B$ 时，$F(A \cup \{y\}) - F(A)$ _____ $F(B \cup \{y\}) - F(B)$。

4. 经典单调次模基数约束贪心保证为 _____。

5. 论文中负责“减少不必要边际收益重算”的加速方法叫作 _____。

11.4　基础解答题（4 题）

1. 用自己的话解释：为什么“每次选后验方差最大的点”不一定是最好的传感器布置策略？要求至少说出“边界问题”和“对未选区域预测”的关系。

2. 已知两个候选点 a, b。当前集合 A 下，$\sigma^2_{a|A} = 4$，$\sigma^2_{a|\bar{A}} = 1$；$\sigma^2_{b|A} = 3$，$\sigma^2_{b|\bar{A}} = 1.5$。利用

$$\Delta(y \mid A) = \frac{1}{2} \log \frac{\sigma^2_{y|A}}{\sigma^2_{y|\bar{A}}}$$

判断贪心下一步应选哪个点。

3. 设某次模函数在当前集合 A 上加入候选点 y 的边际收益为 8，在更大的集合 $B \supseteq A$ 上加入同一 y 的边际收益为 5。说明这与次模性是否一致，并写出对应不等式。
4. 用“问题—建模—目标—困难—方法—加速/鲁棒—实验”七个关键词，复述这篇论文的摘要逻辑。

11.5 答案速查

单选

题号	1	2	3	4	5	6	7	8	9	10
答案	B	B	A	B	B	B	C	B	A	B

多选

题号	1	2	3	4	5
答案	ABCD	ABCD	ABC	ABC	ABCD

填空

1. $\frac{1}{2}\log(2\pi e\sigma^2)$。
2. $H(X \mid Y)$。
3. $\geq$。
4. $1 - 1/e \approx 0.632$。
5. lazy evaluation（懒惰求值）。

CHAPTER 12

详细解析

12.1 单选题解析

1. **答案 B**。本文研究的是从候选空间位置中选择有限个传感器位置。A 属于硬件设计，C 是采样率设计，D 是维护问题，都不是标题中的 *sensor placements*。
2. **答案 B**。GP 的正式定义就是任意有限个随机变量具有联合高斯分布。A、C、D 都与定义不符。
3. **答案 A**。因为 $H(X) = \frac{1}{2}\log(2\pi e\sigma^2)$，对 σ^2 单调递增。B 与公式相反；C 只有方差不变时才可能；D 没有依据。
4. **答案 B**。互信息是知道 Y 后 X 不确定性的减少。A、C、D 都不是互信息定义。
5. **答案 B**。论文最大化 $I(X_A; X_{V\setminus A})$，目的就是让已选位置对未选位置携带尽可能多信息。A“完全独立”反而可能削弱共同信息；C 是熵策略容易出现的偏差；D 不可能普遍做到。
6. **答案 B**。次模性是集合函数的边际收益递减。A 与其相反；C、D 都不是必要条件。
7. **答案 C**。$1 - 1/e \approx 0.6321$。注意这是经典单调次模情形的最坏情况近似因子，不意味着所有实验都只能做到 63.2%。
8. **答案 B**。Lazy evaluation 通过上界和优先队列避免对所有候选点每轮都完整重算。A、C、D 都没

有表达这一核心。

9. **答案 A**。局部核/截断就是利用远距离协方差足够小，把远处影响近似忽略，从而把计算限制在局部邻域。
10. **答案 B**。95% 是论文一个小规模可精确求解实验中的经验结果，不是通用定理。理论保证与该实验结论必须分开。

12.2 多选题解析

1. **ABCD**。四项都直接出现在摘要主线：GP 建模、互信息目标、次模近似、鲁棒扩展。
2. **ABCD**。GP 的相关结构、均值、方差以及由此得到的条件分布/条件熵，都是本文传感器选址计算的基础。
3. **ABC**。D 错：次模性可以让近似优化更好做，但不代表精确最优问题自动变容易；本文反而明确证明互信息最大化是 NP-complete。
4. **ABC**。Lazy evaluation、优先队列和局部核都是扩展效率的核心。D 是直接被规模问题淘汰的暴力思路。
5. **ABCD**。四项都正确，并且非常适合作为论文阅读中的“证据层级”检查清单。

12.3 填空题解析

1. $\frac{1}{2}\log(2\pi e\sigma^2)$。这说明高斯变量的熵只随方差单调变化，均值不会改变熵。
2. $H(X \mid Y)$。互信息等于“原不确定性减去知道 Y 后的剩余不确定性”。
3. $\geq$。小集合上的边际收益至少不低于大集合上的边际收益。
4. $1 - 1/e \approx 0.632$。这是经典结果；本文在近似单调/离散化条件下还会带误差项。
5. **Lazy evaluation**。它通常与优先队列结合使用。

12.4 解答题解析

第 1 题

题意分析：要求区分“选最不确定的位置”和“选最能帮助预测整个未测区域的位置”。

核心逻辑：

1. 后验方差大只说明“这个位置本身当前很不确定”。
2. 边界位置往往因为离已有观测远而方差大，因此最大熵策略容易不断向边界放点。
3. 但边界点只覆盖/代表一侧区域，对其余未选区域的整体预测帮助可能有限。
4. 互信息 $I(X_A; X_{V\setminus A})$ 直接衡量“已选位置与未选位置共享多少信息”，因此更贴近空间预测目标。

一句话总结：最大方差只看“这个点值不值得测”，互信息还看“测了这个点能不能帮我理解其他没测的点”。

第 2 题

对点 a：

$$\Delta(a \mid A) = \frac{1}{2}\log\frac{4}{1} = \frac{1}{2}\log 4 = \log 2.$$

对点 b:

$$\Delta(b \mid A) = \frac{1}{2}\log\frac{3}{1.5} = \frac{1}{2}\log 2.$$

因为 $\log 2 > \frac{1}{2}\log 2$，所以

$$\boxed{\text{下一步选择}a.}$$

本题无需计算小数；比较条件方差比值 4 与 2 就足够。

第 3 题

已知 $A \subseteq B$，同一候选点 y 的边际收益分别为 8 和 5。次模性要求

$$F(A \cup \{y\}) - F(A) \geq F(B \cup \{y\}) - F(B).$$

代入数值:

$$8 \geq 5,$$

成立。因此该现象与次模性一致，体现了“已有信息越多，再加同一点的新增价值越小”。

第 4 题

可以按下面七句复述:

1. **问题：**有限传感器应该放在哪里，才能最好地监测空间现象?
2. **建模：**用高斯过程表示空间位置之间的相关性和不确定性。
3. **目标：**最大化已选位置与未选位置之间的互信息。
4. **困难：**这个离散选择问题的精确优化是 NP-complete。
5. **方法：**利用互信息目标的次模性，构造贪心近似算法并获得常数因子保证。
6. **加速/鲁棒：**使用 lazy evaluation 和局部结构加速，并扩展到节点失效和模型参数不确定性。
7. **实验：**在真实温度与降水数据上比较预测质量、算法效果和运行效率。

12.5 高频易错点总表

易错说法	问题	正确理解
GP 就是一条拟合曲线	忽略概率分布与不确定性	GP 是对函数的概率分布, 后验同时给均值与方差
方差最大的位置一定最值得放传感器	只看本地不确定性	还要考虑对未选区域的代表性和预测价值
互信息越大说明两个位置距离越近	把统计依赖等同几何距离	MI 衡量统计依赖, 距离只是可能影响相关性的因素之一
次模函数一定容易精确优化	混淆“可近似”与“可精确”	次模性常带来强近似算法，但精确问题仍可很难
$1 - 1/e$ 就是算法实际只有 63.2%	混淆最坏情况保证与实测表现	实际可能远好于保证，论文小例子中非常接近最优

易错说法	问题	正确理解
95% 实验结果就是普适理论保证	把样本结果升级为定理	95% 是特定小规模实验观察
lazy greedy 改变了贪心策略	混淆计算策略与选择规则	它主要减少重复计算，在条件满足时保持同一贪心选择
鲁棒就是“传感器不会坏”	对鲁棒性的理解过强	鲁棒性是故障/参数不确定性下性能仍保持可接受

CHAPTER 13

下一步学习路线

如果你准备继续真正读原论文：分 4 次，不要一次硬啃 50 页

01 ｜建立主线
只读摘要、Introduction、Figure 1–5，确认问题、GP、熵 vs MI、贪心主线。

02 ｜吃透核心公式
精读 Section 2–4，把条件高斯、熵、互信息增量和次模性写进自己的公式笔记。

03 ｜理解工程化
读 Section 5–6，只追“为什么能加速、为什么能鲁棒”，先不纠结所有复杂度细节。

04 ｜按证据读实验
读 Section 9，逐图写出“横轴—纵轴—基线—结论—是否支持作者主张”。

13.1　最小前置知识清单

模块	当前阶段补到什么程度即可
线性代数	矩阵乘法、逆矩阵、正定矩阵、行列式、分块矩阵概念
概率论	多元高斯、条件概率、期望、协方差
信息论	熵、条件熵、互信息基本恒等式
算法	Big-O、贪心、优先队列
优化	组合优化；NP-hard / NP-complete 先做到概念层理解

当前阶段不必过早啃的内容

Appendix A 的完整证明、MIP 的全部细节、非均匀成本的精细近似常数、局部核的严格误差界，都可以放到第二轮之后。第一次阅读先锁定下面这条主线：

$$\boxed{\text{GP} \rightarrow \text{MI} \rightarrow \text{submodularity} \rightarrow \text{greedy} \rightarrow \text{scaling} \rightarrow \text{robustness} \rightarrow \text{experiments}}$$

参考资料

[1] Andreas Krause, Ajit Singh, Carlos Guestrin. *Near-Optimal Sensor Placements in Gaussian Processes: Theory, Efficient Algorithms and Empirical Studies*. Journal of Machine Learning Research, 9:235–284, 2008. https://www.jmlr.org/papers/v9/krause08a.html

[2] Carl Edward Rasmussen, Christopher K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. https://gaussianprocess.org/gpml/

[3] Thomas M. Cover, Joy A. Thomas. *Elements of Information Theory*, Chapter 2: Entropy, Relative Entropy and Mutual Information. Wiley, 2nd ed., 2006.

[4] G. L. Nemhauser, L. A. Wolsey, M. L. Fisher. An analysis of approximations for maximizing submodular set functions. *Mathematical Programming*, 14:265–294, 1978.

[5] MIT CSAIL course notes. Submodular maximization lecture notes: greedy $(1-1/e)$ guarantee. https://people.csail.mit.edu/stefje/fall15/notes_lecture15.pdf

这些参考资料分别在讲义中承担什么角色

JMLR 原论文	论文问题、算法、鲁棒扩展、实验数据与结论的第一依据
Rasmussen & Williams	Gaussian Process 的标准定义、核函数与后验预测背景
Cover & Thomas	熵、条件熵、互信息等信息论概念的教材级依据
Nemhauser 等 / MIT 讲义	次模最大化与经典 $1-1/e$ 贪心近似保证

制作与核验说明

- 原始手写内容已重构：标题拆解、GP 直觉、摘要六步逻辑、关键词。
- 显式纠正：正式论文标题中保留 *Efficient*；并区分“理论 $1-1/e$ 保证”与“小规模实验 95% 以内”两种证据。
- 新增 LaTeX 原生图：研究逻辑流程、候选点与传感器布置、核函数衰减、GP 均值与不确定性带、熵 vs MI 位置示意、次模性示意、贪心流程、近似保证曲线、局部截断示意、节点失效示意、前置知识地图等。
- 正式练习严格为：单选 10、多选 5、填空 5、解答 4，共 24 题；答案统一置于题目之后。
- 核心事实交叉参考 JMLR 原论文、Rasmussen & Williams 的 GP 教材、Cover & Thomas 的信息论教材、Nemhauser–Wolsey–Fisher 的次模优化结果及 MIT 课程讲义。